



AI VIET NAM

Dự đoán tuổi thọ pin Lithium-ion: từ hồi quy tabular dự đoán sớm đến dự báo chuỗi thời gian SOH

Nhóm Xì Trum

Phan Văn Tiến - Lê Xuân Dũng - Đồng Tiến Đoàn

Võ Ngọc Gia Bảo - Phan Tam Anh

I. Tóm tắt báo cáo

Pin Lithium-ion suy giảm dung lượng theo số chu kỳ sạc-xả; việc **dự đoán tuổi thọ** và **dự báo quỹ đạo sức khỏe** (State of Health, SOH) của pin là bài toán cốt lõi cho hệ quản lý pin (BMS) và xe điện (EV). Báo cáo này được thực hiện trên bộ dữ liệu chuẩn Severson/Attia (MIT-Stanford, *Nature Energy* 2019, 140 cell LFP/graphite) [1] và khảo sát **hai dạng bài toán bổ trợ nhau**:

- **Bài toán A — Dự đoán sớm (tabular):** từ 100 chu kỳ đầu, trích đặc trưng tổng hợp và dự đoán `cycle_life`. Đây là bài toán *early prediction* kinh điển, cho **kết quả dương rõ** (XGBoost: $R^2 = 0,71$, MAPE = 16,1%).
- **Bài toán B — Dự báo chuỗi thời gian SOH (sequence-to-sequence):** từ cửa sổ SOH quá khứ, dự báo chuỗi SOH tương lai.

Đóng góp chính: (1) thiết lập baseline rõ ràng và đánh giá *out-of-sample* cho cả hai bài toán; (2) chỉ ra rằng **khoảng ~50 chu kỳ đầu đã chứa phần lớn tín hiệu dự đoán**; (3) định lượng **khoảng tụt khi tổng quát hóa sang chính sách sạc chưa thấy**; (4) phát hiện rằng kỹ thuật **delta-modeling** là điều kiện then chốt giúp mạng neural hoạt động trên tín hiệu SOH dải hẹp; và (5) một **phát hiện dựa-trên-dữ-liệu trung thực**: trên dữ liệu scalar theo chu kỳ, các mô hình chuỗi phức tạp (LSTM, Transformer) *không* vượt trội so với mô hình đơn giản — giới hạn nằm ở **dữ liệu**, không ở mô hình.

Mục lục

I.	Tóm tắt báo cáo	1
II.	Giới thiệu	4
III.	Phát biểu bài toán	4
III.1.	Bài toán A — Dự đoán sớm <code>cycle_life</code> (tabular regression)	4
III.2.	Bài toán B — Dự báo chuỗi SOH (sequence-to-sequence forecasting)	5
III.3.	Câu hỏi nghiên cứu	5
IV.	Tổng quan nghiên cứu liên quan	5
V.	Phương pháp thực nghiệm	6
V.1.	Bài toán A — đặc trưng và mô hình	6
V.2.	Bài toán B — chuỗi, delta-modeling và mô hình	6
V.3.	Đánh giá không rò rỉ	6
VI.	Dữ liệu và thiết lập thí nghiệm	6
VI.1.	Tập dữ liệu	6
VI.2.	Chia dữ liệu	7
VI.3.	Thiết lập	8
VI.4.	Đánh giá	8
VII.	Kết quả thí nghiệm	8
VII.1.	Bài toán A — dự đoán sớm (RQ1)	8
VII.2.	Bài toán A — tổng quát hóa cross-policy (RQ2)	9
VII.3.	Bài toán B — dự báo chuỗi theo tầm H (RQ3)	9
VII.4.	Bài toán B — mô hình chuỗi LSTM & Transformer (RQ4)	10
VIII.	Phân tích thành phần và đánh giá bổ sung	10
VIII.1.	Delta-modeling cấu trúc deep learning	10
VIII.2.	Đầu vào đa kênh (RQ4)	10
VIII.3.	Giải thích mô hình bằng SHAP (Bài A)	10
VIII.4.	Độ tin cậy — Quantile Random Forest (Bài A)	11
IX.	Thảo luận	11

X.	Phân tích lỗi và hạn chế	12
XI.	Tái lập kết quả và mã nguồn	12
XII.	Kết luận và hướng phát triển tiếp theo	13
XIII.	Tài liệu tham khảo	14
	Phụ lục	15

II. Giới thiệu

Đề tài thuộc lĩnh vực **Machine Learning cho dữ liệu chuỗi thời gian trong khoa học pin**. Pin Li-ion là thành phần thiết yếu của thiết bị di động và xe điện; tuy nhiên việc đo tuổi thọ thật rất tốn kém: mỗi chu kỳ mất nhiều giờ, một viên pin có thể sống tới hơn 2000 chu kỳ ([1]). Do đó, khả năng **dự đoán sớm** tuổi thọ và **dự báo** quỹ đạo suy giảm từ thông tin chu kỳ đầu có ý nghĩa thực tiễn lớn (rút ngắn kiểm định, bảo hành, bảo trì dự đoán) và ý nghĩa học thuật (kiểm chứng giới hạn của các mô hình học sâu trên dữ liệu đo lường thực).

Khó khăn của bài toán. Ở giai đoạn đầu vòng đời, pin gần như chưa suy giảm rõ rệt, nên tín hiệu dự đoán rất tinh tế. Dữ liệu nhỏ (hàng trăm cell), nhiễu đo, phân bố tuổi thọ lệch phải mạnh, và sự đa dạng của chính sách sạc khiến mô hình dễ thiếu khả năng tổng quát hóa. Riêng với bài toán dự báo chuỗi SOH, tín hiệu nằm trong một *dải rất hẹp* (khoảng 0,80–0,97), khiến cách đặt mục tiêu (target formulation) trở nên quan trọng không kém việc chọn kiến trúc.

Khoảng trống. Nhiều reproduction trước chỉ báo lỗi trên tập *train*; phần lớn nghiên cứu tập trung vào một dạng bài toán (hoặc dự đoán một số, hoặc dự báo chuỗi) mà ít khi đặt cạnh nhau để so sánh. Hơn nữa, các mô hình chuỗi mạnh đều dựa vào tín hiệu *trong* chu kỳ (V/I/T), chưa rõ chúng còn lợi thế hay không khi chỉ có **scalar tổng hợp theo chu kỳ**.

Đóng góp chính.

- Xây dựng baseline rõ ràng cho **cả hai** bài toán: dự đoán sớm `cycle_life` (tabular) và dự báo chuỗi SOH (time-series), trên cùng một bộ dữ liệu.
- Đánh giá out-of-sample bằng cross-validation lặp lại và chia tập theo cell / theo chính sách sạc.
- Thực hiện ablation cho số chu kỳ cần thiết (20/50/100), cho delta-modeling, và cho đầu vào đa kênh.
- Phân tích giải thích (SHAP) và độ tin cậy (Quantile Random Forest), rồi phân tích lỗi, chỉ ra giới hạn do dữ liệu và đề xuất hướng phát triển tiếp theo.

III. Phát biểu bài toán

Báo cáo này khảo sát hai bài toán bổ trợ nhau trên cùng bộ dữ liệu.

III.1. Bài toán A — Dự đoán sớm `cycle_life` (tabular regression)

- **Đầu vào:** 12 đặc trưng tổng hợp trích từ N chu kỳ đầu của mỗi cell (đặc trưng mạnh nhất: $\log_{10} |\Delta Q|$ — mức suy giảm dung lượng sớm).
- **Đầu ra:** một số — `cycle_life` (số chu kỳ tới khi dung lượng còn 80% danh định).
- **Mục tiêu & metric:** tối thiểu sai số dự đoán; báo cáo R^2 , MAPE (%), RMSE (chu kỳ). Hồi quy trên $\log_{10}(\text{cycle_life})$ do phân bố lệch phải mạnh.

III.2. Bài toán B — Dự báo chuỗi SOH (sequence-to-sequence forecasting)

- **Đầu vào:** cửa sổ $L = 30$ giá trị SOH quá khứ ($\text{SOH} = Q_D/1,1$).
- **Đầu ra:** chuỗi H giá trị SOH kế tiếp.
- **Mục tiêu & metric:** tối thiểu RMSE trên SOH ($\times 10^{-2}$); khảo sát theo tầm dự báo $H \in \{10, 20, 50, 100\}$.

III.3. Câu hỏi nghiên cứu

- **RQ1 (A):** Có dự đoán được tuổi thọ chỉ từ chu kỳ đầu không, và cần bao nhiêu chu kỳ (20/50/100)?
- **RQ2 (A):** Mô hình có tổng quát hóa sang **chính sách sạc chưa từng thấy** không?
- **RQ3 (B):** Có dự báo được chuỗi SOH không; sai số biến đổi thế nào theo tầm dự báo H ?
- **RQ4 (B):** Thêm kênh vật lý (điện trở trong, nhiệt độ) và dùng mô hình chuỗi mạnh (LSTM, Transformer) có cải thiện so với baseline đơn giản không?

IV. Tổng quan nghiên cứu liên quan

Dự đoán sớm tuổi thọ. Severson et al. [1] là công trình nền tảng trong dự đoán sớm tuổi thọ pin lithium-ion. Nghiên cứu sử dụng các đặc trưng được trích xuất từ những chu kỳ đầu, đặc biệt là độ biến thiên của đường cong điện áp xả, để dự đoán số chu kỳ sống của pin trước khi xuất hiện suy giảm dung lượng rõ rệt. Kết quả cho thấy có thể đạt độ chính xác cao chỉ với dữ liệu từ giai đoạn đầu của vòng đời pin, mở ra hướng tiếp cận dữ liệu cho bài toán đánh giá tuổi thọ pin.

Dự báo chuỗi SOH / RUL. Pham et al. [2] đề xuất mô hình học đa nhiệm (*multitask learning*) dựa trên Conv2DLSTM encoder-decoder nhằm đồng thời dự báo trạng thái sức khỏe pin (State of Health – SOH) và tuổi thọ còn lại (Remaining Useful Life – RUL). Mô hình sử dụng dữ liệu đa biến theo chu kỳ và cho thấy khả năng cải thiện độ chính xác dự báo so với các phương pháp truyền thống.

Khoảng trống. (i) Hai hướng nghiên cứu dự đoán sớm tuổi thọ và dự báo chuỗi SOH/RUL thường được đánh giá trên các bộ dữ liệu hoặc thiết lập thí nghiệm khác nhau; (ii) chưa có nhiều nghiên cứu so sánh trực tiếp giữa mô hình tabular và mô hình chuỗi trên cùng một nguồn dữ liệu; (iii) vai trò của các đặc trưng tổng hợp từ số lượng chu kỳ đầu khác nhau vẫn cần được đánh giá một cách hệ thống. Báo cáo này hướng tới việc lấp đầy các khoảng trống đó.

V. Phương pháp thực nghiệm

V.1. Bài toán A — đặc trưng và mô hình

Từ N chu kỳ đầu, trích **12 đặc trưng** theo tinh thần Severson (thích nghi cho cửa sổ N tùy biến), miêu tả ở Bảng 1. Mô hình: **Elastic Net** (baseline tuyến tính được sử dụng trong nghiên cứu của Severson et al. [1]), **Random Forest**, **XGBoost**.

Bảng 1: 12 đặc trưng trích từ N chu kỳ đầu của mỗi cell (Bài toán A).

Đặc trưng	Ý nghĩa
<code>log_delQ</code>	$\log_{10} QD_N - QD_{10} $ — mức suy giảm dung lượng sớm (đặc trưng mạnh nhất)
<code>slope_qd / var_QD</code>	độ dốc & phương sai của Q_D theo chu kỳ
<code>qd_2</code>	dung lượng xả tại chu kỳ 2
<code>IRdiff / slope_ir / mean_IR</code>	thay đổi / độ dốc / trung bình điện trở trong
<code>Avgct</code>	thời gian sạc trung bình (chu kỳ 2–6)
<code>Tmax / Tint</code>	nhiệt độ tối đa & nhiệt độ tích phân theo chu kỳ
<code>C1, Q1</code>	tham số chính sách sạc

V.2. Bài toán B — chuỗi, delta-modeling và mô hình

Tạo dữ liệu chuỗi: trượt cửa sổ dọc mỗi đường SOH; input $L = 30$, target H , stride 10; chia tập theo cell. **Delta-modeling (điểm mấu chốt):** SOH nằm trong dải rất hẹp (0,80–0,97), nên việc dự báo giá trị tuyệt đối không phải là mục tiêu nhóm hướng tới. Ta huấn luyện mọi mô hình trong **không gian delta**: trừ giá trị quan sát cuối khỏi cả cửa sổ và target, chuẩn hóa X và Y , dự báo *mức thay đổi* rồi cộng lại. **Mô hình:** baseline phi mô hình (Persistence, Linear-extrapolation); mô hình học (Ridge, Random Forest, MLP); và mô hình chuỗi (LSTM encoder–decoder dạng RepeatVector + TimeDistributed; Transformer self-attention gồm MultiHeadAttention + positional embedding + FFN + residual).

V.3. Đánh giá không rò rỉ

Với bài toán A: **repeated 5-fold CV** (5 fold $\times$ 3 lần), chuẩn hóa và log target fit *bên trong từng fold*; thêm **Group KFold** theo chính sách sạc cho RQ2.


Với bài toán B: chia theo cell (112 train / 28 test), mọi phép chuẩn hóa fit trên train.

VI. Dữ liệu và thiết lập thí nghiệm

VI.1. Tập dữ liệu


Bộ Severson/Attia (MIT–Stanford) [1], bản Kaggle [3]: 140 cell LFP/graphite (A123 APR18650M1A, 1,1 Ah), ~ 70 chính sách sạc, tuổi thọ 148–1935 chu kỳ (trung bình 802 ± 332). Mỗi dòng = 1 chu kỳ, gồm dung lượng xả Q_D , điện trở trong IR, nhiệt độ $T_{avg/min/max}$, thời gian sạc, và chính

sách sặc $C_1/Q_1/C_2$. Bài A dùng file 100-cycle; Bài B dùng **file đầy đủ** (114738 dòng — cần toàn bộ đường suy giảm).



Hình 1: Phân tích dữ liệu (Bài A). *Trái*: phân bố tuổi thọ của 140 cell (lệch phải mạnh). *Phải*: đường dung lượng xả Q_D theo chu kỳ, tô màu theo tuổi thọ — các cell sống lâu duy trì Q_D cao lâu hơn.

Lọc dòng khởi tạo ($Q_D \leq 0,5$), khử trùng số chu kỳ, và làm trơn bằng rolling-median(5) để thu được một đường SOH sạch mỗi cell (Hình 2).



Hình 2: Đường suy giảm SOH của 40 cell đại diện (Bài B). Đường chấm là ngưỡng EOL = 0,8.

VI.2. Chia dữ liệu

A: repeated 5-fold CV ngẫu nhiên + Group KFold theo chính sách sặc.

B: 112 cell train / 28 cell test, cell trong test chưa từng xuất hiện lúc train (không rò rỉ giữa các quỹ đạo).

VI.3. Thiết lập

SOH = $Q_D/1,1$, EOL = 0,8; $L = 30$, stride = 10. LSTM/Transformer: 100 epochs, batch 128, optimizer Adam, loss MSE, chạy trên Kaggle GPU (Tesla T4); seed = 42. MLP: hidden (128, 64), early stopping. Các baseline phi mô hình không cần huấn luyện.

VI.4. Đánh giá

A: R^2 , MAPE, RMSE (trung bình $\pm$ std qua các fold).

B: RMSE trên SOH ($\times 10^{-2}$), so với baseline Persistence và Linear-extrapolation.


VII. Kết quả thí nghiệm

VII.1. Bài toán A — dự đoán sớm (RQ1)

Với 100 chu kỳ đầu, XGBoost đạt $R^2 = 0,706$, MAPE = 16,1% trên cell chưa thấy. Bảng 2 và Hình 3 so sánh theo số chu kỳ.

Bảng 2: R^2 theo số chu kỳ đầu (và MAPE tại $N = 100$), trung bình qua cross-validation lặp lại.

Mô hình	N=20	N=50	N=100	MAPE@100
XGBoost	0,634	0,702	0,706	16,1%
RandomForest	0,629	0,670	0,669	17,4%
ElasticNet	0,518	0,704	0,208	18,0%



Hình 3: R^2 (trái) và MAPE (phải) theo số chu kỳ đầu. Hiệu năng tăng rõ từ 20 $\rightarrow$ 50 chu kỳ nhưng gần như đi ngang từ 50 $\rightarrow$ 100.

Phát hiện: độ chính xác **nhảy mạnh từ 20 $\rightarrow$ 50 chu kỳ** (R^2 0,63 $\rightarrow$ 0,70) rồi gần như đi ngang 50 $\rightarrow$ 100 — nghĩa là $\sim$ 50 chu kỳ đầu đã chứa phần lớn tín hiệu, có thể rút ngắn gần một nửa thời gian thử nghiệm.

VII.2. Bài toán A — tổng quát hóa cross-policy (RQ2)


So sánh chia ngẫu nhiên (in-distribution) với chia theo chính sách sạch (Group KFold), dùng XGBoost @100 cycle: in-distribution $R^2 = 0,706$, MAPE 16,1%; out-of-distribution (policy chưa thấy) $R^2 = 0,626$, MAPE 17,1% — **khoảng tụt** $\Delta R^2 = -0,08$. Mô hình một phần dựa vào việc đã thấy policy tương tự.

VII.3. Bài toán B — dự báo chuỗi theo tầm H (RQ3)

Bảng 3 và Hình 4 trình bày $\text{RMSE} \times 10^{-2}$ theo tầm dự báo.

Bảng 3: RMSE dự báo SOH $\times 10^{-2}$ theo tầm H (test theo cell).

H	Persistence	Linear	Ridge	RandomForest	MLP
10	0,237	0,068	0,046	0,038	0,036
20	0,440	0,110	0,072	0,060	0,056
50	0,956	0,295	0,178	0,145	0,141
100	1,533	0,656	0,388	0,346	0,354



Hình 4: Sai số dự báo SOH theo tầm H . Các baseline ngây thơ (Persistence, Linear) sụp sớm; các mô hình học tách khỏi baseline nhưng chụm lại gần nhau.

Phát hiện: sai số tăng đều theo H (đặc trưng cốt lõi của forecasting); baseline ngây thơ sụp sớm; ở tầm xa Random Forest nhỉnh nhất. Đáng chú ý, các mô hình học **chụm vào dải hẹp 0,04–0,07** và tách rõ khỏi baseline phi mô hình.

VII.4. Bài toán B — mô hình chuỗi LSTM & Transformer (RQ4)

Xếp hạng đầy đủ tại $H = 20$ ($\text{RMSE} \times 10^{-2}$): Persistence 0,440, Linear 0,110, Ridge 0,072, RandomForest 0,060, **MLP 0,056**, LSTM 0,057, Transformer 0,066. Mọi mô hình học **chùm vào 0,056–0,072**; Transformer *không* thắng — một kết quả được thảo luận ở Mục 8.

VIII. Phân tích thành phần và đánh giá bổ sung

VIII.1. Delta-modeling cứu deep learning

Bảng 4 cho thấy *không có* delta-modeling, LSTM **thua cả persistence**; sau khi áp delta về ngang MLP. Đây là ablation quan trọng nhất: với tín hiệu dài hạn, *cách đặt target* quan trọng hơn độ phức tạp mô hình.

Bảng 4: Ảnh hưởng của delta-modeling ($\text{RMSE} \times 10^{-2}$ SOH, $H = 20$).


Mô hình @H20	Tuyệt đối	Delta
Ridge	0,279	0,072
RandomForest	0,074	0,060
MLP	0,610	0,056
LSTM	1,113	0,057

VIII.2. Đầu vào đa kênh (RQ4)

Thêm điện trở trong (IR) + nhiệt độ vào input **gần như không cải thiện** ở tầm ngắn (SOH tự tương quan rất mạnh): cải thiện ≈ 0 tại $H = 10, 20$, chỉ +0,007 (RF) và +0,003 (MLP) tại $H = 50$ — khớp việc IR là tín hiệu suy giảm chậm/dài hạn.

VIII.3. Giải thích mô hình bằng SHAP (Bài A)

Hình 5 cho thấy các đặc trưng có tác động lớn nhất lên dự đoán là **điện trở trong trung bình** (mean_IR), **thời gian sạc** (Avgct) và **suy giảm dung lượng sớm** (log_delQ), kể đến là nhiệt độ tích phân và độ dốc điện trở trong — hoàn toàn nhất quán với cơ chế vật lý suy giảm pin (tăng trở kháng và mất lithium hoạt động).



Hình 5: Giá trị SHAP của mô hình cây tốt nhất (XGBoost, 100 chu kỳ). Trục hoành là tác động lên $\log_{10}(\text{cycle_life})$; màu thể hiện giá trị đặc trưng (đỏ = cao, xanh = thấp).

VIII.4. Độ tin cậy — Quantile Random Forest (Bài A)

Thay vì một con số, Quantile Regression Forest cho khoảng tin cậy 90%; độ phủ thực nghiệm đạt **89%** (sát mục tiêu 90%) — phù hợp ngữ cảnh an toàn BMS.


IX. Thảo luận

Dữ liệu là yếu tố quyết định đến độ chính xác, không phải độ phức tạp mô hình. Transformer/LSTM không vượt MLP/Random Forest vì tín hiệu SOH tổng hợp quá mượt và **thiếu cấu trúc trong-cycle** (V/I/T) — thứ mà các SOTA [2] dựa vào. Đây là một *data-driven insight* trung thực và có giá trị: nó định lượng được giới hạn của dữ liệu scalar, đồng thời chỉ ra hướng cải thiện (lấy dữ liệu giàu hơn) thay vì quá tập trung vào kiến trúc.

Hai bài toán bổ trợ. Bài A chứng minh “có tín hiệu dự đoán được” với kết quả dương rõ; Bài B đặt đúng dạng time-series và chỉ ra rằng để khai thác mô hình chuỗi cần dữ liệu giàu hơn. Kết quả delta-modeling là bài học kỹ thuật chung cho time-series dải hẹp (không chỉ pin).

So với nghiên cứu trước. MAPE 16% của nhóm cao hơn $\sim 9\%$ của Severson chủ yếu vì thiếu $\text{Var}[\Delta Q(V)]$ (cần dữ liệu trong-cycle); quan sát Elastic Net bất ổn ở vùng tuổi thọ cao. Ở Bài B, dải sai số $0,04\text{--}0,07 (\times 10^{-2} \text{ SOH})$ hợp lý so với mức RMSE-SOH mà Pham et al. [2] báo cáo khi có tín hiệu trong-cycle.

Dự báo độ quy và điểm gối. Khi lần dự báo về phía trước từ một cửa sổ sớm (Hình 6), mô hình bắt được xu hướng giảm nhẹ ban đầu nhưng **trượt đoạn rơi nhanh cuối đời** (“knee point”). Đây là thách thức mở cốt lõi của dự báo SOH.



Hình 6: Dự báo độ quy toàn đường cong (Bài B): từ $L = 30$ quan sát đầu, lần dự báo về phía cuối đời. Mô hình bám giai đoạn suy giảm chậm nhưng trượt “điểm gối” tăng tốc gần EOL.

X. Phân tích lỗi và hạn chế

- **Elastic Net bất ổn** ở $N = 100$ ($R^2 = 0,208 \pm 1,095$): có fold nổ âm nặng ở vùng tuổi thọ cao, trong khi mô hình cây ổn định.
- **Điểm gối (knee point)**: dự báo độ quy toàn đường cong bắt được xu hướng giảm nhẹ ban đầu nhưng **trượt đoạn rơi nhanh cuối đời** — thách thức mở của dự báo SOH.
- **Thiếu tín hiệu trong-cycle**: CSV chỉ có scalar/cycle; không có đường $Q(V)$ nên phải dùng proxy $\log_{10} |\Delta Q|$ thay cho $\text{Var}[\Delta Q(V)]$ của Severson; đây là nguyên nhân chính của khoảng cách 16% vs. 9% MAPE.
- **Dữ liệu nhỏ** (140 cell) $\Rightarrow$ mô hình tuyến tính dễ bất ổn; kết quả dao động nhẹ giữa các seed.
- **Tài nguyên**: mô hình chuỗi chỉ chạy trên Kaggle GPU; mỗi cấu hình Bài B chạy một lần (chưa lặp nhiều seed).

XI. Tái lập kết quả và mã nguồn

Toàn bộ thí nghiệm nằm trong hai notebook, tự dò đường dẫn dữ liệu trong `/kaggle/input/...` (chạy Kaggle GPU cho phần LSTM/Transformer). Chạy cục bộ cũng được hỗ trợ qua `run_local.py` (Bài A).

Cấu trúc mã nguồn:

```
lithium-ion-battery/recent/
|-- early-battery-cycle-life.ipynb      # Bài toán A (tabular, early prediction)
|-- battery-soh-forecasting.ipynb      # Bài toán B (time-series, SOH forecasting)
```

```

|-- run_local.py / make_shap_plot.py    # chạy cục bộ Bài A + sinh biểu đồ SHAP
|-- figs/                               # các hình trong báo cáo
|-- references.bib                       # tài liệu tham khảo

```

Chạy trên Kaggle:

1. New Notebook -> Add Input: solitaryseeker/lithium-ion-battery-cycle-life-time-series-dataset
2. Upload notebook -> bật GPU T4 (cho phần LSTM/Transformer) -> Run All.

XII. Kết luận và hướng phát triển tiếp theo

Kết luận. Tuổi thọ pin **dự đoán được** từ chu kỳ đầu ($R^2 \approx 0,71$, $\text{MAPE} \approx 16\%$), với ~ 50 chu kỳ đã đủ; tổng quát hóa sang chính sách sạc mới còn khoảng tụt $\Delta R^2 = -0,08$. SOH **dự báo được** dưới dạng chuỗi, sai số tăng theo tầm dự báo, và **delta-modeling** là chìa khóa kỹ thuật giúp mô hình neural cạnh tranh được. Tuy nhiên, trên dữ liệu scalar/cycle, **mô hình chuỗi phức tạp không vượt baseline đơn giản** — giới hạn nằm ở dữ liệu, không ở mô hình.

Hướng phát triển tiếp theo.

- Tải Severson raw .mat $\Rightarrow$ có chuỗi $Q(V)$ trong-cycle $\Rightarrow$ tái hiện $\text{Var}[\Delta Q(V)]$ và huấn luyện mô hình chuỗi bằng tín hiệu giàu hơn.
- **Multitask** (đồng thời dự báo SOH + RUL) theo Pham et al. [2].
- **Physics-informed + attention** dự báo toàn đường cong để bắt knee và ngoại suy sang chính sách sạc mới.
- Domain adaptation thu hẹp khoảng tụt cross-policy; conformal prediction cho khoảng tin cậy bảo đảm lý thuyết.

XIII. Tài liệu tham khảo

- [1] K. A. Severson et al., “Data-driven prediction of battery cycle life before capacity degradation”, *Nature Energy*, vol. 4, no. 5, pp. 383–391, 2019. DOI: 10.1038/s41560-019-0356-8.
- [2] T. Pham et al., “A multitask data-driven model for battery remaining useful life prediction”, *REV Journal on Electronics and Communications*, vol. 12, no. 1–2, pp. 9–16, 2022. DOI: 10.21553/rev-jec.290.
- [3] SolitarySeeker. “Lithium-ion battery cycle life time-series dataset”, Accessed: Jun. 15, 2026. [Online]. Available: <https://www.kaggle.com/datasets/solitaryseeker/lithium-ion-battery-cycle-life-time-series-dataset>.

Phụ lục

1. AIVIETNAM: aivietnam.edu.vn.
2. GitHub Repository: [GitHub – Lithium-ion Battery Life Prediction](#).
3. Dataset: [Kaggle — Lithium-Ion Battery Cycle Life Time-Series](#).
4. **Kết quả bổ sung:** bảng R^2 /MAPE/RMSE chi tiết (Bài A), bảng RMSE-theo-tâm và delta-modeling (Bài B), biểu đồ SHAP, đường suy giảm SOH và dự báo độ quy toàn đường cong — xem trong các notebook.