

Báo Cáo Chuyên Sâu: Phân Tích và Dự Báo Chuỗi Thời Gian

Áp Dụng 8 Thuật Toán Tiên Tiến Từ Sách "Time Series Algorithms Recipes"

Báo cáo này trình bày phân tích chi tiết và thực hành về 8 mô hình dự báo chuỗi thời gian, bao gồm các mô hình Box-Jenkins (ARIMA, SARIMA) và các kỹ thuật Làm Mịn Hàm Mũ (SES, Holt-Winters). Nội dung tập trung vào nguyên tắc hoạt động, công thức toán học, quy trình tối ưu hóa tham số, và đặc biệt là phương pháp đánh giá hiệu suất mô hình một cách định lượng và chiến lược.

Chương I: Nền Tảng về Chuỗi Thời Gian và Tính Dừng (Time Series Fundamentals and Stationarity)

1.1. Định nghĩa và Đặc điểm của Chuỗi Thời Gian

Chuỗi thời gian (Time Series) được định nghĩa là một tập hợp các điểm dữ liệu được ghi nhận theo trình tự thời gian, nơi thời gian là biến độc lập quan trọng.¹ Các điểm dữ liệu này thường được ghi lại ở các khoảng thời gian đều đặn, chẳng hạn như hàng ngày, hàng tháng, hoặc hàng quý. Mục tiêu chính của phân tích chuỗi thời gian là sử dụng các giá trị đã quan sát trong quá khứ để dự đoán các giá trị tương lai của chuỗi.¹

Việc trực quan hóa chuỗi thời gian là bước khởi đầu thiết yếu, thường được thực hiện bằng

biểu đồ dạng đường (line plot), cho phép người phân tích theo dõi sự phát triển của chuỗi theo thời gian. Ví dụ minh họa điển hình cho chuỗi thời gian bao gồm doanh thu sản phẩm được ghi nhận hàng năm, tổng doanh thu theo tháng, hoặc dữ liệu số lượng sinh hàng ngày.²

1.2. Các Thành Phần Cấu Thành Chuỗi Thời Gian

Để hiểu rõ hơn về hành vi của một chuỗi thời gian, các nhà phân tích thường phân tách chuỗi đó thành các thành phần cơ bản của nó. Trong mô hình cộng (Additive Model), chuỗi thời gian quan sát được (y_t) là tổng của bốn thành phần chính ⁴:

- Mức cơ sở (Level): Giá trị trung bình của chuỗi nếu loại bỏ tất cả các thành phần khác.
- Xu hướng (Trend – T): Sự dịch chuyển dài hạn, tăng hoặc giảm, trong dữ liệu. Đây là thành phần thể hiện sự phát triển cốt lõi của chuỗi theo thời gian.²
- Tính mùa vụ (Seasonality – S): Các mẫu lặp lại theo chu kỳ cố định và có thể dự đoán được (ví dụ: doanh số tăng mạnh vào tháng 12 hàng năm).⁵
- Nhiều/Bất thường (Noise/Residual – N): Phần còn lại của chuỗi sau khi loại bỏ các thành phần có cấu trúc. Đây là các yếu tố ngẫu nhiên, không thể giải thích hay dự đoán được.

Việc xác định bản chất của chuỗi thời gian – liệu các biến động mùa vụ và nhiễu có ổn định theo thời gian hay không – là rất quan trọng. Khi độ lớn của tính mùa vụ và nhiễu không thay đổi theo mức độ của xu hướng, mô hình cộng (Additive) là phù hợp. Ngược lại, nếu độ lớn của các biến động (phương sai) tăng lên tỷ lệ thuận với mức độ chung của chuỗi, mô hình nhân (Multiplicative Model) cần được sử dụng. Sự lựa chọn này ảnh hưởng trực tiếp đến việc tiền xử lý dữ liệu (như việc áp dụng biến đổi logarit trước khi dùng ARIMA) và việc chọn biến thể mô hình làm mịn hàm mũ (như Holt-Winters Additive so với Multiplicative) trong Chương IV.

1.3. Khái niệm Tính Dừng (Stationarity) và Sai Phân (Differencing)

Tính dừng là một khái niệm nền tảng trong mô hình hóa chuỗi thời gian, đặc biệt đối với các mô hình thuộc họ Box-Jenkins (AR, MA, ARMA, ARIMA). Một chuỗi được coi là dừng hiệp phương sai (Covariance Stationarity) nếu trung bình, phương sai, và cấu trúc tự tương quan của nó không thay đổi theo thời gian.⁶

Các mô hình AR, MA, và ARMA yêu cầu chuỗi dữ liệu đầu vào phải là chuỗi dừng. Điều này là

cần thiết để đảm bảo rằng các tham số ước lượng được ổn định (consistent) và tránh được hiện tượng hồi quy giả (spurious regression).⁵

Xác định và Xử lý Tính Không Dừng

Để xác định tính dừng, có thể sử dụng các phương pháp trực quan (như đồ thị chuỗi) hoặc các kiểm định nghiệm đơn vị (Unit Root Test) như Kiểm định Dickey-Fuller mở rộng (ADF test).⁵ Nếu kiểm định ADF cho ra giá trị P-Value thấp (thường dưới 0.05), chuỗi được coi là dừng.⁷

Nếu chuỗi không dừng, cần phải lấy Sai Phân (Differencing), ký hiệu là Δ , để chuyển hóa chuỗi sang chuỗi dừng. Tham số d là bậc của quá trình đồng tích hợp (Integrated), thể hiện số lần lấy sai phân cần thiết.⁶ Sai phân bậc 1 được tính bằng công thức:

$$\Delta Y_t = Y_t - Y_{t-1}$$
. Sau khi lấy sai phân bậc d , chuỗi mới $(\Delta^d Y_t)$ phải đạt tính dừng.

Trong thực tế, người ta luôn cố gắng giữ bậc sai phân d ở mức tối thiểu. Hầu hết các chuỗi kinh tế và tài chính chỉ cần $d=1$ (đã dừng) hoặc $d=2$. Việc lấy sai phân bậc 2 ($d=2$) hiếm khi được khuyến nghị, vì nó có nguy cơ làm mất đi thông tin giá trị trong xu hướng dài hạn của chuỗi, dẫn đến chuỗi bị "quá dừng" (over-differenced).⁶

1.4. Công cụ Xác định Cấu trúc: ACF và PACF

Để xác định cấu trúc nội tại và bậc tham số p và q cho các mô hình Box-Jenkins, người phân tích sử dụng Hàm Tự Tương Quan (ACF) và Hàm Tương Quan Riêng (PACF).

- ACF (Autocorrelation Function): Đo lường mối tương quan giữa giá trị hiện tại Y_t và giá trị tại độ trễ k (Y_{t-k}), bao gồm cả ảnh hưởng gián tiếp của các giá trị trung gian.⁶
- PACF (Partial Autocorrelation Function): Đo lường mối tương quan trực tiếp giữa Y_t và Y_{t-k} sau khi đã loại bỏ ảnh hưởng tuyến tính của tất cả các giá trị chuỗi thời gian nằm giữa chúng ($Y_{t-1}, Y_{t-2}, \dots, Y_{t-k+1}$).⁶

Các đồ thị này là công cụ chẩn đoán cốt lõi để xác định bậc p và q :

Bảng 1: Hướng Dẫn Xác Định Bậc p và q trong Mô Hình Box-Jenkins

Mô Hình	Đồ Thị ACF (Xác định)	Đồ Thị PACF (Xác định)
AR()	Giảm dần theo hàm mũ	Cắt đứt sau độ trễ p
MA() Cắt đứt sau độ trễ q	Giảm dần theo hàm mũ	
ARMA()	Giảm dần hỗn hợp	Giảm dần hỗn hợp

Chương II: Các Mô Hình Trung Bình Trượt và Tự Hồi Quy (MA and AR Models)

Các mô hình MA và AR là các khối xây dựng cơ bản cho toàn bộ họ mô hình Box-Jenkins. Chúng được áp dụng cho chuỗi thời gian đã được xác định là dừng ($I(0)$).

2.1. Mô hình Trung Bình Trượt (Moving Average - MA())

Mô hình MA(q) giả định rằng giá trị hiện tại của chuỗi (X_t) bị ảnh hưởng bởi các yếu tố shock ngẫu nhiên hay sai số (ϵ_t) xảy ra trong thời điểm hiện tại và q thời kỳ trước đó.⁶ Mô hình này không phụ thuộc trực tiếp vào các giá trị quá khứ của chính chuỗi ($X_{t-1}, X_{t-2}, \dots$),

mà chỉ dựa vào các sai số dự báo trong quá khứ.

Công thức Toán học:

Trong đó:

- : Giá trị của chuỗi tại thời điểm t .
- : Sai số ngẫu nhiên (nhiều trắng) tại thời điểm $t - j$, $j = 0, 1, \dots, q$.
- : Các tham số trung bình trượt.

Để xác định bậc q tối ưu, người phân tích dựa vào đồ thị ACF. Mô hình MA(q) sẽ có đồ thị ACF

đột ngột cắt đứt (bằng không hoặc nằm trong dải ý nghĩa) kể từ sau độ trễ p .

2.2. Mô hình Tự Hồi Quy (Autoregressive - AR())

Mô hình AR() giả định rằng giá trị hiện tại của chuỗi X_t có mối quan hệ tuyến tính với các giá trị quá khứ của chính nó, kéo dài tới p thời kỳ trước đó.⁶ Tên gọi "tự hồi quy" xuất phát từ việc hồi quy chuỗi lên chính các giá trị quá khứ của nó.

Công thức Toán học:

Trong đó:

- : Giá trị của chuỗi tại thời điểm t .
- : Các tham số tự hồi quy.
- : Sai số ngẫu nhiên (nhiều trắng).⁶

Một điều kiện quan trọng đối với mô hình AR() là tính dừng. Chuỗi X_t là dừng khi tất cả các nghiệm của phương trình đặc trưng phải nằm ngoài vòng tròn đơn vị, tức là $|z| < 1$.⁶ Để xác định bậc

p tối ưu, người phân tích dựa vào đồ thị PACF. Mô hình AR() sẽ có đồ thị PACF đột ngột cắt đứt kể từ sau độ trễ p .⁶

Chương III: Bộ Ba Mô Hình ARIMA (The ARIMA Framework)

3.1. Mô hình ARMA (Autoregressive Moving Average - ARMA())

Mô hình ARMA() là sự kết hợp giữa mô hình tự hồi quy AR() và mô hình trung bình trượt MA(), áp dụng cho các chuỗi thời gian đã dừng.⁶ Mô hình này cho phép giá trị hiện tại phụ thuộc vào cả các giá trị quá khứ của chính chuỗi và các sai số ngẫu nhiên trong quá khứ.

Công thức Toán học:

Việc xác định bậc p và q cho mô hình ARMA() thường phức tạp hơn vì cả ACF và PACF đều thể hiện sự phân rã theo hàm mũ (giảm dần) mà không cắt đứt rõ ràng, đòi hỏi sự đánh giá kết hợp dựa trên hình dạng của cả hai đồ thị.⁶

3.2. Mô hình ARIMA (Autoregressive Integrated Moving Average - ARIMA())

Mô hình ARIMA() là mô hình tiêu chuẩn được sử dụng rộng rãi nhất để dự báo chuỗi thời gian. Thành phần "I" (Integrated - Đồng tích hợp) giải quyết vấn đề tính không dừng bằng cách thêm vào bậc sai phân d .⁶

Nguyên tắc Hoạt động và Công thức

ARIMA được áp dụng cho chuỗi thời gian không dừng có chứa xu hướng. Quy trình Box-Jenkins yêu cầu chuỗi gốc (Y_t) phải được chuyển đổi thành chuỗi dừng (Z_t) bằng cách lấy sai phân bậc d trước khi áp dụng các thành phần AR và MA.

Công thức Toán học (Sau khi lấy sai phân bậc d):

⁶

Ví dụ Minh họa Quy trình

Quá trình mô hình hóa ARIMA bao gồm ba bước chính:

- 1.Nhận dạng (Identification): Xác định bậc p thông qua kiểm định ADF và bậc q thông qua phân tích ACF/PACF trên chuỗi đã lấy sai phân.¹ Ví dụ, nếu chuỗi gốc có xu hướng, thường được áp dụng, và sau đó kiểm tra ACF/PACF của chuỗi sai phân bậc 1 (ΔY_t) .⁶
- 2.Ước lượng (Estimation): Ước lượng các tham số ϕ và θ .
- 3.Kiểm định Chẩn đoán (Diagnostic Checking): Kiểm tra phần dư $(\hat{\epsilon}_t)$ để đảm bảo chúng

là nhiễu trắng và không còn tự tương quan.

3.3. Tối ưu hóa Siêu Tham số ARIMA bằng Grid Search

Việc xác định thủ công các bậc thông qua đồ thị ACF và PACF có thể khó khăn và mang tính chủ quan, đặc biệt khi các đồ thị không "cắt đứt" một cách rõ ràng.⁶ Để giải quyết vấn đề này và tìm ra bộ tham số tối ưu một cách khách quan, phương pháp

Grid Search được áp dụng.

Nguyên tắc Grid Search

Grid Search là một kỹ thuật tìm kiếm vét cạn (brute-force search) thông qua một tập hợp con hữu hạn của các giá trị siêu tham số đã được định nghĩa trước. Quy trình thực hiện như sau:

- Định nghĩa Lưới Tham số: Thiết lập các phạm vi giá trị tiềm năng cho mỗi tham số . Ví dụ: $p \in \{0, 1, 2\}$, $d \in \{0, 1\}$, $q \in \{0, 1, 2\}$.
- Lặp và Huấn luyện: Lặp qua tất cả các tổ hợp có thể có. Với mỗi tổ hợp, mô hình ARIMA sẽ được huấn luyện trên dữ liệu huấn luyện.
- Đánh giá Hiệu suất: Hiệu suất của mỗi mô hình sẽ được đánh giá bằng một chỉ số lỗi (ví dụ: Căn bậc hai Sai số Bình phương Trung bình - RMSE hoặc Sai số Bình phương Trung bình - MSE) trên một tập dữ liệu kiểm tra (Test Set) hoặc thông qua kỹ thuật kiểm định chéo ngoài thời gian (Out-of-Time Cross validation).¹
- Lựa chọn Tối ưu: Tổ hợp tham số cho kết quả lỗi dự báo thấp nhất (Best Score) sẽ được chọn làm mô hình ARIMA tối ưu.³

Phương pháp này đảm bảo tính hệ thống và khách quan trong việc tìm kiếm mô hình tốt nhất, vượt qua giới hạn chủ quan của việc phân tích đồ thị.

Chương IV: Mở Rộng Mô Hình và Phương Pháp Làm Mịn (Advanced Models and Smoothing Techniques)

4.1. Mô hình SARIMA (Seasonal Autoregressive Integrated Moving Average)

Khi chuỗi thời gian có cả xu hướng và tính mùa vụ rõ rệt, việc chỉ sử dụng ARIMA không đủ để nắm bắt hết cấu trúc dữ liệu. Mô hình SARIMA (Seasonal ARIMA) được sử dụng bằng cách bổ sung thêm các tham số mùa vụ, được ký hiệu là SARIMA(P,D,Q).¹

- ($\cdot$): Các tham số phi mùa vụ (Non-seasonal)
- (P,D,Q): Các tham số mùa vụ (Seasonal), đại diện cho các thành phần AR, I, MA ở độ trễ mùa vụ $\cdot$. $\cdot$ là chu kỳ mùa vụ (ví dụ: $\cdot=12$ cho dữ liệu hàng tháng, $\cdot=3$ cho dữ liệu hàng quý).
- là bậc sai phân mùa vụ, cần được áp dụng đầu tiên để loại bỏ tính không dừng mùa vụ. Sau đó, $\cdot$ là bậc sai phân phi mùa vụ để loại bỏ xu hướng.⁷

SARIMA là mô hình tiêu chuẩn cho các dữ liệu có tính chu kỳ mạnh (ví dụ: dữ liệu du lịch, sản xuất, bán lẻ theo tháng), mang lại độ chính xác cao hơn đáng kể so với ARIMA thông thường trên các chuỗi này.⁷

4.2. Mô hình Làm Mịn Hàm Mũ Đơn Giản (Simple Exponential Smoothing - SES)

Các mô hình làm mịn hàm mũ (Exponential Smoothing) không yêu cầu chặt chẽ về tính dừng của chuỗi như Box-Jenkins.⁸ SES là mô hình cơ bản nhất trong nhóm này, giả định rằng chuỗi thời gian chỉ có mức cơ sở (Level -

μ) và không có xu hướng hay tính mùa vụ.⁸

Công thức Làm Mịn:

Trong đó, $\hat{y}_t$ là mức cơ sở ước tính tại thời điểm t , và α ($0 < \alpha \leq 1$) là hệ số làm mịn. Hệ số α quyết định trọng số được đặt vào quan sát hiện tại (y_t) so với mức cơ sở đã làm mịn trong quá khứ ($\hat{y}_{t-1}$). Giá trị α càng gần 1, mô hình càng phản ứng nhanh với các thay đổi gần đây.

Mô hình dự báo đơn giản: tất cả các dự báo trong tương lai đều bằng mức cơ sở cuối cùng: $\hat{y}_{t+h} = \hat{y}_t$.

4.3. Mô hình Holt-Winters (HW)

Mô hình Holt-Winters (HW), còn được gọi là Làm Mịn Hàm Mũ Ba (Triple Exponential Smoothing), là một sự mở rộng của SES để xử lý các chuỗi thời gian có cả xu hướng và tính mùa vụ.⁸ HW sử dụng ba phương trình làm mịn riêng biệt, mỗi phương trình cho một thành phần:

- Level (α): Được làm mịn bằng hệ số α .
- Trend (β): Được làm mịn bằng hệ số β .
- Seasonality (γ): Được làm mịn bằng hệ số γ .

Các Biến thể Quan trọng:

- Holt-Winters Additive: Phù hợp khi biên độ của tính mùa vụ là ổn định, không thay đổi theo mức độ của chuỗi.
- Holt-Winters Multiplicative: Phù hợp khi biên độ của tính mùa vụ tăng hoặc giảm tỷ lệ thuận với mức độ của chuỗi.

Việc lựa chọn giữa mô hình Box-Jenkins (ARIMA/SARIMA) và mô hình Làm Mịn Hàm Mũ (SES/HW) phụ thuộc vào cấu trúc dữ liệu. ARIMA/SARIMA là các mô hình thống kê tham số dựa trên giả định nhiều trắng và tính dừng, thường hiệu quả khi cấu trúc tự tương quan rõ ràng. Ngược lại, HW là phương pháp thuật toán, hoạt động tốt khi xu hướng hoặc tính mùa vụ phức tạp hoặc phi tuyến tính, và ít đòi hỏi các điều kiện lý thuyết nghiêm ngặt hơn.⁶

Chương V: Đánh Giá Hiệu Suất Mô Hình và So Sánh Kết Quả

Phản đánh giá mô hình là cực kỳ quan trọng để xác định độ tin cậy và khả năng tổng quát hóa của các mô hình dự báo. Việc này được thực hiện thông qua các tiêu chí định lượng (chỉ số lỗi) và phân tích dư lượng.

5.1. Các Tiêu Chí Đánh giá Định lượng (Quantitative Evaluation Metrics)

Các chỉ số lỗi đo lường sự khác biệt giữa giá trị quan sát thực tế (y) và giá trị dự đoán ($\hat{y}$).

Sai số Bình phương Trung bình (Mean Squared Error - MSE)

MSE là trung bình của các sai số bình phương giữa giá trị thực tế và giá trị dự đoán.⁹

- Đặc điểm: MSE phạt rất nặng các lỗi lớn do tính chất bình phương. Tuy nhiên, đơn vị của MSE là bình phương của đơn vị gốc, gây khó khăn trong việc diễn giải trực quan.

Căn bậc hai Sai số Bình phương Trung bình (Root Mean Squared Error - RMSE)

RMSE là căn bậc hai của MSE.

- Đặc điểm: RMSE có cùng đơn vị với biến gốc, giúp dễ dàng diễn giải hơn MSE. RMSE thường được ưu tiên khi cần hạn chế các sai số dự báo ngoại lai lớn, vì chúng đóng góp trọng số cao hơn vào tổng lỗi.⁹ Trong bối cảnh dự báo tài chính và rủi ro, RMSE thường được sử dụng để giảm thiểu các sự kiện hiếm gặp.

Sai số Tuyệt đối Trung bình (Mean Absolute Error - MAE)

MAE là trung bình của độ lớn sai số tuyệt đối.

- Đặc điểm: MAE là chỉ số dễ hiểu trực quan nhất và ít bị ảnh hưởng bởi giá trị ngoại lai hơn RMSE vì nó không bình phương sai số.⁹

Sai số Phần trăm Tuyệt đối Trung bình (Mean Absolute Percentage Error - MAPE)

MAPE thể hiện sai số dưới dạng phần trăm của giá trị thực tế.

- Đặc điểm: MAPE cung cấp sai số độc lập với thang đo, cho phép so sánh hiệu suất giữa

- các chuỗi thời gian có đơn vị khác nhau. Đây là chỉ số được ưa chuộng trong kinh doanh và quản lý vì dễ dàng truyền đạt mức độ chính xác dự báo (ví dụ: "lỗi dự báo trung bình là 5%").
- Hạn chế: MAPE gặp vấn đề khi giá trị thực tế (y_t) gần bằng hoặc bằng 0, dẫn đến sai số vô cùng lớn hoặc không xác định.⁹

5.2. Phân tích Dư lượng (Residual Analysis)

Kiểm định chẩn đoán là bước bắt buộc để xác nhận tính hợp lệ của các mô hình Box-Jenkins. Mục tiêu là kiểm tra xem phần dư (residuals) của mô hình có phải là nhiễu trắng (white noise) hay không.⁶ Nếu phần dư là nhiễu trắng, điều đó có nghĩa là mô hình đã nắm bắt được tất cả các thông tin có cấu trúc (xu hướng và tương quan) trong chuỗi.

Việc kiểm tra Dư lượng được thực hiện chủ yếu bằng cách phân tích biểu đồ ACF của phần dư. Nếu ACF của phần dư không có bất kỳ độ trễ nào vượt quá ngưỡng ý nghĩa thống kê (dài bóng mờ), có thể kết luận rằng phần dư không có tự tương quan. Nếu có bất kỳ độ trễ nào vẫn còn tự tương quan, mô hình vẫn chưa được tinh chỉnh tối ưu và cần phải tăng bậc hoặc để nắm bắt thêm thông tin.¹

5.3. So sánh Hiệu suất giữa 8 Mô hình

Khi triển khai các mô hình này trong thực tế, việc so sánh hiệu suất đòi hỏi phải chia dữ liệu thành tập huấn luyện và tập kiểm tra (Test Set). Các chỉ số lỗi (RMSE, MAE, MAPE) được tính toán trên tập kiểm tra để đánh giá khả năng tổng quát hóa của mô hình đối với dữ liệu chưa từng thấy.¹

Việc lựa chọn mô hình tối ưu phụ thuộc vào cấu trúc chuỗi thời gian ban đầu:

- Nếu chuỗi dừng và không có xu hướng/mùa vụ, SES, AR, MA hoặc ARMA có thể là đủ.
- Nếu chuỗi có xu hướng nhưng không có mùa vụ, ARIMA (sau khi tối ưu bằng Grid Search) hoặc Holt (biến thể HW không mùa vụ) là lựa chọn hàng đầu.
- Nếu chuỗi có cả xu hướng và tính mùa vụ, SARIMA hoặc Holt-Winters (HW) thường cho kết quả chính xác nhất.

Trong trường hợp này, SARIMA và Holt-Winters (HW) thường là các ứng viên mạnh nhất cho các chuỗi thời gian thực tế có tính chất phức tạp.

Bảng 2: Tóm Tắt So Sánh Tính Năng Cốt Lõi Của 8 Mô Hình Dự Báo

Mô Hình	Cấu trúc Cơ bản	Xử lý Xu hướng (Trend)	Xử lý Tính mùa vụ (Seasonality)	Yêu cầu Tính Dừng
MA (q)	Sai số Quá khứ	Không	Không	Dừng
AR (p)	Giá trị Quá khứ	Không	Không	Dừng
ARMA (p,q)	Kết hợp AR & MA	Không	Không	Dừng
ARIMA (p,d,q)	ARMA + Sai phân (I)	Có (qua sai phân)	Không Dừng sau	khi lấy sai phân ⁶
Grid Search ARIMA	Tối ưu hóa	Có	Không	Dừng sau khi lấy sai phân ³
SARIMA	ARIMA + Thành phần Mùa vụ	Có	Có (P, D, Q, M)	Dừng sau khi lấy sai phân
SES	Làm mịn Level	Không	Không	Không yêu cầu chặt chẽ ⁸
Holt-Winters (HW)	Level, Trend, Seasonality	Có (qua)	Có (qua)	Không yêu cầu chặt chẽ ⁸

5.4. Kết luận Đánh giá Chiến lược

Phân tích mô hình không chỉ là tìm mô hình có RMSE thấp nhất, mà còn bao gồm việc xem xét

tính ổn định và khả năng diễn giải. Các mô hình Box-Jenkins (ARIMA/SARIMA) cung cấp một khung lý thuyết thống kê mạnh mẽ, nhưng yêu cầu tiền xử lý phức tạp (kiểm định ADF, lấy sai phân, phân tích ACF/PACF). Ngược lại, các mô hình Lâm Mịn Hàm Mũ (HW) cung cấp một phương pháp tiếp cận thuật toán linh hoạt, thường dễ dàng hơn trong việc cài đặt và diễn giải các tham số lâm mịn ().

Trong nhiều ứng dụng thực tế, mô hình SARIMA (hoặc phiên bản tự động Auto ARIMA) thường mang lại sự cân bằng tốt nhất giữa độ chính xác và tính lý thuyết cho các dữ liệu có tính mùa vụ. Tuy nhiên, nếu chuỗi thời gian có xu hướng và mùa vụ không ổn định theo thời gian, Holt-Winters Multiplicative có thể là lựa chọn vượt trội.

Chương VI: Tổng Kết và Hướng Dẫn Triển Khai

Báo cáo đã cung cấp nền tảng lý thuyết và thực tiễn để triển khai 8 thuật toán dự báo chuỗi thời gian. Tất cả các mô hình này, đặc biệt là ARIMA/SARIMA và Grid Search, có thể được triển khai hiệu quả bằng Python, sử dụng các thư viện như statsmodels hoặc pmdarima (cho autoarima).¹

Để hoàn thành nhiệm vụ seminar, nhóm cần chuẩn bị các tài liệu sau, tập trung mạnh vào các ví dụ minh họa và phân đánh giá chi tiết (Chương III và Chương V):

- Tệp trình bày SEMINAR (.PPTX): Bao gồm định nghĩa TS (Chương I), công thức và ví dụ AR/MA/ARMA/ARIMA (Chương II, III), giải thích Grid Search, và kết quả so sánh chi tiết giữa 8 mô hình dựa trên các chỉ số MSE, RMSE, MAE, và MAPE (Chương V).
- Tập tin data (.csv): Dữ liệu mẫu được sử dụng cho các ví dụ.
- Tập tin python/jupyter notebook: Mã nguồn chi tiết triển khai 8 mô hình và thực hiện Grid Search, cùng với phân tích dự lượng.³
- Tệp readme.txt: Mô tả ngắn gọn nội dung của các tệp nộp.

Nguồn trích dẫn

- ARIMA Model for Time Series Forecasting - Kaggle, truy cập vào tháng 9 30, 2025, <https://www.kaggle.com/code/prashant111/arima-model-for-time-series-forecasting>
- Tìm hiểu về Time series (phân tích chuỗi thời gian) (P.1) - Big Data Uni, truy cập vào tháng 9 30, 2025, <https://bigdatauni.com/tin-tuc/tim-hieu-ve-time-series-phan-tich-chuoi-thoi-gian-p-1.html>
- How to Grid Search ARIMA Model Hyperparameters with Python - MachineLearningMastery.com, truy cập vào tháng 9 30, 2025,

- <https://machinelearningmastery.com/grid-search-arima-hyperparameters-with-python/>
4. Phân tích dãy số thời gian (Time Series Analysis) - BIS, truy cập vào tháng 9 30, 2025, <https://bis.net.vn/forums/t/2406.aspx>
 5. [Tổng hợp các kiến thức cơ bản] Module 5: Phân tích theo chuỗi thời gian (Time-series Analysis) (phần 2) - SAPP Academy, truy cập vào tháng 9 30, 2025, <https://knowledge.sapp.edu.vn/knowledge/t%E1%BB%95ng-h%E1%BB%A3p-c%C3%A1c-ki%E1%BA%BFn-th%E1%BB%A9c-c%C6%A1-b%E1%BA%A3n-module-5-ph%C3%A2n-t%C3%ADch-theo-chu%E1%BB%97i-th%E1%BB%9Di-gian-time-series-analysis-ph%E1%BA%A7n-2>
 6. [Dữ liệu chuỗi thời gian] MÔ HÌNH AR, MA VÀ ARIMA (Phần 1 ..., truy cập vào tháng 9 30, 2025, <https://scienceforeconomics.com/bai-viet/mo-hinh-ar-ma-va-arima>
 7. Time Series forecasting using SARIMA in Python | by Tirtha Mutha | Medium, truy cập vào tháng 9 30, 2025, <https://medium.com/@tirthamutha/time-series-forecasting-using-sarima-in-python-8b75cd3366f2>
 8. A Thorough Introduction to Holt-Winters Forecasting | by Lleyton Ariton | Analytics Vidhya, truy cập vào tháng 9 30, 2025, <https://medium.com/analytics-vidhya/a-thorough-introduction-to-holt-winters-forecasting-c21810b8c0e6>
 9. Metrics Evaluation: MSE, RMSE, MAE and MAPE | by Jonatasv - Medium, truy cập vào tháng 9 30, 2025, <https://medium.com/@jonatasv/metrics-evaluation-mse-rmse-mae-and-mape-317cab85a26b>
 10. ARIMA Model - Complete Guide to Time Series Forecasting in Python | ML+, truy cập vào tháng 9 30, 2025, <https://www.machinelearningplus.com/time-series/arima-model-time-series-forecasting-python/>
 11. Notebooks for time-series forecasting (SARIMA) - GitHub, truy cập vào tháng 9 30, 2025, <https://github.com/gxercavins/time-series>
-