




Tutorial: Swin Transformer V2

Trần Hoàng Duy Vũ Yến Linh Dương Đình Thắng Đinh Quang Vinh

I. Dẫn nhập

Sau khi Swin Transformer chứng minh được hiệu quả trong các tác vụ dense prediction, thách thức tiếp theo được đặt ra là khả năng mở rộng của mô hình. Trong khi lĩnh vực NLP đã tìm ra cách cải thiện hiệu suất nhất quán theo quy mô dữ liệu thì các mô hình CV lại thường đối mặt với sự bất ổn định khi tăng kích thước và độ phân giải. Xuất phát từ thực tế đó, Swin Transformer V2 được thiết kế để khắc phục nhược điểm này và giúp kiến trúc Swin mở rộng hiệu quả trên cả hai phương diện là tham số mô hình cùng độ phân giải đầu vào.



Hình 1: So sánh khả năng mở rộng quy mô giữa mô hình NLP và mô hình CV. Trong khi các mô hình NLP duy trì khả năng tăng hiệu năng tương ứng với kích thước mô hình, các mô hình CV trước đây gặp phải tình trạng bão hòa và mất ổn định ở quy mô lớn. Swin Transformer V2 được đề xuất nhằm thu hẹp khoảng cách này, hướng tới khả năng mở rộng hiệu quả cả về dung lượng lẫn độ phân giải cho các tác vụ CV.

Khi bắt tay vào việc mở rộng quy mô, nhóm tác giả đã nhận thấy ba rào cản thực tế. Đầu tiên là sự mất ổn định, mô hình càng lớn thì quá trình huấn luyện càng khó kiểm soát và dễ gặp lỗi. Thứ hai là sự không đồng bộ về cấu hình. Để tiết kiệm tài nguyên tính toán, giai đoạn tiền huấn luyện thường dùng ảnh và cửa sổ attention nhỏ, nhưng khi ứng dụng thực tế (downstream) lại cần độ phân giải cao hơn. Sự thay đổi này khiến các tham số vị trí cũ không kịp thích nghi, làm giảm đáng kể hiệu quả. Cuối cùng, một vấn đề khác là quy mô mô hình tăng lên cũng đồng nghĩa với việc nhu cầu về dữ liệu đã gán nhãn cũng tăng theo.

Để tháo gỡ những nút thắt này, Swin Transformer V2 tập trung giải quyết hai vấn đề cốt lõi: sự mất ổn định khi huấn luyện và khả năng thích nghi kém khi thay đổi độ phân giải. Nhóm tác giả đã thực hiện điều này bằng cách điều chỉnh lại cấu trúc bên trong khối Transformer và làm mới cơ chế mã hóa vị trí tương đối.

Những thay đổi này đã mang lại hiệu quả rõ rệt, mô hình mở rộng thành công lên tới 3 tỷ tham số với đầu vào cực lớn (1536×1536). Ngay tại thời điểm công bố, Swin V2 đã vươn lên dẫn đầu ở cả bốn nhóm tác vụ quan trọng bao gồm Image Classification, Object Detection và Segmentation, Semantic Segmentation, và Human Action Recognition.

Benchmark	Tác vụ	Chỉ số đánh giá	Kết quả
ImageNet-V2	Image Classification	Top-1 Accuracy (%)	84.0
COCO	Object Detection	Box mAP	63.1
COCO	Instance Segmentation	Mask mAP	54.4
ADE20K	Semantic Segmentation	mIoU (%)	59.9
Kinetics-400	Human Action Recognition	Top-1 Accuracy (%)	86.8

Bảng 1: Kết quả Swin Transformer V2 trên các benchmark và các tác vụ đại diện được báo cáo.

Mục lục

I.	Dẫn nhập	1
II.	Hạn chế của Swin Transformer	6
II.1.	Sự mất ổn định khi mở rộng kích thước mô hình	6
II.2.	Sự mất ổn định của Attention Logit	8
II.3.	Performance giảm khi thay đổi kích thước của sổ	9
III.	Swin Transformer V2	11
III.1.	Residual-post-norm	11
III.2.	Log-spaced continuous position bias	13
III.3.	Scaled cosine attention	15
III.4.	SimMIM	19
IV.	Câu hỏi trắc nghiệm	21
V.	Tài liệu tham khảo	23
	Phụ lục	24

Nhằm hỗ trợ việc đọc xuyên suốt bài viết, bảng chú thích dưới đây tóm tắt các thuật ngữ chính về kiến trúc Swin Transformer V2.

Bảng chú thích thuật ngữ	
Thuật ngữ	Giải thích
Backbone	Mạng xương sống đóng vai trò trích xuất đặc trưng cho các tác vụ hạ tầng.
Pre-norm	Cấu trúc đặt lớp chuẩn hóa (LayerNorm) trước nhánh biến đổi; phổ biến trong các Transformer đời đầu.
Residual-post-norm	Cấu trúc đặt LayerNorm sau nhánh biến đổi nhưng trước phép cộng residual; giúp ổn định mô hình cực lớn.
Scaled Cosine Attention	Cơ chế chú ý tính độ tương đồng dựa trên góc (cosine) thay vì tích vô hướng để tránh bão hòa logit.
Log-spaced CPB	Mã hóa vị trí tương đối trong không gian logarit; giúp mô hình thích nghi tốt khi thay đổi độ phân giải.
Window Attention	Cơ chế chú ý chỉ tính toán trong phạm vi cửa sổ cục bộ để giảm chi phí tính toán.
Shifted Window	Kỹ thuật dịch chuyển cửa sổ để tạo sự liên kết thông tin giữa các cửa sổ lân cận.
Logit Saturation	Hiện tượng giá trị logit quá lớn làm hàm softmax trở nên cực đoan, gây khó khăn cho huấn luyện.
SimMIM	Phương pháp tiền huấn luyện tự giám sát dựa trên việc khôi phục các vùng ảnh bị che (Masked Image Modeling).
Fine-tuning	Giai đoạn tinh chỉnh mô hình đã tiền huấn luyện trên các tập dữ liệu tác vụ cụ thể.


Để việc đọc thuận tiện hơn, bảng sau liệt kê và chuẩn hoá các ký hiệu toán học xuất hiện trong bài viết về SwinV2.

Bảng ký hiệu toán học

Ký hiệu	Ý nghĩa
$\mathbf{x}_\ell$	Tensor đặc trưng đầu vào của khối Transformer thứ ℓ .
$F(\cdot)$	Nhánh biến đổi phi tuyến (Attention sub-layer hoặc MLP sub-layer).
$\text{LN}(\cdot)$	Lớp chuẩn hóa Layer Normalization.
M	Kích thước của sổ attention (tính theo số lượng token).
$\mathbf{q}_i, \mathbf{k}_j$	Vector Query của token i và Vector Key của token j .
d	Số chiều của mỗi attention head.
s_{ij}	Giá trị logit attention giữa hai token i và j .
τ	Tham số nhiệt độ (Temperature) có khả năng học được trong Scaled Cosine Attention.
$(\Delta x, \Delta y)$	Độ lệch tọa độ tương đối giữa hai token theo hai trục.
$b(\cdot, \cdot)$	Hàm hoặc bảng tra cứu Relative Position Bias (RPB).
$\psi(\cdot)$	Hàm biến đổi tọa độ sang không gian logarit.
$G(\cdot)$	Mạng nơ-ron đa lớp (MLP) nhỏ dùng để sinh bias vị trí liên tục.
$\mathcal{M}$	Tập hợp các vị trí/mảnh ảnh bị che trong cơ chế SimMIM.

II. Hạn chế của Swin Transformer

II.1. Sự mất ổn định khi mở rộng kích thước mô hình



Hình 2: Kiến trúc tổng thể của Swin Transformer. Mô hình áp dụng thiết kế phân cấp gồm bốn giai đoạn để xử lý đặc trưng ở đa tỉ lệ. Đơn vị xử lý trung tâm là các khối Swin Transformer, sử dụng cơ chế W-MSA và SW-MSA nhằm thiết lập các kết nối liên cửa sổ hiệu quả.

Để hiểu rõ nguồn gốc của sự mất ổn định, chúng ta sẽ xem xét lại kiến trúc Transformer tiêu chuẩn sử dụng Pre-Norm. Tại một khối (block) thứ ℓ bất kỳ, với đầu vào là $\mathbf{x}_\ell$, dòng tín hiệu đi qua nhánh biến đổi $F(\cdot)$ (có thể là Attention hoặc MLP) được mô tả theo công thức:

$$\mathbf{x}_{\ell+1} = \mathbf{x}_\ell + F(\text{LN}(\mathbf{x}_\ell)).$$

Trong đó:


- $\mathbf{x}_\ell \in \mathbb{R}^{N \times C}$ là tensor đặc trưng ở đầu vào của block thứ ℓ .
- N là số token trong miền xử lý.
- C là số kênh hay số chiều embedding của mỗi token.
- $\mathbf{x}_{\ell+1} \in \mathbb{R}^{N \times C}$ là tensor đặc trưng đầu ra sau khi đi qua block và cộng residual.
- $\text{LN}(\cdot)$ là phép chuẩn hoá.
- $F(\cdot)$ là nhánh biến đổi phi tuyến trong block.

Cấu trúc residual bảo đảm tồn tại một đường truyền đồng nhất từ $\mathbf{x}_\ell$ sang $\mathbf{x}_{\ell+1}$, nhờ đó gradient có thể lan truyền qua nhiều tầng mà không bị triệt tiêu hoàn toàn. LayerNorm ở trước nhánh F giúp ổn định phân phối đầu vào của phép biến đổi, nhưng điểm quan trọng là nó không trực tiếp kiểm soát độ lớn của tín hiệu được cộng vào nhánh chính.

Nếu coi $\Delta_\ell = F(\text{LN}(\mathbf{x}_\ell))$ là “bước cập nhật” tại mỗi tầng, thì giá trị đặc trưng tại tầng sâu nhất L thực chất là tổng tích lũy của các bước này:

$$\mathbf{x}_L = \mathbf{x}_0 + \sum_{\ell=0}^{L-1} \Delta_\ell. \quad (1)$$

Vấn đề nảy sinh khi quy mô mô hình được mở rộng. Ở các mô hình nhỏ, các giá trị Δ_ℓ thường hoạt động ổn định. Nhưng khi tăng kích thước (số kênh C lớn, số block nhiều), nhánh F trở nên nhạy cảm hơn và giàu tham số hơn. Điều này dẫn đến việc các giá trị Δ_ℓ không còn giữ được sự ổn định vốn có, mà có xu hướng biến thiên mạnh và tích tụ dần qua các tầng.




Hình 3: Biểu đồ so sánh phương sai đặc trưng trung bình giữa các quy mô mô hình (Small, Base, Large, Huge) qua các khối xử lý. Đặc biệt, mô hình Huge (đường màu đỏ, H-Pre) cho thấy sự tích tụ của phương sai đặc trưng, dẫn đến mất ổn định và đổ vỡ trong quá trình huấn luyện.

Hệ quả trực tiếp của cơ chế này là sự mất cân xứng về thang đo tín hiệu trong mạng. Mặc dù LayerNorm đảm bảo F nhận được đầu vào đã chuẩn hoá, nhưng đầu ra Δ_ℓ lại được cộng thẳng vào dòng chính $\mathbf{x}_\ell$ mà không chịu bất kỳ ràng buộc nào về độ lớn. Khi Δ_ℓ đủ lớn, nhánh residual bắt đầu chi phối quá trình cập nhật, khiến độ lớn của đặc trưng tăng vọt theo chiều sâu của mô hình. Điều này kích hoạt một chuỗi phản ứng dây chuyền: độ lớn đặc trưng lớn tạo ra các logit lớn tại các phép chiếu tuyến tính, đẩy phân phối attention và gradient vào các trạng thái cực đoan, từ đó làm mất đi sự ổn định cần thiết.

Trên thực tế, sự lệch thang này biểu hiện rõ rệt qua độ nhạy cảm quá mức của quá trình huấn luyện đối với các siêu tham số. Ở quy mô nhỏ, hiện tượng này có thể bị bỏ qua do số tầng ít, mức độ tích lũy chưa đủ để gây nhiễu loạn. Tuy nhiên, khi mô hình đủ lớn, tổng tích lũy $\sum \Delta_\ell$ trở thành một điểm nghẽn chí mạng. Lúc này, chỉ một thay đổi nhỏ trong learning rate, warm-up hay batch size cũng đủ để khiến hàm loss dao động dữ dội hoặc mất hội tụ hoàn toàn, biến việc huấn luyện các mô hình khổng lồ trở thành một thách thức lớn.

II.2. Sự mất ổn định của Attention Logit

Bên cạnh vấn đề về độ lớn đặc trưng, kiến trúc Swin Transformer nguyên bản còn đối mặt với một thách thức nội tại khác nằm ngay trong cơ chế tính toán sự chú ý. Mặc dù tích vô hướng là tiêu chuẩn vàng trong các mô hình Transformer, nó lại bộc lộ những hạn chế về tính ổn định khi mở rộng quy mô. Cốt lõi của vấn đề là giá trị logit bị chi phối quá lớn bởi độ lớn của các vector đặc trưng, thay vì chỉ phụ thuộc vào sự tương đồng ngữ nghĩa.



Hình 4: Cơ chế Self-Attention dựa trên tích vô hướng.

Để phân tích kỹ hơn, hãy xét cơ chế tính toán tại một attention head của SwinV1. Giá trị logit trước khi đi qua hàm kích hoạt Softmax được xác định bởi công thức:

$$s_{ij} = \frac{\mathbf{q}_i^\top \mathbf{k}_j}{\sqrt{d}} + b_{ij}, \quad (2)$$

Trong đó:

- $\mathbf{q}_i, \mathbf{k}_j \in \mathbb{R}^d$ lần lượt là vector query của token i và vector key của token j .
- d là số chiều của mỗi attention head; hệ số $\sqrt{d}$ đóng vai trò điều tiết nhằm giữ cho phương sai của tích vô hướng ổn định.
- b_{ij} là thành phần relative position bias tương ứng với vị trí tương đối giữa token i và j .
- s_{ij} là logit attention, giá trị đầu vào của hàm kích hoạt softmax.


Vấn đề nảy sinh khi mô hình trở nên sâu hơn. Trong quá trình huấn luyện các mạng lớn, độ lớn $\|\mathbf{q}\|$ và $\|\mathbf{k}\|$ thường có xu hướng tích lũy và tăng dần qua các lớp. Khi những giá trị này vượt quá khả năng kiểm soát của hệ số $\sqrt{d}$, chúng đẩy logit s_{ij} vào các miền giá trị cực đoan, gây ra hai hệ quả nghiêm trọng làm tê liệt quá trình tối ưu hóa:

- **Hiện tượng bão hòa Softmax:** Khi logit có độ lớn quá lớn, hàm Softmax trở nên cực kỳ sắc và tiến dần về dạng one-hot (argmax). Lúc này, gradient chỉ tập trung vào một vài token có giá trị cao nhất và triệt tiêu ở các vị trí khác, làm mất đi tính đa dạng của sự chú ý và khiến quá trình cập nhật trọng số bị tắc nghẽn.
- **Sự suy giảm khả năng phân biệt:** Ở chiều ngược lại, nếu logit quá nhỏ, phân phối attention sẽ trở nên phẳng. Mô hình khi đó mất khả năng tập trung vào các đặc trưng quan trọng, dẫn đến tốc độ hội tụ rất chậm.

Đối với các mô hình kích thước nhỏ như Swin-T hay Swin-S, những hiệu ứng này chưa đủ lớn để phá vỡ quá trình huấn luyện vì độ lớn vector vẫn nằm trong vùng an toàn. Tuy nhiên, khi tham vọng mở rộng lên các cấu hình lớn hơn như Swin-L hay Swin-H, sự mất kiểm soát về độ lớn logit này trở thành rào cản chính, không chỉ làm chậm quá trình hội tụ mà còn gây ra rủi ro đổ vỡ mô hình trong quá trình huấn luyện.

II.3. Performance giảm khi thay đổi kích thước cửa sổ

Một đặc điểm kiến trúc của Swin Transformer là việc tính toán self-attention được giới hạn trong các cửa sổ cục bộ kích thước $M \times M$. Để mô hình nhận thức được cấu trúc không gian bên trong các cửa sổ này, thay vì sử dụng Positional Embedding tuyệt đối như các Transformer truyền thống, Swin đưa thông tin vị trí vào thông qua cơ chế Relative Position Bias (RPB). Về mặt toán học, đây là một hạng tử bias được cộng trực tiếp vào logit attention, đại diện cho mối quan hệ hình học tương đối giữa các token.



Hình 5: Sự chênh lệch về yêu cầu độ phân giải đầu vào giữa các tác vụ thị giác. Tác vụ tiền huấn luyện điển hình như phân loại ảnh (bên trái) thường sử dụng độ phân giải thấp (ví dụ: 224×224). Ngược lại, các tác vụ downstream như object detection (bên phải) đòi hỏi đầu vào có độ phân giải cao hơn đáng kể (ví dụ: 1920×1080) để đảm bảo hiệu năng. Sự không đồng nhất giữa độ phân giải khi huấn luyện và khi fine-tuning này tạo ra một thách thức kỹ thuật lớn trong việc mở rộng quy mô các mô hình thị giác hiện đại.

Cụ thể, với mỗi cặp token i và j có tọa độ (x, y) trên lưới cửa sổ, độ lệch vị trí tương đối được xác định bởi:

$$(\Delta x_{ij}, \Delta y_{ij}) = (x_i - x_j, y_i - y_j), \quad \Delta x_{ij}, \Delta y_{ij} \in \{-(M-1), \dots, M-1\}.$$

Swin Transformer V1 tham số hóa bias này bằng một bảng tra cứu (lookup table) $B \in \mathbb{R}^{(2M-1) \times (2M-1)}$. Khi tính toán attention, giá trị bias tương ứng với độ lệch $(\Delta x, \Delta y)$ sẽ được lấy từ bảng và cộng vào tích vô hướng giữa query và key:

$$\text{Attention}(Q, K, V) = \text{Softmax} \left(\frac{QK^\top}{\sqrt{d}} + B \right) V.$$

Cơ chế bảng tra cứu này hoạt động ổn định và hiệu quả miễn là kích thước cửa sổ M được giữ nguyên. Tuy nhiên, đây chính là vấn đề trong quy trình chuyển giao học tập. Trong thực tế, giai đoạn tiền huấn luyện thường được thực hiện trên ảnh độ phân giải thấp (ví dụ 224×224) với cửa sổ nhỏ (ví dụ $M=7$) để tiết kiệm tài nguyên. Ngược lại, khi tinh chỉnh cho các tác vụ đòi hỏi độ chính xác cao như object detection hay segmentation, độ phân giải đầu vào thường lớn hơn nhiều, buộc kích thước cửa sổ M phải tăng lên (ví dụ $M=12$ hoặc lớn hơn) để đảm bảo vùng tiếp nhận đủ rộng.

Khi M thay đổi, kích thước bảng tra cứu $(2M - 1)^2$ cũng thay đổi theo, khiến các trọng số đã học ở giai đoạn tiền huấn luyện không thể áp dụng trực tiếp cho mô hình mới. Giải pháp tình thế thường được sử dụng là dùng phép nội suy để phóng to bảng bias cũ khớp với kích thước mới.


Mặc dù giải quyết được vấn đề tương thích về mặt kích thước, nhưng phép nội suy lại gây ra sự sai lệch nghiêm trọng về mặt ngữ nghĩa hình học. Bảng bias trong Swin gắn chặt với lưới tọa độ rời rạc; việc nội suy một cách cơ học sẽ làm biến dạng các quy luật không gian mà mô hình đã học được, đặc biệt là ở các tần số cao hoặc các chi tiết tinh vi. Hệ quả là hiệu năng của mô hình thường bị suy giảm đáng kể khi chuyển sang các độ phân giải mới, đặc biệt ở những tác vụ nhạy cảm với vị trí, buộc quá trình tinh chỉnh phải tốn nhiều thời gian hơn để học lại các quan hệ không gian này.

III. Swin Transformer V2

Swin Transformer V2 không chỉ là bản nâng cấp về kích thước, mà là sự tái cấu trúc căn bản để giải quyết bài toán ổn định ở quy mô lớn. Trong khi vẫn giữ nguyên kiến trúc phân cấp và cơ chế cửa sổ trượt của phiên bản đầu, SwinV2 thay đổi cách tiếp cận, thay vì cố gắng kiểm soát mô hình bằng các kỹ thuật ngoại vi phức tạp (như gradient clipping, ...), kiến trúc này tích hợp sẵn các cơ chế tự điều tiết vào ngay trong luồng tính toán. Các cải tiến tập trung vào ba trụ cột chính là quản lý độ lớn tín hiệu, tham số hóa lại không gian hình học, và giải quyết sự cực đoan của hàm chú ý.

III.1. Residual-post-norm

Để giải quyết vấn đề tích tụ phương sai ở các tầng sâu, Swin Transformer V2 giới thiệu một cải tiến kiến trúc mang tên Residual-post-norm. Khác với cách tiếp cận Pre-Norm truyền thống, nơi tín hiệu đầu ra của nhánh biến đổi không bị ràng buộc độ lớn, phương pháp mới di chuyển lớp chuẩn hóa (LayerNorm) ra phía sau các khối chức năng, đặt ngay trước khi tín hiệu được cộng gộp vào dòng chính. Chiến lược này thay đổi căn bản cách mô hình kiểm soát năng lượng của dòng gradient.



Hình 6: Trong khi SwinV1 (trái) sử dụng cấu hình Tiền chuẩn hóa (Pre-Normalization), SwinV2 (phải) chuyển sang chiến lược Hậu chuẩn hóa (Post-Normalization). Bằng cách đặt lớp Layer Norm sau các nhánh tính toán Self-Attention và MLP, kiến trúc đề xuất giúp giảm thiểu hiệu quả sự tích tụ phương sai đặc trưng trong các lớp sâu, từ đó đảm bảo tính ổn định khi huấn luyện các mô hình quy mô lớn.

Sự thay đổi này được cụ thể hóa qua công thức cập nhật trạng thái mới:

$$\mathbf{x}_{\ell+1} = \mathbf{x}_{\ell} + \text{LN}\left(F(\mathbf{x}_{\ell})\right). \quad (3)$$

Trong đó, toàn bộ tín hiệu từ nhánh biến đổi $F(\mathbf{x}_\ell)$ bắt buộc phải đi qua lớp chuẩn hóa $\text{LN}(\cdot)$ trước khi tác động lên trạng thái $\mathbf{x}_\ell$. Thay đổi nhỏ về vị trí này mang lại một tác động lớn về mặt toán học, nó áp đặt một ràng buộc cứng lên độ lớn của phần dư. Bất kể các phép tính trong F phức tạp hay sâu đến đâu, đầu ra của chúng luôn được đưa về một phân phối ổn định trước khi tham gia vào quá trình cập nhật.

Việc áp dụng chuẩn hóa tại vị trí này tạo ra một cơ chế tự điều tiết tự nhiên cho mạng. Tổng tích lũy của các đặc trưng không còn bị bùng nổ theo chiều sâu, giúp dòng gradient lan truyền xuyên suốt mà không gặp phải các điểm nghẽn về độ lớn. Nhờ đó, Swin V2 loại bỏ được sự phụ thuộc vào các kỹ thuật can thiệp thủ công như gradient clipping khởi đầu cho việc huấn luyện ổn định các mô hình khổng lồ với hàng tỷ tham số.

Ví dụ tính toán Residual-post-norm

Giả sử ta xét một đầu vào z^{l-1} có kích thước 2×2 (đại diện cho 1 cửa sổ hay 1 vùng feature map nhỏ).

$$z^{l-1} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Để đơn giản hóa tính toán số học, giả sử các toán tử trong block được cho bởi:

$$\text{LN}(x) = x, \quad \text{MSA}(x) = x, \quad \text{MLP}(x) = 2x.$$

(Các giả định này chỉ phục vụ cho ví dụ minh họa và không làm thay đổi cấu trúc toán học của Swin Transformer)

Block l : Sử dụng W-MSA (Window Attention)

Trong Block này, ta thực hiện tính toán Attention trong cửa sổ tiêu chuẩn.

Bước 1: Nhánh Attention (W-MSA + Post-Norm)

Tính toán nhánh phụ (Residual Branch):

$$\text{Branch}_1 = \text{LN}(\text{W-MSA}(z^{l-1})) = \text{LN}\left(\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}\right) = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Cập nhật trạng thái trung gian (Cộng Residual vào dòng chính):

$$\hat{z}^l = z^{l-1} + \text{Branch}_1 = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} + \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 2 & 4 \\ 6 & 8 \end{bmatrix}.$$

Bước 2: Nhánh MLP (MLP + Post-Norm)

Tính toán nhánh phụ từ trạng thái trung gian $\hat{z}^l$:

$$\text{Branch}_2 = \text{LN}(\text{MLP}(\hat{z}^l)) = \text{LN}\left(2 \cdot \begin{bmatrix} 2 & 4 \\ 6 & 8 \end{bmatrix}\right) = \begin{bmatrix} 4 & 8 \\ 12 & 16 \end{bmatrix}.$$

Cập nhật trạng thái đầu ra của Block l :

$$z^l = \hat{z}^l + \text{Branch}_2 = \begin{bmatrix} 2 & 4 \\ 6 & 8 \end{bmatrix} + \begin{bmatrix} 4 & 8 \\ 12 & 16 \end{bmatrix} = \begin{bmatrix} 6 & 12 \\ 18 & 24 \end{bmatrix}.$$

Block $l + 1$: Sử dụng SW-MSA (Shifted Window Attention)

Đầu vào của block này là z^l . Block này thực hiện dịch chuyển cửa sổ (Cyclic Shift) trước khi tính Attention.

Bước 3: Nhánh Shifted Attention (SW-MSA + Post-Norm)

Đầu vào: $z^l = \begin{bmatrix} 6 & 12 \\ 18 & 24 \end{bmatrix}$.

Tính toán nhánh phụ:

$$\text{Branch}_3 = \text{LN}(\text{SW-MSA}(z^l)) = \text{LN} \left(\begin{bmatrix} 6 & 12 \\ 18 & 24 \end{bmatrix} \right) = \begin{bmatrix} 6 & 12 \\ 18 & 24 \end{bmatrix}.$$

(Lưu ý: Trong thực tế, SW-MSA sẽ hoán vị các phần tử của ma trận trước khi tính attention rồi hoán vị ngược lại. Ở đây ta giả sử hàm đồng nhất để dễ theo dõi).

Cập nhật trạng thái trung gian:

$$\hat{z}^{l+1} = z^l + \text{Branch}_3 = \begin{bmatrix} 6 & 12 \\ 18 & 24 \end{bmatrix} + \begin{bmatrix} 6 & 12 \\ 18 & 24 \end{bmatrix} = \begin{bmatrix} 12 & 24 \\ 36 & 48 \end{bmatrix}.$$

Bước 4: Nhánh MLP (MLP + Post-Norm)

Tính toán nhánh phụ từ trạng thái $\hat{z}^{l+1}$:


$$\text{Branch}_4 = \text{LN}(\text{MLP}(\hat{z}^{l+1})) = \text{LN} \left(2 \cdot \begin{bmatrix} 12 & 24 \\ 36 & 48 \end{bmatrix} \right) = \begin{bmatrix} 24 & 48 \\ 72 & 96 \end{bmatrix}.$$

Cập nhật trạng thái đầu ra cuối cùng của Block $l + 1$:

$$z^{l+1} = \hat{z}^{l+1} + \text{Branch}_4 = \begin{bmatrix} 12 & 24 \\ 36 & 48 \end{bmatrix} + \begin{bmatrix} 24 & 48 \\ 72 & 96 \end{bmatrix} = \begin{bmatrix} 36 & 72 \\ 108 & 144 \end{bmatrix}.$$

III.2. Log-spaced continuous position bias

Để giải quyết vấn đề mất mát thông tin do phép nội suy bằng rời rạc gây ra, Swin Transformer V2 đã thực hiện một bước chuyển đổi táo bạo trong cách mã hóa vị trí. Thay vì lưu trữ các tham số bias trong một bảng tra cứu tĩnh cố định theo kích thước cửa sổ, mô hình chuyển sang sử dụng cơ chế Log-spaced Continuous Position Bias (Log-CPB). Ý tưởng cốt lõi là thay thế việc tra cứu bằng việc sinh giá trị: một mạng nơ-ron nhỏ (thường là MLP 2 lớp) sẽ đóng vai trò là hàm sinh, trực tiếp tính toán bias dựa trên tọa độ tương đối.



Hình 7: Sự chuyển đổi từ tham số hóa rời rạc sang Bias vị trí liên tục (CPB). Khác với các phương pháp trước đây tối ưu hóa một bảng tra cứu tĩnh cho các bias vị trí (trái), Swin V2 đề xuất sử dụng một mạng nơ-ron nhỏ (MLP) để sinh ra các giá trị bias (phải). Bằng cách ánh xạ trực tiếp tọa độ tương đối $(\Delta x, \Delta y)$ thành giá trị $B_{i,j}$ thông qua một hàm liên tục, cơ chế này khắc phục hạn chế của phép nội suy khi thay đổi kích thước của sổ, đảm bảo khả năng chuyển đổi tốt hơn giữa các độ phân giải khác nhau.

Cụ thể, giá trị độ lệch vị trí tương đối b_{ij} không còn là một tham số độc lập, mà là đầu ra của một hàm biến đổi liên tục:

$$b_{ij} = G(\psi(\Delta x_{ij}), \psi(\Delta y_{ij})). \quad (4)$$

Trong đó:

- $(\Delta x_{ij}, \Delta y_{ij})$ là tọa độ tương đối giữa hai token trong lưới cửa sổ.
- $\psi(\cdot)$ là hàm biến đổi giãn cách logarit.
- G là mạng nơ-ron đa lớp (MLP) đóng vai trò là mạng meta (meta-network) để sinh bias.

Điểm đột phá nằm ở hàm biến đổi ψ , thực hiện việc chuyển tọa độ từ không gian tuyến tính sang không gian logarit trước khi đưa vào mạng G :

$$\psi(\Delta) = \text{sign}(\Delta) \cdot \log(1 + |\Delta|). \quad (5)$$

Việc chuyển sang không gian logarit mang ý nghĩa quan trọng trong việc bảo toàn đặc trưng hình học khi thay đổi tỷ lệ. Biến đổi này cho phép mạng nơ-ron duy trì độ phân giải cao cho các khoảng cách gần (nơi các quan hệ không gian chi tiết rất quan trọng), đồng thời nén các khoảng cách xa vào một miền giá trị nhỏ hơn. Nhờ đó, khi kích thước của sổ mở rộng trong quá trình fine-tuning, mô hình không cần thực hiện các phép nội suy tuyến tính vốn dễ gây biến dạng thông tin. Thay vào đó, mạng nơ-ron G có thể suy rộng các giá trị bias một cách mượt mà sang miền tọa độ mới mà vẫn giữ được tính nhất quán của các đặc trưng đã học.

Ví dụ tính toán Log-spaced Continuous Position Bias (Log-CPB)

Xét một cửa sổ có kích thước $M = 2$. Tổng số token là $N = M^2 = 4$. Giả sử ta cần tính giá trị bias vị trí cho cặp Token 1 (vị trí $(0, 0)$) và Token 4 (vị trí $(1, 1)$).

Để đơn giản hóa tính toán số học, giả sử các toán tử trong block được cho bởi:

$$\text{LN}(x) = x, \quad \text{MSA}(x) = x, \quad \text{MLP}(x) = 2x.$$

(Các giả định này chỉ phục vụ cho ví dụ minh họa và không làm thay đổi cấu trúc toán học của Swin Transformer)

Bước 1: Tính tọa độ tương đối

$$\Delta x = x_{\text{query}} - x_{\text{key}} = 0 - 1 = -1.$$

$$\Delta y = y_{\text{query}} - y_{\text{key}} = 0 - 1 = -1.$$

Bước 2: Chuyển sang không gian Log (Log-spaced Transformation)

Khác với Swin V1 sử dụng chỉ số $(-1, -1)$ để tra bảng, Swin V2 chuyển đổi tọa độ này sang miền liên tục thông qua công thức:

$$\hat{\Delta} = \text{sign}(\Delta) \cdot \log(1 + |\Delta|).$$

Áp dụng cho trường hợp này:

$$\hat{\Delta}x = \text{sign}(-1) \cdot \log(1 + |-1|) = -1 \cdot \log(2) \approx -0.693.$$

$$\hat{\Delta}y = \text{sign}(-1) \cdot \log(1 + |-1|) = -1 \cdot \log(2) \approx -0.693.$$

Bước 3: Sinh Bias thông qua mạng MLP

Cặp tọa độ log $(-0.693, -0.693)$ được đưa vào một mạng nơ-ron nhỏ (Meta-network, thường là 2 lớp MLP với hàm kích hoạt ReLU) để sinh ra một giá trị thực duy nhất.

$$b_{1,4} = \text{MLP}(-0.693, -0.693).$$


Thực hiện tương tự cho tất cả các cặp token (i, j) trong cửa sổ, ta thu được ma trận Bias B kích thước 4×4 . Với ma trận B dưới đây:

$$B = \begin{bmatrix} 0 & -1.4 & -1.4 & -1.4 \\ -1.4 & 0 & -1.4 & -1.4 \\ -1.4 & -1.4 & 0 & -1.4 \\ -1.4 & -1.4 & -1.4 & 0 \end{bmatrix}$$

III.3. Scaled cosine attention

Để giải nút thắt về mất ổn định của attention logit đã phân tích ở trên, Swin Transformer V2 thực hiện một cuộc phẫu thuật quan trọng vào trái tim của cơ chế self-attention là thay thế tích vô hướng truyền thống bằng độ tương đồng cosine (Scaled Cosine Attention).

Trong các mô hình quy mô lớn, độ lớn của các vector đặc trưng có xu hướng tăng không kiểm soát. Với cơ chế dot-product cũ (QK^T), điều này kéo theo giá trị logit tăng vọt, đẩy hàm Softmax vào vùng bão hòa, nơi gradient gần như bằng 0. Đây là nguyên nhân chính khiến việc huấn luyện các mạng khổng lồ trở nên bế tắc do hiện tượng vanishing gradient.



Hình 8: Minh họa cơ chế Scaled Cosine Attention. Khác với cơ chế chú ý tích vô hướng tiêu chuẩn (trái) nơi giá trị logit không bị giới hạn và phụ thuộc vào độ lớn đặc trưng, phương pháp mới (phải) tính toán điểm chú ý dựa trên độ tương đồng cosin giữa vector truy vấn và khóa ($\cos(q, k)$), được chuẩn hóa bởi tham số học τ . Việc chuẩn hóa này giúp tách biệt logit chú ý khỏi norm của đầu vào, giải quyết triệt để vấn đề mất ổn định logit và đảm bảo sự hội tụ khi huấn luyện các mô hình quy mô lớn.

Swin V2 khắc phục điểm yếu này bằng cách chuẩn hóa các vector query và key về độ dài đơn vị trước khi tính toán độ tương đồng. Công thức tính logit mới được định nghĩa như sau:

$$s_{ij} = \frac{\cos(\mathbf{q}_i, \mathbf{k}_j)}{\tau} + b_{ij}. \quad (6)$$

Trong đó:

- $\mathbf{q}_i, \mathbf{k}_j$ là các vector query và key.
- $\cos(\mathbf{q}_i, \mathbf{k}_j)$ là độ tương đồng cosine, bản chất là tích vô hướng của hai vector sau khi đã được chuẩn hóa.
- τ là một tham số vô hướng có thể học được (learnable scalar), không chia sẻ giữa các head.

Cơ chế này mang lại hai lợi ích chiến lược. Thứ nhất, giá trị logit giờ đây hoàn toàn phụ thuộc vào góc giữa hai vector (tức ngữ nghĩa) chứ không còn bị nhiễu bởi độ lớn của chúng. Thứ hai, tham số τ (thường được khởi tạo lớn hơn 0.01) đóng vai trò là một van điều tiết chủ động, cho phép mạng tự động điều chỉnh độ “sắc” của phân phối attention theo nhu cầu thực tế thay vì bị ép buộc bởi các giá trị logit khổng lồ. Kết quả là quá trình huấn luyện trở nên cực kỳ ổn định, triệt tiêu hiện tượng cực đoan của hàm Softmax ngay cả khi kích thước mô hình được mở rộng lên hàng tỷ tham số.

Ví dụ tính toán Scaled Cosine Attention (W-MSA)

Xét một cửa sổ có kích thước $M = 2$, tổng số token $N = M^2 = 4$. Giả sử số chiều đặc trưng $d = 1$ để đơn giản hóa.

Dữ liệu đầu vào:

- Vector Query: $Q = [1, 2, 3, 4]^\top$.
- Vector Key: $K = [1, \epsilon, 1, \epsilon]^\top$ (với $\epsilon > 0$ rất nhỏ để tránh vector 0).
- Vector Value: $V = [1, 1, 2, 2]^\top$.
- Tham số $\tau = 0.1 \Rightarrow \frac{1}{\tau} = 10$.
- Ma trận Log-CPB (B) giả định:

$$B = \begin{bmatrix} 5 & 4 & 2 & 1 \\ 6 & 5 & 3 & 2 \\ 8 & 7 & 5 & 4 \\ 9 & 8 & 6 & 5 \end{bmatrix}.$$

Để đơn giản hóa tính toán số học, giả sử các toán tử trong block được cho bởi:

$$\text{LN}(x) = x, \quad \text{MSA}(x) = x, \quad \text{MLP}(x) = 2x.$$

(Các giả định này chỉ phục vụ cho ví dụ minh họa và không làm thay đổi cấu trúc toán học của Swin Transformer)

Bước 1: Tính ma trận Cosine Similarity

Do $d = 1$ và các phần tử trong Q, K đều dương, khi chuẩn hóa về vector đơn vị (L2-norm):

$$\hat{q}_i = \frac{q_i}{\|q_i\|} = 1, \quad \hat{k}_j = \frac{k_j}{\|k_j\|} = 1.$$

Suy ra độ tương đồng Cosine cho mọi cặp (i, j) là:

$$\cos(Q_i, K_j) = \hat{q}_i \cdot \hat{k}_j = 1 \cdot 1 = 1.$$

Ma trận Cosine:

$$\text{CosMatrix} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \end{bmatrix}.$$

Bước 2: Scale và cộng Bias

Áp dụng công thức $S = \frac{\cos(Q, K)}{\tau} + B$:

$$\frac{\text{CosMatrix}}{0.1} = 10 \cdot \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 10 & 10 & 10 & 10 \\ 10 & 10 & 10 & 10 \\ 10 & 10 & 10 & 10 \\ 10 & 10 & 10 & 10 \end{bmatrix}.$$

Cộng với ma trận Bias B :

$$S = \begin{bmatrix} 10 & 10 & 10 & 10 \\ 10 & 10 & 10 & 10 \\ 10 & 10 & 10 & 10 \\ 10 & 10 & 10 & 10 \end{bmatrix} + \begin{bmatrix} 5 & 4 & 2 & 1 \\ 6 & 5 & 3 & 2 \\ 8 & 7 & 5 & 4 \\ 9 & 8 & 6 & 5 \end{bmatrix} = \begin{bmatrix} 15 & 14 & 12 & 11 \\ 16 & 15 & 13 & 12 \\ 18 & 17 & 15 & 14 \\ 19 & 18 & 16 & 15 \end{bmatrix}.$$

Bước 3: Softmax và tính Output

Quan sát ma trận S , giá trị tại cột 0 (15) và cột 1 (14) chênh lệch nhau không quá lớn, trong khi lớn hơn hẳn cột 2 và 3. Hàm Softmax sẽ phân phối trọng số chủ yếu cho hai cột đầu. Dựa trên kết quả thực nghiệm:

$$\text{Attention Weights } A \approx \begin{bmatrix} 0.70 & 0.26 & 0.03 & 0.01 \\ 0.70 & 0.26 & 0.03 & 0.01 \\ 0.70 & 0.26 & 0.03 & 0.01 \\ 0.70 & 0.26 & 0.03 & 0.01 \end{bmatrix}.$$

Tính kết quả đầu ra $Output = A \times V$. Với $V = [1, 1, 2, 2]^T$:

$$\text{Output} \approx \begin{bmatrix} 0.70 & 0.26 & 0.03 & 0.01 \\ \dots & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots \\ \dots & \dots & \dots & \dots \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 1.0474 \\ 1.0474 \\ 1.0474 \\ 1.0474 \end{bmatrix}$$

Cơ chế Shifted Window (SW-MSA)

Cơ chế dịch chuyển cửa sổ (Cyclic Shift) và che mặt nạ (Masking) để xử lý các mối quan hệ liên cửa sổ trong Swin V2 được giữ nguyên bản như Swin V1. Điểm thay đổi duy nhất nằm ở công thức tính điểm chú ý bên trong lõi tính toán.

Công thức tổng quát cho SW-MSA trong Swin V2:

$$\text{SW-MSA}(Q, K, V) = \text{SoftMax}_{\text{row}} \left(\frac{\cos(Q, K)}{\tau} + B_{\log} + \mathcal{M} \right) V.$$

Vẫn sử dụng ma trận Score S từ ví dụ trên, nhưng áp dụng trong ngữ cảnh Shifted Window với ma trận mặt nạ $\mathcal{M}$ (chứa các giá trị 0 và $-\infty$).

Giả sử ma trận Mask $\mathcal{M}$ (cho vùng biên) có dạng:

$$\mathcal{M} = \begin{bmatrix} 0 & -\infty & 0 & -\infty \\ -\infty & 0 & -\infty & 0 \\ 0 & -\infty & 0 & -\infty \\ -\infty & 0 & -\infty & 0 \end{bmatrix}.$$


$$S' = S + \mathcal{M} = \begin{bmatrix} 15 & 14 & 12 & 11 \\ 16 & 15 & 13 & 12 \\ 18 & 17 & 15 & 14 \\ 19 & 18 & 16 & 15 \end{bmatrix} + \begin{bmatrix} 0 & -\infty & 0 & -\infty \\ -\infty & 0 & -\infty & 0 \\ 0 & -\infty & 0 & -\infty \\ -\infty & 0 & -\infty & 0 \end{bmatrix}$$

$$S' = \begin{bmatrix} 15 & -\infty & 12 & -\infty \\ -\infty & 15 & -\infty & 12 \\ 18 & -\infty & 15 & -\infty \\ -\infty & 18 & -\infty & 15 \end{bmatrix}.$$

Sau đó áp dụng Softmax, các vị trí có giá trị $-\infty$ sẽ có trọng số bằng 0, đảm bảo attention chỉ tập trung vào các vùng hợp lệ (cùng ngữ cảnh không gian sau khi dịch chuyển).

III.4. SimMIM

Khi quy mô mô hình tiến tới ngưỡng hàng tỷ tham số, sự phụ thuộc vào dữ liệu có nhãn trở thành một vấn đề lớn. Trong khi việc thu thập và gán nhãn thủ công vừa tốn kém lại vừa thiếu tính đa dạng, thì nhu cầu về một phương pháp huấn luyện có khả năng tận dụng nguồn dữ liệu thô khổng lồ ngày càng trở nên cấp thiết. Xuất phát từ thực tế đó, Swin Transformer V2 đã tích hợp SimMIM (Simple Masked Image Modeling) - một khung tự giám sát tối giản giúp biến hàng triệu bức ảnh chưa gán nhãn thành nguồn dữ liệu vô tận để huấn luyện mạng backbone.



Hình 9: Tiền huấn luyện tự giám sát SimMIM được áp dụng trong Swin Transformer V2. Để hiện thực hóa khả năng học biểu diễn ở quy mô lớn, mô hình sử dụng chiến lược mô hình hóa ảnh bị che với backbone SwinV2 đóng vai trò encoder. Một bộ decoder đơn giản được sử dụng để tái tạo trực tiếp giá trị điểm ảnh tại các vùng bị che thông qua hàm mất mát L_1 .

Khác với các phương pháp tiếp cận phức tạp trước đây, SimMIM tập trung vào sự tối giản, loại bỏ hoàn toàn các encoder rời rạc hay từ điển hình ảnh để tập trung vào việc dự đoán trực tiếp giá trị điểm ảnh thô. Để vận hành cơ chế này hiệu quả, nhóm tác giả đã xây dựng hệ thống dựa trên ba trụ cột chiến lược:

- **Chiến lược che mảnh ảnh lớn:** Thay vì che các điểm ảnh rời rạc, SimMIM thực hiện che các mảng lớn (thường là 32×32). Việc sử dụng kích thước mảnh che lớn ngăn cản mô

hình học vệt bằng cách suy diễn từ các điểm ảnh lân cận vốn có độ tương quan cao. Thay vào đó, mô hình buộc phải tư duy ở mức độ ngữ nghĩa và cấu trúc hình học tổng thể để khôi phục thông tin bị thiếu.

- **Kiến trúc bất đối xứng:** Hệ thống được thiết kế với sự chênh lệch lớn về trọng số: SwinV2 đóng vai trò là encoder chính hạng nặng, trong khi đầu dự đoán (decoder) lại cực kỳ đơn giản, thường chỉ là một lớp chiếu tuyến tính. Thiết kế này đảm bảo rằng mọi áp lực trích xuất đặc trưng đều dồn lên mạng xương sống, tránh trường hợp đầu dự đoán quá mạnh sẽ tự đảm nhận việc tái tạo mà không giúp encoder học được các đặc trưng hữu ích.
- **Mục tiêu tái tạo điểm ảnh thô:** Việc loại bỏ các lớp phân loại trung gian giúp đơn giản hóa quá trình tính toán. Hệ thống sử dụng hàm mất mát L_1 để so sánh trực tiếp giữa giá trị điểm ảnh gốc và giá trị dự đoán.

Hàm mất mát của SimMIM được định nghĩa cụ thể như sau:

$$\mathcal{L} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \|\hat{\mathbf{p}}_i - \mathbf{p}_i\|_1 \quad (7)$$

Trong đó, $\mathcal{M}$ là tập hợp các pixel bị che, $\mathbf{p}_i$ và $\hat{\mathbf{p}}_i$ lần lượt là giá trị màu thực tế và giá trị dự đoán. Việc sử dụng chuẩn L_1 thay vì L_2 giúp quá trình huấn luyện ổn định hơn và ít nhạy cảm với các nhiễu ngoại lai.

Sự kết hợp giữa SimMIM và kiến trúc phân cấp của SwinV2 tạo nên sự cộng hưởng hài hòa. Cơ chế cửa sổ trượt cho phép mô hình quan sát và tái tạo lại hình ảnh từ chi tiết đến tổng thể, các tầng nông khôi phục kết cấu bề mặt, trong khi các tầng sâu tái cấu trúc hình dáng vật thể. Kết thúc quá trình này, đầu dự đoán tuyến tính được loại bỏ, để lại một mạng backbone SwinV2 đã được huấn luyện tốt, sở hữu khả năng biểu diễn đặc trưng mạnh mẽ, sẵn sàng chuyển giao sang các tác vụ đích với tốc độ hội tụ nhanh và độ chính xác cao.

IV. Câu hỏi trắc nghiệm

- Mục tiêu chính của Swin Transformer V2 theo nội dung bài là:
 - Giảm số lượng tham số của Swin Transformer.
 - Thay thế hoàn toàn CNN bằng Transformer toàn cục.
 - Cải thiện khả năng mở rộng theo kích thước mô hình và độ phân giải đầu vào.
 - Loại bỏ hoàn toàn cơ chế Window Attention.
- Trong Swin Transformer V1, công thức logit attention trong một head được viết là:
 - $s_{ij} = \cos(\mathbf{q}_i, \mathbf{k}_j) + b_{ij}$
 - $s_{ij} = \frac{\mathbf{q}_i^\top \mathbf{k}_j}{\sqrt{d}} + b_{ij}$
 - $s_{ij} = \frac{\cos(\mathbf{q}_i, \mathbf{k}_j)}{\tau}$
 - $s_{ij} = \mathbf{q}_i^\top \mathbf{k}_j + b_{ij} + \tau$
- Cấu trúc Residual-post-norm trong SwinV2 được mô tả bởi công thức:
 - $x_{\ell+1} = x_\ell + F(LN(x_\ell))$
 - $x_{\ell+1} = LN(x_\ell + F(x_\ell))$
 - $x_{\ell+1} = x_\ell + LN(F(x_\ell))$
 - $x_{\ell+1} = LN(F(LN(x_\ell)))$
- Trong Log-spaced Continuous Position Bias, hàm biến đổi $\psi(\Delta)$ được định nghĩa là:
 - $\psi(\Delta) = \log(\Delta)$
 - $\psi(\Delta) = \text{sign}(\Delta) \cdot \log(1 + |\Delta|)$
 - $\psi(\Delta) = |\Delta| \log(\Delta)$
 - $\psi(\Delta) = \frac{\Delta}{1 + |\Delta|}$
- Trong Scaled Cosine Attention của SwinV2, logit attention được tính theo công thức:
 - $s_{ij} = \frac{\cos(\mathbf{q}_i, \mathbf{k}_j)}{\tau} + b_{ij}$
 - $s_{ij} = \frac{\mathbf{q}_i^\top \mathbf{k}_j}{\sqrt{d}} + b(\Delta x_{ij}, \Delta y_{ij})$
 - $s_{ij} = \tau \cos(\mathbf{q}_i, \mathbf{k}_j) + b_{ij}$
 - $s_{ij} = \cos(\mathbf{q}_i, \mathbf{k}_j) + b_{ij}$
- Trong SimMIM, hàm mất mát được định nghĩa là:

$$\mathcal{L} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \|\hat{\mathbf{p}}_i - \mathbf{p}_i\|_1 \quad (8)$$

Ý nghĩa của tập $\mathcal{M}$ là:

- (a) Tập hợp toàn bộ token trong cửa sổ attention.
- (b) Tập hợp các head attention.
- (c) Tập hợp các chỉ số của mảnh ảnh bị che.
- (d) Tập hợp các lớp Transformer.

7. Với cửa sổ attention kích thước $M \times M$, tổng số quan hệ vị trí tương đối trong hai chiều là:

- (a) M^2
- (b) $2M - 1$
- (c) $(2M - 1)^2$
- (d) $4M^2$

8. Cho $M = 4$. Tổng số quan hệ vị trí tương đối trong hai chiều bằng:

- (a) 9
- (b) 16
- (c) 49
- (d) 25

9. Cho $\Delta = -3$. Giá trị của $\psi(\Delta)$ bằng:

- (a) $\log(3)$
- (b) $-\log(3)$
- (c) $\log(4)$
- (d) $-\log(4)$

10. Trong Scaled Cosine Attention, giả sử $\cos(q_i, k_j) = 1$, $\tau = 0.5$, và $b_{ij} = 2$. Giá trị logit s_{ij} bằng:

- (a) 2
- (b) 3
- (c) 4
- (d) 5

V. Tài liệu tham khảo

- [1] A. Vaswani et al., “Attention is all you need”, in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017. arXiv: 1706.03762.
- [2] A. Dosovitskiy et al., “An image is worth 16x16 words: Transformers for image recognition at scale”, in *International Conference on Learning Representations (ICLR)*, 2021. arXiv: 2010.11929.
- [3] Z. Liu et al., “Swin transformer: Hierarchical vision transformer using shifted windows”, in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 10 012–10 022.
- [4] P. Shaw et al., “Self-attention with relative position representations”, in *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, 2018. arXiv: 1803.02155.
- [5] T. Lin et al., “Feature pyramid networks for object detection”, in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 2117–2125.
- [6] H. Hu et al., *Swin Transformer supports 3-billion-parameter vision models that can train with higher-resolution images for greater task applicability*, Microsoft Research Blog, 2022. (visited on 02/12/2026).

Phụ lục

1. **Datasets:** Các file dataset được đề cập trong bài có thể được tải tại [đây](#).
2. **Code:** Các file code cài đặt hoàn chỉnh có thể được tải tại [đây](#).

AIO_QAs-Verified

🔒 Private group · 1.4K members



Hình 10: Hình ảnh group facebook AIO Q&A.