

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

Khoa Toán - Tin học



Học viên: **Võ Long Tuấn**

Mã học viên: **21C29025**

ĐỀ TÀI NGHIÊN CỨU LUẬN VĂN THẠC SĨ

**ƯỚC LƯỢNG THAM SỐ TRỰC TIẾP
CHO DỮ LIỆU KHUYẾT NGẪU
NHIÊN DƯỚI SỰ TÁC ĐỘNG CỦA
BIẾN PHÂN LOẠI**

Ngành: **Cơ sở toán cho tin học - Khoa học dữ liệu**

Mã ngành: **8480109**

Xác nhận của cán bộ hướng dẫn

(Ký tên và ghi rõ họ tên)

Nguyễn Thị Hoài Thương

TP. HỒ CHÍ MINH, THÁNG 5 NĂM 2023

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
Khoa Toán - Tin học



Học viên: **Võ Long Tuấn**

Mã học viên: **21C29025**

ĐỀ TÀI NGHIÊN CỨU LUẬN VĂN THẠC SĨ

**DIRECT PARAMETER ESTIMATION
FOR RANDOMLY MISSING DATA
UNDER THE IMPACT OF
CATEGORICAL VARIABLES**

Ngành: **Cơ sở toán cho tin học - Khoa học dữ liệu**

Mã ngành: **8480109**

Xác nhận của cán bộ hướng dẫn

(Ký tên và ghi rõ họ tên)

Nguyễn Thị Hoài Thương


TP. HỒ CHÍ MINH, THÁNG 5 NĂM 2023

Mục lục

1	Giới thiệu tổng quan	2
2	Mục đích nghiên cứu	4
3	Đối tượng nghiên cứu	4
4	Các phương pháp nghiên cứu	5
5	Phạm vi của vấn đề sẽ đi sâu nghiên cứu	5
6	Nơi thực hiện đề tài nghiên cứu	5
7	Thời gian thực hiện	6
8	Tài liệu tham khảo	6

1 Giới thiệu tổng quan

Trong việc phân tích dữ liệu, tiền xử lý đóng vai trò hết sức quan trọng bởi nó ảnh hưởng nhiều đến kết quả phân tích. Có nhiều kỹ thuật trong tiền xử lý dữ liệu và xử lý dữ liệu khuyết là một vấn đề phổ biến, thường xuyên gặp phải. Chẳng hạn, khi thực hiện khảo sát có yêu cầu điền mức thu nhập thì người thực hiện khảo sát sẽ thường bỏ qua mục này vì mức thu nhập của họ quá thấp hoặc quá cao; hay khi việc lấy dữ liệu từ các cảm biến có thể bị thiếu do cảm biến bị hỏng. Có nhiều cách xử lý dữ liệu khuyết như:



Do tính phổ biến của dữ liệu khuyết, nhiều phương pháp khác nhau đã được đề xuất, phát triển để giải quyết vấn đề trên. Có thể kể tới các phương pháp cổ điển như EM [2], Bayesian/multiple imputation [2],... các phương pháp gần đây như RESI [3], SICE [4],... Nhóm các phương pháp dựa trên việc hoàn thành ma trận như hoàn thành ma trận đa thức [5], cực tiểu hóa chuẩn hạt nhân [6]. Nhóm những phương pháp dựa trên phương pháp hồi quy và bình phương nhỏ nhất như CBRL và CBRC [7], sử dụng phương trình chuỗi MICE [8], bình phương tối thiểu cục bộ dựa trên phân cụm [9].

Trong thực tế, các phương pháp thay thế dữ liệu được quan tâm nhiều so với các phương pháp khác vì nó có hiệu suất cao và không làm mất dữ liệu. Các phương pháp trong các công trình nghiên cứu [10, 11] yêu cầu phải lặp lại quá trình tính toán nhiều lần nhưng lại có thể không hội tụ do đó tốn kém về mặt tính toán, đặc biệt là

đối với dữ liệu nhiều chiều. Các công trình khác có cách tiếp cận quy nạp [12], trong khi đó một số kết quả của việc ước lượng tham số trực tiếp cho dữ liệu thiếu nhưng có ràng buộc dữ liệu khuyết phải đơn điệu [13]. Nhìn chung, có nhiều công trình nghiên cứu đều được sử dụng cho dữ liệu khuyết ngẫu nhiên. Điều này dẫn tới việc tìm ra phương pháp ước lượng tham số trực tiếp cho dữ liệu khuyết ngẫu nhiên nói chung (DPER) [1]. Thuật toán trên lấy ý tưởng từ việc ước lượng tham số cho từng cặp dữ liệu thay vì ước lượng tham số đồng thời cho toàn bộ khi dữ liệu không đơn điệu. Vì quá trình tính toán của thuật toán DPER là tính toán trực tiếp nên không yêu cầu lặp lại nhiều lần việc tính toán nên tốc độ ước lượng nhanh hơn. Việc tính toán trực tiếp cũng khắc phục được hạn chế của phương pháp quy nạp là chạy chậm hơn khi số lượng dữ liệu khuyết lớn. Trong [14] yêu cầu một giả định mạnh là tính chuẩn nhiều chiều, trong khi thuật toán DPER chỉ cần giả định tính chuẩn hai chiều đối với từng cặp dữ liệu. Mặc dù vậy, trong trường hợp phân phối của dữ liệu không xác định thì bằng cách sử dụng Định lý giới hạn trung tâm, phân phối Gaussian là công cụ tính gần đúng được sử dụng nên thuật toán DPER đủ mạnh để áp dụng trong nhiều trường hợp. Thuật toán DPER đã có nhiều đóng góp như

(i) Tính toán ước lượng hợp lý cực đại cho ma trận trung bình và ma trận hiệp phương sai của dữ liệu khuyết một lớp hay nhiều lớp. Bên cạnh đó, đưa ra ước lượng cho phân phối cơ bản của dữ liệu.

(ii) Cung cấp thuật toán để tính toán ước lượng hợp lý cực đại cho các tập dữ liệu nhỏ và lớn.

(iii) Giảm tỉ lệ lỗi và tăng tốc độ xử lý so với các phương pháp khác đã nêu.

Trong luận văn cao học này, tôi sẽ nghiên cứu sự tác động của biến phân loại đến thuật toán ước lượng tham số trực tiếp cho dữ liệu khuyết ngẫu nhiên. Kết quả mong muốn là việc cải thiện được hiệu quả của thuật toán DPER bằng cách nghiên cứu hàm phân phối xác suất đồng thời của phân phối chuẩn $N(0; \sigma)$ và một phân phối của biến phân loại như phân phối Bernoulli, phân phối nhị thức hoặc nghiên cứu thêm một số ràng buộc của biến phân loại.

2 Mục đích nghiên cứu

Nghiên cứu sự tác động của biến phân loại đến thuật toán ước lượng tham số trực tiếp cho dữ liệu khuyết ngẫu nhiên (DPER) với hy vọng cải thiện kết quả của việc thay thế dữ liệu khuyết, tức làm giảm giá trị của metric được sử dụng để đánh giá

$$r = \frac{||\mu - \mu^*||}{n_\mu} + \frac{||\Sigma - \Sigma^*||}{n_\Sigma}$$

Đồng thời, tăng cường tốc độ tính toán vì biến phân loại sẽ tác động tích cực đến việc ước lượng tham số cho từng cặp dữ liệu.

3 Đối tượng nghiên cứu

Các tập dữ liệu của thư viện Scikit-learn và kho dữ liệu của kaggle cụ thể như sau:

- Digits: Bộ dữ liệu sklearn này là tập hợp các chữ số viết tay từ 0 đến 9, được lưu trữ dưới dạng hình ảnh thang độ xám. Nó chứa tổng cộng 1797 mẫu, với mỗi mẫu là một mảng hình dạng 2D (8,8)
- Iris: Bộ dữ liệu Iris là một tập dữ liệu chứa thông tin về kích thước cánh hoa và đài hoa. Tập dữ liệu có 3 lớp với 50 cá thể trong mỗi lớp.
- Wine: Bộ dữ liệu sklearn này chứa kết quả phân tích hóa học của các loại rượu vang được trồng ở một khu vực cụ thể của Ý, để phân loại các loại rượu vang theo đúng loại của chúng.
- MNIST: Nó bao gồm 70.000 hình ảnh thang độ xám của các chữ số viết tay từ 0–9, với 60.000 hình ảnh để đào tạo và 10.000 để kiểm tra. Mỗi hình ảnh có kích thước 28x28 pixel và có một nhãn tương ứng biểu thị các chữ số mà nó đại diện.
- Fashion-MNIST: ộ dữ liệu Fashion MNIST bao gồm 70.000 hình ảnh thang độ xám (tập huấn luyện 60.000 và tập kiểm tra 10.000) mặt hàng quần áo. Hình ảnh có kích thước 28x28 pixel và đại diện cho 10 loại mặt hàng quần áo khác

nhau, bao gồm áo phông/áo, quần tây, áo chui đầu, váy, áo khoác, xăng đan, áo sơ mi, giày thể thao, túi xách và bột đến mắt cá chân.

4 Các phương pháp nghiên cứu

- Tìm kiếm, tổng hợp tài liệu liên quan tới mục đích nghiên cứu.
- Đọc, nghiên cứu các tài liệu liên quan, các phương pháp có sẵn. Thực nghiệm và so sánh các kết quả giữa phương pháp được đề xuất với các phương pháp đã có trước đó.
- Học hỏi, trao đổi chuyên môn với giảng viên hướng dẫn.

5 Phạm vi của vấn đề sẽ đi sâu nghiên cứu

Tôi mong muốn sẽ cải thiện kết quả của thuật toán DPER thông qua việc có thêm điều kiện của biến phân loại. Giả sử ta có các biến ngẫu nhiên (X_1, X_2, Z) với $(X_1, X_2) \sim N(0; \sigma)$ và Z có phân phối của biến phân loại, chẳng hạn $Z \sim Ber(p)$. Trước tiên, tôi thực hiện tìm hàm phân phối đồng thời của các biến ngẫu nhiên trên và sau đó tìm các ước lượng hợp lý cực đại.

Tôi cũng sẽ tìm hiểu về việc tác động của biến phân loại đến một số phương pháp xử lý dữ liệu khuyết ngẫu nhiên cũng như việc sử dụng thuật toán DPER cho biến phân loại thông qua việc nhị phân hóa và sử dụng phân tích phân biệt tuyến tính (LDA) và phân tích phân biệt bậc hai (QDA).

6 Nơi thực hiện đề tài nghiên cứu

Trường Đại học Khoa học Tự Nhiên - Đại học Quốc Gia Thành phố Hồ Chí Minh.

7 Thời gian thực hiện

Từ tháng 5/2023 đến tháng 11/2023.

8 Tài liệu tham khảo

Tài liệu

- [1] T. Nguyen, D.K.M. Nguyen, D.H.M Nguyen, B.T. Nguyen, B.A Wade, *DPER: Direct Parameter Estimation for Randomly missing data*, Inform. Sci. 240 (2022) 108082.
- [2] R.J. Little, D.B. Rubin, *Statistical Analysis with Missing Data*, Vol. 793, John Wiley & Sons, 2019.
- [3] D. Peng, M. Zou, C. Liu, J. Lu, *RESI: A region-splitting imputation method for different types of missing data*, Expert Syst. Appl. 168 (2021) 114425.
- [4] S.I. Khan, A.S.M.L. Hoque, *SICE: an improved missing data imputation technique*, J. Big Data 7 (1) (2020) 1–21
- [5] J. Fan, Y. Zhang, M. Udell, *Polynomial matrix completion for missing data imputation and transductive learning*, in: *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol 34, 2020, pp. 3842–3849.
- [6] E.J. Candès, B. Recht, *Exact matrix completion via convex optimization*, Found. Comput. Math. 9 (6) (2009) 717
- [7] S.M. Mostafa, A.S. Eladimy, S. Hamad, H. Amano, *CBRL and CBRC: Novel algorithms for improving missing value imputation accuracy based on Bayesian ridge regression*, Symmetry 12 (10) (2020) 1594

- [8] S.v. Buuren, K. Groothuis-Oudshoorn, *Mice: Multivariate imputation by chained equations in R*, J. Stat. Softw. (2010) 1–68
- [9] Z. Yu, T. Li, S.-J. Horng, Y. Pan, H. Wang, Y. Jing, *An iterative locally autoweighted least squares method for microarray missing value estimation*, *IEEE Trans. Nanobiosci.* 16 (1) (2016) 21–33
- [10] X. Hu, W. Pedrycz, K. Wu, Y. Shen, *Information granule-based classifier: A development of granular imputation of missing data*, *Knowl.-Based Syst.* 214 (2021) 106737.
- [11] S. Yoon, S. Sull, *GAMIN: Generative adversarial multiple imputation network for highly missing data*, in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020, pp. 8456–8464.
- [12] G. Chhabra, V. Vashisht, J. Ranjan, *Missing value imputation using hybrid K-means and association rules*, in: *2018 International Conference on Advances in Computing, Communication Control and Networking, ICACCCN, IEEE*, 2018, pp. 501–509
- [13] T.W. Anderson, *Maximum likelihood estimates for a multivariate normal distribution when some observations are missing*, *J. Amer. Statist. Assoc.* 52 (278) (1957) 200–203
- [14] T. Nguyen, D.H. Nguyen, H. Nguyen, B.T. Nguyen, B.A. Wade, *EPEM: Efficient parameter estimation for multiple class monotone missing data*, *Inform. Sci.* 567 (2021) 1–22, <http://dx.doi.org/10.1016/j.ins.2021.02.077>