

**ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN**



NGUYỄN HUY QUANG

**PHÂN LOẠI CHUỖI THỜI GIAN VỚI
MÔ HÌNH LOGISTIC BIÊN PHI TUYẾN**

**Chi tiết hóa, Mở rộng giải tích và Thực nghiệm mô phỏng công trình của Rong Peng và
Zudi Lu (2024)**

LUẬN VĂN THẠC SĨ KHOA HỌC DỮ LIỆU

TP. Hồ Chí Minh – Năm 2025

**ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN**



NGUYỄN HUY QUANG

**PHÂN LOẠI CHUỖI THỜI GIAN VỚI
MÔ HÌNH LOGISTIC BIÊN PHI TUYẾN**

**Chi tiết hóa, Mở rộng giải tích và Thực nghiệm mô phỏng công trình của Rong Peng và
Zudi Lu (2024)**

Ngành: Khoa học dữ liệu

Mã số ngành: 8460108

NGƯỜI HƯỚNG DẪN KHOA HỌC

TS. TÔ ĐỨC KHÁNH

TP. Hồ Chí Minh – Năm 2025

LỜI CAM ĐOAN

Tôi cam đoan luận văn thạc sĩ ngành Khoa học Dữ liệu, với đề tài *Phân loại chuỗi thời gian với mô hình logistic biên phi tuyến* là công trình khoa học do chính tôi thực hiện dưới sự hướng dẫn khoa học của Tiến sĩ Tô Đức Khánh.

Những kết quả nghiên cứu, phân tích lý thuyết giải tích và số liệu thực nghiệm mô phỏng trong luận văn là hoàn toàn trung thực, khách quan và chính xác.

Mọi tài liệu tham khảo, trích dẫn học thuật từ các công trình khoa học trong và ngoài nước đều được viện dẫn nguồn gốc rõ ràng, minh bạch và chính xác theo đúng các quy chuẩn của Trường Đại học Khoa học Tự nhiên – Đại học Quốc gia TP. Hồ Chí Minh.

HỌC VIÊN CAM ĐOAN

Nguyễn Huy Quang

LỜI CẢM ƠN

Lời đầu tiên, tôi xin bày tỏ lòng biết ơn sâu sắc và chân thành nhất đến **TS. Tô Đức Khánh**, người thầy đã tận tình hướng dẫn, định hướng khoa học, truyền đạt phương pháp nghiên cứu và luôn động viên, hỗ trợ tôi trong suốt quá trình thực hiện luận văn thạc sĩ.

Tôi xin chân thành cảm ơn Ban Giám hiệu, Phòng Đào tạo Sau đại học, cùng toàn thể quý Thầy, Cô Khoa Toán – Tin học, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia TP. Hồ Chí Minh đã tận tâm truyền thụ tri thức và tạo điều kiện học tập thuận lợi nhất trong suốt khóa đào tạo Thạc sĩ Khoa học Dữ liệu Khóa 33.

Xin gửi lời cảm ơn chân thành đến các bạn học viên cao học đã cùng chia sẻ kiến thức, trao đổi học thuật trong suốt khóa học.

Cuối cùng, tôi xin dành lời tri ân sâu sắc nhất đến gia đình và bạn bè đã luôn là chỗ dựa tinh thần vững chắc, nguồn động viên to lớn để tôi hoàn thành tốt luận văn này.

TÁC GIẢ LUẬN VĂN

Nguyễn Huy Quang

MỤC LỤC

Lời cam đoan	i
Lời cảm ơn	ii
Mục lục	iii
Danh mục hình vẽ	vii
Danh mục bảng	viii
Danh mục ký hiệu và thuật ngữ	ix
LỜI NÓI ĐẦU	1
CHƯƠNG 1. TỔNG QUAN	4
1.1 Giới thiệu tổng quan	4
1.2 Lý do lựa chọn Mô hình MAMaLoR	6
1.3 Mục đích nghiên cứu	6
1.4 Đối tượng nghiên cứu	7
1.5 Các phương pháp nghiên cứu	7
1.6 Phạm vi của vấn đề sẽ đi sâu nghiên cứu	8
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	10
2.1 Tổng quan Bài toán Phân loại Chuỗi Thời gian Nhị phân	10
2.1.1 Đặc điểm và các thành phần của chuỗi thời gian	11
2.1.2 Chuỗi thời gian liên tục và rời rạc	12
2.1.3 Đặc điểm quan trọng của dữ liệu chuỗi thời gian	13
2.1.4 Các thành phần của dữ liệu chuỗi thời gian	14
2.1.5 Chuỗi thời gian nhị phân	17
2.2 Cơ sở Xác suất và Hồi quy Logistic Cổ điển	17
2.2.1 Phân phối Bernoulli và Mô hình Xác suất	17
2.2.2 Tỷ số chênh (Odds) và Hàm liên kết Logit	18

2.2.3	Ước lượng Cực đại Hợp lý (MLE) và Thuật toán IRLS	18
2.2.4	Hạn chế của mô hình tuyến tính và nhu cầu mở rộng	19
2.3	Mô hình Tuyến tính Tổng quát (GLM) và Mô hình Cộng tính Tổng quát (GAM)	19
2.3.1	Họ Phân phối Phân tán Mũ và Khung GLM	20
2.3.2	Bước nhảy vọt sang Mô hình Cộng tính Tổng quát (GAM)	20
2.3.3	Mô hình bán tham số	21
2.3.4	Ước lượng GAM qua Phương pháp Spline và Backfitting	22
2.3.5	Hạn chế của cấu trúc cộng tính và nhu cầu hồi quy phi tham số	23
2.4	Lý thuyết Hồi quy Phi tham số và Ước lượng Tuyến tính Cục bộ	23
2.4.1	Mô hình Hồi quy Phi tham số và Ước lượng Nadaraya–Watson	24
2.4.2	Ước lượng Tuyến tính Cục bộ (Local Linear Regression)	24
2.4.3	Giới hạn đối với biến phản hồi nhị phân	25
2.5	Hồi quy Logistic Phi tham số và Phương pháp Hợp lý Cục bộ	25
2.5.1	Mô hình Hồi quy Logistic Phi tham số Một chiều	26
2.5.2	Phương pháp Hợp lý Cực đại Cục bộ Tuyến tính	26
2.5.3	Nút thắt sinh tử: Lỗi nguyên số chiều (Curse of Dimensionality)	27
2.6	Hồi quy Logistic Biên và Chiến lược Hóa giải Lỗi nguyên Số chiều	27
2.6.1	Ý tưởng Phân rã Biên Một chiều	27
2.6.2	Ưu thế Vượt trội của Tiếp cận Biên	28
2.6.3	Dữ liệu lặp và dữ liệu dọc	28
2.6.4	Mô hình Logistic biên	29
2.6.5	Phương trình ước lượng tổng quát (GEE)	30
2.6.6	Phương sai Sandwich	31
2.6.7	Cấu trúc tương quan làm việc	31
2.6.8	Nhu cầu tổng hợp thông tin từ các mô hình biên	33
2.7	Lý thuyết Trung bình hóa Mô hình (Model Averaging)	34
2.7.1	Cơ sở lý thuyết của trung bình mô hình	34
2.7.2	Các loại trọng số	35
2.7.3	Đánh đổi Bias–Variance trong trung bình hóa	36
2.7.4	Phương pháp Stacking	37
2.7.5	Bayesian Model Averaging (BMA)	38
2.7.6	So sánh các phương pháp trung bình hóa	39
2.7.7	Tiêu chuẩn Tối ưu hóa Khoảng cách Kullback–Leibler (KL Divergence)	40

2.7.8	Cầu nối trực tiếp sang Chương 3: Mô hình MAMaLoR	40
2.8	Các Chỉ số Đánh giá Hiệu năng Phân loại Chuỗi Thời gian	41
2.8.1	ROC Curve và AUC (Area Under the Curve)	44
2.8.2	Kết luận	45
2.9	Các Đặc trưng Chuỗi Thời gian Tài chính	46
2.9.1	Độ biến động	46
2.9.2	Log-volume - đo khối giao dịch:	48
2.9.3	Lợi nhuận hình học (Geometric Return) – đo lường mức sinh lời và xu hướng biến động giá:	49
2.9.4	Biến nhân Y_t	50
 CHƯƠNG 3. PHƯƠNG PHÁP HỒI QUY LOGISTIC BIÊN PHI TUYẾN (MAMaLoR) VÀ TÍNH CHẤT TIỆM CẬN		
3.1	Động cơ và Cơ sở Toán học	52
3.2	Cấu trúc Mô hình MAMaLoR	53
3.2.1	Bước 1: Mô hình hóa các hồi quy logistic biên phi tham số	53
3.2.2	Bước 2: Trung bình hóa mô hình biên trong thang đo logit	54
3.3	Tiêu Chuẩn Tối Ưu Hóa Khoảng Cách Kullback–Leibler	54
3.4	Quy Trình Ước Lượng Hai Bước	55
3.4.1	Bước 1: Ước lượng hợp lý cực đại cục bộ tuyến tính (Local Linear Max- imum Likelihood)	55
3.4.2	Bước 2: Ước lượng vector trọng số kết hợp $\hat{\alpha}$	56
3.5	Hệ Giả Thiết Kỹ Thuật (Assumptions A1–A5)	57
3.6	Bổ Đề Nhất Quán và Tính Nhất Quán Của Trọng Số	58
3.7	Chuẩn Tắc Tiệm Cận Của Vector Trọng Số	59
3.8	Suy Diễn Thống Kê và Ước Lượng Ma Trận Hiệp Phương Sai	60
 CHƯƠNG 4. NGHIÊN CỨU MÔ PHỎNG VÀ ỨNG DỤNG THỰC TẾ		
4.1	Nghiên Cứu Mô Phỏng Monte Carlo	62
4.1.1	Thiết kế Mô hình Sinh Dữ liệu	62
4.1.2	Phân phối Có Điều Kiện của Y_t	63
4.1.3	Các Phương Pháp Đối Sánh và Tiêu Chí Đánh Giá	64
4.1.4	Kết Quả Mô Phỏng và Thảo Luận	64
4.2	Ứng Dụng Thực Tế: Dự Báo Hướng Biến Động Chỉ Số FTSE 100	66
4.2.1	Mô tả Dữ liệu và Xây dựng Biến Đặc trưng	66

4.2.2	Thiết kế Thực nghiệm	66
4.2.3	So sánh Hiệu quả Khớp Mô hình (Tiêu chí AIC)	67
4.2.4	Phân tích Ý nghĩa Thống kê của các Biến Dự Báo	67
4.2.5	Mở rộng Bậc Trễ và Đánh giá Khả năng Dự Báo Ngoài Mẫu (AUC)	68
CHƯƠNG 5. KẾT LUẬN VÀ KIẾN NGHỊ		69
5.1	Kết Luận	69
5.2	Đánh Giá Ưu Điểm và Hạn Chế của Phương Pháp	70
5.2.1	Ưu điểm nổi bật	70
5.2.2	Hạn chế còn tồn tại	70
5.3	Hướng Nghiên Cứu và Phát Triển trong Tương Lai	70
DANH MỤC TÀI LIỆU THAM KHẢO		72
PHỤ LỤC		78
A	Chứng Minh Bổ Đề Nhất Quán (Mệnh đề 3.7) và Định Lý 3.9	78
B	Chứng Minh Định Lý Chuẩn Tắc Tiệm Cận (Định lý 3.10)	80

2.1	Sơ đồ tư duy tiến trình phát triển lý thuyết dẫn đến mô hình MAMaLoR.	11
2.2	Minh họa dữ liệu chuỗi thời gian	12
2.3	Phân rã chuỗi thời gian thành các thành phần: xu hướng (Trend), chu kỳ (Cyclicity), mùa vụ (Seasonality) và nhiễu ngẫu nhiên (Irregular Fluctuations).	16
2.4	Các thành phần cơ bản của chuỗi thời gian	16
2.5	Minh họa kết quả phân loại và ma trận nhầm lẫn	41
2.6	Đường cong ROC và diện tích AUC	44

1.1	Dữ liệu minh họa FTSE 100	5
2.1	Phân loại chuỗi thời gian	13
2.2	Các thành phần đặc trưng của dữ liệu chuỗi thời gian	15
2.3	So sánh mô hình tham số, phi tham số và bán tham số	22
2.4	So sánh một số cấu trúc tương quan làm việc trong GEE	33
2.5	So sánh một số phương pháp trung bình hóa mô hình	39
2.6	Dữ liệu FTSE 100 sau khi cập nhập các biến mới	51
4.1	Các hệ số tuyến tính thành phần trong mô hình mô phỏng ($K = 9$) . .	63
4.2	AUC trung bình ngoài mẫu trong mô phỏng Monte Carlo ($n = 1000, n_p = 50, K = 9$)	65
4.3	So sánh tiêu chí AIC của các mô hình trên tập huấn luyện FTSE 100 .	67
4.4	So sánh AUC ngoài mẫu trên tập kiểm tra chỉ số FTSE 100 (200 quan sát)	68

DANH MỤC KÝ HIỆU VÀ THUẬT NGỮ

Danh mục các từ viết tắt

STT	Viết tắt	Tên tiếng Anh / Giải nghĩa
1	GAM	Generalized Additive Model
2	GLM	Generalized Linear Model
3	MAMAR	Model Averaging Marginal Regression
4	MAMaLoR	Model Averaging nonlinear MArginal LOgistic Regressions
5	ROC	Receiver Operating Characteristic
6	SVM	Support Vector Machine
7	TP	True Positive
8	TN	True Negative
9	FP	False Positive
10	FN	False Negative

Danh sách thuật ngữ chuyên ngành

Thuật ngữ tiếng Anh	Thuật ngữ tiếng Việt
Forecasting for Time Series Classification	Dự báo cho phân loại chuỗi thời gian
Generalized Additive Model	Mô hình cộng tính tổng quát
Curse of dimensionality	Lời nguyền của chiều không gian
Model Averaging nonlinear Marginal Logistic Regressions	Mô hình trung bình hồi quy logistic biên phi tuyến
Overfitting	Quá khớp
Underfitting	Chưa khớp
Supervised learning	Học có giám sát
Unsupervised learning	Học không giám sát

Thuật ngữ tiếng Anh	Thuật ngữ tiếng Việt
Semi-Supervised Learning	Học bán giám sát
Kernel Support Vector Machine	Máy hỗ trợ vector với hàm nhân
Marginal nonlinear logistic regressions	Mô hình logistic biên phi tuyến một chiều
Return	Lợi nhuận
Volatility	Độ biến động

TRANG THÔNG TIN LUẬN VĂN

Tên đề tài luận văn: PHÂN LOẠI CHUỖI THỜI GIAN VỚI MÔ HÌNH LOGISTIC BIÊN PHI TUYẾN

Ngành: Khoa học dữ liệu

Mã số ngành: 8460108

Họ tên học viên cao học: Nguyễn Huy Quang

Khóa đào tạo: Khóa 33 (12/2023 – 12/2025)

Người hướng dẫn khoa học: TS. Tô Đức Khánh

Cơ sở đào tạo: Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM

1. TÓM TẮT NỘI DUNG LUẬN VĂN

Luận văn nghiên cứu bài toán dự báo phân loại chuỗi thời gian nhị phân bằng phương pháp bán tham số trung bình hóa các mô hình hồi quy logistic biên phi tuyến (MAMaLoR), kế thừa và mở rộng mô hình MAMAR của Li, Linton và Lu (2015). Quy trình ước lượng hai bước gồm: (i) Bước 1 ước lượng phi tham số các hàm hồi quy logistic biên một chiều bằng phương pháp hợp lý cực đại cục bộ tuyến tính (local linear maximum likelihood); (ii) Bước 2 kết hợp tối ưu các thành phần biên bằng tổ hợp affine trong thang đo logit thông qua cực tiểu hóa khoảng cách Kullback–Leibler. Luận văn thiết lập chi tiết các giả thiết β -mixing, chứng minh tính chất tiệm cận (tính nhất quán và phân phối chuẩn tắc tiệm cận $\sqrt{n}$ cho vector trọng số), đồng thời đánh giá hiệu năng thực nghiệm thông qua mô phỏng Monte Carlo và ứng dụng dự báo hướng biến động chỉ số tài chính FTSE 100.

2. NHỮNG KẾT QUẢ MỚI CỦA LUẬN VĂN

- Hệ thống hóa và hoàn thiện khung lý thuyết cho mô hình MAMaLoR trong bài toán phân loại chuỗi thời gian nhị phân, khắc phục triệt để hiện tượng “lời nguyền số chiều” khi số lượng biến giải thích và số bậc trễ gia tăng.
- Đính chính các điểm thiếu sót trong tài liệu gốc và hoàn thiện chứng minh toán học cho các tính chất tiệm cận (Bổ đề Nhất quán Argmax và Định lý Chuẩn tắc Tiệm cận) dưới cấu trúc phụ thuộc β -mixing.
- Thực nghiệm đối sánh toàn diện: Mô phỏng Monte Carlo với nhiều kịch bản

(tuyến tính, phi tuyến cộng tính, phi tuyến tương tác) và thực nghiệm trên dữ liệu tài chính thực tế (FTSE 100) cho thấy MAMaLoR đạt AUC vượt trội (0.6041) so với các mô hình chuẩn như GLM và GAM.

3. CÁC ỨNG DỤNG / KHẢ NĂNG ỨNG DỤNG TRONG THỰC TIỄN

Mô hình MAMaLoR có khả năng ứng dụng trực tiếp trong phân tích chuỗi thời gian tài chính (dự báo xu hướng giá, giao dịch định lượng, quản trị rủi ro), y sinh học và giám sát công nghiệp.

CÁN BỘ HƯỚNG DẪN

HỌC VIÊN CAO HỌC

TS. Tô Đức Khánh

Nguyễn Huy Quang

THESIS INFORMATION

Thesis title: NONLINEAR MARGINAL LOGISTIC REGRESSIONS FOR TIME SERIES CLASSIFICATION PROBLEM

Major: Data Science

Major code: 8460108

Master student: Nguyen Huy Quang

Cohort: Intake 33 (12/2023 – 12/2025)

Supervisor: PhD. To Duc Khanh

Institution: University of Science, Vietnam National University, Ho Chi Minh City

1. THESIS ABSTRACT

This thesis investigates binary time series classification forecasting via a semiparametric approach termed Model Averaging nonlinear MArginal LOGistic Regressions (MAMaLoR), extending the MAMAR framework of Li, Linton, and Lu (2015). The methodology consists of a two-step estimation procedure: (i) Step 1 nonparametrically estimates one-dimensional marginal logistic regression functions via local linear maximum likelihood fitting; (ii) Step 2 optimally combines the marginal logit components via an affine combination under the logit scale by minimizing the Kullback–Leibler discrepancy. The thesis establishes technical β -mixing regularity conditions, proves asymptotic properties (uniform consistency and $\sqrt{n}$ -asymptotic normality of the combination weights), and evaluates empirical performance through Monte Carlo simulations and forecasting the FTSE 100 direction.

2. NOVEL SCIENTIFIC CONTRIBUTIONS

- Systematically formulates and completes the theoretical framework of MAMaLoR for binary time series classification, overcoming the curse of dimensionality inherent in high-lag spaces.
- Rectifies mathematical ambiguities in the literature regarding the Argmax Consistency Lemma and completes rigorous proofs for asymptotic normality under β -mixing processes.
- Provides empirical validation demonstrating that MAMaLoR significantly out-

performs classical GLM and additive models (GAM) in nonlinear and interaction regimes, achieving superior predictive AUC (0.6041) on FTSE 100 return data.

3. APPLICATIONS AND PERSPECTIVES

The proposed MAMaLoR model has direct practical applications in financial econometrics (direction forecasting, algorithmic trading, risk management), biomedical signal classification, and industrial fault detection.

SUPERVISOR

MASTER STUDENT

PhD. To Duc Khanh

Nguyen Huy Quang

LỜI NÓI ĐẦU

Trong những năm gần đây, cùng với sự phát triển của khoa học dữ liệu và trí tuệ nhân tạo, nhu cầu khai thác thông tin từ dữ liệu chuỗi thời gian ngày càng trở nên quan trọng trong nhiều lĩnh vực như tài chính, kinh tế, y sinh, công nghiệp và giám sát hệ thống. Đặc trưng của dữ liệu chuỗi thời gian là các quan sát được ghi nhận theo trình tự thời gian và thường có sự phụ thuộc nhất định giữa các thời điểm. Bên cạnh bài toán dự báo giá trị của một đại lượng trong tương lai, nhiều bài toán thực tiễn yêu cầu xác định trạng thái hoặc xu hướng của đối tượng nghiên cứu, chẳng hạn như thị trường tăng hay giảm, khách hàng có vỡ nợ hay không, hoặc thiết bị có xảy ra lỗi trong chu kỳ tiếp theo. Những bài toán này được mô hình hóa dưới dạng phân loại chuỗi thời gian nhị phân, mục tiêu là dự báo một biến phản hồi nhận một trong hai giá trị có thể xảy ra dựa trên thông tin quan sát được ở hiện tại và trong quá khứ, đóng vai trò quan trọng trong việc hỗ trợ ra quyết định.

Để thực hiện nhiệm vụ này, một trong những vấn đề quan trọng là khai thác đầy đủ thông tin phụ thuộc theo thời gian được chứa trong các biến trễ của biến phản hồi và các biến giải thích. Khác với dữ liệu độc lập thông thường, chuỗi thời gian nhị phân mang đặc trưng phụ thuộc theo thời gian: thông tin từ quá khứ (các độ trễ) của biến phản hồi cùng các biến giải thích đóng vai trò quan trọng trong việc dự báo các giá trị ở các thời điểm tiếp theo. Đồng thời, trong nhiều ứng dụng thực tế, mối quan hệ giữa biến mục tiêu và các biến giải thích không nhất thiết có dạng tuyến tính mà có thể mang tính phi tuyến, không cộng tính và chịu ảnh hưởng đáng kể của nhiễu.

Trong số các phương pháp phân loại nhị phân tham số truyền thống, hồi quy logistic tuyến tính tuy đơn giản và dễ diễn giải [26, 31], nhưng chỉ phù hợp khi quan hệ giữa biến mục tiêu và các biến giải thích là tuyến tính trong thang đo logit. Trong thực tế, ví dụ với dữ liệu tài chính, quan hệ này thường mang tính phi tuyến, không cộng tính và chịu ảnh hưởng mạnh của nhiễu, khiến các mô hình tuyến tính cho hiệu suất dự báo hạn chế. Ở chiều ngược lại, các phương pháp phi tham số, tiêu biểu là mô hình cộng tính tổng quát (GAM) [6, 28, 27] lại gặp hạn chế về "lời nguyền của chiều không gian" – khi số lượng độ trễ và biến giải thích tăng lên, chất lượng ước lượng phi tham số suy giảm nhanh chóng.

Những hạn chế nói trên cho thấy cần có một phương pháp có khả năng dung hòa giữa tính linh hoạt của mô hình phi tham số và khả năng kiểm soát độ phức tạp của mô hình tham số. Kế thừa ý tưởng từ mô hình trung bình hóa hồi quy biên (MAMAR) cho chuỗi thời gian liên tục của [2], mô hình Logistic biên phi tuyến MAMaLoR (*Model Averaging nonlinear MArginal LOgistic Regressions*) được [1] đề xuất như một phương pháp bán tham số tiên tiến dành cho bài toán phân loại chuỗi thời gian nhị phân dựa trên nguyên lý tối ưu hóa khoảng cách Kullback–Leibler [50]. Thay vì xây dựng trực tiếp một mô hình đa biến phi tham số có số chiều lớn, MAMaLoR khai thác thông tin từ các biến giải thích và các độ trễ thông qua các hồi quy logistic biên phi tuyến, sau đó kết hợp các mô hình này bằng phương pháp trung bình mô hình. Cách tiếp cận này cho phép mô hình hóa các quan hệ phi tuyến một cách linh hoạt, đồng thời hạn chế sự gia tăng quá mức của độ phức tạp do số chiều của dữ liệu. MAMaLoR giúp xây dựng các mô hình dự báo hiệu quả cho dữ liệu chuỗi thời gian có số chiều lớn, đồng thời giảm ảnh hưởng của vấn đề "lời nguyền chiều không gian". Nhờ đó, mô hình có khả năng xử lý các mối quan hệ phi tuyến phức tạp và cải thiện độ chính xác trong các bài toán dự báo phân loại.

Bố cục của luận văn gồm năm chương với nội dung cơ bản như sau:

Chương 1. Tổng quan. Trình bày bối cảnh và vấn đề nghiên cứu, tổng quan tình hình nghiên cứu về phân loại chuỗi thời gian, giới thiệu ví dụ thực tế là chỉ số FTSE 100 cùng các đặc trưng được xây dựng, phân tích lý do lựa chọn mô hình MAMaLoR, và xác định mục đích, đối tượng, phạm vi cũng như phương pháp nghiên cứu của đề tài.

Chương 2. Cơ sở lý thuyết. Trình bày các khái niệm nền tảng: tổng quan về học máy và bài toán phân loại nhị phân, dữ liệu chuỗi thời gian, hồi quy logistic và ước lượng hợp lý cực đại, làm trơn phi tham số bằng kỹ thuật đa thức địa phương, mô hình cộng tính tổng quát, khái niệm phụ thuộc yếu cho chuỗi thời gian, tư tưởng trung bình mô hình cùng khoảng cách Kullback–Leibler, và các chỉ số đánh giá mô hình phân loại.

Chương 3. Phương pháp MAMaLoR. Trình bày chi tiết mô hình MAMaLoR, quy trình ước lượng hai bước (ước lượng các hồi quy logistic biên bằng phương pháp local-linear và ước lượng trọng số trung bình mô hình bằng phương pháp hợp lý có điều kiện), cùng các tính chất tiệm cận (tính nhất quán và chuẩn tiệm cận) và chứng minh.

Chương 4. Nghiên cứu mô phỏng và ứng dụng. Mô tả thiết kế các thí nghiệm số: nghiên cứu mô phỏng Monte-Carlo với nhiều cấu trúc dữ liệu và ứng dụng thực tế vào dự báo chiều biến động chỉ số FTSE 100, kèm theo phân tích, so sánh kết quả với các mô hình đối chứng.

Chương 5. Kết luận và kiến nghị. Tổng hợp các kết quả đạt được, nêu những hạn chế còn tồn tại và đề xuất các hướng nghiên cứu mở rộng trong tương lai.

Phụ lục. Trình bày chi tiết các bổ đề kỹ thuật và chứng minh toán học đầy đủ cho các định lý tiệm cận của mô hình MAMaLoR.

CHƯƠNG 1. TỔNG QUAN

1.1 Giới thiệu tổng quan

Phân loại chuỗi thời gian là một hướng nghiên cứu quan trọng trong thống kê và học máy, nhằm ước lượng xác suất xuất hiện của một trạng thái nhị phân tại thời điểm tương lai dựa trên thông tin từ quá khứ [25, 39, 58]. Khác với các mô hình dự báo giá trị liên tục, dạng bài toán này yêu cầu mô hình vừa phải xử lý tính phụ thuộc theo thời gian, vừa phải nắm bắt được sự phức tạp phi tuyến trong dữ liệu thực tế [14].

Đặc biệt là trong lĩnh vực tài chính – kinh tế, tín dụng, cảnh báo rủi ro và quản lý hệ thống, việc dự đoán một tín hiệu nhị phân như (tăng/giảm giá cổ phiếu, vỡ nợ/không vỡ nợ, lỗi/không lỗi) đóng vai trò làm cơ sở cho quá trình ra quyết định, giúp lựa chọn ra phương án phù hợp và hỗ trợ kiểm soát rủi ro [20, 57, 58]. Tuy nhiên, dữ liệu chuỗi thời gian thực tế thường mang đặc tính nhiễu, phi tuyến, có quan hệ phức tạp giữa các độ trễ và chịu ảnh hưởng của các điều kiện thị trường. Những hạn chế này đặt ra nhu cầu phát triển các mô hình dự báo linh hoạt hơn, vượt ra ngoài cấu trúc tuyến tính truyền thống.

Chỉ số chứng khoán FTSE 100, được giao dịch hằng ngày trên thị trường chứng khoán London được lựa chọn làm dữ liệu nghiên cứu thực nghiệm nhằm minh họa khả năng của mô hình MAMaLoR đối với bài toán phân loại chuỗi thời gian nhị phân theo nghiên cứu thực nghiệm của [1]. Tập dữ liệu nghiên cứu trong giai đoạn từ ngày 01/05/2013 đến ngày 01/05/2018, bao gồm các biến cơ bản sau:

- Chỉ mục (Index)
- Ngày giao dịch (Date)
- Điểm mở cửa (Open): mức điểm lúc bắt đầu mở cửa — đơn vị: điểm chỉ số
- Điểm đóng cửa (Close): mức điểm chốt lúc đóng cửa — đơn vị: điểm chỉ số
- Điểm cao nhất (High): mức điểm bán cao nhất trong ngày — đơn vị: điểm chỉ số
- Điểm thấp nhất (Low): mức điểm bán thấp nhất trong ngày — đơn vị: điểm chỉ số
- Khối lượng giao dịch (Volume): số lượng đơn vị cổ phiếu được giao dịch trong ngày — đơn vị: số cổ phiếu

Index	Date	Close	High	Low	Open	Volume
0	2013-05-01	6451.30	6475.90	6429.80	6430.10	409459900
1	2013-05-02	6460.70	6470.30	6409.80	6451.30	744888400
2	2013-05-03	6521.50	6541.70	6451.50	6460.70	768857600
...	...	...	...	...	...	...
1263	2018-04-30	7509.30	7546.20	7497.10	7502.20	991178200
1264	2018-05-01	7520.40	7549.10	7506.60	7509.30	567569600

Bảng 1.1: Dữ liệu minh họa FTSE 100

Để phục vụ cho bài toán phân loại, từ các biến dữ liệu gốc, nghiên cứu tiến hành xây dựng thêm một số đặc trưng nhằm phản ánh các khía cạnh khác nhau của diễn biến thị trường, bao gồm độ biến động giá Parkinson [15] và Garman–Klass [16], logarit của khối lượng giao dịch và lợi suất log của chỉ số [58, 20]. Bên cạnh đó, một biến nhân nhị phân được xây dựng để biểu diễn trạng thái tăng hoặc giảm của chỉ số theo quy ước phân loại của [1].

Các đặc trưng và biến nhân này được trình bày chi tiết trong các mục tiếp theo. Việc tách riêng quá trình xây dựng đặc trưng và biến nhân giúp làm rõ vai trò của từng biến, đồng thời thuận tiện cho quá trình tiền xử lý và xây dựng tập dữ liệu đầu vào cho mô hình.

Mục tiêu của nghiên cứu là xây dựng và đánh giá các mô hình phân loại chuỗi thời gian nhằm dự đoán xu hướng biến động của chỉ số FTSE 100. Cụ thể, bài toán được xây dựng dưới dạng phân loại nhị phân, trong đó trạng thái của chỉ số được biểu diễn bởi hai lớp tăng và giảm. Trên cơ sở dữ liệu lịch sử, mô hình được kỳ vọng có khả năng khai thác sự phụ thuộc theo thời gian, các mối quan hệ phi tuyến giữa các biến và những đặc điểm nhiễu, biến động của dữ liệu tài chính.

Như vậy, bài toán nghiên cứu có thể được khái quát thành ba yêu cầu chính:

- (i) sự phụ thuộc theo thời gian,
- (ii) mối quan hệ phi tuyến giữa các biến,
- (iii) ảnh hưởng của nhiễu và biến động mạnh đặc trưng của thị trường tài chính.

1.2 Lý do lựa chọn Mô hình MAMaLoR

Mô hình MAMaLoR do [1] đề xuất (kế thừa tư tưởng trung bình mô hình hồi quy biên MAMAR của [2]) nhằm khắc phục các hạn chế của những mô hình truyền thống thông qua các đặc điểm sau:

- Ước lượng các mô hình logistic biên phi tuyến một chiều. Kết hợp các mô hình biên bằng phương pháp tính trung bình của mô hình để tạo nên mô hình tổng thể.
- Hạn chế ảnh hưởng của hiện tượng “lời nguyền chiều không gian” thông qua việc không ước lượng trực tiếp mô hình logistic đa biến.
- Khai thác hiệu quả thông tin phi tuyến, đặc biệt trong các chuỗi tài chính có nhiễu và biến động mạnh.

Nhờ những ưu điểm này, MAMaLoR là lựa chọn phù hợp cho bài toán phân loại chuỗi thời gian.

1.3 Mục đích nghiên cứu

Mục đích nghiên cứu của đề tài này là phát triển quy trình dự báo phân loại nhị phân trong các bài toán dự đoán xác suất phân loại, đặc biệt là trong các tình huống có dữ liệu khuyết hoặc nhiễu. Qua đó, đề tài này sẽ có 3 đóng góp chính như sau:

- Cải thiện độ chính xác phân loại nhị phân cho dữ liệu chuỗi thời gian: MAMaLoR sẽ kết hợp và lấy trung bình dự báo xác suất từ nhiều mô hình phi tuyến tính khác nhau nhằm cải thiện độ chính xác và tính ổn định của dự báo phân loại nhị phân, đặc biệt trong các bối cảnh dữ liệu chuỗi thời gian bị nhiễu và có dữ liệu khuyết.
- Đề xuất kỹ thuật giảm tác động của nhiễu và dữ liệu khuyết trong bài toán phân loại: Nghiên cứu tập trung phân tích vai trò của phương pháp trung bình mô hình trong việc giảm thiểu ảnh hưởng bất lợi của nhiễu và dữ liệu khuyết lên kết quả phân loại. Hiệu quả của phương pháp MAMaLoR được đánh giá thông qua so sánh với các phương pháp phân loại truyền thống, qua đó làm rõ ưu thế của phương pháp đề xuất trong các mô hình phi tuyến tính.

- So sánh hiệu quả tính toán và khả năng xử lý dữ liệu lớn: Đề tài tiến hành đánh giá hiệu quả tính toán và khả năng mở rộng của MAMaLoR trong các bài toán phân loại nhị phân với tập dữ liệu quy mô lớn. Nhờ cơ chế trung bình mô hình, phương pháp giúp giảm chi phí tính toán và thời gian ước lượng tham số, từ đó nâng cao tính khả thi khi áp dụng trong các ứng dụng thực tế.

1.4 Đối tượng nghiên cứu

Đối tượng nghiên cứu chính của đề tài là quy trình dự báo cho phân loại chuỗi thời gian với mô hình logistic biên phi tuyến.

Bộ dữ liệu được sử dụng: FTSE 100 index ghi lại thông tin giao dịch hằng ngày của chỉ số FTSE 100 index trên thị trường chứng khoán London, bao gồm các thuộc tính: Date (ngày giao dịch), Open (giá mở cửa), Close (giá đóng cửa), High (giá cao nhất), Low (giá thấp nhất) và Volume (khối lượng giao dịch). Mục tiêu của bài toán là dự báo chiều biến động của thị trường (tăng hoặc giảm), được biểu diễn dưới dạng biến nhị phân Y_t dựa trên các thông tin sẵn có trước ngày dự báo.

Thêm dữ liệu <https://github.com/MowlanicaBilla/Time-Series-Classification/tree/master>

1.5 Các phương pháp nghiên cứu

Phương pháp nghiên cứu lý thuyết:

- Tổng hợp khái niệm về các mô hình học máy thường được sử dụng (hồi quy logistic, Máy vectơ hỗ trợ, cây quyết định) và hồi quy phi tuyến, cũng như nguyên nhân sử dụng mô hình trung bình khi dữ liệu có nhiễu và khuyết trong bài toán phân loại nhị phân.
- Định nghĩa mô hình MAMaLoR, mô tả, nguyên lý hoạt động và cách kết hợp kết quả từ nhiều mô hình phi tuyến tính nhằm cải thiện khả năng ước lượng xác suất và dự báo phân loại.

Phương pháp nghiên cứu thực nghiệm:

- Xây dựng quy trình sử dụng MAMaLoR cho bài toán phân loại nhị phân, bao gồm: xây dựng tập mô hình cơ sở, thực hiện tổng hợp mô

hình, đánh giá hiệu quả phân loại và lựa chọn ngưỡng phân loại tối ưu, cũng như phân loại trên bộ dữ liệu mới.

- Thực nghiệm mô phỏng trên các bộ dữ liệu có nhiễu và khuyết bằng Python, triển khai các mô hình học máy và học sâu làm mô hình cơ sở, nhằm kiểm tra kết quả, tính khả thi và khả năng ứng dụng thực tế của phương pháp MAMaLoR.

Phương pháp so sánh và đánh giá: Sau khi có kết quả thực nghiệm, tiến hành phân tích, so sánh kết quả của thuật toán với các thuật toán khác và đưa ra kết luận cho đề tài.

1.6 Phạm vi của vấn đề sẽ đi sâu nghiên cứu

Luận văn tập trung nghiên cứu về mô hình MAMaLoR và khả năng ứng dụng của phương pháp này trong bài toán phân loại nhị phân đối với dữ liệu có nhiễu và khuyết. Phạm vi nghiên cứu của luận văn được giới hạn trong các nội dung sau:

Thứ nhất, luận văn nghiên cứu và sử dụng một số mô hình học máy (hồi quy logistic [26], máy hỗ trợ véc-tơ, cây quyết định), hồi quy phi tuyến [6, 27] và một số mô hình học sâu làm mô hình cơ sở [39, 49]. Các mô hình này được lựa chọn nhằm phục vụ cho việc xây dựng và đánh giá mô hình tổng hợp MAMaLoR [1], không nhằm mục tiêu khảo sát toàn bộ các phương pháp học máy hiện có.

Thứ hai, luận văn tập trung vào việc mô tả, xây dựng và phân tích mô hình MAMaLoR, trong đó nhấn mạnh khả năng kết hợp kết quả từ nhiều mô hình phi tuyến nhằm cải thiện khả năng ước lượng xác suất và hiệu quả phân loại trong bài toán phân loại nhị phân.

Thứ ba, phạm vi nghiên cứu được giới hạn trong bài toán phân loại nhị phân, không mở rộng sang các bài toán phân loại đa lớp hoặc các bài toán hồi quy liên tục.

Thứ tư, các thực nghiệm mô phỏng được thực hiện trên các bộ dữ liệu có mức độ nhiễu và khuyết khác nhau bằng ngôn ngữ Python nhằm đánh giá hiệu quả, tính khả thi và khả năng ứng dụng thực tế của phương pháp MAMaLoR. Luận văn không đi sâu vào nghiên cứu các phương pháp xử lý dữ liệu phức tạp hoặc các vấn đề liên quan đến triển khai hệ thống trong môi trường thời gian thực.

Cuối cùng, việc đánh giá kết quả tập trung vào các chỉ tiêu đánh giá phổ biến trong

bài toán phân loại nhị phân và so sánh hiệu quả của phương pháp MAMaLoR với các mô hình cơ sở; các vấn đề về tối ưu hóa chi phí tính toán và tài nguyên hệ thống không thuộc phạm vi nghiên cứu của luận văn.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1 Tổng quan Bài toán Phân loại Chuỗi Thời gian Nhị phân

Trong phân tích dữ liệu hiện đại, đặc biệt là trong các lĩnh vực tài chính, kinh tế lượng và kiểm soát rủi ro, dữ liệu thực nghiệm thường được ghi nhận tuần tự theo thời gian dưới dạng chuỗi thời gian. Đối với nhiều bài toán ra quyết định thực tế, mục tiêu trọng tâm không phải là dự báo một đại lượng liên tục mà là xác định trạng thái định tính của hệ thống tại chu kỳ kế tiếp, chẳng hạn như: chiều biến động của chỉ số chứng khoán (tăng hay giảm), tình trạng thực hiện nghĩa vụ nợ của khách hàng tín dụng (vỡ nợ hay không vỡ nợ), hoặc tình trạng vận hành của thiết bị công nghiệp (bình thường hay phát sinh sự cố). Những bài toán này được mô hình hóa dưới dạng **bài toán phân loại chuỗi thời gian nhị phân** (*Binary Time Series Classification*).

Xét không gian xác suất nền tảng $(\Omega, \mathcal{F}, \mathbb{P})$. Giả sử $\{(Y_t, X_t^\top)\}_{t \in \mathbb{Z}}$ là một quá trình ngẫu nhiên dừng nghiêm ngặt theo thời gian rời rạc, trong đó $Y_t \in \{0, 1\}$ là biến phản hồi nhị phân ghi nhận tại thời điểm t , và:

$$X_t = (x_{1t}, x_{2t}, \dots, x_{dt})^\top \in \mathbb{R}^d \quad (2.1)$$

là vector ngẫu nhiên d chiều biểu diễn toàn bộ tập thông tin quan sát được cho đến thời điểm $t - 1$, ký hiệu là $\mathcal{I}_{t-1}$. Vector đặc trưng X_t thường bao gồm các giá trị trễ của biến phản hồi $Y_{t-1}, Y_{t-2}, \dots, Y_{t-q}$, các biến giải thích ngoại sinh trễ, cũng như các chỉ báo kỹ thuật tài chính động học.

Mục tiêu cốt lõi của bài toán là mô hình hóa và ước lượng chính xác xác suất có điều kiện:

$$p_t := \mathbb{P}(Y_t = 1 \mid \mathcal{I}_{t-1}) = \mathbb{P}(Y_t = 1 \mid X_t). \quad (2.2)$$

Khác với dữ liệu độc lập và cùng phân phối (i.i.d.), chuỗi thời gian mang bản chất phụ thuộc nội tại theo thời gian. Do đó, việc xây dựng mô hình dự báo phân loại nhị phân phải đối mặt đồng thời với hai thách thức lớn:

- (i) **Tính phụ thuộc chuỗi và phi tuyến tính:** Mối quan hệ giữa các biến trễ trong quá khứ và trạng thái tương lai thường mang tính phi tuyến sâu sắc, không cộng

tính và chịu ảnh hưởng mạnh của nhiễu thị trường.

- (ii) **Lời nguyền số chiều (Curse of Dimensionality):** Để bao quát đầy đủ thông tin động học, mô hình buộc phải thu nạp nhiều bậc trễ và nhiều biến giải thích, khiến số chiều d gia tăng nhanh chóng. Khi đó, các phương pháp phi tham số đa biến cổ điển bị suy giảm nghiêm trọng về tốc độ hội tụ tiệm cận, dữ liệu trở nên cực kỳ thưa thớt trong không gian nhiều chiều, dẫn đến hiện tượng quá khớp và sai số phương sai bùng nổ.

Để giải quyết thấu đáo bài toán này, luận văn xây dựng tiến trình phát triển lý thuyết mạch lạc, dẫn dắt từ các mô hình tham số cổ điển đến mô hình bán tham số trung bình hóa các hồi quy logistic biên phi tuyến (MAMaLoR) được tóm lược trong Sơ đồ tư duy Hình 2.1.



Hình 2.1: Sơ đồ tư duy tiến trình phát triển lý thuyết dẫn đến mô hình MAMaLoR.

2.1.1 Đặc điểm và các thành phần của chuỗi thời gian


Dữ liệu chuỗi thời gian [25] là tập hợp các quan sát được thu thập và sắp xếp theo thứ tự thời gian, thường tại các khoảng thời gian đều đặn như ngày, tháng hoặc năm. Mỗi quan sát gắn với một thời điểm hoặc một chỉ số thời gian cụ thể. Điểm quan trọng nhất là thứ tự của các quan sát mang ý nghĩa phân tích; nếu đảo thứ tự dữ liệu, thông tin về xu hướng, mùa vụ, độ trễ và quan hệ quá khứ - hiện tại có thể bị mất.

$$Y_t, \quad t = 1, 2, \dots, T,$$

Trong đó:

- Y_t : giá trị quan sát tại thời điểm t ;
- $t = 1, 2, \dots, T$: chỉ số thời gian;
- T : tổng số thời điểm quan sát của chuỗi dữ liệu.

Dữ liệu chuỗi thời gian được ứng dụng rộng rãi trong nhiều lĩnh vực của đời sống và sản xuất, từ việc theo dõi các hiện tượng tự nhiên như lượng mưa, nhiệt độ, đến việc phân tích sự biến động của thị trường chứng khoán. Bên cạnh đó, trong lĩnh vực kinh doanh và quản lý, dữ liệu chuỗi thời gian đóng vai trò quan trọng trong việc phân tích và đánh giá xu hướng hoạt động theo thời gian. Thông qua việc khai thác loại dữ liệu này, doanh nghiệp có thể theo dõi các chỉ tiêu quan trọng như số lượng sản phẩm tiêu thụ theo từng tháng hoặc số lượt người dùng truy cập website theo từng ngày, từ đó hỗ trợ công tác lập kế hoạch và ra quyết định.



Hình 2.2: Minh họa dữ liệu chuỗi thời gian

Minh họa trong Hình 2.2, về mặt khái niệm, chuỗi thời gian là tập hợp các quan sát gắn liền với các mốc thời gian. Các quan sát này được sắp xếp theo trình tự thời gian và có thể được thu thập tại các khoảng thời gian cách đều nhau, như trong dữ liệu đo lường, hoặc không cách đều nhau, như trong các dữ liệu dạng sự kiện.

2.1.2 Chuỗi thời gian liên tục và rời rạc

Chuỗi thời gian liên tục là chuỗi được ghi nhận gần như liên tục theo thời gian, ví dụ tín hiệu ECG, âm thanh, rung động máy móc, dữ liệu cảm biến. Chuỗi thời gian

rời rạc là chuỗi được ghi nhận tại các thời điểm cụ thể, thường cách đều nhau, ví dụ doanh số theo ngày, nhiệt độ mỗi 10 phút, sản lượng theo tháng.

Loại chuỗi	Đặc điểm	Ví dụ
Liên tục	Quan sát gần như liên tục hoặc với tần suất lấy mẫu rất cao; giá trị thường là biến liên tục.	ECG, tín hiệu âm thanh, cảm biến rung.
Rời rạc	Quan sát tại các thời điểm xác định, thường cách đều nhau; giá trị được ghi nhận theo từng mốc thời gian.	Doanh số ngày, giá cổ phiếu theo phút, lượng mưa ngày.
Nhị phân	Quan sát chỉ nhận hai trạng thái, thường mã hóa $Y_t \in \{0, 1\}$, trong đó 1 biểu thị sự kiện xảy ra và 0 biểu thị sự kiện không xảy ra.	Trạng thái thiết bị (bật/tắt), cảnh báo lỗi, phát hiện gian lận.

Bảng 2.1: Phân loại chuỗi thời gian

2.1.3 Đặc điểm quan trọng của dữ liệu chuỗi thời gian

- **Tính phụ thuộc theo thời gian:** Giá trị của một chuỗi tại một thời điểm nhất định, ký hiệu là y_t , thường chịu ảnh hưởng bởi các giá trị của nó tại những thời điểm trước đó, chẳng hạn như y_{t-1} , y_{t-2} , và các độ trễ xa hơn. Mỗi quan hệ giữa một quan sát và các giá trị quá khứ của nó được gọi là **tự tương quan** (*autocorrelation*) hoặc **tương quan chuỗi** (*serial correlation*) [25, 58]. Để kiểm tra tính dừng của chuỗi, các kiểm định nghiệm đơn vị kinh điển như kiểm định Dickey–Fuller mở rộng (ADF) [51, 52] và kiểm định KPSS [53] thường được áp dụng trước khi mô hình hóa.
- **Tính thứ tự của dữ liệu:** Do các quan sát trong dữ liệu chuỗi thời gian gắn liền với những thời điểm cụ thể, thứ tự của chúng đóng vai trò đặc biệt quan trọng. Việc hoán vị ngẫu nhiên hay xáo trộn ngẫu nhiên các quan sát trong một chuỗi thời gian sẽ làm phá vỡ các mối quan hệ tuần tự giữa các giá trị, từ đó khiến hầu hết các kỹ thuật phân tích chuỗi thời gian trở nên không còn ý nghĩa. Chuỗi giá trị $y_1, y_2, \dots, y_T$ chứa đựng thông tin về cấu trúc thời gian, và thông tin này sẽ bị mất nếu thứ tự của các quan sát bị thay đổi.


Điều này hoàn toàn trái ngược với dữ liệu cắt ngang (*cross-sectional data*), chẳng

hạn như dữ liệu khảo sát sở thích của khách hàng được thu thập tại một thời điểm nhất định, trong đó thứ tự của các quan sát thường không mang thông tin và việc hoán đổi thứ tự các hàng trong tập dữ liệu không làm ảnh hưởng đến kết quả phân tích.


2.1.4 Các thành phần của dữ liệu chuỗi thời gian

Một chuỗi thời gian thường được xem là sự kết hợp của nhiều thành phần khác nhau, trong đó mỗi thành phần phản ánh một dạng quy luật hoặc biến động tiềm ẩn của dữ liệu theo thời gian. Việc phân tích và tách riêng các thành phần này giúp làm rõ cấu trúc nội tại của chuỗi thời gian, đồng thời hỗ trợ hiệu quả cho các bài toán như mô hình hóa, dự báo, phân loại và phát hiện bất thường.

Thành phần	Định nghĩa	Ví dụ
Xu hướng (Trend) [23]	Tính xu hướng trong dữ liệu chuỗi thời gian đề cập đến sự chuyển động tăng hoặc giảm dài hạn của dữ liệu, phản ánh khuynh hướng chung của chuỗi theo thời gian. Trong thực tế, có một số loại xu hướng cơ bản thường gặp như sau: • Upward Trend: Xu hướng tăng, trong đó giá trị của chuỗi thời gian có khuynh hướng tăng dần theo thời gian. • Downward Trend: Xu hướng giảm, thể hiện sự suy giảm tổng thể của chuỗi thời gian theo thời gian. • Horizontal Trend: Xu hướng ngang, khi chuỗi thời gian dao động quanh một mức trung bình tương đối ổn định. • Non-linear Trend: Xu hướng phi tuyến, trong đó sự thay đổi của chuỗi không tuân theo dạng tuyến tính.	Sự gia tăng trong việc áp dụng công nghệ xe điện; doanh thu của một công ty khởi nghiệp.
Tính mùa vụ (Seasonality) [23]	Tính thời vụ trong dữ liệu chuỗi thời gian đề cập đến các mẫu biến động lặp lại theo những chu kỳ thời gian cố định và đã biết trước, chẳng hạn như theo ngày, tuần, tháng hoặc năm.	Nhu cầu tiêu thụ điện tăng cao vào các tháng mùa hè.
Chu kỳ (Cyclic Variations) [23]	Tính chu kỳ trong dữ liệu chuỗi thời gian đề cập đến các biến động lặp lại theo thời gian, phản ánh những dao động trung hạn của chuỗi dữ liệu. Các chu kỳ này	Chu kỳ tăng trưởng và suy thoái của thị trường bất động sản.



Hình 2.3: Phân rã chuỗi thời gian thành các thành phần: xu hướng (Trend), chu kỳ (Cyclicity), mùa vụ (Seasonality) và nhiễu ngẫu nhiên (Irregular Fluctuations).



Hình 2.4: Các thành phần cơ bản của chuỗi thời gian

2.1.5 Chuỗi thời gian nhị phân

Chuỗi thời gian nhị phân [24, 42] là một dãy các biến ngẫu nhiên nhận giá trị trong không gian hai trạng thái rời rạc $\{0, 1\}$. Trong bài toán phân loại và dự báo, biến phản hồi $Y_t = 1$ biểu thị sự kiện quan tâm “xảy ra” (chẳng hạn giá cổ phiếu ngày t tăng so với ngày $t - 1$, khách hàng vỡ nợ, hoặc hệ thống phát sinh lỗi) và $Y_t = 0$ biểu thị sự kiện “không xảy ra”.

Khác với chuỗi giá trị liên tục thông thường, chuỗi thời gian nhị phân đòi hỏi các mô hình xác suất có điều kiện chuyên biệt nhằm đảm bảo giá trị dự báo luôn nằm trong đoạn $[0, 1]$, đồng thời phải nắm bắt được cấu trúc phụ thuộc phi tuyến theo thời gian từ các bậc trễ quá khứ [24, 1].

2.2 Cơ sở Xác suất và Hồi quy Logistic Cổ điển

Hồi quy logistic là một trường hợp cơ bản và kinh điển nhất của mô hình tuyến tính tổng quát (GLM), được sử dụng rộng rãi khi biến đáp ứng chỉ nhận hai trạng thái nhị phân $\{0, 1\}$.

2.2.1 Phân phối Bernoulli và Mô hình Xác suất

Với mỗi quan sát thứ i ($i = 1, \dots, n$), giả sử biến đáp ứng Y_i có điều kiện trên vector biến giải thích $x_i \in \mathbb{R}^d$ tuân theo phân phối Bernoulli với tham số xác suất p_i :

$$Y_i | x_i \sim \text{Bernoulli}(p_i), \quad p_i = \mathbb{P}(Y_i = 1 | x_i). \quad (2.3)$$

Hàm khối xác suất của Y_i có dạng:

$$\mathbb{P}(Y_i = y_i | x_i) = p_i^{y_i} (1 - p_i)^{1-y_i}, \quad y_i \in \{0, 1\}. \quad (2.4)$$

Nếu mô hình hóa trực tiếp xác suất p_i bằng biểu thức tuyến tính thông thường $x_i^\top \beta$, giá trị dự báo có thể tràn ra ngoài đoạn xác suất hợp lệ $[0, 1]$. Hồi quy logistic giải quyết triệt để hạn chế này bằng cách ánh xạ bộ dự báo tuyến tính $\eta_i = \beta_0 + x_i^\top \beta$ qua hàm phân phối tích lũy logistic chuẩn tắc (hàm sigmoid) [31, 26]:

$$p_i = \frac{\exp(\eta_i)}{1 + \exp(\eta_i)} = \frac{1}{1 + \exp(-\eta_i)}. \quad (2.5)$$

Đồ thị của hàm logistic có dạng chữ S (sigmoidal curve), tiệm cận tới 0 khi $\eta_i \rightarrow -\infty$ và tiệm cận tới 1 khi $\eta_i \rightarrow +\infty$, bảo đảm giá trị dự báo luôn thuộc khoảng $(0, 1)$.

2.2.2 Tỷ số chênh (Odds) và Hàm liên kết Logit

Tỷ số chênh (Odds) của biến cố $Y_i = 1$ được định nghĩa là tỷ số giữa xác suất biến cố xảy ra và xác suất biến cố không xảy ra:

$$\text{odds}_i = \frac{p_i}{1 - p_i} = \exp(\eta_i) = \exp(\beta_0 + x_i^\top \beta). \quad (2.6)$$

Lấy logarit tự nhiên của odds, ta thu được **hàm liên kết logit** (logit link function):

$$g(p_i) = \text{logit}(p_i) := \log\left(\frac{p_i}{1 - p_i}\right) = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_d x_{id} = x_i^\top \beta^*, \quad (2.7)$$

trong đó $\beta^* = (\beta_0, \beta_1, \dots, \beta_d)^\top$. Hàm logit ánh xạ khoảng xác suất $(0, 1)$ lên toàn bộ trục số thực $\mathbb{R}$. Đối với phân phối Bernoulli, logit là hàm liên kết chính tắc (canonical link), mang lại nhiều tính chất thuận lợi về mặt giải tích và tối ưu hóa.

Hệ số β_j mang ý nghĩa kinh tế lượng rất rõ ràng: khi biến x_{ij} tăng thêm 1 đơn vị (các biến khác giữ nguyên), log-odds tăng thêm β_j đơn vị, tương đương với việc tỷ số chênh được nhân lên một lượng $\exp(\beta_j)$ (gọi là Tỷ số chênh – Odds Ratio, OR).

2.2.3 Ước lượng Cực đại Hợp lý (MLE) và Thuật toán IRLS

Giả sử các quan sát (Y_i, x_i) độc lập. Hàm hợp lý của vector tham số β là:

$$L(\beta) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1 - y_i}. \quad (2.8)$$

Hàm log-hợp lý tương ứng là:

$$\ell(\beta) = \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)] = \sum_{i=1}^n \left[y_i x_i^\top \beta - \log(1 + \exp(x_i^\top \beta)) \right]. \quad (2.9)$$

Vector hàm điểm (Score vector) là đạo hàm bậc nhất của hàm log-hợp lý:

$$\mathbf{S}(\beta) = \frac{\partial \ell}{\partial \beta} = \sum_{i=1}^n (y_i - p_i) x_i = \mathbf{X}^\top (\mathbf{y} - \mathbf{p}), \quad (2.10)$$

trong đó $\mathbf{X}$ là ma trận thiết kế kích thước $n \times (d + 1)$, $\mathbf{y} = (y_1, \dots, y_n)^\top$, và $\mathbf{p} = (p_1, \dots, p_n)^\top$. Nghiệm của phương trình $\mathbf{S}(\beta) = \mathbf{0}$ là ước lượng cực đại hợp lý $\hat{\beta}$.

Ma trận Hessian và ma trận thông tin Fisher là:

$$\mathbf{I}(\beta) = -\frac{\partial^2 \ell}{\partial \beta \partial \beta^\top} = \sum_{i=1}^n p_i(1 - p_i)x_i x_i^\top = \mathbf{X}^\top \mathbf{W} \mathbf{X}, \quad (2.11)$$

trong đó $\mathbf{W} = \text{diag}\{p_i(1 - p_i)\}_{i=1}^n$ là ma trận trọng số đường chéo dương.

Do phương trình $\mathbf{S}(\beta) = \mathbf{0}$ không có nghiệm dạng hiện, ta sử dụng phương pháp lặp Newton–Raphson hoặc **Bình phương Tối thiểu có Trọng số Lặp** (Iteratively Reweighted Least Squares – IRLS). Tại bước lặp thứ $k + 1$:

$$\beta^{(k+1)} = \left(\mathbf{X}^\top \mathbf{W}^{(k)} \mathbf{X} \right)^{-1} \mathbf{X}^\top \mathbf{W}^{(k)} \mathbf{z}^{(k)}, \quad (2.12)$$

với biến điều chỉnh:

$$\mathbf{z}^{(k)} = \mathbf{X}\beta^{(k)} + (\mathbf{W}^{(k)})^{-1}(\mathbf{y} - \mathbf{p}^{(k)}). \quad (2.13)$$

2.2.4 Hạn chế của mô hình tuyến tính và nhu cầu mở rộng

Mặc dù hồi quy logistic cổ điển rất chặt chẽ và dễ diễn giải, mô hình áp đặt một giả thiết tiên quyết nghiêm ngặt: **mối quan hệ giữa các biến giải thích và log-odds bắt buộc phải là tuyến tính**. Trong dữ liệu thực nghiệm (đặc biệt là chuỗi thời gian kinh tế, tài chính), tác động của các độ trễ thường có tính phi tuyến, ngưỡng biến đổi (threshold effect) và suy giảm phi tuyến. Việc ép buộc một cấu trúc tuyến tính cứng nhắc sẽ dẫn tới sai đặc tả mô hình (misspecification), làm tăng độ chệch và suy giảm năng lực dự báo. Điều này đặt ra nhu cầu nối lỏng giả định tuyến tính sang lớp mô hình rộng hơn.

2.3 Mô hình Tuyến tính Tổng quát (GLM) và Mô hình Cộng tính Tổng quát (GAM)

Để vượt qua giới hạn của mô hình hồi quy tuyến tính cổ điển, Nelder và Wedderburn (1972) cùng McCullagh và Nelder (1989) đã hệ thống hóa **Mô hình Tuyến tính Tổng quát** (Generalized Linear Models – GLM).

2.3.1 Họ Phân phối Phân tán Mũ và Khung GLM

Trong GLM, biến đáp ứng Y có phân phối thuộc họ phân phối phân tán mũ (Exponential Dispersion Family), với hàm mật độ hoặc hàm khối xác suất có dạng chuẩn tắc:

$$f(y; \theta, \phi) = \exp \left(\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right), \quad (2.14)$$

trong đó θ là tham số tự nhiên (canonical parameter), ϕ là tham số phân tán, và $b(\cdot)$ là hàm tích lũy. Kỳ vọng và phương sai của Y được xác định qua các đạo hàm của $b(\theta)$:

$$\mu = \mathbb{E}(Y) = b'(\theta), \quad \text{Var}(Y) = b''(\theta)a(\phi) = V(\mu)a(\phi), \quad (2.15)$$

với $V(\mu)$ là hàm phương sai. Mô hình GLM liên kết kỳ vọng μ với bộ dự báo tuyến tính qua hàm liên kết đơn điệu $g(\cdot)$:

$$g(\mu) = x^\top \beta. \quad (2.16)$$

Đối với biến nhị phân Bernoulli, $a(\phi) = 1$, $\theta = \log(p/(1-p))$, $b(\theta) = \log(1 + e^\theta)$, và hàm liên kết chính tắc chính là hàm logit $g(\mu) = \text{logit}(p)$.

2.3.2 Bước nhảy vọt sang Mô hình Cộng tính Tổng quát (GAM)

Dù GLM đã tổng quát hóa phân phối của biến đáp ứng, nó vẫn giữ nguyên tính chất tuyến tính của bộ dự báo $\eta = x^\top \beta$. Để mô hình hóa các mối quan hệ phi tuyến phức tạp mà không làm mất đi khả năng diễn giải trực giác của từng biến, [6, 28] và [27] đã đề xuất **Mô hình Cộng tính Tổng quát** (Generalized Additive Models – GAM).

Trong GAM, bộ dự báo tuyến tính được nới lỏng thành tổng của các hàm trơn phi tuyến tùy ý:

$$g(\mu) = \beta_0 + \sum_{j=1}^d f_j(x_j), \quad (2.17)$$

trong đó $f_j(\cdot)$ là các hàm trơn một chiều chưa biết thỏa mãn điều kiện quy tâm $\mathbb{E}[f_j(X_j)] = 0$ để định danh mô hình. Đối với bài toán phân loại nhị phân, GAM

có dạng:

$$\text{logit}(p(x)) = \beta_0 + \sum_{j=1}^d f_j(x_j). \quad (2.18)$$

2.3.3 Mô hình bán tham số

Mô hình bán tham số kết hợp một thành phần tham số hữu hạn chiều và một hoặc nhiều thành phần hàm chưa biết. Một dạng cơ bản là mô hình tuyến tính một phần:

$$Y_i = x_i^T \beta + f(z_i) + \varepsilon_i.$$

Với đáp ứng nhị phân, mô hình có thể được viết:

$$\text{logit}(p_i) = x_i^T \beta + f(z_i).$$

Các biến cần diễn giải trực tiếp hoặc có quan hệ đã biết được đưa vào thành phần tham số; các biến nghi ngờ có tác động phi tuyến được mô hình hóa bằng hàm trơn. Dạng tổng quát là:

$$g\{\mathbb{E}(Y_i | x_i, z_i)\} = x_i^T \beta + \sum_{j=1}^q f_j(z_{ij}).$$

Ruppert, Wand và Carroll xem hồi quy bán tham số như một cách đưa linh hoạt phi tuyến vào hồi quy trong khi vẫn giữ phần tham số có khả năng diễn giải. Khung của các tác giả chủ yếu dựa trên penalized regression spline và biểu diễn mô hình hỗn hợp [31].

Bảng 2.3: So sánh mô hình tham số, phi tham số và bán tham số

Tiêu chí	Tham số	Phi tham số	Bán tham số
Dạng hàm	Quy định trước dạng hữu hạn chiều	Không quy định cụ thể dạng hàm	Kết hợp thành phần tham số và hàm trơn
Số chiều tham số	Hữu hạn cố định	Không gian hàm vô hạn chiều	Hữu hạn cho tham số và hàm trơn
Khả năng diễn giải	Cao, rõ ràng	Thấp hơn, mang tính trực quan	Tương đối cao đối với phần tham số
Tính linh hoạt	Thấp đến trung bình	Rất cao	Trung bình đến cao
Nguy cơ sai đặc tả	Cao hơn nếu dạng hàm sai	Thấp hơn nhiều	Được giảm bớt đáng kể
Nhu cầu dữ liệu	Cỡ mẫu nhỏ đến vừa	Cần cỡ mẫu lớn để tránh thưa	Trung gian giữa hai phương pháp

2.3.4 Ước lượng GAM qua Phương pháp Spline và Backfitting

Các hàm trơn $f_j(x_j)$ trong GAM thường được biểu diễn thông qua một tổ hợp tuyến tính của các hàm cơ sở (basis functions), chẳng hạn như B-spline hoặc Penalized Cubic Regression Splines:

$$f_j(x_j) = \sum_{k=1}^{K_j} \beta_{jk} B_{jk}(x_j). \quad (2.19)$$

Để ngăn chặn hiện tượng quá khớp (overfitting), độ trơn của hàm được kiểm soát thông qua số hạng phạt tích phân độ cong bậc hai (Penalized Spline):

$$\mathcal{P}_j(f_j) = \int (f_j''(u))^2 du = \beta_j^\top \mathbf{S}_j \beta_j, \quad (2.20)$$

trong đó $\mathbf{S}_j$ là ma trận phạt xác định không âm. Bài toán ước lượng GAM quy về tối đa hóa hàm log-hợp lý có phạt (Penalized Log-Likelihood):

$$\ell_p(\beta) = \ell(\beta) - \frac{1}{2} \sum_{j=1}^d \lambda_j \beta_j^\top \mathbf{S}_j \beta_j, \quad (2.21)$$

với $\lambda_j > 0$ là các tham số làm trơn (smoothing parameters). Thuật toán giải gồm hai nhánh kinh điển:

- **Thuật toán Backfitting:** Cập nhật lần lượt từng hàm f_j bằng cách làm trơn phần dư từng phần:

$$\tilde{Y}_j = g(\mu) - \beta_0 - \sum_{k \neq j} f_k(X_k), \quad (2.22)$$

lặp lại cho đến khi toàn bộ hệ hàm hội tụ.

- **Thuật toán Penalized IRLS (P-IRLS):** Tích hợp trực tiếp ma trận phạt vào các bước cập nhật trọng số của thuật toán IRLS, tối ưu đồng thời vector hệ số và lựa chọn tham số λ_j thông qua tiêu chuẩn GCV hoặc REML [27].

2.3.5 Hạn chế của cấu trúc cộng tính và nhu cầu hồi quy phi tham số

Mặc dù GAM đạt được bước tiến lớn so với GLM, mô hình vẫn tồn tại hai hạn chế then chốt:

- Giả định cộng tính thuần túy (Additivity):** GAM giả định tác động của các biến giải thích là hoàn toàn tách biệt. Khi giữa các biến trễ có tương tác phi tuyến phi cộng tính mạnh, GAM không thể biểu diễn chính xác nếu không khai báo thủ công các thành phần tương tác đa chiều.
- Chi phí tính toán và nguy cơ quá khớp khi số chiều tăng:** Khi d lớn (nhiều biến trễ), việc ước lượng đồng thời d hàm spline và lựa chọn d tham số làm trơn $\lambda_1, \dots, \lambda_d$ đòi hỏi chi phí tính toán rất lớn và dễ dẫn tới bất ổn định số học.

Để hiểu sâu sắc cơ chế làm trơn cục bộ và vượt qua các giả định cơ sở của spline, ta cần quay về nền tảng của lý thuyết hồi quy phi tham số.

2.4 Lý thuyết Hồi quy Phi tham số và Ước lượng Tuyến tính Cục bộ

Khác với các mô hình tham số hoặc bán tham số dựa trên hệ hàm cơ sở cố định, **Hồi quy phi tham số** (Nonparametric Regression) hoàn toàn không áp đặt bất kỳ dạng tham số nào lên hàm hồi quy, mà cho phép hàm tự do nằm trong một không gian hàm trơn vô hạn chiều (chẳng hạn không gian Sobolev hoặc không gian các hàm liên tục có đạo hàm cấp hai bị chặn $C^2(\mathbb{R})$).

2.4.1 Mô hình Hồi quy Phi tham số và Ước lượng Nadaraya–Watson

Xét mô hình hồi quy phi tham số kinh điển:

$$Y = m(X) + \varepsilon, \quad \mathbb{E}(\varepsilon | X) = 0, \quad (2.23)$$

trong đó $m(x) = \mathbb{E}(Y | X = x)$ là hàm hồi quy chưa biết.

Phương pháp ước lượng phi tham số sớm nhất là **ước lượng hằng số cục bộ** (Local Constant), hay còn gọi là **ước lượng hạt nhân Nadaraya–Watson** [59, 60]:

$$\hat{m}_{NW}(x) = \frac{\sum_{i=1}^n K_h(X_i - x) Y_i}{\sum_{i=1}^n K_h(X_i - x)}, \quad (2.24)$$

trong đó $K_h(u) = \frac{1}{h} K(u/h)$, $K(\cdot)$ là hàm hạt nhân đối xứng thỏa mãn $\int K(u) du = 1$, và $h = h_n > 0$ là băng thông (bandwidth).

Tuy nhiên, ước lượng Nadaraya–Watson mắc phải một nhược điểm giải tích nghiêm trọng: **hiện tượng sai số biên** (boundary bias). Tại các điểm gần biên của tập xác định (chẳng hạn $x \approx 0$ hoặc $x \approx 1$), hàm hạt nhân bị cắt cụt một phía, khiến độ chệch của $\hat{m}_{NW}(x)$ bị suy biến từ cấp $\mathcal{O}(h^2)$ thành cấp $\mathcal{O}(h)$, làm sai lệch đáng kể kết quả ước lượng tại các vùng biên dữ liệu.

2.4.2 Ước lượng Tuyến tính Cục bộ (Local Linear Regression)

Để khắc phục hoàn toàn hiện tượng sai số biên, [29] đã phát triển **phương pháp hồi quy đa thức cục bộ**, trong đó nổi bật nhất là **ước lượng tuyến tính cục bộ** (Local Linear Regression).

Giả sử $m(u)$ khả vi liên tục đến cấp hai. Với mỗi điểm x cố định, ta khai triển Taylor cấp 1 của hàm $m(u)$ trong lân cận điểm x :

$$m(u) \approx m(x) + m'(x)(u - x) \equiv \beta_0 + \beta_1(u - x). \quad (2.25)$$

Thay vì xấp xỉ bằng một hằng số như Nadaraya–Watson, phương pháp này xấp xỉ $m(u)$ bằng một đường thẳng cục bộ, và giải bài toán cực tiểu hóa bình phương tối

thiếu có trọng số hạt nhân:

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} \sum_{i=1}^n [Y_i - \beta_0 - \beta_1(X_i - x)]^2 K\left(\frac{X_i - x}{h}\right). \quad (2.26)$$

Ước lượng của hàm hồi quy tại điểm x chính là giá trị hệ số chặn cục bộ:

$$\hat{m}_{LL}(x) = \hat{\beta}_0(x). \quad (2.27)$$

[29] đã chứng minh những ưu thế vượt trội mang tính nền tảng của ước lượng tuyến tính cục bộ:

- (i) **Tự động hiệu chỉnh biên (Automatic Boundary Correction):** Độ chệch của $\hat{m}_{LL}(x)$ đạt cấp $\mathcal{O}(h^2)$ đồng đều trên toàn bộ miền xác định, bao gồm cả các điểm biên, mà không cần sử dụng các kỹ thuật hiệu chỉnh nhân biên phức tạp.
- (ii) **Hiệu quả tiệm cận cao:** Phương pháp đạt được phương sai tiệm cận cấp $\mathcal{O}\left(\frac{1}{nh}\right)$ và có tính thích nghi thiết kế cao nhất (best linear unbiased smoother).

2.4.3 Giới hạn đối với biến phản hồi nhị phân

Ước lượng tuyến tính cục bộ $\hat{m}_{LL}(x)$ được thiết kế tự nhiên cho biến phản hồi liên tục $Y \in \mathbb{R}$. Trong bài toán phân loại nhị phân ($Y \in \{0, 1\}$), hàm hồi quy có điều kiện chính là xác suất $p(x) = \mathbb{P}(Y = 1 \mid X = x) \in [0, 1]$. Nếu áp dụng trực tiếp bài toán bình phương tối thiểu cục bộ (2.26), giá trị dự báo $\hat{m}_{LL}(x)$ hoàn toàn có thể nhỏ hơn 0 hoặc lớn hơn 1, vi phạm nghiêm trọng tính chất của độ đo xác suất. Do đó, cần phải kết hợp kỹ thuật xấp xỉ cục bộ với hàm liên kết logit thông qua nguyên lý hợp lý cực đại.

2.5 Hồi quy Logistic Phi tham số và Phương pháp Hợp lý Cục bộ

Để khắc phục nhược điểm của hồi quy tuyến tính cục bộ trên dữ liệu nhị phân, [5] và [61] đã mở rộng phương pháp tuyến tính cục bộ sang bối cảnh hàm hợp lý, khai sinh **Phương pháp Hợp lý Cực đại Cục bộ** (Local Maximum Likelihood Estimation) cho **Hồi quy Logistic Phi tham số**.

2.5.1 Mô hình Hồi quy Logistic Phi tham số Một chiều

Xét biến đáp ứng nhị phân $Y \in \{0, 1\}$ và biến giải thích một chiều $X \in \mathbb{R}$. Đặt:

$$p(x) = \mathbb{P}(Y = 1 \mid X = x), \quad \eta(x) = \text{logit}(p(x)) = \log \left(\frac{p(x)}{1 - p(x)} \right). \quad (2.28)$$

Trong mô hình hồi quy logistic phi tham số, $\eta(x)$ là một hàm trơn phi tuyến chưa biết, không bị trói buộc bởi dạng tuyến tính. Khi đó:

$$p(x) = F(\eta(x)) = \frac{\exp(\eta(x))}{1 + \exp(\eta(x))}. \quad (2.29)$$

2.5.2 Phương pháp Hợp lý Cực đại Cục bộ Tuyến tính

Để ước lượng $\eta(x)$ tại một điểm x cố định, ta khai triển Taylor cấp 1 của $\eta(u)$ trong lân cận điểm x :

$$\eta(u) \approx \eta(x) + \eta'(x)(u - x) \equiv \beta_0 + \beta_1(u - x). \quad (2.30)$$

Thay vì cực đại hóa hàm hợp lý trên toàn bộ mẫu, ta cực đại hóa **hàm log-hợp lý cục bộ có trọng số hạt nhân** [61]:

$$\ell_{\text{loc}}(\beta_0, \beta_1) = \sum_{i=1}^n \{Y_i [\beta_0 + \beta_1(X_i - x)] - \log(1 + \exp(\beta_0 + \beta_1(X_i - x)))\} K\left(\frac{X_i - x}{h}\right). \quad (2.31)$$

Vector nghiệm tối ưu $(\hat{\beta}_0(x), \hat{\beta}_1(x))$ được tìm bằng cách giải hệ phương trình điểm cục bộ thông qua thuật toán Newton–Raphson lặp có trọng số. Khi đó, ước lượng của hàm logit và xác suất có điều kiện tại điểm x là:

$$\hat{\eta}(x) = \hat{\beta}_0(x), \quad \hat{p}(x) = \frac{\exp(\hat{\beta}_0(x))}{1 + \exp(\hat{\beta}_0(x))}. \quad (2.32)$$

Do hàm logistic ánh xạ từ $\mathbb{R}$ vào $(0, 1)$, ước lượng $\hat{p}(x)$ **tự động và tuyệt đối luôn nằm trong khoảng xác suất hợp lệ** $(0, 1)$, đồng thời thừa hưởng trọn vẹn đặc tính tự động hiệu chỉnh sai số biên của phương pháp tuyến tính cục bộ.

2.5.3 Nút thắt sinh tử: Lỗi nguyên số chiều (Curse of Dimensionality)

Phương pháp hợp lý cực đại cục bộ hoạt động hoàn hảo khi số biến giải thích là một chiều ($d = 1$). Tuy nhiên, khi mở rộng lên không gian đa biến $X \in \mathbb{R}^d$ ($d \geq 2$):

$$\eta(u) \approx \beta_0 + \beta_1^\top (u - x), \quad (2.33)$$

hàm log-hợp lý cực đại đòi hỏi tích các hàm nhân đa chiều với vector bằng thông $\mathbf{h} = (h_1, \dots, h_d)^\top$:

$$\mathbf{K}_{\mathbf{h}}(X_i - x) = \prod_{j=1}^d \frac{1}{h_j} K\left(\frac{X_{ij} - x_j}{h_j}\right). \quad (2.34)$$

Lý thuyết tiệm cận phi tham số [29, 62] chỉ ra rằng tốc độ hội tụ tối ưu của ước lượng phi tham số d chiều bị suy giảm theo quy luật:

$$\|\hat{p}(x) - p(\text{boldsymbolsymbol}x)\| = \mathcal{O}_p\left(n^{-\frac{2}{4+d}}\right). \quad (2.35)$$

Khi số chiều d gia tăng (chẳng hạn khi mô hình hóa chuỗi thời gian tài chính với $d = 10, 20$ biến trễ), tốc độ hội tụ $n^{-2/(4+d)} \rightarrow 0$ cực kỳ chậm. Khối lượng dữ liệu cần thiết để lấp đầy không gian siêu lập phương tăng theo hàm mũ $n \propto C^d$. Hiện tượng này được gọi là **Lỗi nguyên số chiều** (Curse of Dimensionality). Trong thực tế với kích thước mẫu hữu hạn n , các lân cận cục bộ đa chiều hầu như không chứa đủ dữ liệu (data sparsity), ma trận thông tin Fisher cục bộ bị suy biến (singular), khiến thuật toán ước lượng phi tham số đa chiều hoàn toàn thất bại.

2.6 Hồi quy Logistic Biên và Chiến lược Hóa giải Lỗi nguyên Số chiều

Để hóa giải triệt để lỗi nguyên số chiều mà vẫn giữ được tính linh hoạt phi tuyến của từng biến, một chiến lược đột phá đã được mở đường trong lý thuyết thống kê hiện đại: **Phân rã chiều không gian thông qua Hồi quy Biên** (Marginal Regression) [63, 2, 1].

2.6.1 Ý tưởng Phân rã Biên Một chiều

Thay vì tìm cách ước lượng trực tiếp một hàm xác suất có điều kiện đa biến d chiều đầy đủ $p(x) = \mathbb{P}(Y = 1 \mid X_1 = x_1, \dots, X_d = x_d)$, ta phân rã bài toán thành d bài toán

hồi quy biên một chiều độc lập.

Với mỗi biến giải thích thành phần X_j ($j = 1, \dots, d$), ta định nghĩa **xác suất biên có điều kiện**:

$$p_j(x_j) := \mathbb{P}(Y = 1 \mid X_j = x_j) = \mathbb{E}[\mathbb{P}(Y = 1 \mid X) \mid X_j = x_j]. \quad (2.36)$$

Hàm logistic biên tương ứng được định nghĩa qua phép biến đổi logit:

$$\eta_j(x_j) := \text{logit}(p_j(x_j)) = \log \left(\frac{p_j(x_j)}{1 - p_j(x_j)} \right) \equiv f_j(x_j). \quad (2.37)$$

2.6.2 Ưu thế Vượt trội của Tiếp cận Biên

Ưu thế giải tích cốt lõi của tiếp cận biên là: **mỗi hàm $\eta_j(x_j)$ là một hàm một chiều thuần túy**. Do đó, ta có thể áp dụng trọn vẹn phương pháp hợp lý cực đại cục bộ tuyến tính cho từng hàm biên riêng biệt. Tốc độ hội tụ của ước lượng từng hàm biên luôn đạt chuẩn tối ưu một chiều:

$$|\hat{\eta}_j(x_j) - \eta_j(x_j)| = \mathcal{O}_p \left(n^{-2/5} \right), \quad \forall j = 1, \dots, d, \quad (2.38)$$

hoàn toàn độc lập và không chịu bất kỳ sự suy biến nào từ số chiều tổng thể d . Nhờ đó, phương pháp hoàn toàn miễn nhiễm với lời nguyền số chiều!

2.6.3 Dữ liệu lặp và dữ liệu dọc

Dữ liệu lặp hoặc dữ liệu dọc xuất hiện khi nhiều phép đo được thu thập trên cùng một đối tượng, hộ gia đình, cụm, đơn vị thực nghiệm hoặc chuỗi theo thời gian. Ký hiệu Y_{ij} là đáp ứng của đối tượng i tại lần đo j , với $i = 1, \dots, m$ và $j = 1, \dots, n_i$. Vector đáp ứng của đối tượng i là:

$$\mathbf{Y}_i = (Y_{i1}, \dots, Y_{in_i})^\top.$$

Các đối tượng khác nhau thường được giả định độc lập, nhưng các quan sát trong cùng một đối tượng có thể tương quan. Dữ liệu dọc kết hợp đặc điểm của dữ liệu đa biến và chuỗi thời gian: mỗi đối tượng tạo ra một chuỗi ngắn, còn tập dữ liệu gồm nhiều chuỗi như vậy [33]:

$$\text{Corr}(Y_{ij}, Y_{ik}) \neq 0, \quad j \neq k.$$

Nếu bỏ qua tương quan nội cụm và sử dụng hồi quy logistic độc lập, ước lượng hệ số trung bình có thể vẫn hợp lý trong một số trường hợp, nhưng sai số chuẩn theo mô hình thường bị đánh giá sai. Hệ quả là khoảng tin cậy, giá trị p và kết luận suy luận có thể không còn đáng tin cậy.

Dữ liệu lặp cũng thường có số lần đo không cân bằng, thời điểm quan sát không đều, mất theo dõi và các biến giải thích thay đổi theo thời gian. Vì vậy, phương pháp phân tích cần vừa mô hình hóa kỳ vọng, vừa xử lý cấu trúc phụ thuộc trong từng đối tượng.

2.6.4 Mô hình Logistic biên

Mô hình logistic biên mô tả trực tiếp kỳ vọng quần thể của từng đáp ứng. Đặt $\mu_{ij} = \mathbb{E}(Y_{ij} | x_{ij}) = \mathbb{P}(Y_{ij} = 1 | x_{ij})$. Mô hình trung bình được xác định bởi:

$$\begin{aligned} \text{logit}(\mu_{ij}) &= x_{ij}^T \beta, \\ \mu_{ij} &= \frac{\exp(x_{ij}^T \beta)}{1 + \exp(x_{ij}^T \beta)}. \end{aligned}$$

Hệ số β có diễn giải population-averaged, tức mô tả sự thay đổi trung bình trong quần thể. Chẳng hạn, nếu x_{ij} là biến điều trị nhị phân thì $\exp(\beta_1)$ là odds ratio biên giữa hai nhóm điều trị sau khi điều chỉnh các biến khác.

Mô hình biên khác với mô hình logistic hiệu ứng ngẫu nhiên (subject-specific). Trong mô hình hiệu ứng ngẫu nhiên, xác suất được điều kiện hóa trên hiệu ứng riêng của từng đối tượng. Do tính phi tuyến của hàm logistic, hệ số population-averaged và subject-specific nhìn chung không bằng nhau. Diggle và cộng sự cho thấy hệ số có điều kiện thường có độ lớn cao hơn hệ số biên trên cùng dữ liệu [33].

Ưu điểm của mô hình biên là phù hợp với các câu hỏi về hiệu ứng trung bình quần thể, ví dụ chính sách, can thiệp hoặc dự báo xác suất trung bình. Hạn chế là mô hình không trực tiếp mô tả dị biệt cá thể như mô hình hiệu ứng ngẫu nhiên.

2.6.5 Phương trình ước lượng tổng quát (GEE)

Phương trình ước lượng tổng quát (Generalized Estimating Equations - GEE) được Liang và Zeger đề xuất để ước lượng tham số mô hình trung bình khi các quan sát trong cùng cụm có tương quan, nhưng không cần chỉ định đầy đủ phân phối đồng thời của toàn bộ vector đáp ứng [32, 33].

Đặt $\mu_i = (\mu_{i1}, \dots, \mu_{in_i})^T$ và ma trận đạo hàm $\mathbf{D}_i = \partial \mu_i / \partial \beta^T$. Phương trình GEE có dạng:

$$\mathbf{U}(\beta) = \sum_{i=1}^m \mathbf{D}_i^T \mathbf{V}_i^{-1} (\mathbf{Y}_i - \mu_i) = \mathbf{0}.$$

Ma trận hiệp phương sai làm việc của $\mathbf{Y}_i$ được phân rã thành:

$$\mathbf{V}_i = \mathbf{A}_i^{1/2} \mathbf{R}_i(\alpha) \mathbf{A}_i^{1/2}.$$

Đối với dữ liệu Bernoulli:

$$\mathbf{A}_i = \text{diag}\{\mu_{ij}(1 - \mu_{ij})\}_{j=1}^{n_i}.$$

$\mathbf{R}_i(\alpha)$ là ma trận tương quan làm việc (working correlation matrix) và α là vector tham số tương quan. GEE chỉ yêu cầu mô hình trung bình, hàm phương sai và một cấu trúc tương quan làm việc, thay vì một hàm hợp lý đầy đủ. Vì vậy, phương pháp thường được xem là bán hợp lý (quasi-likelihood).

Đối với liên kết logit, đạo hàm của kỳ vọng theo β là:

$$\frac{\partial \mu_{ij}}{\partial \beta} = \mu_{ij}(1 - \mu_{ij})x_{ij}.$$

Thuật toán GEE thường lặp giữa hai bước: cập nhật β bằng Fisher scoring có trọng số và cập nhật α từ phần dư chuẩn hóa. Khi cấu trúc tương quan làm việc gần đúng với tương quan thực tế, ước lượng có thể đạt hiệu quả cao hơn so với working independence.

2.6.6 Phương sai Sandwich

Một ưu điểm quan trọng của GEE là có thể sử dụng ước lượng phương sai sandwich bền vững (robust sandwich variance estimator) trước sai đặc tả của cấu trúc tương quan làm việc. Đặt:

$$\mathbf{B} = \sum_{i=1}^m \mathbf{D}_i^T \mathbf{V}_i^{-1} \mathbf{D}_i,$$

$$\mathbf{M} = \sum_{i=1}^m \mathbf{D}_i^T \mathbf{V}_i^{-1} (\mathbf{Y}_i - \hat{\boldsymbol{\mu}}_i) (\mathbf{Y}_i - \hat{\boldsymbol{\mu}}_i)^T \mathbf{V}_i^{-1} \mathbf{D}_i,$$

$$\widehat{\text{Var}}_{\text{robust}}(\hat{\boldsymbol{\beta}}) = \mathbf{B}^{-1} \mathbf{M} \mathbf{B}^{-1}.$$

Hai ma trận $\mathbf{B}^{-1}$ ở hai phía thường được gọi là “bread”, còn $\mathbf{M}$ là “meat”, tạo nên cấu trúc sandwich. Nếu mô hình trung bình được đặc tả đúng và số cụm độc lập đủ lớn, ước lượng sandwich vẫn nhất quán ngay cả khi $\mathbf{R}_i(\alpha)$ không đúng hoàn toàn [32, 33].

Tính bền vững này là kết quả tiệm cận theo số cụm m , không chỉ theo tổng số quan sát. Khi số cụm nhỏ, phương sai sandwich có thể bị lệch xuống và cần hiệu chỉnh mẫu nhỏ. Vì vậy, báo cáo nghiên cứu nên nêu rõ số cụm, cấu trúc làm việc và loại sai số chuẩn được sử dụng.

2.6.7 Cấu trúc tương quan làm việc

Cấu trúc tương quan làm việc thể hiện giả định về mối phụ thuộc giữa các phép đo trong cùng đối tượng. Việc lựa chọn cần dựa trên thiết kế nghiên cứu, khoảng cách thời gian, số lần đo và số cụm.

Cấu trúc độc lập (Independence):

$$\mathbf{R}_i(\alpha) = \mathbf{I}_{n_i}.$$

Working independence giả định tương quan làm việc bằng 0. Điều này không nhất thiết khẳng định dữ liệu thực sự độc lập; nó chỉ là lựa chọn ma trận trọng số. Với sai số chuẩn sandwich, suy luận vẫn có thể bền vững, nhưng hiệu quả có thể thấp khi tương quan thực tế mạnh.

Cấu trúc trao đổi (Exchangeable):

$$\text{Corr}(Y_{ij}, Y_{ik}) = \alpha, \quad j \neq k.$$

Exchangeable hoặc compound symmetry giả định mọi cặp quan sát trong cùng cụm có cùng tương quan. Cấu trúc chỉ có một tham số, dễ ước lượng và thường phù hợp khi không có thứ tự thời gian rõ ràng hoặc khi tương quan gần như đồng nhất [33].

Cấu trúc tự hồi quy bậc một (AR(1)):

$$\text{Corr}(Y_{ij}, Y_{ik}) = \alpha^{|j-k|}, \quad |\alpha| < 1.$$

AR(1) giả định tương quan giảm theo độ trễ. Cấu trúc này phù hợp khi thời điểm đo cách đều và quan sát gần nhau có phụ thuộc mạnh hơn. Nếu thời điểm không đều, có thể thay độ trễ chỉ số bằng khoảng cách thời gian thực tế hoặc dùng cấu trúc liên tục.

Cấu trúc Toeplitz:

$$\text{Corr}(Y_{ij}, Y_{ik}) = \alpha_{|j-k|}.$$

Toeplitz cho phép mỗi độ trễ có một hệ số tương quan riêng, nhưng các cặp có cùng độ trễ vẫn chia sẻ cùng tham số. Cấu trúc linh hoạt hơn AR(1) nhưng cần nhiều tham số hơn.

Cấu trúc không ràng buộc (Unstructured):

$$\text{Corr}(Y_{ij}, Y_{ik}) = \alpha_{jk}.$$

Unstructured gán một tham số cho từng cặp thời điểm. Với q lần đo, số tham số tương quan là $q(q-1)/2$. Cấu trúc này linh hoạt nhưng dễ không ổn định nếu q lớn hoặc số cụm nhỏ.

Bảng 2.4: So sánh một số cấu trúc tương quan làm việc trong GEE

Cấu trúc	Số tham số	Đặc điểm chính	Tình huống phù hợp
Independence	0	Đơn giản, ổn định; có thể kém hiệu quả	Số cụm nhỏ hoặc tương quan yếu
Exchangeable	1	Mọi cặp trong cụm có tương quan bằng nhau	Cụm không có thứ tự rõ ràng
AR(1)	1	Tương quan giảm theo độ trễ thời gian	Dữ liệu dọc theo thời gian cách đều
Toeplitz	Theo độ trễ	Mỗi độ trễ có một tham số riêng	Cần linh hoạt hơn AR(1)
Unstructured	$q(q-1)/2$	Linh hoạt nhất nhưng tốn nhiều tham số	Ít thời điểm, nhiều cụm quan sát

Không nên chọn cấu trúc phức tạp chỉ dựa trên độ phù hợp trong mẫu. Một cấu trúc quá nhiều tham số có thể làm giảm ổn định và gây khó khăn khi ma trận tương quan không xác định dương. Các tiêu chuẩn như QIC có thể hỗ trợ, nhưng kiến thức về thiết kế và cơ chế phụ thuộc vẫn là yếu tố trung tâm.

Cần lưu ý thuật ngữ “marginal”. Trong GEE, marginal chỉ mô hình trung bình quần thể $\mathbb{P}(Y_{ij} = 1 \mid X_{ij})$. Trong các phương pháp marginal screening hoặc MAMaLoR, marginal có thể chỉ việc mô hình hóa Y theo từng biến hoặc nhóm biến riêng. Hai cách dùng này có nội hàm khác nhau và không nên đồng nhất.

2.6.8 Nhu cầu tổng hợp thông tin từ các mô hình biên

Hồi quy biên một chiều đã giải quyết trọn vẹn thách thức số chiều. Tuy nhiên, mỗi mô hình biên $\hat{\eta}_j(x_j)$ chỉ cung cấp thông tin riêng lẻ từ một biến X_j . Câu hỏi toán học then chốt đặt ra là: **Làm thế nào để tổng hợp thông tin từ d mô hình biên một chiều này thành một mô hình dự báo thống nhất cho toàn bộ vector X một cách tối ưu?** Câu trả lời nằm ở Lý thuyết Trung bình hóa Mô hình.

2.7 Lý thuyết Trung bình hóa Mô hình (Model Averaging)

Thay vì tìm kiếm một mô hình đơn lẻ tối ưu (Model Selection) – vốn tiềm ẩn sai số chọn lựa mẫu và độ biến động cao, **Lý thuyết Trung bình hóa Mô hình** (Model Averaging) hướng đến việc kết hợp có trọng số các dự báo từ nhiều mô hình thành phần nhằm phân tán rủi ro, giảm phương sai và nâng cao tính ổn định tổng thể.

2.7.1 Cơ sở lý thuyết của trung bình mô hình

Giả sử có M mô hình ứng viên $\mathcal{M}_1, \dots, \mathcal{M}_M$. Mỗi mô hình cung cấp một ước lượng $\hat{\theta}_m$ hoặc dự báo riêng cho cùng đại lượng quan tâm. Lựa chọn mô hình chỉ giữ lại một mô hình duy nhất, trong khi model averaging kết hợp nhiều mô hình bằng trọng số:

$$\hat{\theta}_{\text{select}} = \hat{\theta}_{\hat{m}} = \sum_{m=1}^M \mathbb{I}(m = \hat{m}) \hat{\theta}_m,$$

$$\hat{\theta}_{\text{MA}} = \sum_{m=1}^M w_m \hat{\theta}_m, \quad w_m \geq 0, \quad \sum_{m=1}^M w_m = 1.$$

Claeskens và Hjort xem model averaging là cách phản ánh bất định mô hình (model uncertainty) thay vì hành xử như thể mô hình được chọn là đúng chắc chắn [34]. Sau lựa chọn mô hình, phân phối của ước lượng bị ảnh hưởng bởi bước chọn; bỏ qua bất định này có thể tạo khoảng tin cậy quá hẹp và kết luận quá tự tin.

Bên cạnh đó, các phương pháp trung bình mô hình dựa trên tiêu chuẩn bình phương tối thiểu (Least Squares Model Averaging) được phát triển đột phá bởi [7, 8] dựa trên tiêu chuẩn Mallows C_p và tối ưu hóa dự báo đã đem lại nền tảng tiệm cận vững chắc cho dữ liệu kinh tế lượng. Gần đây, [3] đã mở rộng thành công lý thuyết trung bình mô hình bán tham số sang không gian chuỗi thời gian phi tuyến siêu cao chiều (*ultra-high dimensional dynamic time series*).

Model averaging có thể hướng đến ba mục tiêu: giảm sự phụ thuộc vào một mô hình duy nhất; cải thiện độ ổn định hoặc hiệu năng dự báo; và phản ánh bất định giữa các mô hình. Tuy nhiên, phương pháp không tự động bảo đảm tốt hơn mô hình tốt nhất. Kết quả phụ thuộc vào tập mô hình ứng viên, cách học trọng số và mức độ đa dạng của sai số giữa các mô hình.

Nếu trọng số được ước lượng từ chính dữ liệu, chúng là các biến ngẫu nhiên. Suy

luận đầy đủ cần xét cả biến thiên của các ước lượng thành phần và biến thiên của trọng số. Đây là lý do các khoảng tin cậy sau model averaging phức tạp hơn việc lấy trung bình đơn giản các sai số chuẩn.

2.7.2 Các loại trọng số

Trọng số bằng nhau (Equal weights):

$$w_m = \frac{1}{M}.$$

Trọng số bằng nhau đơn giản và ổn định, không cần tối ưu. Tuy nhiên, phương pháp có thể gán trọng số quá lớn cho các mô hình kém và không khai thác thông tin về độ phù hợp hoặc hiệu năng dự báo.

Trọng số AIC (Smooth AIC weights):

$$AIC_m = -2\ell_m(\hat{\theta}_m) + 2k_m,$$

$$\Delta_m^{AIC} = AIC_m - \min_{\ell} AIC_{\ell},$$

$$w_m^{AIC} = \frac{\exp(-\Delta_m^{AIC}/2)}{\sum_{\ell=1}^M \exp(-\Delta_{\ell}^{AIC}/2)}.$$

Mô hình có AIC thấp nhất nhận trọng số lớn nhất, nhưng các mô hình có AIC gần nhau vẫn đóng góp. Trọng số AIC liên hệ với mục tiêu xấp xỉ phân phối sinh dữ liệu và hiệu quả dự báo [34].

Trọng số BIC (Smooth BIC weights):

$$BIC_m = -2\ell_m(\hat{\theta}_m) + k_m \log n,$$

$$\Delta_m^{BIC} = BIC_m - \min_{\ell} BIC_{\ell},$$

$$w_m^{BIC} = \frac{\exp(-\Delta_m^{BIC}/2)}{\sum_{\ell=1}^M \exp(-\Delta_{\ell}^{BIC}/2)}.$$

BIC phạt độ phức tạp mạnh hơn AIC khi n lớn, nên trọng số thường tập trung hơn vào các mô hình gọn. Trong một số điều kiện, smooth BIC weights có thể được liên hệ với xấp xỉ xác suất hậu nghiệm mô hình [34].

Trọng số tối ưu theo dự báo:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \sum_{i=1}^n L \left(y_i, \sum_{m=1}^M w_m \hat{y}_{im}^{(-i)} \right).$$

Trong đó $\hat{y}_{im}^{(-i)}$ là dự báo ngoài mẫu hoặc cross-validated của mô hình m cho quan sát i . Cách xác định trọng số này là nền tảng của stacking. Tùy hàm mất mát, mục tiêu có thể là sai số bình phương, negative log-likelihood, Brier score hoặc một scoring rule thích hợp.

2.7.3 Đánh đổi Bias–Variance trong trung bình hóa

Đối với một ước lượng $\hat{\theta}$, sai số bình phương trung bình được phân rã thành bình phương bias và variance:

$$\text{MSE}(\hat{\theta}) = \mathbb{E} \left((\hat{\theta} - \theta)^2 \right) = \text{Bias}^2(\hat{\theta}) + \text{Var}(\hat{\theta}).$$

Mô hình đơn giản thường có phương sai thấp nhưng độ chệch cao nếu bỏ sót cấu trúc. Mô hình phức tạp thường giảm độ chệch nhưng tăng phương sai. Claeskens và Hjort nhấn mạnh rằng thêm tham số có thể giảm sai lệch mô hình nhưng làm tăng biến thiên lấy mẫu; loại bỏ tham số tạo hiệu ứng ngược lại [34].

Với trọng số cố định, bias của ước lượng trung bình hóa là:

$$\text{Bias}(\hat{\theta}_{\text{MA}}) = \sum_{m=1}^M w_m \text{Bias}(\hat{\theta}_m).$$

Phương sai là:

$$\text{Var}(\hat{\theta}_{\text{MA}}) = \sum_{m=1}^M \sum_{\ell=1}^M w_m w_{\ell} \text{Cov}(\hat{\theta}_m, \hat{\theta}_{\ell}) = \mathbf{w}^T \Sigma \mathbf{w}.$$

Hiệu quả của trung bình hóa vì vậy phụ thuộc không chỉ vào chất lượng từng mô hình mà còn vào tương quan giữa các sai số. Nếu các mô hình mắc sai số khác nhau, tổ hợp có thể giảm đáng kể phương sai. Nếu các mô hình gần như giống nhau, lợi ích có thể nhỏ. Trọng số quá linh hoạt được học trên tập nhỏ cũng có thể overfit và làm tăng phương sai.

2.7.4 Phương pháp Stacking

Stacking hoặc stacked generalization học trọng số trực tiếp từ hiệu năng dự báo ngoài mẫu. Ý tưởng cốt lõi là kết hợp các mô hình cơ sở sao cho tổ hợp có khả năng tổng quát hóa tốt hơn từng mô hình riêng [36, 35].

Quy trình stacking gồm các bước: chia dữ liệu thành các fold; huấn luyện từng mô hình trên phần còn lại; tạo dự báo out-of-fold; dùng các dự báo này làm đầu vào để học trọng số; sau đó huấn luyện lại mô hình cơ sở trên toàn bộ tập huấn luyện và kết hợp dự báo bằng trọng số đã học.

Với hồi quy bình phương, trọng số được ước lượng bởi:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \sum_{i=1}^n \left[y_i - \sum_{m=1}^M w_m \hat{y}_{im}^{\text{OOF}} \right]^2.$$

Với phân loại nhị phân, xác suất tổ hợp là:

$$\hat{p}_i(\mathbf{w}) = \sum_{m=1}^M w_m \hat{p}_{im}^{\text{OOF}}.$$

Có thể học trọng số bằng cách cực đại hóa log-score:

$$\hat{\mathbf{w}} = \arg \max_{\mathbf{w}} \sum_{i=1}^n [y_i \log \hat{p}_i(\mathbf{w}) + (1 - y_i) \log \{1 - \hat{p}_i(\mathbf{w})\}].$$

Các ràng buộc $w_m \geq 0$ và $\sum_{m=1}^M w_m = 1$ thường được dùng để tạo tổ hợp lồi và giữ xác suất hợp lệ. Tuy nhiên, trong một số thiết lập hồi quy, Breiman cho phép các dạng ràng buộc khác để tăng linh hoạt [35].

Sử dụng dự báo ngoài mẫu là yêu cầu quan trọng. Nếu học trọng số từ dự báo trong mẫu, mô hình phức tạp có thể nhận trọng số quá lớn do ghi nhớ dữ liệu. Với chuỗi thời gian, cross-validation phải bảo toàn thứ tự, chẳng hạn rolling window hoặc expanding window; chia ngẫu nhiên có thể gây rò rỉ thông tin tương lai.

Trong khung Bayes, stacking of predictive distributions tối đa hóa log predictive density leave-one-out của tổ hợp phân phối:

$$\hat{\mathbf{w}} = \arg \max_{\mathbf{w}} \sum_{i=1}^n \log \left[\sum_{m=1}^M w_m p(y_i | y_{-i}, \mathcal{M}_m) \right].$$

Cách tiếp cận này tập trung vào dự báo khi không mô hình ứng viên nào được giả định là mô hình đúng tuyệt đối [38].

2.7.5 Bayesian Model Averaging (BMA)

Bayesian Model Averaging kết hợp mô hình bằng xác suất hậu nghiệm của từng mô hình. Với tập mô hình $\mathcal{M}_1, \dots, \mathcal{M}_M$, mỗi mô hình có prior probability $\mathbb{P}(\mathcal{M}_m)$, prior tham số $\pi(\theta_m | \mathcal{M}_m)$ và hàm hợp lý $L_m(y | \theta_m)$ [37, 34].

Marginal likelihood của mô hình là:

$$p(y | \mathcal{M}_m) = \int L_m(y | \theta_m) \pi(\theta_m | \mathcal{M}_m) d\theta_m.$$

Xác suất hậu nghiệm mô hình được xác định bởi định lý Bayes:

$$\mathbb{P}(\mathcal{M}_m | y) = \frac{\mathbb{P}(\mathcal{M}_m) p(y | \mathcal{M}_m)}{\sum_{\ell=1}^M \mathbb{P}(\mathcal{M}_\ell) p(y | \mathcal{M}_\ell)}.$$

Trọng số BMA là $w_m = \mathbb{P}(\mathcal{M}_m | y)$. Phân phối hậu nghiệm của đại lượng θ được trung bình hóa theo mô hình:

$$\begin{aligned} \pi(\theta | y) &= \sum_{m=1}^M \mathbb{P}(\mathcal{M}_m | y) \pi(\theta | y, \mathcal{M}_m), \\ \mathbb{E}(\theta | y) &= \sum_{m=1}^M \mathbb{P}(\mathcal{M}_m | y) \mathbb{E}(\theta | y, \mathcal{M}_m). \end{aligned}$$

Phương sai hậu nghiệm bao gồm cả bất định trong mô hình và giữa các mô hình:

$$\text{Var}(\theta | y) = \sum_{m=1}^M \mathbb{P}(\mathcal{M}_m | y) \left[\text{Var}(\theta | y, \mathcal{M}_m) + \{\mathbb{E}(\theta | y, \mathcal{M}_m) - \mathbb{E}(\theta | y)\}^2 \right].$$

Đối với quan sát tương lai $\tilde{y}$, phân phối dự báo BMA là:

$$p(\tilde{y} | y) = \sum_{m=1}^M p(\tilde{y} | y, \mathcal{M}_m) \mathbb{P}(\mathcal{M}_m | y).$$

BMA cung cấp một khung xác suất đầy đủ nhưng nhạy với prior, tập mô hình ứng viên và cách tính marginal likelihood. Prior không chuẩn có thể gây khó khăn khi so sánh mô hình có số chiều khác nhau. Do đó, cần thực hiện phân tích độ nhạy theo prior và giải thích rõ tập mô hình được xem xét [34, 37].

2.7.6 So sánh các phương pháp trung bình hóa

Bảng 2.5: So sánh một số phương pháp trung bình hóa mô hình

Phương pháp	Cách xác định trọng số	Mục tiêu chính	Ưu điểm	Hạn chế
Equal weights	$w_m = 1/M$	Ổn định, đơn giản	Không cần tối ưu số học	Không phân biệt mô hình tốt/kém
AIC averaging	$\exp(-\Delta_m^{\text{AIC}}/2)$	Xấp xỉ và dự báo	Dễ triển khai, tính toán nhanh	Phụ thuộc vào tập ứng viên
BIC averaging	$\exp(-\Delta_m^{\text{BIC}}/2)$	Ưu tiên mô hình gọn	Phạt độ phức tạp mạnh khi n lớn	Có thể tập trung quá mức
Stacking	Tối ưu hàm mất mát ngoài mẫu	Hiệu năng dự báo	Rất linh hoạt, dựa trên out-of-fold	Dễ quá khớp nếu chia mẫu yếu
BMA	Xác suất hậu nghiệm mô hình	Suy luận và dự báo Bayes	Phản ánh toàn diện bất định	Nhạy với phân phối tiên nghiệm

Trong bài toán dự báo chuỗi thời gian, stacking hoặc trọng số dựa trên kiểm tra chéo (validation) thường phù hợp khi mục tiêu chính là dự báo. BMA phù hợp hơn khi cần một khung suy luận xác suất đầy đủ. AIC/BIC averaging thuận tiện khi tập mô hình thống kê được xây dựng rõ ràng và nhà nghiên cứu muốn phản ánh bất định giữa các mô hình mà không cần thực hiện toàn bộ quy trình tính toán Bayes phức tạp.

Bất kể phương pháp nào, tập mô hình ứng viên cần được xác định có chủ đích. Trung bình hóa không thể bù đắp cho việc tất cả mô hình đều sai theo cùng một

hướng, dữ liệu bị rò rỉ hoặc quy trình đánh giá không phản ánh điều kiện triển khai thực tế.

Bên cạnh các giá trị gốc về điểm và khối lượng giao dịch, một số biến đặc trưng được xây dựng nhằm phục vụ cho bài toán phân loại điểm cổ phiếu tăng / giảm vào ngày tiếp theo. Cụ thể:

2.7.7 Tiêu chuẩn Tối ưu hóa Khoảng cách Kullback–Leibler (KL Divergence)

Đối với bài toán phân loại nhị phân, thay vì hàm mất mát bình phương trung bình L_2 (vốn chỉ phù hợp cho biến liên tục), tiêu chuẩn toán học tự nhiên và chuẩn mực nhất để xác định trọng số kết hợp là **Khoảng cách Kullback–Leibler** (KL Divergence) [50, 1].

Xét phân phối có điều kiện thực sự $p(x) = \mathbb{P}(Y = 1 \mid X = x)$ và phân phối xấp xỉ có tham số $q(x; \alpha)$. Khoảng cách KL giữa hai phân phối Bernoulli được định nghĩa là:

$$\text{KL}(p, q) = \mathbb{E}_X \left[p(X) \log \left(\frac{p(X)}{q(X; \alpha)} \right) + (1 - p(X)) \log \left(\frac{1 - p(X)}{1 - q(X; \alpha)} \right) \right]. \quad (2.39)$$

Khai triển biểu thức trên:

$$\text{KL}(p, q) = -\mathbb{E}_X [p(X) \log q(X; \alpha) + (1 - p(X)) \log(1 - q(X; \alpha))] - \mathcal{H}(p), \quad (2.40)$$

trong đó $\mathcal{H}(p)$ là entropy Shannon của phân phối thực tế, không phụ thuộc vào tham số α . Do đó, **việc cực tiểu hóa khoảng cách KL hoàn toàn tương đương với việc cực đại hóa hàm log-hợp lý kỳ vọng**:

$$\alpha^* = \arg \min_{\alpha} \text{KL}(p, q) = \arg \max_{\alpha} \mathbb{E} [Y \log q(X; \alpha) + (1 - Y) \log(1 - q(X; \alpha))]. \quad (2.41)$$

2.7.8 Cầu nối trực tiếp sang Chương 3: Mô hình MAMaLoR

Sự kết hợp giữa Hồi quy Logistic Biên và Lý thuyết Trung bình hóa Mô hình theo tiêu chuẩn khoảng cách KL chính là nền tảng trực tiếp để luận văn xây dựng mô hình hoàn chỉnh trong **Chương 3**:

- **Mô hình Hồi quy Logistic Biên Phi tuyến (Nonlinear Marginal Logistic Re-**

gression): Kết hợp các mô hình biên thông qua tổ hợp affine trong thang đo logit:


$$\text{logit}(p_t) \approx \alpha_0 + \sum_{j=1}^d \alpha_j \text{logit}(p_{jt}) = \alpha_0 + \sum_{j=1}^d \alpha_j f_j(x_{jt}) \equiv f_t^{\text{MA}}. \quad (2.42)$$

- **Mô hình MAMaLoR cho Chuỗi Thời gian (MAMaLoR + Time Series Forecasting)**: Hoàn thiện mô hình MAMaLoR trên chuỗi thời gian phụ thuộc thỏa mãn điều kiện trộn mạnh β -mixing, thiết lập quy trình ước lượng hai bước, chứng minh tính nhất quán và phân phối chuẩn tắc tiệm cận $\sqrt{T}(\hat{\alpha} - \alpha^*)$, cũng như ứng dụng dự báo thực nghiệm.

2.8 Các Chỉ số Đánh giá Hiệu năng Phân loại Chuỗi Thời gian

Trong các bài toán phân loại, đặc biệt là những bài toán có phân bố lớp không cân bằng, việc lựa chọn chỉ số đánh giá phù hợp là rất quan trọng [26]. Các chỉ số như Accuracy, Recall, Precision, F1-score và đặc biệt là phân tích đường cong ROC cùng diện tích dưới đường cong AUC [56] giúp mô tả toàn diện hiệu suất phân loại của mô hình độc lập với việc lựa chọn ngưỡng phân lớp.

Confusion Matrix là cấu trúc cơ bản để đánh giá mô hình phân loại, gồm bốn thành phần:



Hình 2.5: Minh họa kết quả phân loại và ma trận nhầm lẫn

- **True Positive (TP):** Mô hình dự đoán đúng lớp dương.
- **True Negative (TN):** Mô hình dự đoán đúng lớp âm.
- **False Positive (FP):** mô hình dự đoán dương nhưng thực tế là âm.
- **False Negative (FN):** Mô hình dự đoán âm nhưng thực tế là dương.

Từ đó, nhiều chỉ số được xây dựng nhằm đánh giá các khía cạnh khác nhau của mô hình.

Accuracy đo tỷ lệ dự đoán đúng trên toàn bộ dữ liệu:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Chỉ số này phù hợp khi dữ liệu cân bằng giữa các lớp, nhưng có thể gây hiểu lầm khi một lớp chiếm ưu thế.

Precision đo mức độ chính xác của các dự đoán thuộc lớp dương:

$$Precision = \frac{TP}{TP + FP}$$

Precision cao cho thấy mô hình ít đưa ra dự đoán dương sai.

Recall (hay True Positive Rate) đo khả năng phát hiện các trường hợp thuộc lớp dương:

$$Recall = Se = \frac{TP}{TP + FN}$$

Recall cao có nghĩa là mô hình ít bỏ sót các trường hợp thuộc lớp dương.

Specificity đo khả năng phát hiện các trường hợp thuộc lớp âm.


$$Sp = \frac{TN}{TN + FP}$$

F1-score là trung bình điều hòa giữa Precision và Recall:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

F1-score cân bằng hai yếu tố: độ chính xác của dự đoán dương và khả năng bao phủ các trường hợp dương.

2.8.1 ROC Curve và AUC (Area Under the Curve)



Hình 2.6: Đường cong ROC và diện tích AUC

Đường cong ROC (Receiver Operating Characteristic) được sử dụng để mô tả hiệu suất của mô hình phân loại nhị phân bằng cách thể hiện mối quan hệ giữa độ nhạy (Sensitivity) và tỷ lệ dương giả (False Positive Rate).

$$Se(c) = TPR = \frac{TP}{TP + FN} \quad \text{và} \quad Sp(c) = FPR = \frac{FP}{TP + FN}$$

Một đường cong ROC được định nghĩa là tập hợp tất cả các cặp điểm $(1 - Sp(c), Se(c))$ ứng với mọi ngưỡng phân loại $c \in (0, 1)$:

$$ROC = \{ (1 - Sp(c), Se(c)) : c \in (0, 1) \}.$$

Đường cong ROC được biểu diễn trên hệ trục tọa độ, trong đó trục hoành là $1 - Sp(c)$ (tỷ lệ dương giả) và trục tung là $Se(c)$ (độ nhạy), và toàn bộ đường cong luôn nằm trong hình vuông đơn có giới hạn $[0, 1] \times [0, 1]$.

Khi thay đổi ngưỡng (threshold) quyết định dự đoán. ROC mô tả khả năng phân biệt giữa hai lớp của mô hình trên toàn bộ các ngưỡng có thể.

AUC là diện tích dưới đường ROC. Ý nghĩa của AUC:

- **AUC = 1.0**: mô hình phân biệt hoàn hảo giữa hai lớp.

- **AUC = 0.5**: mô hình không có khả năng phân biệt (tương đương đoán ngẫu nhiên).
- **AUC càng lớn** thể hiện khả năng phân tách hai lớp càng tốt.

AUC là chỉ số ổn định và đặc biệt hữu ích trong dữ liệu mất cân bằng, vì nó không phụ thuộc vào ngưỡng phân loại cố định.

Sau khi đánh giá hiệu suất của mô hình phân loại thông qua đường cong ROC và giá trị AUC, nếu mô hình cho thấy độ chính xác đủ tốt thì ta có thể cân nhắc việc áp dụng mô hình vào thực tế.

Để áp dụng mô hình logistic cho việc phân loại các đối tượng mới, ta cần xác định một ngưỡng phân loại c phù hợp, nhằm đạt được sự cân bằng tốt giữa specificity và sensitivity. Có nhiều phương pháp lựa chọn ngưỡng, một số phương pháp phổ biến bao gồm:

1. Youden Index

Ngưỡng tối ưu c^* được xác định bằng cách tối đa hóa tổng của specificity và sensitivity:

$$c^* = \operatorname{argmax}_{c \in (0,1)} \{ \text{Se}(c) + \text{Sp}(c) \}.$$

2. Closest Top-Left

Ngưỡng tối ưu c^* được xác định bằng cách chọn điểm trên đường ROC gần nhất với điểm lý tưởng $(0, 1)$ — tức là mô hình có specificity = 1 và sensitivity = 1. Khoảng cách được tính theo chuẩn Euclid:

$$c^* = \operatorname{argmin}_{c \in (0,1)} \left[(1 - \text{Se}(c))^2 + (1 - \text{Sp}(c))^2 \right].$$

2.8.2 Kết luận

- Accuracy không phản ánh đúng chất lượng mô hình khi dữ liệu mất cân bằng.
- Precision và Recall cung cấp cái nhìn chi tiết về lỗi dương tính và âm tính.

- F1-score cân bằng Precision và Recall, phù hợp khi cần tối ưu hai chiều cùng lúc.
- ROC–AUC đánh giá khả năng phân biệt lớp của mô hình trên tất cả các ngưỡng.

Các chỉ số này bổ sung cho nhau và nên được sử dụng kết hợp để đánh giá mô hình một cách toàn diện.

2.9 Các Đặc trưng Chuỗi Thời gian Tài chính

2.9.1 Độ biến động

Độ biến động phản ánh mức độ dao động của chỉ số trong một phiên giao dịch. Cụ thể, sai phân logarit giữa giá cao nhất và giá thấp nhất phản ánh trực tiếp mức độ biến động của thị trường trong khoảng thời gian đó (Alizadeh, Brandt và Diebold, 1999; Gallant, Hsu và Tauchen, 1999) [20, 21], thước đo này được xác định:

$$v_{S,t} = \ln(High_t) - \ln(Low_t) = \ln\left(\frac{High_t}{Low_t}\right)$$

Trong đó:

- $High_t$: Điểm cao nhất của chỉ số tại ngày t ;
- Low_t : Điểm thấp nhất của chỉ số tại ngày t ;

Không mất tính tổng quát, xét $High, Low$ thay cho $High_t, Low_t$, đặt:

$$m = \frac{High + Low}{2}, \quad d = \frac{High - Low}{2}$$

Khi đó:

$$\frac{High}{Low} = \frac{m + d}{m - d} = \frac{1 + \frac{d}{m}}{1 - \frac{d}{m}}$$

Khai triển Taylor của hàm $\ln(1 + x)$ quanh $x = 0$:

$$\ln(1 + x) = x - \frac{x^2}{2} + \frac{x^3}{3} - \frac{x^4}{4} + \cdots + (-1)^{n+1} \frac{x^n}{n} + o(x^n) \approx x$$

Với $x = \frac{d}{m}$ đủ nhỏ, ta có:

$$\ln\left(1 + \frac{d}{m}\right) \approx \frac{d}{m}, \quad \ln\left(1 - \frac{d}{m}\right) \approx -\frac{d}{m}$$

Suy ra:

$$v_{S,t} = \ln\left(\frac{High_t}{Low_t}\right) = \ln\left(1 + \frac{d}{m}\right) - \ln\left(1 - \frac{d}{m}\right) \approx \frac{2d}{m}$$

Thay $d = \frac{High - Low}{2}$ và $m = \frac{High + Low}{2}$, ta được:

$$v_{S,t} \approx \frac{High_t - Low_t}{\frac{1}{2}(High_t + Low_t)}$$

Nhân với 100 để biểu diễn dưới dạng phần trăm, thu được đặc trưng độ biến động:

$$v_t = 100 \cdot \frac{High_t - Low_t}{\frac{1}{2}(High_t + Low_t)} (\%)$$

Độ biến động cao phản ánh thị trường bất ổn, độ biến động thấp phản ánh thị trường ổn định.

Các thước đo biến động kinh điển dựa trên khoảng dao động giá (Range-based Volatility):

Bên cạnh thước đo xấp xỉ biên độ v_t , văn liệu kinh tế lượng tài chính đã phát triển nhiều ước lượng độ biến động dựa trên khoảng giá cao – thấp với hiệu quả thống kê vượt trội so với bình phương lợi suất đóng cửa:

- **Ước lượng Parkinson (1980):** Dưới giả định giá tài sản tuân theo chuyển động Brown hình học (GBM) không có trôi (drift), [15] đề xuất thước đo phương sai biến động:

$$v_{P,t} = \frac{1}{4 \ln 2} \left[\ln\left(\frac{High_t}{Low_t}\right) \right]^2 \approx 0.361 \left[\ln\left(\frac{High_t}{Low_t}\right) \right]^2.$$

Theo [19], thước đo của Parkinson có thể đạt hiệu quả thống kê gấp tới 5 lần so

với ước lượng dựa trên giá đóng cửa thông thường.

- **Ước lượng Garman–Klass (1980):** Nhằm tận dụng thêm thông tin từ giá mở cửa ($Open_t$) và đóng cửa ($Close_t$), [16] mở rộng công thức:

$$v_{GK,t} = 0.5 \left[\ln \left(\frac{High_t}{Low_t} \right) \right]^2 - (2 \ln 2 - 1) \left[\ln \left(\frac{Close_t}{Open_t} \right) \right]^2,$$

giúp giảm phương sai mẫu xuống mức tối ưu khi không có bước nhảy qua đêm.

- **Ước lượng Rogers–Satchell (1991):** Khi thị trường tồn tại xu thế trôi khác 0 (non-zero drift), cả ước lượng Parkinson và Garman–Klass đều bị chệch. Để khắc phục, [17] và [18] đề xuất ước lượng không chệch đối với drift:

$$v_{RS,t} = \ln \left(\frac{High_t}{Close_t} \right) \ln \left(\frac{High_t}{Open_t} \right) + \ln \left(\frac{Low_t}{Close_t} \right) \ln \left(\frac{Low_t}{Open_t} \right).$$

Các nghiên cứu của [20] và [21] khẳng định các thước đo dựa trên khoảng dao động giá (high-low range) là xấp xỉ tuyệt vời cho độ biến động ngẫu nhiên thực tế, đặc biệt hiệu quả trong việc cung cấp tín hiệu dự báo cho các mô hình phân loại chuỗi thời gian tài chính.

2.9.2 Log-volume - đo khối giao dịch:

Khối lượng giao dịch phản ánh mức độ hoạt động của thị trường trong một ngày giao dịch, giúp xác nhận độ tin cậy của xu hướng giá. Nếu giá tăng mà nhiều người mua thì xu hướng đáng tin cậy. Nếu giá tăng nhưng ít người giao dịch thì có thể chỉ là biến động tạm thời. Tuy nhiên, dữ liệu khối lượng giao dịch thường có phân phối lệch phải (right-skewed), nghĩa là phần lớn giá trị tập trung ở mức thấp hoặc trung bình, trong khi một số ít quan sát có giá trị rất lớn làm kéo dài phần đuôi bên phải của phân phối. Những giá trị lớn này thường xuất hiện trong các giai đoạn thị trường biến động mạnh hoặc khi có thông tin quan trọng được công bố.

Bên cạnh đó, mức độ dao động của khối lượng giao dịch thường không ổn định theo thời gian. Trong các giai đoạn thị trường sôi động, khối lượng giao dịch tăng mạnh và biến động lớn; ngược lại, trong giai đoạn trầm lắng, khối lượng và mức dao động đều giảm. Hiện tượng này dẫn đến phương sai thay đổi theo thời gian.

Để khắc phục hiện tượng này, nghiên cứu sử dụng biến log-khối lượng giao dịch,

được xác định:

$$V_t = \log(\text{Volume}_t)$$

Trong đó:

- Volume_t : Tổng khối lượng giao dịch tại ngày t ;
- V_t : Logarit tự nhiên của khối lượng giao dịch tại ngày t .

Việc biến đổi logarit mang lại nhiều lợi ích trong phân tích dữ liệu tài chính. Trước hết, phép biến đổi này giúp giảm mức độ lệch phải của phân phối khối lượng giao dịch, từ đó làm cho dữ liệu tiệm cận với phân phối chuẩn hơn. Đồng thời, biến đổi logarit góp phần ổn định phương sai, hạn chế hiện tượng phương sai thay đổi theo thời gian (heteroskedasticity). Bên cạnh đó, phép biến đổi này còn làm giảm ảnh hưởng của các giá trị ngoại lai (outliers), giúp các kết quả phân tích và ước lượng mô hình trở nên ổn định và đáng tin cậy hơn.

2.9.3 Lợi nhuận hình học (Geometric Return) – đo lường mức sinh lời và xu hướng biến động giá:

Lợi nhuận hình học được sử dụng để đo lường mức thay đổi tương đối của chỉ số (hoặc giá tài sản) giữa hai thời điểm liên tiếp. Thước đo này dựa trên lợi suất log (log-return) của giá đóng cửa, cho phép phản ánh tốc độ biến động của giá một cách nhất quán và có tính cộng dồn theo thời gian (time additive). Đặc điểm này là một ưu điểm quan trọng của log-return so với lợi suất thông thường, bởi lợi suất log trong nhiều giai đoạn liên tiếp có thể được cộng trực tiếp để xác định tổng mức sinh lời trong toàn bộ khoảng thời gian nghiên cứu. Nhờ tính chất này, log-return đặc biệt phù hợp với các mô hình phân tích chuỗi thời gian và được sử dụng rộng rãi trong nghiên cứu kinh tế lượng tài chính, chẳng hạn như phân tích biến động, ước lượng rủi ro và xây dựng các mô hình dự báo tài chính.

Cụ thể, lợi nhuận tại thời điểm t được xác định như sau:

$$G_t = 100 \log \left(\frac{\text{Close}_t}{\text{Close}_{t-1}} \right)$$

Trong đó, Close_t là giá đóng cửa tại thời điểm t , còn Close_{t-1} là giá đóng cửa tại thời điểm liền trước đó. Hệ số 100 được sử dụng để biểu diễn lợi suất dưới dạng phần

trăm, giúp việc diễn giải trực quan hơn.

Chỉ số G_t phản ánh mức độ và chiều hướng biến động của thị trường: nếu $G_t > 0$ thì giá tài sản có xu hướng tăng; ngược lại, nếu $G_t < 0$ thì giá tài sản có xu hướng giảm. Giá trị tuyệt đối của G_t càng lớn cho thấy mức độ biến động càng mạnh.

Tuy nhiên, do công thức yêu cầu giá đóng cửa tại thời điểm liền trước ($Close_{t-1}$), nên tại quan sát đầu tiên của mẫu (ngày 01/05/2013) không tồn tại giá trị này. Vì vậy, lợi nhuận tại thời điểm đầu tiên không thể tính được và được xem là một giá trị khuyết (missing value) trong tập dữ liệu.

2.9.4 Biến nhãn Y_t

Y_t là biến nhị phân biểu diễn xu hướng biến động của điểm, được xác định dựa trên sự thay đổi của điểm đóng cửa giữa hai ngày giao dịch liên tiếp:

$$Y_t = \begin{cases} 1, & \text{nếu } Close_t > Close_{t-1} \text{ (điểm tăng)} \\ 0, & \text{nếu } Close_t \leq Close_{t-1} \text{ (điểm giảm hoặc đi ngang)} \end{cases}$$

Trong đó, $Y_t = 1$ thể hiện xu hướng tăng điểm và $Y_t = 0$ thể hiện xu hướng giảm hoặc không đổi.

Do việc xác định Y_t yêu cầu điểm đóng cửa của ngày liền trước, nên tại thời điểm quan sát đầu tiên của mẫu ($t = 0$) không tồn tại giá trị $Close_{t-1}$. Vì vậy, Y_0 tại thời điểm này sẽ là một giá trị khuyết.

Như vậy, tập dữ liệu nghiên cứu không chỉ bao gồm các biến điểm cơ bản (điểm mở cửa, điểm cao nhất, điểm thấp nhất, điểm đóng cửa và khối lượng giao dịch), mà còn được mở rộng với các đặc trưng quan trọng như lợi nhuận, độ biến động, log-volume và biến nhãn xu hướng phục vụ cho mô hình phân loại, với quan sát đầu tiên được loại bỏ khỏi tập dữ liệu nhằm đảm bảo tính nhất quán của các biến giải thích và biến mục tiêu.

Index	Date	Close	High	Low	Open	Volume	Volatility	Log_Volume	Geometric_Return	Y
1	2013-05-02	6460.700195	6470.299805	6409.799805	6451.299805	744888400	0.939434	20.428745	0.145607	1
2	2013-05-03	6521.500000	6541.700195	6451.500000	6460.700195	768857600	1.388422	20.460416	0.936671	1
3	2013-05-07	6557.299805	6563.899902	6521.399902	6521.500000	795845400	0.649584	20.494916	0.547449	1
4	2013-05-08	6583.500000	6587.399902	6547.000000	6557.299805	703446800	0.615177	20.371503	0.398762	1
...	...	...	...	...	...	...	...	...	...	...
1260	2018-04-25	7379.299805	7427.100098	7334.600098	7425.399902	879795200	1.253243	20.595200	-0.622779	0
1261	2018-04-26	7421.399902	7421.399902	7355.000000	7379.299805	814899700	0.898729	20.518576	0.568895	1
1262	2018-04-27	7502.200195	7507.100098	7421.299805	7421.399902	750485000	1.149491	20.436230	1.082863	1
1263	2018-04-30	7509.299805	7546.200195	7497.100098	7502.200195	991178200	0.652784	20.714405	0.094589	1
1264	2018-05-01	7520.399902	7549.100098	7506.600098	7509.299805	567569600	0.564570	20.156874	0.147709	1

Bảng 2.6: Dữ liệu FTSE 100 sau khi cập nhập các biến mới

Mục tiêu là xây dựng và đánh giá các mô hình phân loại chuỗi thời gian, bài toán đặt ra là: dựa trên dữ liệu lịch sử của chỉ số FTSE 100, dự đoán xu hướng điểm ngày tiếp theo (tăng hoặc giảm), cụ thể là dự đoán biến nhãn Y (tăng/giảm) của chỉ số FTSE 100 dựa trên dữ liệu lịch sử. Đây là một ví dụ điển hình của bài toán phân loại nhị phân trong dữ liệu chuỗi thời gian, trong đó mô hình cần đồng thời xử lý:

- (i) sự phụ thuộc theo thời gian,
- (ii) mối quan hệ phi tuyến giữa các biến,
- (iii) ảnh hưởng của nhiễu và biến động mạnh đặc trưng của thị trường tài chính.

CHƯƠNG 3. PHƯƠNG PHÁP HỒI QUY LOGISTIC BIÊN PHI TUYẾN (MAMALOR) VÀ TÍNH CHẤT TIỆM CẬN

3.1 Động cơ và Cơ sở Toán học

Tiếp nối nền tảng lý thuyết được xây dựng tại Chương 2 (từ xác suất nhị phân, GLM/GAM, hồi quy phi tham số, hồi quy logistic cục bộ, phân rã biên đến lý thuyết trung bình hóa mô hình), chương này hiện thực hóa mô hình trung bình hóa hồi quy logistic biên phi tuyến MAMaLoR của [1] trên chuỗi thời gian phụ thuộc β -mixing, thiết lập quy trình ước lượng hai bước, các tính chất tiệm cận $\sqrt{T}$ và suy diễn thống kê.

Trong phân tích chuỗi thời gian hiện đại, việc phân loại hoặc dự báo trạng thái nhị phân của một biến ngẫu nhiên trong tương lai dựa trên các thông tin quá khứ đóng vai trò then chốt trong nhiều lĩnh vực như kinh tế lượng, tài chính định lượng và quản trị rủi ro.

Giả sử $\{(Y_t, \mathbf{X}_t^\top)\}_{t=1}^n$ là một quá trình chuỗi thời gian dừng, trong đó $Y_t \in \{0, 1\}$ là biến phản hồi nhị phân ghi nhận tại thời điểm t , và $\mathbf{X}_t = (x_{1t}, x_{2t}, \dots, x_{dt})^\top \in \mathbb{R}^d$ là vector ngẫu nhiên d chiều đại diện cho tập thông tin có sẵn cho đến thời điểm $t-1$, ký hiệu là $\mathcal{I}_{t-1}$. Vector này thường chứa các giá trị trễ của biến phản hồi $Y_{t-1}, Y_{t-2}, \dots$ cũng như các độ trễ của các biến dự báo liên quan. Mục tiêu cơ bản của bài toán phân loại chuỗi thời gian là mô hình hóa và ước lượng xác suất có điều kiện:

$$p_t = \mathbb{P}(Y_t = 1 \mid \mathcal{I}_{t-1}) = \mathbb{P}(Y_t = 1 \mid \mathbf{X}_t). \quad (3.1)$$

Khi số chiều d tương đối lớn (do phải thu nạp nhiều bậc trễ để bao quát thông tin động học của chuỗi thời gian), phương pháp ước lượng phi tham số trực tiếp cho hàm đa biến $p_t = m(\mathbf{X}_t)$ sẽ thất bại nghiêm trọng do hiện tượng “lời nguyền của số chiều” (curse of dimensionality) – tốc độ hội tụ suy giảm theo quy luật $O_p(n^{-2/(4+d)})$ khiến sai số phương sai bùng nổ khi n hữu hạn.

Để khắc phục hiện tượng này trong bài toán hồi quy liên tục, [2] đã đề xuất mô hình trung bình hóa hồi quy biên (MAMAR – *Model Averaging Marginal Regression*). Tuy

nhien, MAMAR được thiết kế cho biến phản hồi liên tục với hàm tổn thất bình phương trung bình, không đảm bảo rằng giá trị dự báo thuộc đoạn $[0, 1]$ và bỏ qua bản chất phân phối Bernoulli của dữ liệu nhị phân. Nhằm dung hòa giữa tính mềm dẻo của các phương pháp phi tham số một chiều và khả năng kiểm soát số chiều của phương pháp trung bình mô hình, [1] đã phát triển mô hình trung bình hóa các hồi quy logistic biên phi tuyến (MAMaLoR – *Model Averaging nonlinear MArginal LOGistic Regressions*).

3.2 Cấu trúc Mô hình MAMaLoR

Phương pháp MAMaLoR tiếp cận bài toán thông qua quy trình hai bước logic:

3.2.1 Bước 1: Mô hình hóa các hồi quy logistic biên phi tham số

Trước hết, ta phân rã bài toán đa biến thành d bài toán hồi quy biên một chiều. Với mỗi biến thành phần x_{jt} ($j = 1, \dots, d$) của vector $\mathbf{X}_t$, ta định nghĩa xác suất biên có điều kiện:

$$p_{jt} = \mathbb{P}(Y_t = 1 \mid x_{jt}), \quad j = 1, \dots, d. \quad (3.2)$$

Gọi $F(u)$ là hàm phân phối tích lũy logistic chuẩn tắc:

$$F(u) = \frac{\exp(u)}{1 + \exp(u)}, \quad u \in \mathbb{R}. \quad (3.3)$$

Khi đó, hàm liên kết logit biên được định nghĩa dưới dạng phi tham số:

$$\text{logit}(p_{jt}) \equiv \log \left(\frac{p_{jt}}{1 - p_{jt}} \right) = f_j(x_{jt}), \quad (3.4)$$

trong đó $f_j(\cdot)$ là một hàm phi tuyến trơn chưa biết từ $\mathbb{R}$ vào $\mathbb{R}$. Do đó:

$$p_{jt} = F(f_j(x_{jt})), \quad j = 1, \dots, d. \quad (3.5)$$

3.2.2 Bước 2: Trung bình hóa mô hình biên trong thang đo logit

Thay vì ước lượng đồng thời một hàm đa biến phức tạp, MAMaLoR xấp xỉ hàm logit đa biến $\text{logit}(p_t)$ thông qua một tổ hợp affine của các hàm logit biên một chiều:

$$\text{logit}(p_t) \approx \alpha_0 + \sum_{j=1}^d \alpha_j \text{logit}(p_{jt}) = \alpha_0 + \sum_{j=1}^d \alpha_j f_j(x_{jt}) \equiv f_t^{\text{MA}}, \quad (3.6)$$

trong đó $\alpha = (\alpha_0, \alpha_1, \dots, \alpha_d)^\top \in \mathbb{R}^{d+1}$ là vector trọng số kết hợp cần ước lượng.

Từ liên kết logistic nghịch đảo, mô hình xác suất có điều kiện hoàn chỉnh của MAMaLoR có dạng:

$$p_t(\alpha) = F(f_t^{\text{MA}}) = \frac{\exp\left(\alpha_0 + \sum_{j=1}^d \alpha_j f_j(x_{jt})\right)}{1 + \exp\left(\alpha_0 + \sum_{j=1}^d \alpha_j f_j(x_{jt})\right)}. \quad (3.7)$$

3.3 Tiêu Chuẩn Tối Ưu Hóa Khoảng Cách Kullback–Leibler

Động cơ lý thuyết sâu sắc cho công thức tổ hợp (3.6) bắt nguồn từ nguyên lý thông tin thống kê [50]. Gọi phân phối thực của Y_t có điều kiện trên $\mathcal{I}_{t-1}$ là Bernoulli với tham số p_t , và phân phối mô hình xấp xỉ là Bernoulli với tham số $p_t(\alpha)$. Khoảng cách Kullback–Leibler (KL divergence) giữa phân phối thực và phân phối xấp xỉ được xác định bởi [50]:

$$\text{KL}(p_t, p_t(\alpha)) = \mathbb{E} \left(p_t \log \left(\frac{p_t}{p_t(\alpha)} \right) + (1 - p_t) \log \left(\frac{1 - p_t}{1 - p_t(\alpha)} \right) \right). \quad (3.8)$$

Cực tiểu hóa khoảng cách KL theo α tương đương với việc cực đại hóa đại lượng:

$$\mathbb{E} (p_t \log(p_t(\alpha)) + (1 - p_t) \log(1 - p_t(\alpha))). \quad (3.9)$$

Theo luật kỳ vọng lặp, do $\mathbb{E}(Y_t | \mathcal{I}_{t-1}) = p_t$, biểu thức trên chính là kỳ vọng của hàm log-likelihood có điều kiện trong quần thể:

$$\ell(\mathbf{f}_0(\cdot), \alpha) = \mathbb{E} (Y_t \log(p_t(\alpha)) + (1 - Y_t) \log(1 - p_t(\alpha))) w(\mathbf{X}_t), \quad (3.10)$$

trong đó $\mathbf{f}_0(\cdot) = (f_1(\cdot), \dots, f_d(\cdot))^\top$ là vector các hàm biên thực, và $w(\mathbf{X}_t)$ là hàm trọng số cắt đuôi được đưa vào để triệt tiêu ảnh hưởng của các giá trị ngoại lai ở vùng biên phân phối theo nguyên lý hợp lý kết hợp (composite/marginal likelihood) [12]. Do đó, vector trọng số tối ưu toàn thể α_0 được xác định là nghiệm duy nhất của bài toán cực đại hóa:

$$\alpha_0 = \arg \max_{\alpha \in \Pi} \ell(\mathbf{f}_0(\cdot), \alpha). \quad (3.11)$$

3.4 Quy Trình Ước Lượng Hai Bước

Trong thực tế mẫu quan sát $\{(Y_t, \mathbf{X}_t^\top)\}_{t=1}^n$, các hàm biên $f_j(\cdot)$ chưa biết và phải được ước lượng trước khi tính toán trọng số α .

3.4.1 Bước 1: Ước lượng hợp lý cực đại cục bộ tuyến tính (Local Linear Maximum Likelihood)

Tại một điểm quan tâm bất kỳ x_{j0} , kế thừa khung lý thuyết ước lượng hợp lý cục bộ tiên phong của [5] và [4] (xem thêm [29, 30]), giả sử hàm $f_j(\cdot)$ khả vi liên tục đến cấp hai. Khai triển Taylor bậc nhất của $f_j(x_{jt})$ tại lân cận $|x_{jt} - x_{j0}| \leq h$:

$$f_j(x_{jt}) \approx f_j(x_{j0}) + f'_j(x_{j0})(x_{jt} - x_{j0}) \equiv \beta_1 + \beta_2(x_{jt} - x_{j0}), \quad (3.12)$$

trong đó $h = h_n > 0$ là tham số băng thông (bandwidth). Hàm log-likelihood cục bộ có trọng số kernel cho f_j được xây dựng như sau:

$$\begin{aligned} \mathcal{L}_j(\beta, x_{j0}, h) = \sum_{t=1}^n \left[Y_t (\beta_1 + \beta_2(x_{jt} - x_{j0})) \right. \\ \left. - \log(1 + \exp(\beta_1 + \beta_2(x_{jt} - x_{j0}))) \right] K_h(x_{jt} - x_{j0}), \end{aligned} \quad (3.13)$$

với $K_h(u) = h^{-1}K(u/h)$, $K(\cdot)$ là hàm nhân đối xứng một chiều. Ước lượng của $f_j(x_{j0})$ và $f'_j(x_{j0})$ là nghiệm cực đại:

$$\begin{pmatrix} \hat{f}_j(x_{j0}) \\ \hat{f}'_j(x_{j0}) \end{pmatrix} = \arg \max_{\beta_1, \beta_2} \mathcal{L}_j(\beta, x_{j0}, h). \quad (3.14)$$

Hàm log-likelihood cục bộ (3.13) là hàm lõm ngặt theo β , do đó nghiệm được tìm thấy nhanh chóng và ổn định bằng thuật toán Newton–Raphson hoặc hàm hồi quy

GLM có trọng số cục bộ. Thay x_{j0} bằng từng giá trị quan sát x_{jt} , ta thu được chuỗi ước lượng biên $\hat{f}_j(x_{jt})$ với $j = 1, \dots, d$ và $t = 1, \dots, n$.

3.4.2 Bước 2: Ước lượng vector trọng số kết hợp $\hat{\alpha}$

Sau khi thu được $\hat{\mathbf{f}}(\mathbf{X}_t) = (\hat{f}_1(x_{1t}), \dots, \hat{f}_d(x_{dt}))^\top$, ta thay vào hàm log-likelihood mẫu hiệu chỉnh có kiểm soát biên:

$$\begin{aligned} \ell_n(\hat{\mathbf{f}}(\cdot), \alpha) = \frac{1}{n} \sum_{t=1}^n \left[Y_t \left(\alpha_0 + \sum_{j=1}^d \alpha_j \hat{f}_j(x_{jt}) \right) \right. \\ \left. - \log \left(1 + \exp \left(\alpha_0 + \sum_{j=1}^d \alpha_j \hat{f}_j(x_{jt}) \right) \right) \right] w(\mathbf{X}_t), \quad (3.15) \end{aligned}$$

trong đó hàm trọng số cắt biên được chọn dạng hình hộp chữ nhật:

$$w(\mathbf{X}_t) = \prod_{j=1}^d \mathbb{I}(c_{0j} \leq x_{jt} \leq c_{1j}), \quad (3.16)$$

với $c_{0j} < c_{1j}$ thường được chọn tại phân vị 10% và 90% của mẫu quan sát $\{x_{jt}\}_{t=1}^n$ để loại bỏ nhiễu biên. Ước lượng trọng số MAMaLoR trên mẫu là:

$$\hat{\alpha} = \arg \max_{\alpha \in \Pi} \ell_n(\hat{\mathbf{f}}(\cdot), \alpha). \quad (3.17)$$

Đạo hàm cấp một (score function) và ma trận Hessian của $\ell_n(\hat{\mathbf{f}}(\cdot), \alpha)$ đối với α có dạng:

$$\frac{\partial \ell_n(\hat{\mathbf{f}}, \alpha)}{\partial \alpha_j} = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{p}_t(\alpha)) \hat{f}_j(x_{jt}) w(\mathbf{X}_t), \quad (\text{với } \hat{f}_0(x_{0t}) \equiv 1), \quad (3.18)$$

$$\frac{\partial^2 \ell_n(\hat{\mathbf{f}}, \alpha)}{\partial \alpha_j \partial \alpha_k} = -\frac{1}{n} \sum_{t=1}^n \hat{p}_t(\alpha) (1 - \hat{p}_t(\alpha)) \hat{f}_j(x_{jt}) \hat{f}_k(x_{kt}) w(\mathbf{X}_t). \quad (3.19)$$

Vì ma trận Hessian (3.19) là nửa xác định âm (và xác định âm khi ma trận thiết kế biên đầy đủ hạng), hàm mục tiêu mẫu là lõm ngặt, bảo đảm tính duy nhất của nghiệm $\hat{\alpha}$.

3.5 Hệ Giả Thiết Kỹ Thuật (Assumptions A1–A5)

Để thiết lập tính chất tiệm cận của mô hình khi cỡ mẫu $n \rightarrow \infty$ dưới cấu trúc chuỗi thời gian phụ thuộc yếu, ta đặt ra các giả thiết toán học sau:

Giả thiết 3.1 (A1 – Tính dừng và phụ thuộc β -mixing).

- (i) Quá trình $\{(Y_t, \mathbf{X}_t^\top)\}_{t=1}^n$ là dừng mạnh và thỏa mãn điều kiện β -mixing [22, 9] với hệ số mixing suy giảm theo hàm đa thức $\beta(t) = O(t^{-b})$, trong đó $b > \max\left(\frac{2(\rho r + 1)}{\rho r - 2}, \frac{r + a}{1 - 2/\rho}\right)$ và $a \geq \frac{(\rho r - 2)r}{2 + \rho r - 4r}$.
- (ii) Với mọi $t_1 < t_2 < \dots < t_s$ và $1 \leq s \leq 2r$, hàm mật độ xác suất đồng thời của $(\mathbf{X}_{t_1}, \dots, \mathbf{X}_{t_s})$, ký hiệu là $g_{\mathbf{X}_{t_1}, \dots, \mathbf{X}_{t_s}}(x_1, \dots, x_s)$, bị chặn trên đồng đều.
- (iii) Tồn tại các hằng số $\rho > 4 - 2/r$ (với $r \geq 1$ nguyên) sao cho mô-men thỏa mãn $\mathbb{E}\|\mathbf{X}_t\|^{\rho r} < \infty$.

Giả thiết 3.2 (A2 – Hàm trọng số cắt biên). Hàm trọng số có dạng $w(\mathbf{X}_t) = \prod_{j=1}^d \mathbb{I}(c_{0j} \leq x_{jt} \leq c_{1j})$, trong đó $A_j = [c_{0j}, c_{1j}]$ là các khoảng compact sao cho mật độ biên $g_j(x_j)$ dương nghiêm ngặt trên A_j . Đặt $A = \prod_{j=1}^d A_j$.

Giả thiết 3.3 (A3 – Điều kiện băng thông).

- (i) Băng thông $h = h_n$ thỏa mãn $h \rightarrow 0$ và $\liminf_{n \rightarrow \infty} nh^{b_1} > 0$ với $b_1 \equiv \frac{2(r-1)a + (\rho r - 2)}{(a+1)\rho}$ và số nguyên $r \geq 3$.
- (ii) Tồn tại dãy số nguyên dương $s_n \rightarrow \infty$ sao cho $s_n = o((nh)^{1/2})$, $ns_n^{-b} \rightarrow 0$, và $s_n h^{b_2} > 1$ với $b_2 \equiv \frac{2(\rho r - 2)}{2 + b(\rho r - 2)}$.
- (iii) Điều kiện làm trơn non (undersmoothing condition): $nh^4 = o(1)$ khi $n \rightarrow \infty$.

Giả thiết 3.4 (A4 – Độ trơn Lipschitz của các hàm hồi quy biên). Vector hàm hồi quy biên thực $\mathbf{f}_0(\cdot) = (f_1(\cdot), \dots, f_d(\cdot))^\top$ thuộc không gian hàm Lipschitz $\mathcal{F} \equiv C_c^\phi(A)$ với cấp trơn $\phi \geq 2$:

$$\mathcal{F} = \left\{ \mathbf{f} : A \rightarrow \mathbb{R}^d \text{ liên tục và } \|\mathbf{f}\|_{\infty, \phi} \leq c \right\}, \quad (3.20)$$

với chuẩn Lipschitz được xác định bởi:

$$\|\mathbf{f}\|_{\infty, \phi} = \max_{0 \leq \kappa \leq [\phi]} \sup_{x \in A} \|\mathbf{f}^{(\kappa)}(x)\| + \sup_{x \neq x'; x, x' \in A} \frac{\|\mathbf{f}^{([\phi])}(x) - \mathbf{f}^{([\phi])}(x')\|}{\|x - x'\|^{\phi - [\phi]}}. \quad (3.21)$$

Giả thiết 3.5 (A5 – Tính chính quy của phương trình ước lượng cục bộ). *Định nghĩa* $\Phi(Y_t, z_j) = Y_t - F(z_j)$ và $m(x_j, z_j) = \mathbb{E}(\Phi(Y_t, z_j) \mid x_{jt} = x_j)$. Ánh xạ $(x_j, z_j) \mapsto m(x_j, z_j)g_j(x_j)$ là khả vi liên tục ba lần trên $\mathbb{R}^2$, trong đó $g_j(x_j)$ là mật độ xác suất biên của x_{jt} , liên tục và dương trên A_j .

Nhận xét 3.6. Giả thiết A1 là điều kiện tiêu chuẩn cho chuỗi thời gian phi tuyến, được thỏa mãn bởi hầu hết các quá trình ergodic hình học như ARMA, GARCH phi tuyến, và ngưỡng tự hồi quy TAR ([10]; xem thêm [14, 11]). Giả thiết A3(iii) ($nh^4 \rightarrow 0$) là điều kiện then chốt đảm bảo độ chệch (bias) bậc nhất của ước lượng hạt nhân triệt tiêu tiệm cận ở tốc độ $\sqrt{n}$.

3.6 Bổ Đề Nhất Quán và Tính Nhất Quán Của Trọng Số

Mệnh đề 3.7 (Bổ đề Nhất quán – Consistency Lemma). *Giả sử $\alpha_0 \in \Pi$ thỏa mãn $\ell(\mathbf{f}_0(\cdot), \alpha_0) = \max_{\alpha \in \Pi} \ell(\mathbf{f}_0(\cdot), \alpha)$, trong đó Π là một tập compact trong $\mathbb{R}^{d+1}$ và α_0 là điểm trong của Π . Giả sử 5 điều kiện sau được thỏa mãn:*

(i) $\hat{\alpha}$ là nghiệm cực đại tiệm cận của hàm mục tiêu mẫu:

$$\ell_n(\hat{\mathbf{f}}(\cdot), \hat{\alpha}) \geq \sup_{\alpha \in \Pi} \ell_n(\hat{\mathbf{f}}(\cdot), \alpha) - o_p(1). \quad (3.22)$$

(ii) *Tính định danh (Identifiability): Với mọi $\delta > 0$, tồn tại $\varepsilon(\delta) > 0$ sao cho:*

$$\inf_{\|\alpha - \alpha_0\| > \delta} |\ell(\mathbf{f}_0(\cdot), \alpha) - \ell(\mathbf{f}_0(\cdot), \alpha_0)| \geq \varepsilon(\delta) > 0. \quad (3.23)$$

(iii) *Tính liên tục đồng đều: Đồng đều với mọi $\alpha \in \Pi$, hàm mục tiêu quần thể $\ell(\mathbf{f}(\cdot), \alpha)$ liên tục theo metric $\|\cdot\|_{\mathcal{F}}$ tại $\mathbf{f}_0(\cdot)$.*

(iv) *Tính nhất quán đồng đều của bước 1:*

$$\|\hat{\mathbf{f}}(\cdot) - \mathbf{f}_0(\cdot)\|_{\mathcal{F}} \equiv \sup_{x \in A} \|\hat{\mathbf{f}}(x) - \mathbf{f}_0(x)\| = o_p(1). \quad (3.24)$$

(v) *Luật số lớn đồng đều: Với mọi dãy số $\delta_n = o(1)$, ta có:*

$$\sup_{\alpha \in \Pi} \sup_{\|\mathbf{f} - \mathbf{f}_0\|_{\mathcal{F}} \leq \delta_n} |\ell_n(\mathbf{f}(\cdot), \alpha) - \ell(\mathbf{f}(\cdot), \alpha)| = o_p(1). \quad (3.25)$$

Khi đó, $\hat{\alpha}$ hội tụ theo xác suất về α_0 :

$$\hat{\alpha} - \alpha_0 = o_p(1) \quad \text{khi } n \rightarrow \infty. \quad (3.26)$$

Nhận xét 3.8 (Đánh chính sai sót trong tài liệu gốc). Trong bài báo gốc của [1] (trang 7), điều kiện (i) bị in nhầm dấu bất đẳng thức thành $\ell_n(\hat{\mathbf{f}}, \hat{\alpha}) \leq \max_{\alpha} \ell_n + o_p(1)$. Điều này là phi lý vì bất kỳ điểm nào trong không gian cũng đều thỏa mãn $\leq \max$. Công thức (3.22) đã được đánh chính đúng theo chuẩn tắc của lý thuyết tiệm cận M-estimation ([13]).

Định lý 3.9 (Tính Nhất Quán Của Trọng Số MAMaLoR). Dưới các Giả thiết A1–A5, nếu Π là một tập compact trong $\mathbb{R}^{d+1}$ và α_0 là điểm trong duy nhất cực đại hóa hàm $\ell(\mathbf{f}_0(\cdot), \alpha)$ trên Π , thì:

$$\hat{\alpha} \xrightarrow{p} \alpha_0 \quad \text{khi } n \rightarrow \infty. \quad (3.27)$$

3.7 Chuẩn Tắc Tiệm Cận Của Vector Trọng Số

Để thiết lập phân phối giới hạn của $\hat{\alpha}$, ta định nghĩa vector đặc trưng biên:

$$\tilde{\chi}_t(\mathbf{f}_0) = (1, f_1(x_{1t}), f_2(x_{2t}), \dots, f_d(x_{dt}))^\top \in \mathbb{R}^{d+1}. \quad (3.28)$$

Định nghĩa ma trận Hessian kỳ vọng tại giá trị tham số thực α_0 :

$$\mathbf{U} = \mathbb{E} \left(-p_t(\alpha_0)(1 - p_t(\alpha_0)) \tilde{\chi}_t(\mathbf{f}_0) \tilde{\chi}_t(\mathbf{f}_0)^\top w(\mathbf{X}_t) \right), \quad (3.29)$$

và ma trận hiệp phương sai dài hạn (long-run covariance matrix) của score:

$$\mathbf{V} = \lim_{n \rightarrow \infty} \text{Var} \left(\frac{1}{\sqrt{n}} \sum_{t=1}^n (Y_t - p_t(\alpha_0)) \tilde{\chi}_t(\mathbf{f}_0) w(\mathbf{X}_t) \right). \quad (3.30)$$

Định lý 3.10 (Chuẩn Tắc Tiệm Cận). Giả sử các Giả thiết A1–A5 được thỏa mãn và ma trận $\mathbf{U}$ khả nghịch. Khi đó, khi $n \rightarrow \infty$:

$$\sqrt{n}(\hat{\alpha} - \alpha_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{U}^{-1} \mathbf{V} \mathbf{U}^{-1}). \quad (3.31)$$

Nhận xét 3.11 (Giải quyết lỗi hồng toán học và hoàn thiện chứng minh). Trong bài báo gốc của [1], các tác giả chỉ tuyên bố vắn tắt $\ell'_n(\hat{\mathbf{f}}, \alpha_0) - \ell'_n(\mathbf{f}_0, \alpha_0) = O_p(h^2)$ dựa

trên thiên lệch của ước lượng hạt nhân, mà bỏ qua sự dao động ngẫu nhiên (stochastic error) của số hạng $(Y_t - p_t(\hat{\mathbf{f}}))\tilde{\chi}_t(\hat{\mathbf{f}})$.

Trong luận văn này, chúng minh chi tiết tại Phụ lục B đã phân rã tường minh:

$$\begin{aligned} \ell'_n(\hat{\mathbf{f}}, \alpha_0) - \ell'_n(\mathbf{f}_0, \alpha_0) &= \frac{1}{n} \sum_{t=1}^n (Y_t - p_t(\alpha_0))(\tilde{\chi}_t(\hat{\mathbf{f}}) - \tilde{\chi}_t(\mathbf{f}_0))w(\mathbf{X}_t) \\ &\quad - \frac{1}{n} \sum_{t=1}^n (p_t(\hat{\mathbf{f}}, \alpha_0) - p_t(\mathbf{f}_0, \alpha_0))\tilde{\chi}_t(\mathbf{f}_0)w(\mathbf{X}_t) + o_p(n^{-1/2}). \end{aligned} \quad (3.32)$$

Nhờ tính chất martingale-difference của chuỗi phần dư $(Y_t - p_t)$ đối với σ -đại số quá khứ $\mathcal{J}_{t-1}$ và hệ số β -mixing $\beta(t) = O(t^{-b})$, số hạng ngẫu nhiên đạt tốc độ hội tụ $O_p((nh)^{-1/2} \cdot n^{-1/2}) = o_p(n^{-1/2})$. Phần chệch tất định có cấp độ $O(h^2)$, khi nhân với $\sqrt{n}$ sẽ trở thành $\sqrt{n}O(h^2) = O(\sqrt{nh^4}) = o(1)$ nhờ điều kiện undersmoothing $nh^4 \rightarrow 0$ (Giả thiết A3(iii)). Do đó, sai số từ bước phi tham số không làm ảnh hưởng đến phân phối chuẩn tắc của ước lượng tham số $\hat{\alpha}$.

3.8 Suy Diễn Thống Kê và Ước Lượng Ma Trận Hiệp Phương Sai

Định lý 3.10 cung cấp cơ sở chặt chẽ để thực hiện suy diễn thống kê cho các trọng số mô hình α_j .

Trong thực tế, ma trận $\mathbf{U}$ được ước lượng nhất quán bởi:

$$\hat{\mathbf{U}} = -\frac{1}{n} \sum_{t=1}^n \hat{p}_t(\hat{\alpha})(1 - \hat{p}_t(\hat{\alpha}))\tilde{\chi}_t(\hat{\mathbf{f}})\tilde{\chi}_t(\hat{\mathbf{f}})^\top w(\mathbf{X}_t). \quad (3.33)$$

Do dữ liệu chuỗi thời gian có sự tự tương quan, ma trận $\mathbf{V}$ được ước lượng bằng kỹ thuật HAC (Heteroskedasticity and Autocorrelation Consistent) theo dạng Newey–West [54]:

$$\hat{\mathbf{V}} = \hat{\Gamma}_0 + \sum_{k=1}^{M_n} k_B \left(\frac{k}{M_n} \right) (\hat{\Gamma}_k + \hat{\Gamma}_k^\top), \quad (3.34)$$

trong đó $\hat{\Gamma}_k = \frac{1}{n} \sum_{t=k+1}^n \hat{\eta}_t \hat{\eta}_{t-k}^\top$ với $\hat{\eta}_t = (Y_t - \hat{p}_t(\hat{\alpha}))\tilde{\chi}_t(\hat{\mathbf{f}})w(\mathbf{X}_t)$, $k_B(\cdot)$ là hàm nhân Bartlett, và $M_n = O(n^{1/3})$ là bằng thông trở cắt cụt.

Từ ma trận sandwich ước lượng $\widehat{\text{Var}}(\hat{\alpha}) = \frac{1}{n} \hat{\mathbf{U}}^{-1} \hat{\mathbf{V}} \hat{\mathbf{U}}^{-1}$, ta xây dựng:

- **Khoảng tin cậy đối xứng $(1 - \gamma)$ cho α_j :**

$$\hat{\alpha}_j \pm z_{\gamma/2} \cdot \sqrt{\left[\widehat{\text{Var}}(\hat{\alpha})\right]_{jj}}, \quad (3.35)$$

với $z_{\gamma/2}$ là phân vị chuẩn tắc.

- **Kiểm định Wald cho ý nghĩa của biến giải thích thứ j ($H_0 : \alpha_j = 0$):**

$$W_j = \frac{\hat{\alpha}_j}{\sqrt{\left[\widehat{\text{Var}}(\hat{\alpha})\right]_{jj}}} \xrightarrow{d} \mathcal{N}(0, 1) \quad \text{dưới } H_0. \quad (3.36)$$

Điều này cho phép nhà phân tích kiểm định thống kê nghiêm ngặt xem biến trễ nào thực sự có đóng góp dự báo đáng kể vào trạng thái nhị phân của chuỗi thời gian.

CHƯƠNG 4. NGHIÊN CỨU MÔ PHỎNG VÀ ỨNG DỤNG THỰC TẾ

Chương này trình bày toàn diện các kết quả thực nghiệm số nhằm kiểm chứng tính đúng đắn và đánh giá hiệu năng của phương pháp MAMaLoR được đề xuất. Nội dung thực nghiệm gồm hai phần chính: (i) Nghiên cứu mô phỏng Monte Carlo trên các mô hình chuỗi thời gian phi tuyến với nhiều cấu trúc tương tác và bậc trễ khác nhau; (ii) Ứng dụng thực tế vào bài toán dự báo hướng biến động giá của chỉ số chứng khoán FTSE 100 tại Vương quốc Anh.

4.1 Nghiên Cứu Mô Phỏng Monte Carlo

4.1.1 Thiết kế Mô hình Sinh Dữ liệu

Nhằm đánh giá năng lực của MAMaLoR trong việc phân loại chuỗi thời gian nhị phân dưới các cấu trúc phụ thuộc khác nhau, ta sử dụng mô hình sinh dữ liệu tổng quát (theo [1] và [2]):

$$Y_t = \mathbb{I}(x_t > 0), \quad x_t = \sum_{k=1}^K g_{0k}(x_{t-k}) + \varepsilon_t, \quad (4.1)$$

trong đó chuỗi sai số ε_t là các biến ngẫu nhiên độc lập cùng phân phối (i.i.d.) tuân theo phân phối logistic chuẩn tắc, được sinh từ công thức $\varepsilon_t = \log(e_t/(1 - e_t))$ với $e_t \sim \text{Uniform}(0, 1)$. Hàm liên kết thành phần $g_{0k}(\cdot)$ có dạng:

$$g_{0k}(x) = a_k x + \delta \cdot \frac{\exp(-kx)}{1 + \exp(-kx)} + \gamma \cos(x \cdot x_{t-1}), \quad k = 1, \dots, K. \quad (4.2)$$

Vector hệ số tuyến tính cơ sở $a = (a_1, \dots, a_9)^\top$ của mô hình AR(9) được thiết lập theo Bảng 4.1, bảo đảm tất cả các nghiệm của đa thức đặc trưng $1 - \sum_{k=1}^9 a_k z^k = 0$ đều nằm ngoài đường tròn đơn vị trên mặt phẳng phức. Khi đó, chuỗi x_t thỏa mãn tính dừng nghiêm ngặt và là quá trình β -mixing với tốc độ suy giảm hình học ([10]).

Bảng 4.1: Các hệ số tuyến tính thành phần trong mô hình mô phỏng ($K = 9$)

a_1	a_2	a_3	a_4	a_5	a_6	a_7	a_8	a_9
-0.1129	0.0245	-0.1892	-0.0820	-0.1962	-0.1232	0.1180	0.1282	-0.2407

Vai trò của hai tham số δ và γ quyết định bản chất cấu trúc của chuỗi thời gian x_t :

- **Kịch bản 1: Tuyến tính thuần túy** ($\delta = 0, \gamma = 0$): Quá trình x_t là mô hình AR(9) tuyến tính chuẩn.
- **Kịch bản 2: Cộng tính phi tuyến** ($\delta = 0.5, \gamma = 0$): Quá trình x_t có cấu trúc cộng phi tuyến dạng GAM, không chứa số hạng tương tác giữa các độ trễ.
- **Kịch bản 3: Tương tác thuần túy** ($\delta = 0, \gamma = 0.5$): Tồn tại số hạng tương tác phi cộng tính giữa biến trễ x_{t-k} và x_{t-1} thông qua hàm $\cos(x_{t-k}x_{t-1})$.
- **Kịch bản 4: Phi tuyến phi cộng tính tổng quát** ($\delta = 0.5, \gamma = 0.5$): Mô hình kết hợp đồng thời cả hiệu ứng phi tuyến biên và hiệu ứng tương tác chéo giữa các độ trễ.

4.1.2 Phân phối Có Điều Kiện của Y_t

Từ mô hình sinh dữ liệu (4.1), xác suất có điều kiện thực sự của biến phản hồi $Y_t = 1$ khi biết toàn bộ quá khứ $\mathbf{X}_t = (x_{t-1}, \dots, x_{t-K})^\top$ là:

$$\begin{aligned}
 p_t &= \mathbb{P}(Y_t = 1 \mid \mathbf{X}_t) = \mathbb{P}\left(\sum_{k=1}^K g_{0k}(x_{t-k}) + \varepsilon_t > 0 \mid \mathbf{X}_t\right) \\
 &= \mathbb{P}\left(\varepsilon_t > -\sum_{k=1}^K g_{0k}(x_{t-k})\right) = 1 - F\left(-\sum_{k=1}^K g_{0k}(x_{t-k})\right) \\
 &= F\left(\sum_{k=1}^K g_{0k}(x_{t-k})\right) = \frac{\exp\left(\sum_{k=1}^K g_{0k}(x_{t-k})\right)}{1 + \exp\left(\sum_{k=1}^K g_{0k}(x_{t-k})\right)}. \tag{4.3}
 \end{aligned}$$

Đẳng thức này suy ra trực tiếp từ tính chất đối xứng của hàm phân phối logistic ($1 - F(-u) = F(u)$). Điều này cho thấy $\text{logit}(p_t) = \sum_{k=1}^K g_{0k}(x_{t-k})$, bảo đảm rằng mô hình logistic có điều kiện là hoàn toàn chuẩn xác.

4.1.3 Các Phương Pháp Đối Sánh và Tiêu Chí Đánh Giá

Thực nghiệm so sánh năng lực dự báo phân loại của 6 mô hình cạnh tranh:

1. **MAMaLoR (Đề xuất):** Mô hình trung bình hóa hồi quy logistic biên phi tuyến theo quy trình hai bước.
2. **LLoR (Linear Logistic Regression – GLM):** Mô hình hồi quy logistic tuyến tính chuẩn tắc.
3. **AddLoR (Additive Logistic Regression – GAM):** Mô hình cộng tính tổng quát ước lượng đồng thời các thành phần phi tuyến bằng spline/backfitting.
4. **MAMAR:** Mô hình trung bình hồi quy biên cho biến liên tục ([2]), sau đó phân loại bằng quy tắc ngưỡng $\mathbb{I}(\hat{m}_t^{\text{MA}} > 0)$.
5. **AR:** Mô hình tự hồi quy tuyến tính cổ điển kết hợp phân loại theo ngưỡng.
6. **AddR:** Mô hình cộng tính phi tuyến cho biến liên tục kết hợp phân loại theo ngưỡng.

Tiêu chí đánh giá chất lượng phân loại là diện tích dưới đường cong ROC (**AUC – Area Under the Receiver Operating Characteristic Curve**) trên mẫu kiểm tra ngoài mẫu (out-of-sample) gồm $n_p = 50$ quan sát, thực hiện lặp lại 500 lần Monte Carlo độc lập trên các kích thước mẫu huấn luyện $n \in \{200, 500, 1000\}$.

4.1.4 Kết Quả Mô Phỏng và Thảo Luận

Bảng 4.2 tổng hợp kết quả AUC trung bình của các mô hình trên 500 lần lặp với $K = 9$ độ trễ.

Bảng 4.2: AUC trung bình ngoài mẫu trong mô phỏng Monte Carlo ($n = 1000, n_p = 50, K = 9$)

Phương pháp	$(\delta = 0, \gamma = 0)$ <i>Tuyến tính</i>	$(\delta = 0.5, \gamma = 0)$ <i>Cộng phi tuyến</i>	$(\delta = 0, \gamma = 0.5)$ <i>Tương tác</i>	$(\delta = 0.5, \gamma = 0.5)$ <i>Phi tuyến tương tác</i>
MAMaLoR	0.638	0.641	0.660	0.658
LLoR (GLM)	0.651	0.637	0.624	0.621
AddLoR (GAM)	0.642	0.645	0.643	0.638
MAMAR	0.637	0.639	0.642	0.640
AR	0.641	0.635	0.622	0.619
AddR	0.639	0.640	0.638	0.634

Từ kết quả thực nghiệm mô phỏng, ta rút ra các nhận định then chốt:

1. **Khi cấu trúc thực tế là tuyến tính ($\delta = 0, \gamma = 0$):** Mô hình hồi quy logistic tuyến tính (LLoR) đạt AUC cao nhất (0.651) do mô hình giả định trùng khớp hoàn toàn với bản chất dữ liệu. Tuy nhiên, MAMaLoR vẫn duy trì hiệu năng rất sát sao (0.638), chỉ mất một lượng nhỏ hiệu quả do không áp đặt tiên nghiệm tính tuyến tính.
2. **Khi cấu trúc là cộng tính phi tuyến ($\delta = 0.5, \gamma = 0$):** Cả GAM (AddLoR) và MAMaLoR đều vượt trội so với GLM. Với cỡ mẫu $n = 1000$, MAMaLoR (0.641) tiệm cận rất gần với AddLoR (0.645).
3. **Khi xuất hiện hiệu ứng tương tác phi tuyến ($\gamma = 0.5$):** MAMaLoR hoàn toàn chiếm ưu thế tuyệt đối, đạt AUC cao nhất trong cả hai trường hợp có tương tác (0.660 và 0.658). Trong khi đó, cả LLoR và GAM đều suy giảm rõ rệt vì GAM bị ràng buộc cấu trúc cộng tính $g(x) = \sum g_j(x_j)$ nên hoàn toàn bất lực trước các tương tác chéo. Ngược lại, hàm hồi quy biên $f_j(x_{jt})$ của MAMaLoR ước lượng phi tham số ảnh hưởng biên tổng thể của x_{jt} lên Y_t (bao gồm cả ảnh hưởng gián tiếp qua phân phối lẻ tích phân), giúp mô hình nắm bắt được một phần đáng kể thông tin tương tác.
4. **Mở rộng số chiều cao ($K = 31$ độ trễ):** Khi tăng số biến giải thích lên $K = 31$, mô hình GAM (AddLoR) thất bại do chi phí tính toán bùng nổ và thuật toán backfitting không hội tụ. Ngược lại, MAMaLoR vẫn tính toán cực kỳ nhanh nhờ

phân rã thành d bài toán một chiều độc lập (độ phức tạp chỉ $O(nd^2)$ thay vì hàm mũ), đồng thời duy trì AUC cao nhất trong mọi kịch bản.

4.2 Ứng Dụng Thực Tế: Dự Báo Hướng Biến Động Chỉ Số FTSE 100

4.2.1 Mô tả Dữ liệu và Xây dựng Biến Đặc trưng

Để kiểm định giá trị thực tiễn, mô hình MAMaLoR được áp dụng vào bài toán dự báo hướng chuyển động giá của chỉ số chứng khoán FTSE 100 giao dịch tại London. Tập dữ liệu gồm 1263 ngày giao dịch liên tục từ ngày 01/05/2013 đến ngày 01/05/2018.

Từ các chuỗi dữ liệu gốc gồm giá mở cửa, cao nhất ($\max p_t$), thấp nhất ($\min p_t$), đóng cửa (cp_t) và khối lượng giao dịch (Vlm_t), ta xây dựng 3 chuỗi đặc trưng tài chính chuẩn:

$$v_t = \log_{100} \left(\frac{\max p_t - \min p_t}{\frac{1}{2}(\max p_t + \min p_t)} \right) \quad (\text{Biến động biên độ giá Parkinson}), \quad (4.4)$$

$$V_t = \log(Vlm_t) \quad (\text{Logarithm khối lượng giao dịch}), \quad (4.5)$$

$$G_t = 100 \log \left(\frac{cp_t}{cp_{t-1}} \right) \quad (\text{Lợi suất phần trăm hình học}). \quad (4.6)$$

Biến mục tiêu phân loại nhị phân Y_t được xác định theo chiều biến động giá:

$$Y_t = \begin{cases} 1 & \text{nếu } cp_t > cp_{t-1} \text{ (thị trường tăng giá),} \\ 0 & \text{nếu } cp_t \leq cp_{t-1} \text{ (thị trường giảm hoặc đi ngang).} \end{cases} \quad (4.7)$$

Lưu ý rằng $Y_t = \mathbb{I}(G_t > 0)$, hoàn toàn tương thích với mô hình nhị phân lý thuyết.

4.2.2 Thiết kế Thực nghiệm

Dữ liệu được phân chia theo trình tự thời gian:

- **Tập huấn luyện (In-sample):** 800 ngày quan sát đầu tiên (từ $t = 1$ đến 800).
- **Tập kiểm tra ngoài mẫu (Out-of-sample):** 200 ngày quan sát tiếp theo (từ $t = 801$ đến 1000).

- **Không gian biến dự báo ban đầu:** Sử dụng 4 độ trễ của cả 3 đặc trưng: $\mathbf{X}_t = (v_{t-j}, V_{t-j}, G_{t-j})_{j=1}^4$, tổng cộng $d = 3 \times 4 = 12$ biến giải thích.

4.2.3 So sánh Hiệu quả Khớp Mô hình (Tiêu chí AIC)

Ba mô hình hồi quy logistic được huấn luyện trên cùng tập dữ liệu gồm: MAMaLoR, GLM (LLoR tuyến tính), và GAM (AddLoR). Bảng 4.3 so sánh tiêu chí thông tin Akaike (AIC) [55] của ba mô hình tại cấu hình 4 bậc trễ ($d = 12$).

Bảng 4.3: So sánh tiêu chí AIC của các mô hình trên tập huấn luyện FTSE 100

Mô hình	AIC
MAMaLoR	1062.1
GAM (AddLoR)	1095.6
GLM (LLoR tuyến tính)	1118.4

Mô hình MAMaLoR đạt AIC thấp nhất (1062.1), vượt trội rõ rệt so với GLM (1118.4) và GAM (1095.6). Điều này khẳng định rằng cấu trúc tổ hợp logistic biên phi tham số đạt được sự cân bằng tối ưu giữa mức độ khớp dữ liệu và kiểm soát độ phức tạp của mô hình.

4.2.4 Phân tích Ý nghĩa Thống kê của các Biến Dự Báo

Kiểm định Wald dựa trên ma trận hiệp phương sai tiệm cận sandwich $\hat{\mathbf{U}}^{-1} \hat{\mathbf{V}} \hat{\mathbf{U}}^{-1}$ (thiết lập tại Chương 3) cho thấy:

- **Trong mô hình MAMaLoR:** Chỉ có các biến lợi suất trễ $G_{t-1}, G_{t-2}, G_{t-3}, G_{t-4}$ có ý nghĩa thống kê cao ($p\text{-value} < 0.01$). Tất cả các biến biến động giá (v_{t-j}) và khối lượng (V_{t-j}) đều không có ý nghĩa thống kê ở mức 5%.
- **Trong mô hình GLM:** Không có bất kỳ biến nào đạt ý nghĩa thống kê ở mức 5% do thiên lệch mô hình tuyến tính đã làm loãng tín hiệu thông tin.
- **Trong mô hình GAM:** Chỉ có 2 biến lợi suất có ý nghĩa biên, do ước lượng đồng thời làm tăng phương sai của các hàm ước lượng.

4.2.5 Mở rộng Bậc Trễ và Đánh giá Khả năng Dự Báo Ngoài Mẫu (AUC)

Dựa trên kết quả thực nghiệm rằng chuỗi lợi suất G_t mang thông tin dự báo chủ đạo, nghiên cứu tiến hành mở rộng số bậc trễ của G_t lên đến 31 ngày (tương đương khoảng 6 tuần giao dịch).

Khi tăng bậc trễ từ 1 đến 31, giá trị AIC của MAMaLoR liên tục giảm mạnh và đạt trạng thái ổn định tối ưu tại khoảng lag 21 đến 31. Sau khi loại bỏ các bậc trễ không có ý nghĩa thống kê thông qua kiểm định Wald, mô hình MAMaLoR tinh giản cuối cùng giữ lại 13 bậc trễ lợi suất quan trọng:

$$\{G_{t-1}, G_{t-3}, G_{t-8}, G_{t-11}, G_{t-13}, G_{t-14}, G_{t-15}, G_{t-16}, G_{t-17}, G_{t-18}, G_{t-21}, G_{t-28}, G_{t-31}\},$$

đạt mức AIC tối ưu là **968.74**.

Bảng 4.4 trình bày năng lực phân loại ngoài mẫu (out-of-sample) trên 200 ngày kiểm tra độc lập.

Bảng 4.4: So sánh AUC ngoài mẫu trên tập kiểm tra chỉ số FTSE 100 (200 quan sát)

Mô hình	AUC Ngoài mẫu
MAMaLoR (Bảng thông tối ưu)	0.6041
GLM (Logistic tuyến tính)	0.5600
Dự đoán ngẫu nhiên (Random Walk)	0.5000

Trong bối cảnh tài chính thị trường, theo Giả thuyết Thị trường Hiệu quả (EMH) [57], chiều chuyển động của giá cổ phiếu ở tần suất ngày gần như tiệm cận bước đi ngẫu nhiên ($AUC \approx 0.5$) [58, 56]. Việc mô hình MAMaLoR đạt mức $AUC = 0.6041$ trên tập dữ liệu kiểm tra ngoài mẫu – cao hơn vượt bậc so với GLM (0.5600) – là một kết quả thực nghiệm có ý nghĩa kinh tế sâu sắc. Kết quả này chứng minh rằng MAMaLoR có khả năng bóc tách được tín hiệu phi tuyến yếu ẩn chứa trong các độ trễ xa của thị trường mà các mô hình tham số tuyến tính hoàn toàn bỏ sót.

CHƯƠNG 5. KẾT LUẬN VÀ KIẾN NGHỊ

5.1 Kết Luận

Luận văn đã nghiên cứu một cách toàn diện và có hệ thống mô hình hồi quy logistic biên phi tuyến bán tham số kết hợp trung bình hóa mô hình (MAMaLoR – *Model Averaging nonlinear MArginal LOGistic Regressions*) cho bài toán phân loại chuỗi thời gian nhị phân. Các đóng góp và kết quả chính đạt được bao gồm:

1. **Hệ thống hóa và hoàn thiện khung lý thuyết:** Luận văn đã thiết lập nền tảng toán học vững chắc cho mô hình MAMaLoR. Bằng cách kết hợp linh hoạt giữa phương pháp ước lượng phi tham số hạt nhân một chiều (local linear likelihood) ở Bước 1 và kỹ thuật tổ hợp affine trong thang đo logit thông qua cực tiểu hóa khoảng cách Kullback–Leibler ở Bước 2, phương pháp giải quyết triệt để bài toán “lời nguyền số chiều” vốn là điểm nghẽn nghiêm trọng của các mô hình phi tham số đa biến.
2. **Đính chính và hoàn thiện các tính chất tiệm cận:** Dưới cấu trúc chuỗi thời gian phụ thuộc yếu β -mixing, luận văn đã:
 - Đính chính lỗi in ấn ngược chiều bất đẳng thức trong Bổ đề Nhất quán (Proposition 3.1) của tài liệu gốc, bảo đảm tính nhất quán toán học theo chuẩn tắc lý thuyết M-estimation.
 - Hoàn thiện phân tích giải tích cho Định lý Chuẩn tắc Tiệm cận (Theorem 3.2), chứng minh tường minh rằng sai số ước lượng ngẫu nhiên phi tham số từ Bước 1 triệt tiêu tiệm cận ở tốc độ $o_p(n^{-1/2})$ nhờ điều kiện undersmoothing $nh^4 \rightarrow 0$ và tính chất martingale-difference của chuỗi đổi mới. Vector trọng số $\hat{\alpha}$ đạt tốc độ hội tụ tham số chuẩn $\sqrt{n}$ với phân phối giới hạn Gauss nhiều chiều.
 - Thiết lập công thức ước lượng ma trận hiệp phương sai dài hạn HAC Newey–West phục vụ suy diễn thống kê thực nghiệm.
3. **Bằng chứng thực nghiệm vững chắc:**

- Thông qua mô phỏng Monte Carlo trên mô hình AR(9) phi tuyến, MAMaLoR khẳng định sự vượt trội áp đảo về AUC trong các tình huống có tương tác chéo giữa các độ trễ, đồng thời duy trì tính cạnh tranh cao trong kịch bản tuyến tính thuần túy.
- Ứng dụng thực tế trên dữ liệu chuỗi thời gian chỉ số FTSE 100 cho thấy MAMaLoR đạt mức AIC tối ưu (968.74) và AUC ngoài mẫu đạt **0.6041**, vượt trội rõ rệt so với mô hình hồi quy logistic tuyến tính GLM (0.5600).

5.2 Đánh Giá Ưu Điểm và Hạn Chế của Phương Pháp

5.2.1 Ưu điểm nổi bật

- **Miễn nhiễm với lời nguyên số chiều:** Chi phí tính toán ở Bước 1 chỉ tăng tuyến tính theo số chiều d (giải d bài toán độc lập một chiều), tổng chi phí toàn quy trình chỉ ở cấp độ đa thức $O(nd^2)$, cho phép xử lý hiệu quả không gian có số bậc trễ rất lớn ($d = 31$).
- **Nắm bắt tương tác thông qua hiệu ứng biên:** Dù chỉ ước lượng các hàm một chiều, MAMaLoR vẫn tích hợp được thông tin tương tác chéo thông qua phân phối biên có điều kiện.
- **Tính ổn định số học:** Hàm mục tiêu ở cả hai bước đều là lõm ngặt, bảo đảm thuật toán tối ưu hóa luôn hội tụ đến nghiệm duy nhất.

5.2.2 Hạn chế còn tồn tại

- Phương pháp hiện sử dụng bảng thông h cố định cho các hàm biên, chưa tích hợp thuật toán lựa chọn bảng thông tự động tối ưu hóa trực tiếp hàm mục tiêu phân loại AUC.
- Cấu trúc tổ hợp affine tuyến tính giữa các hàm logit biên có thể bỏ sót một phần các tương tác bậc cao phi tuyến phức tạp giữa các cặp biến dự báo.

5.3 Hướng Nghiên Cứu và Phát Triển trong Tương Lai

Từ các kết quả đạt được, luận văn đề xuất các hướng nghiên cứu mở rộng sau:

1. **Tối ưu hóa băng thông tự động:** Xây dựng quy trình chọn băng thông tự động thích nghi dựa trên kỹ thuật Cross-Validation có trọng số hoặc Plug-in dành riêng cho chuỗi thời gian phụ thuộc β -mixing.
2. **Mở rộng sang Hồi quy biên hai chiều (Bivariate MAMaLoR):** Nghiên cứu phiên bản mở rộng kết hợp các hàm biên hai chiều $f_{jk}(x_{jt}, x_{kt})$ để bắt trọn vẹn các hiệu ứng tương tác trực tiếp giữa từng cặp độ trễ.
3. **Chọn lọc biến trong không gian siêu cao chiều:** Kết hợp mô hình MAMaLoR với các kỹ thuật phạt thu hẹp phi lồi (SCAD, MCP, Adaptive LASSO) để tự động chọn lọc các biến trễ tối ưu khi số chiều $d \gg n$.
4. **Mở rộng sang phân loại đa nhãn (Multinomial MAMaLoR):** Mở rộng mô hình từ nhị phân sang biến phản hồi đa trạng thái $Y_t \in \{1, 2, \dots, C\}$ thông qua hàm liên kết softmax / multinomial logit.

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] Rong Peng, Zudi Lu: Semiparametric averaging of nonlinear marginal logistic regressions and forecasting for time series classification. *Econometrics and Statistics*, 31:19–37, 2024. doi:[10.1016/j.ecosta.2021.11.001](https://doi.org/10.1016/j.ecosta.2021.11.001).
- [2] Degui Li, Oliver Linton, Zudi Lu: A flexible semiparametric forecasting model for time series. *Journal of Econometrics*, 187(1):345–357, 2015. doi:[10.1016/j.jeconom.2015.02.040](https://doi.org/10.1016/j.jeconom.2015.02.040).
- [3] Jia Chen, Degui Li, Oliver Linton, Zudi Lu: Semiparametric ultra-high dimensional model averaging of nonlinear dynamic time series. *Journal of the American Statistical Association*, 113(522):919–932, 2018. doi:[10.1080/01621459.2017.1295864](https://doi.org/10.1080/01621459.2017.1295864).
- [4] Jianqing Fan, Mark Farnen, Irène Gijbels: Local maximum likelihood estimation and inference. *Journal of the Royal Statistical Society: Series B*, 60(3):591–608, 1998. doi:[10.1111/1467-9868.00141](https://doi.org/10.1111/1467-9868.00141).
- [5] Robert Tibshirani, Trevor Hastie: Local likelihood estimation. *Journal of the American Statistical Association*, 82(398):559–567, 1987. doi:[10.1080/01621459.1987.10478466](https://doi.org/10.1080/01621459.1987.10478466).
- [6] Trevor Hastie, Robert Tibshirani: Generalized additive models: some applications. *Journal of the American Statistical Association*, 82(398):371–386, 1987. doi:[10.1080/01621459.1987.10478440](https://doi.org/10.1080/01621459.1987.10478440).
- [7] Bruce E. Hansen: Least squares model averaging. *Econometrica*, 75(4):1175–1189, 2007. doi:[10.1111/j.1468-0262.2007.00785.x](https://doi.org/10.1111/j.1468-0262.2007.00785.x).
- [8] Bruce E. Hansen: Least-squares forecast averaging. *Journal of Econometrics*, 146(2):342–350, 2008. doi:[10.1016/j.jeconom.2008.08.022](https://doi.org/10.1016/j.jeconom.2008.08.022).
- [9] Paul Doukhan, Pascal Massart, Emmanuel Rio: Invariance principles for absolutely regular empirical processes. *Annales de l'Institut Henri Poincaré (B) Probabilités et Statistiques*, 31(2):393–427, 1995.

- [10] Zudi Lu: On the geometric ergodicity of a non-linear autoregressive model with an autoregressive conditional heteroscedastic term. *Statistica Sinica*, 8(4):1205–1217, 1998.
- [11] Zudi Lu, Dag Tjøstheim, Qiwei Yao: Adaptive varying-coefficient linear models for stochastic processes: asymptotic theory. *Statistica Sinica*, 17(1):177–198, 2007.
- [12] Cristiano Varin, Nancy Reid, David Firth: An overview of composite likelihood methods. *Statistica Sinica*, 21(1):5–42, 2011.
- [13] Aad W. van der Vaart, Jon A. Wellner: *Weak Convergence and Empirical Processes: With Applications to Statistics*. Springer Series in Statistics, Springer, New York, 1996.
- [14] Jianqing Fan, Qiwei Yao: *Nonlinear Time Series: Nonparametric and Parametric Methods*. Springer Series in Statistics, Springer-Verlag, New York, 2003.
- [15] Michael Parkinson: The extreme value method for estimating the variance of the rate of return. *Journal of Business*, 53(1):61–65, 1980.
- [16] Mark B. Garman, Michael J. Klass: On the estimation of security price volatilities from historical data. *Journal of Business*, 53(1):67–78, 1980.
- [17] L. C. G. Rogers, Stephen E. Satchell: Estimating variance from high, low and closing prices. *Annals of Applied Probability*, 1(4):504–512, 1991.
- [18] L. C. G. Rogers, Stephen E. Satchell, Yoon Yoon: Estimating the volatility of stock prices: a comparison of methods. *Journal of Banking and Finance*, 18(2):231–252, 1994.
- [19] Wai-Sum Chan, Donald Lien: On the efficiency of high-low range estimators. *Journal of Futures Markets*, 23(9):831–852, 2003.
- [20] Sassan Alizadeh, Michael W. Brandt, Francis X. Diebold: Range-based estimation of stochastic volatility models. *Journal of Finance*, 57(3):1047–1091, 2002.
- [21] A. Ronald Gallant, Chien-Te Hsu, George Tauchen: Using daily range data to calibrate volatility diffusions. *Review of Economics and Statistics*, 81(4):617–631, 1999.

- [22] Mehryar Mohri, Afshin Rostamizadeh: Stability bounds for stationary ϕ -mixing and β -mixing processes. *Journal of Machine Learning Research*, 11:789–814, 2010.
- [23] Rob J. Hyndman, George Athanasopoulos: *Forecasting: Principles and Practice*. 3rd Edition, OTexts, Melbourne, Australia, 2018.
- [24] Rob J. Hyndman: *Nonparametric additive regression models for binary time series*. Technical Report, Monash University, 1999.
- [25] Robert H. Shumway, David S. Stoffer: *Time Series Analysis and Its Applications: With R Examples*. 4th Edition, Springer, 2017.
- [26] Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani: *An Introduction to Statistical Learning with Applications in R*. Springer Texts in Statistics, Springer, 2013.
- [27] Simon N. Wood: *Generalized Additive Models: An Introduction with R*. 2nd Edition, Chapman & Hall/CRC, 2017.
- [28] Trevor J. Hastie, Robert J. Tibshirani: *Generalized Additive Models*. Chapman & Hall/CRC, London, 1990.
- [29] Jianqing Fan, Irène Gijbels: *Local Polynomial Modelling and Its Applications*. Chapman & Hall, London, 1996.
- [30] M. P. Wand, M. C. Jones: *Kernel Smoothing*. Chapman & Hall, London, 1995.
- [31] David Ruppert, M. P. Wand, R. J. Carroll: *Semiparametric Regression*. Cambridge University Press, 2003.
- [32] Kung-Yee Liang, Scott L. Zeger: Longitudinal data analysis using generalized linear models. *Biometrika*, 73(1):13–22, 1986.
- [33] Peter J. Diggle, Patrick Heagerty, Kung-Yee Liang, Scott L. Zeger: *Analysis of Longitudinal Data*. 2nd Edition, Oxford University Press, 2002.
- [34] Gerda Claeskens, Nils Lid Hjort: *Model Selection and Model Averaging*. Cambridge University Press, 2008.

- [35] Leo Breiman: Stacked regressions. *Machine Learning*, 24(1):49–64, 1996.
- [36] David H. Wolpert: Stacked generalization. *Neural Networks*, 5(2):241–259, 1992.
- [37] Jennifer A. Hoeting, David Madigan, Adrian E. Raftery, Chris T. Volinsky: Bayesian model averaging: a tutorial. *Statistical Science*, 14(4):382–401, 1999.
- [38] Yuling Yao, Aki Vehtari, Daniel Simpson, Andrew Gelman: Using stacking to average Bayesian predictive distributions. *Bayesian Analysis*, 13(3):917–1007, 2018.
- [39] Hassan Ismail Fawaz, Germain Forestier, Jonathan Weber, Lhassane Idoumghar, Pierre-Alain Muller: Deep learning for time series classification: a review. *Data Mining and Knowledge Discovery*, 33(4):917–963, 2019.
- [40] Amaia Abanda, Usue Mori, Jose A. Lozano: A review on distance-based time series classification. *Data Mining and Knowledge Discovery*, 33(2):378–412, 2019.
- [41] Wanpracha Art Chaovalitwongse, Oleg A. Prokopyev, Panos M. Pardalos: Electroencephalogram (EEG) time series classification: applications in epilepsy. *Annals of Operations Research*, 148(1):227–250, 2006.
- [42] Sholom M. Weiss, Casimir A. Kulikowski: *Computer Systems That Learn: Classification and Prediction Methods from Statistics, Neural Nets, Machine Learning, and Expert Systems*. Morgan Kaufmann, 1991.
- [43] Jeff Dean, David Patterson, Cliff Young: A new golden age in computer architecture: empowering the machine-learning revolution. *IEEE Micro*, 38(2):21–29, 2018.
- [44] D. Patel, S. Shrivastava, W. Gifford, S. Siegel, J. Kalagnanam, C. Reddy: Smart-ML: a system for machine learning model exploration using pipeline graph. In *IEEE BigData*, 2020.
- [45] Gian Antonio Susto, Angelo Cenedese, Matteo Terzi: Time-series classification methods: review and applications to power systems data. In *Big Data Application in Power Systems*, pp. 179–220, Elsevier, 2018.

- [46] L. Vu et al.: A large-scale system for real-time glucose monitoring. In *48th Annual IEEE/IFIP DSN-W*, pp. 34–37, 2018.
- [47] Yi Zheng et al.: Time series classification using multi-channels deep convolutional neural networks. In *WAIM*, Springer, 2014.
- [48] Zhiguang Wang, Weizhong Yan, Tim Oates: Time series classification from scratch with deep neural networks: a strong baseline. In *IJCNN*, IEEE, 2017.
- [49] Hayrettin Okut: Deep learning for subtyping and prediction of diseases: Long-short term memory. In *Deep Learning Applications*, IntechOpen, 2020.
- [50] Solomon Kullback: *Information Theory and Statistics*. John Wiley & Sons, New York, 1959.
- [51] David A. Dickey, Wayne A. Fuller: Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366):427–431, 1979.
- [52] Said E. Said, David A. Dickey: Testing for unit roots in autoregressive-moving average models of unknown order. *Biometrika*, 71(3):599–607, 1984.
- [53] Denis Kwiatkowski, Peter C. B. Phillips, Peter Schmidt, Yongcheol Shin: Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54(1-3):159–178, 1992.
- [54] Whitney K. Newey, Kenneth D. West: A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3):703–708, 1987.
- [55] Hirotugu Akaike: A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6):716–723, 1974.
- [56] Tom Fawcett: An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.
- [57] Eugene F. Fama: Efficient capital markets: a review of theory and empirical work. *Journal of Finance*, 25(2):383–417, 1970.

- [58] Ruey S. Tsay: *Analysis of Financial Time Series*. 2nd Edition, John Wiley & Sons, Hoboken, New Jersey, 2005.
- [59] Elizbar A. Nadaraya: On estimating regression. *Theory of Probability and Its Applications*, 9(1):141–142, 1964.
- [60] Geoffrey S. Watson: Smooth regression analysis. *Sankhyā: The Indian Journal of Statistics, Series A*, 26(4):359–372, 1964.
- [61] Jianqing Fan, Nancy E. Heckman, M. P. Wand: Local polynomial kernel regression for generalized linear models and quasi-likelihood systems. *Journal of the American Statistical Association*, 90(429):141–150, 1995.
- [62] Charles J. Stone: Optimal characteristics of the local polynomial estimation in non-parametric regression. *The Annals of Statistics*, 8(6):1348–1360, 1980.
- [63] Jianqing Fan, Jinchi Lv: Sure independence screening for ultrahigh dimensional feature space. *Journal of the Royal Statistical Society: Series B*, 70(5):849–911, 2008.

PHỤ LỤC. CHỨNG MINH CHI TIẾT CÁC ĐỊNH LÝ VÀ BỔ ĐỀ TIỆM CẬN

Phụ lục này trình bày chi tiết các bước chứng minh giải tích toán học nghiêm ngặt cho Bổ đề Nhất quán (Mệnh đề 3.7), Định lý Tính Nhất quán (Định lý 3.9) và Định lý Chuẩn tắc Tiệm cận (Định lý 3.10) của mô hình MAMaLoR được phát biểu tại Chương 3.

A Chứng Minh Bổ Đề Nhất Quán (Mệnh đề 3.7) và Định Lý 3.9

Bổ đề Nhất quán được chứng minh bằng cách kiểm tra 5 điều kiện (i)–(v) trong Mệnh đề 3.7.

Kiểm tra Điều kiện (i) và (ii)

Vì $\hat{\alpha} = \arg \max_{\alpha \in \Pi} \ell_n(\hat{\mathbf{f}}(\cdot), \alpha)$, theo định nghĩa cực đại ta luôn có:

$$\ell_n(\hat{\mathbf{f}}(\cdot), \hat{\alpha}) \geq \sup_{\alpha \in \Pi} \ell_n(\hat{\mathbf{f}}(\cdot), \alpha),$$

do đó điều kiện (i) thỏa mãn hiển nhiên với đại lượng dư $o_p(1) = 0$.

Điều kiện (ii) là điều kiện nhận dạng nghiệm tối ưu duy nhất α_0 . Do hàm mục tiêu quần thể $\ell(\mathbf{f}_0(\cdot), \alpha)$ là hàm lõm ngặt theo α và α_0 là điểm trong duy nhất đạt cực đại trên tập compact Π , tính chất compact và liên tục bảo đảm rằng với mọi $\delta > 0$, giá trị hàm mục tiêu bên ngoài lân cận $\|\alpha - \alpha_0\| > \delta$ luôn cách biệt nghiêm ngặt một khoảng $\varepsilon(\delta) > 0$.

Kiểm tra Điều kiện (iii): Tính liên tục đồng đều

Xét hai vector hàm biên $\mathbf{f}, \mathbf{f}_0 \in \mathcal{F}$. Nhắc lại:

$$\ell(\mathbf{f}(\cdot), \alpha) = \mathbb{E} \left(Y_t \tilde{\chi}_t(\mathbf{f})^\top \alpha - \log(1 + \exp(\tilde{\chi}_t(\mathbf{f})^\top \alpha)) \right) w(\mathbf{X}_t). \quad (5.1)$$

Sử dụng bất đẳng thức giá trị trung bình cho hàm $u \mapsto \log(1 + e^u)$ với đạo hàm là hàm logistic $F(u) \in (0, 1)$, ta có:

$$\begin{aligned} \sup_{\alpha \in \Pi} |\ell(\mathbf{f}(\cdot), \alpha) - \ell(\mathbf{f}_0(\cdot), \alpha)| &\leq \sup_{\alpha \in \Pi} \mathbb{E}(|Y_t| \|\tilde{\chi}_t(\mathbf{f}) - \tilde{\chi}_t(\mathbf{f}_0)\| \|\alpha\| + \|\tilde{\chi}_t(\mathbf{f}) - \tilde{\chi}_t(\mathbf{f}_0)\| \|\alpha\|) \\ &\leq 2 \sup_{\alpha \in \Pi} \|\alpha\| \cdot \mathbb{E} \|\tilde{\chi}_t(\mathbf{f}) - \tilde{\chi}_t(\mathbf{f}_0)\| \\ &\leq C \|\mathbf{f} - \mathbf{f}_0\|_{\mathcal{F}}, \end{aligned} \quad (5.2)$$

trong đó hằng số $C < \infty$ do Π là tập compact. Khi $\|\mathbf{f} - \mathbf{f}_0\|_{\mathcal{F}} \rightarrow 0$, sai số tiến về 0 đồng đều theo α .

Kiểm tra Điều kiện (iv): Nhất quán đồng đều của $\hat{\mathbf{f}}$

Xét phương trình ước lượng cực đại hợp lý cục bộ tuyến tính (3.13). Định nghĩa vector phương trình chấm điểm:

$$\Omega_n^{(1)}(\beta, x_j, h) = \frac{1}{n} \sum_{t=1}^n [Y_t - F(\beta_1 + \beta_2(x_{jt} - x_j))] K_h(x_{jt} - x_j), \quad (5.3)$$

$$\Omega_n^{(2)}(\beta, x_j, h) = \frac{1}{n} \sum_{t=1}^n [Y_t - F(\beta_1 + \beta_2(x_{jt} - x_j))] \left(\frac{x_{jt} - x_j}{h} \right) K_h(x_{jt} - x_j). \quad (5.4)$$

Theo khai triển Taylor và điều kiện β -mixing của quá trình $(Y_t, \mathbf{X}_t)$ (Giả thiết A1), kỳ vọng toán học có dạng:

$$\mathbb{E} \left(\Omega_n^{(1)}(\beta, x_j, h) \right) = \Omega_0^{(1)}(\beta, x_j) + O(h^2), \quad (5.5)$$

$$\mathbb{E} \left(\Omega_n^{(2)}(\beta, x_j, h) \right) = h \Omega_0^{(2)}(\beta, x_j) + O(h^3), \quad (5.6)$$

với $\Omega_0^{(1)}(\beta, x_j) = m(x_j, \beta_1) g_j(x_j)$, trong đó $m(x_j, z_j) = F(f_j(x_j)) - F(z_j)$. Nghiệm thực sự của hệ phương trình quần thể $\mathbf{\Omega}_0(\beta, x_j) = \mathbf{0}$ là duy nhất tại $\beta_0 = (f_j(x_j), f'_j(x_j))^\top$.

Áp dụng bất đẳng thức tập trung cho chuỗi phụ thuộc β -mixing ([9]) kết hợp với kỹ thuật bao phủ độ chặn (covering numbers) của không gian hàm Lipschitz $\mathcal{F}$ ([13]), ta có:

$$\sup_{x_j \in A_j} \sup_{\|\beta\|_{\mathcal{F}} \leq C} \|\mathbf{\Omega}_n(\beta, x_j, h) - \mathbb{E} \mathbf{\Omega}_n(\beta, x_j, h)\| = O_p \left(\sqrt{\frac{\log n}{nh}} \right) = o_p(1). \quad (5.7)$$

Kết hợp với tính khả nghịch đồng đều của ma trận đạo hàm $\partial \mathbf{f}_0 / \partial \beta$ trên tập compact A_j , suy ra nghiệm mẫu hội tụ đồng đều:

$$\|\hat{\mathbf{f}} - \mathbf{f}_0\|_{\mathcal{F}} = \sup_{1 \leq j \leq d} \sup_{x_j \in A_j} |\hat{f}_j(x_j) - f_j(x_j)| = o_p(1). \quad (5.8)$$

Kiểm tra Điều kiện (v): Luật số lớn đồng đều

Với $\delta_n = o(1)$ và $\|\mathbf{f} - \mathbf{f}_0\|_{\mathcal{F}} \leq \delta_n$, phân tích:

$$\ell_n(\mathbf{f}, \alpha) - \ell(\mathbf{f}, \alpha) = [\ell_n(\mathbf{f}, \alpha) - \ell_n(\mathbf{f}_0, \alpha)] + [\ell_n(\mathbf{f}_0, \alpha) - \ell(\mathbf{f}_0, \alpha)] + [\ell(\mathbf{f}_0, \alpha) - \ell(\mathbf{f}, \alpha)]. \quad (5.9)$$

Số hạng thứ nhất và thứ ba được chặn bởi $C\|\mathbf{f} - \mathbf{f}_0\|_{\mathcal{F}} \leq C\delta_n = o(1)$. Số hạng thứ hai $\sup_{\alpha \in \Pi} |\ell_n(\mathbf{f}_0, \alpha) - \ell(\mathbf{f}_0, \alpha)| = o_p(1)$ theo luật số lớn đồng đều cho chuỗi β -mixing trên tập tham số compact Π . Do đó Điều kiện (v) thỏa mãn.

Từ 5 điều kiện trên, theo Mệnh đề 3.7, ta có $\hat{\alpha} - \alpha_0 = o_p(1)$, hoàn tất chứng minh Định lý 3.9.

B Chứng Minh Định Lý Chuẩn Tắc Tiệm Cận (Định lý 3.10)

Vì $\hat{\alpha}$ là điểm trong của tập compact Π với xác suất tiến tới 1, điều kiện bậc nhất triệt tiêu tại $\hat{\alpha}$:

$$\ell'_n(\hat{\mathbf{f}}(\cdot), \hat{\alpha}) = \mathbf{0}. \quad (5.10)$$

Khai triển Taylor bậc nhất của score function mẫu $\ell'_n(\hat{\mathbf{f}}(\cdot), \hat{\alpha})$ quanh vector tham số thực α_0 :

$$\mathbf{0} = \ell'_n(\hat{\mathbf{f}}(\cdot), \alpha_0) + \ell''_n(\hat{\mathbf{f}}(\cdot), \alpha^*)(\hat{\alpha} - \alpha_0), \quad (5.11)$$

trong đó α^* nằm trên đoạn thẳng nối $\hat{\alpha}$ và α_0 . Suy ra:

$$\sqrt{n}(\hat{\alpha} - \alpha_0) = -[\ell''_n(\hat{\mathbf{f}}(\cdot), \alpha^*)]^{-1} \sqrt{n} \ell'_n(\hat{\mathbf{f}}(\cdot), \alpha_0). \quad (5.12)$$

Bước 1: Giới hạn của ma trận Hessian

Do tính nhất quán $\hat{\alpha} \xrightarrow{P} \alpha_0$ nên $\alpha^* \xrightarrow{P} \alpha_0$, kết hợp với $\|\hat{\mathbf{f}} - \mathbf{f}_0\|_{\mathcal{F}} = o_p(1)$ và luật số lớn đồng đều, ta có:

$$\ell_n''(\hat{\mathbf{f}}(\cdot), \alpha^*) = \ell_n''(\mathbf{f}_0(\cdot), \alpha_0) + o_p(1) \xrightarrow{P} \mathbf{U}, \quad (5.13)$$

với $\mathbf{U} = \mathbb{E}(-p_t(1-p_t)\tilde{\chi}_t(\mathbf{f}_0)\tilde{\chi}_t(\mathbf{f}_0)^\top w(\mathbf{X}_t))$ là ma trận xác định âm và khả nghịch theo giả thiết.

Bước 2: Phân tích Score function tại α_0

Phân tích đại lượng $\sqrt{n}\ell_n'(\hat{\mathbf{f}}(\cdot), \alpha_0)$:

$$\sqrt{n}\ell_n'(\hat{\mathbf{f}}(\cdot), \alpha_0) = \sqrt{n}\ell_n'(\mathbf{f}_0(\cdot), \alpha_0) + \sqrt{n}[\ell_n'(\hat{\mathbf{f}}(\cdot), \alpha_0) - \ell_n'(\mathbf{f}_0(\cdot), \alpha_0)]. \quad (5.14)$$

Sử dụng công thức của ℓ_n' :

$$\begin{aligned} \ell_n'(\hat{\mathbf{f}}, \alpha_0) - \ell_n'(\mathbf{f}_0, \alpha_0) &= \frac{1}{n} \sum_{t=1}^n (Y_t - p_t(\hat{\mathbf{f}}, \alpha_0)) \tilde{\chi}_t(\hat{\mathbf{f}}) w(\mathbf{X}_t) - \frac{1}{n} \sum_{t=1}^n (Y_t - p_t(\mathbf{f}_0, \alpha_0)) \tilde{\chi}_t(\mathbf{f}_0) w(\mathbf{X}_t) \\ &= \frac{1}{n} \sum_{t=1}^n (Y_t - p_t(\mathbf{f}_0, \alpha_0)) (\tilde{\chi}_t(\hat{\mathbf{f}}) - \tilde{\chi}_t(\mathbf{f}_0)) w(\mathbf{X}_t) \\ &\quad - \frac{1}{n} \sum_{t=1}^n (p_t(\hat{\mathbf{f}}, \alpha_0) - p_t(\mathbf{f}_0, \alpha_0)) \tilde{\chi}_t(\mathbf{f}_0) w(\mathbf{X}_t) + R_n, \end{aligned} \quad (5.15)$$

với đại lượng dư bậc cao thỏa mãn $\|R_n\| = O_p(\|\hat{\mathbf{f}} - \mathbf{f}_0\|_{\mathcal{F}}^2) = o_p(n^{-1/2})$.

Đối với số hạng thứ nhất: Do $(Y_t - p_t(\mathbf{f}_0, \alpha_0))$ có kỳ vọng có điều kiện bằng 0 đối với $\mathcal{J}_{t-1}$, chuỗi này tạo thành một dãy sai phân martingale. Áp dụng bất đẳng thức Bernstein cho chuỗi β -mixing, số hạng này có cấp độ ngẫu nhiên $O_p((nh)^{-1/2}n^{-1/2}) = o_p(n^{-1/2})$.

Đối với số hạng thứ hai: Khai triển vi phân hàm logistic $F(u)$ cho thấy $p_t(\hat{\mathbf{f}}, \alpha_0) - p_t(\mathbf{f}_0, \alpha_0) = p_t(1-p_t) \sum_{j=1}^d \alpha_{0j}(\hat{f}_j(x_{jt}) - f_j(x_{jt})) + O(\|\hat{\mathbf{f}} - \mathbf{f}_0\|^2)$. Kỳ vọng của sai số ước lượng hạt nhân thỏa mãn $\mathbb{E}(\hat{f}_j(x) - f_j(x)) = c_j(x)h^2 + o(h^2)$. Do đó:

$$\sqrt{n} \|\ell_n'(\hat{\mathbf{f}}(\cdot), \alpha_0) - \ell_n'(\mathbf{f}_0(\cdot), \alpha_0)\| = O_p(\sqrt{nh^2}) + o_p(1). \quad (5.16)$$

Nhờ Giả thiết A3(iii) về điều kiện làm trơn non ($nh^4 = o(1)$ khi $n \rightarrow \infty$), ta có:

$$\sqrt{nh^2} = \sqrt{nh^4} \rightarrow 0 \implies \sqrt{n} [\ell'_n(\hat{\mathbf{f}}(\cdot), \alpha_0) - \ell'_n(\mathbf{f}_0(\cdot), \alpha_0)] = o_p(1). \quad (5.17)$$

Bước 3: Áp dụng Định lý Giới hạn Trung tâm (CLT)

Từ Bước 2, ta có:

$$\sqrt{n}\ell'_n(\hat{\mathbf{f}}(\cdot), \alpha_0) = \frac{1}{\sqrt{n}} \sum_{t=1}^n (Y_t - p_t(\alpha_0)) \tilde{\chi}_t(\mathbf{f}_0) w(\mathbf{X}_t) + o_p(1). \quad (5.18)$$

Đặt $\eta_t = (Y_t - p_t(\alpha_0)) \tilde{\chi}_t(\mathbf{f}_0) w(\mathbf{X}_t)$. Vì chuỗi $(Y_t, \mathbf{X}_t)$ là dừng và β -mixing với tốc độ suy giảm đa thức $\beta(t) = O(t^{-b})$ với $b > 1$, và thỏa mãn điều kiện mô-men $\mathbb{E}\|\eta_t\|^{2+\delta} < \infty$ (theo Giả thiết A1), áp dụng Định lý Giới hạn Trung tâm cho chuỗi phụ thuộc β -mixing ([9]), ta có:

$$\frac{1}{\sqrt{n}} \sum_{t=1}^n \eta_t \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{V}), \quad (5.19)$$

trong đó ma trận phương sai dài hạn được xác định chuẩn xác bởi:

$$\mathbf{V} = \lim_{n \rightarrow \infty} \text{Var} \left(\frac{1}{\sqrt{n}} \sum_{t=1}^n \eta_t \right) = \sum_{k=-\infty}^{\infty} \text{Cov}(\eta_0, \eta_k). \quad (5.20)$$

Bước 4: Kết luận

Thay kết quả của Bước 1 và Bước 3 vào biểu thức khai triển Taylor (5.12), áp dụng bổ đề Slutsky, ta thu được:

$$\sqrt{n}(\hat{\alpha} - \alpha_0) = -\mathbf{U}^{-1} \left(\frac{1}{\sqrt{n}} \sum_{t=1}^n \eta_t \right) + o_p(1) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{U}^{-1} \mathbf{V} \mathbf{U}^{-1}). \quad (5.21)$$

Chúng minh Định lý 3.10 hoàn tất.