



A Bridge to Linear Regression

Lê Hữu Phước Trần Đại Nhân Dương Đình Thắng Đinh Quang Vinh

I. Giới thiệu

Hãy tưởng tượng bạn là một nhà đầu tư đang cần phải khảo sát tình hình thị trường nhà đất ở Việt Nam. Bạn đã thu thập được rất nhiều thông tin hữu ích từ những nguồn khác nhau như diện tích, kiến trúc, kiểu dáng, vị trí địa lý và giá cả của mặt bằng chung những ngôi nhà tại Việt Nam. Tuy nhiên, nếu chỉ dựa vào giá nhà khảo sát được trong thời gian gần, bạn sẽ vẫn chưa đủ cơ sở để đưa ra quyết định xem kiểu nhà nào sẽ mang lại lợi nhuận mà mình cần phải đầu tư.



Lúc này, bạn tìm thêm những bằng chứng, những thông tin mang tính thuyết phục nhằm hỗ trợ cho quá trình quyết định của mình. Vậy, những thông tin liên quan đến mô hình nhà nào, khi thay đổi, sẽ kéo theo sự dao động của giá cả? Chính sự tò mò này đã dẫn đến quá trình tìm và giải mã công thức, khuôn mẫu đã tạo nên giá trị của mô hình nhà. Khi đó, những con số này sẽ trở thành biến số trong một phương trình lớn thay vì chỉ là những giá trị rời rạc. Và đó cũng là động lực chính cho **Linear Regression** (Tạm dịch: Hồi quy tuyến tính) - một bài toán với mục đích là tìm ra được một phương trình có khả năng hiểu được quy luật của dữ liệu.

Mục lục

I.	Giới thiệu	1
II.	Từ bài toán tối ưu hóa cho tới Hồi quy tuyến tính	3
II.1.	Đặt vấn đề	3
II.2.	Nhắc lại về đạo hàm	5
II.3.	Từ đạo hàm đến bài toán tối ưu hóa	9
II.4.	Tối ưu hóa hàm số bằng Gradient Descent	13
II.5.	Các vấn đề cần lưu ý về Linear Regression	17
III.	Thực hành: Xây dựng mô hình dự đoán giá vàng	20
III.1.	Giới thiệu về bài toán	20
III.2.	Cài đặt và thực nghiệm	22
IV.	Câu hỏi trắc nghiệm	26
V.	Tài liệu tham khảo	28
	Phụ lục	29

II. Từ bài toán tối ưu hóa cho tới Hồi quy tuyến tính

II.1. Đặt vấn đề


Mục đích của Linear Regression là có khả năng tìm ra được một phương trình tuyến tính (mô hình hồi quy) $y = f(x)$, sao cho phương trình này có khả năng hiểu được quy luật của dữ liệu. Từ đó, ta có phương trình $y = wx + b$ mà với mỗi sự thay đổi của x phương trình sẽ phải nhận biết được sự thay đổi của y . Nhờ đó, ta sẽ tìm ra câu trả lời cho câu hỏi “Yếu tố nào?” và “Như thế nào?” mà ta đã đặt ra ở phần dẫn nhập trước đó cho bài toán đầu tư bất động sản nhà đất.

Đặc trưng	Nhãn		Đặc trưng	Nhãn
diện tích	giá nhà		diện tích	giá nhà
6.7	8.1		6.7	8.1
4.6	5.6		4.6	5.6
3.5	4.3		3.5	4.3
5.5	6.7		5.5	6.7
6.0		→	6.0	?

Hình 1: Mô hình hồi quy sau cùng được sử dụng để dự đoán các giá trị x tương lai.


Thật vậy, ở bài toán đầu tư bất động sản nhà đất, nhà đầu tư đã sở hữu riêng cho mình một bộ sưu tầm dữ liệu về các đặc tính của ngôi nhà và phân khúc giá tương đương với ngôi nhà đó. Ở đây, các đặc tính của một ngôi nhà được định nghĩa như là x (hay đặc trưng đầu vào của mô hình hồi quy) còn giá cả sẽ chính là y (hay đầu ra mục tiêu của mô hình). Các giá trị x và y giờ đây là những giá trị đã sẵn có trong phương trình. Việc còn lại cần phải làm là xác định được các biến w và b sao cho $y = wx + b$ mô tả được chính xác nhất quy luật của dữ liệu.

Để trực quan hơn vấn đề, các điểm dữ liệu được biểu diễn ở dạng đồ thị số như hình bên dưới:



Hình 2: Các điểm dữ liệu rời rạc trong không gian 2D và 3D.


Nếu như các điểm dữ liệu này đều nằm trên một đường thẳng, việc nhận biết được mô hình hồi quy, hay đường thẳng tuyến tính đã đề cập là vô cùng dễ dàng. Khi đó, ta chỉ việc lấy 2 điểm dữ liệu bất kỳ trên đường thẳng và tính toán để tìm ra các hệ số $\{w; b\}$ của phương trình. Lúc này, ta sẽ có một hàm số theo đúng dạng phương trình đường thẳng $y = w \times x + b$ và tương ứng với mỗi đầu vào x sẽ cho ra đầu ra y .



Hình 3: Mô hình hồi quy tuyến tính khi các điểm dữ liệu nằm trên cùng một đường thẳng.

💡 **Ví dụ:** Với bảng dữ liệu gồm 2 trường là diện tích và giá nhà, giả sử diện tích của ngôi nhà (x) là $600m^2$ thì giá của ngôi nhà lúc này sẽ là bao nhiêu? Hay nói cách khác, mô hình hồi quy với đầu vào là $x = 6$ thì y sẽ bằng bao nhiêu?

Tuy nhiên, ở đa số bài toán thực tiễn, dữ liệu sẽ vô cùng khó đoán, rời rạc, phân tán khắp nơi. Ví dụ như trong bài toán về đầu tư bất động sản nhà đất ở trên, tùy theo cách xây dựng của căn nhà mà phần diện tích được dùng sẽ khác đi một ít dẫn tới các điểm dữ liệu sẽ trở nên khó đoán hơn.




Hình 4: Ở các trường hợp dữ liệu rời rạc, với cùng một câu hỏi sẽ có thể xuất hiện nhiều lời giải khác nhau.

Thật vậy, trong **Hình 4**, ta nhận thấy cùng một câu hỏi “Với diện tích bằng $600m^2$ thì giá nhà sẽ bằng bao nhiêu?” lại khả dĩ tới tận ba cách giải. Mỗi cách giải tượng trưng cho một cách tính toán riêng, đại diện cho một hàm số riêng. Khi này, việc phân vân xem cách nào là tốt nhất là không thể tránh khỏi. Rõ ràng, chúng ta cần một phương pháp khách quan để đo lường mức độ hiệu quả của từng lời giải thay vì lựa chọn một cách cảm tính.

Để giải quyết câu hỏi trên, trong bài này, ta sẽ tìm hiểu về **Optimization** (Tạm dịch: tối ưu hóa). Tối ưu hóa cung cấp một phương pháp toán học chặt chẽ để tìm ra một mô hình phù hợp nhất với dữ liệu bằng cách sử dụng **Loss Function** (Tạm dịch: hàm mất mát) để đo lường độ sai lệch của kết quả dự đoán từ mô hình so với dữ liệu thực tế. Qua quá trình tối ưu, kết quả của hàm mất mát này sẽ được sử dụng để cập nhật lại các tham số của mô hình mà trong bài này là $\{w; b\}$ sao cho sau mỗi lần cập nhật, giá trị của hàm mất mát ở lần tính toán tiếp theo là nhỏ nhất. Một trong các khái niệm đầu tiên và quan trọng nhất để tiến tới tối ưu hóa chính là đạo hàm.

II.2. Nhắc lại về đạo hàm

Là loại giới hạn mà chúng ta tính toán để tìm độ dốc của đường tiếp tuyến với đồ thị hàm số tại một điểm xuất hiện trong rất nhiều ứng dụng thuộc nhiều lĩnh vực khác nhau. Các ứng dụng này bao gồm vận tốc và gia tốc trong vật lý, các hàm lợi nhuận cận biên trong kinh doanh, và tốc độ tăng trưởng trong sinh học. Vì giới hạn này xuất hiện rất thường xuyên, chúng ta đặt cho giá trị của nó một cái tên đặc biệt: **Derivative** (tạm dịch: đạo hàm). Quá trình tìm ra đạo hàm được gọi là **Differentiation** (tạm dịch: phép lấy vi phân).



Hình 5: Mô tả đạo hàm của hàm số $y = f(x)$ sau khi x thay đổi một đoạn Δx .

Đạo hàm của một hàm số tại một điểm cụ thể cho ta xác định được **Slope of the tangent line** (Tạm dịch: độ dốc của đường tiếp tuyến). Đồng thời, đạo hàm còn cho biết được tốc độ thay đổi

tức thời của hàm số đó. Hay nói cách khác, giả sử ta có một giá trị x_0 và ta tăng x_0 thêm một lượng là Δx thì hàm số $y = f(x)$ sẽ tăng hoặc giảm một lượng giá trị nhất định. Và cái ta cần là xác định được tốc độ thay đổi tức thời này.

Để trả lời cho câu hỏi trên, xét trường hợp ở **Hình 5** theo các quan sát sau:

- x_0 là giá trị trên trục hoành ban đầu. Từ đó, ta có $f(x_0)$ là giá trị của hàm số ban đầu. Ta gọi điểm này là điểm **A** ($x_0, f(x_0)$).
- Sau khi dịch x_0 một đoạn Δx (rất nhỏ, lớn hơn 0), ta có một điểm mới là **B** ($x_0 + \Delta x, f(x_0 + \Delta x)$) tương ứng.
- Khi đó, ta tính được độ chênh lệch của hàm số $f(x)$ sau khi chuyển dời một đoạn Δx là $\Delta y = f(x_0 + \Delta x) - f(x_0)$.


Từ hai giá trị Δx và Δy , thành lập được tỷ số tốc độ thay đổi của hàm số $y = f(x)$ là:

$$\frac{\Delta y}{\Delta x} = \frac{f(x + \Delta x) - f(x)}{\Delta x}, \quad \Delta x \neq 0$$

Trong đó,

- Δx là độ thay đổi của giá trị đầu vào x .
- Δy là độ thay đổi của hàm số hay giá trị đầu ra y .

Đây cũng chính là công thức tính toán độ dốc của **Secant line** (Tạm dịch: đường cát tuyến). Đường cát tuyến là một đường thẳng đi qua hai điểm A và B, biểu thị cho tốc độ thay đổi trung bình của Δy trên một khoảng Δx .




Hình 6: Mô tả đường cát tuyến, đường tiếp tuyến của hàm số tại một thời điểm số cụ thể.

Tuy nhiên, cái cần tìm lại là tốc độ thay đổi tức thời của hàm số ngay tại một thời điểm nhất định. Do đó, nhiệm vụ tiếp theo của bài toán là làm sao cho biến đường cát tuyến (màu xanh lá) này thành đường tiếp tuyến (màu đỏ) như ở **Hình 6**.

Cũng cùng bối cảnh ở **Hình 6**, ta giữ điểm A cố định và cho B trượt trên đường cong $y = f(x)$ lại gần điểm A. Điểm B càng gần điểm A đồng nghĩa với việc khoảng cách Δ_x sẽ càng nhỏ dần và tiến về 0 hay $x_0 + \Delta_x$ tiến tới x_0 . Từ đó, đường cát tuyến sẽ xoay dần lại và khớp chính xác vào vị trí của đường tiếp tuyến tại A. Quá trình chuyển dời cho Δ_x tiến dần về 0 trong toán học được biểu diễn bằng cách lấy **Lim** (tạm dịch: giới hạn của hàm số). Từ đó, bằng cách áp dụng giới hạn vào công thức tính độ dốc của đường cát tuyến, chúng ta sẽ có được công thức tính độ dốc của đường tiếp tuyến, hay còn gọi là đạo hàm của hàm số:

$$f'(x) = \lim_{\Delta_x \rightarrow 0} \frac{\Delta_y}{\Delta_x} = \lim_{\Delta_x \rightarrow 0} \frac{f(x + \Delta_x) - f(x)}{\Delta_x}, \quad \Delta_x \neq 0$$



Hình 7: Minh họa cho tính âm dương của đạo hàm.

Tùy thuộc vào giá trị x hiện tại và sự thay đổi Δ_x của giá trị x mà kết quả của đạo hàm có thể trả về là âm hoặc dương. Hai đồ thị hình dưới thể hiện rõ nhất điều này khi mà đối với hàm số $f(x) = mx^2 (m > 0)$. Cụ thể:

TH1: Khi $x_1 < x_2$ và $f(x_2) < f(x_1)$,


$$f'(x) = \lim_{\Delta_x \rightarrow 0} \frac{\Delta_y}{\Delta_x} = \frac{f(x_2) - f(x_1)}{x_2 - x_1} < 0, \quad \Delta_y < 0, \quad \Delta_x > 0.$$

Ở trường hợp này, giá trị của x tăng từ -3 đến khoảng -2 nhưng hàm số $f(x)$ lại giảm từ 38 đến 15 dẫn tới việc tử số $\Delta_y < 0$ trong khi $\Delta_x > 0$ làm cho tỷ số $\frac{\Delta_y}{\Delta_x} < 0$. Như vậy, kết quả của đạo hàm lúc này đang âm.

TH2: Khi $x_1 < x_2$ và $f(x_2) > f(x_1)$,

$$f'(x) = \lim_{\Delta_x \rightarrow 0} \frac{\Delta_y}{\Delta_x} = \frac{f(x_2) - f(x_1)}{x_2 - x_1} > 0, \quad \Delta_y > 0, \quad \Delta_x > 0.$$

Trường hợp ngược lại, x tăng từ 2.7 đến 3.5 và đồng thời $f(x)$ cũng tăng một lượng tương tự như trường hợp trước. Lúc này, cả hai thành phần tử số và mẫu số của tỷ số $\frac{\Delta y}{\Delta x} > 0$ làm cho kết quả của đạo hàm tương ứng dương.



Hình 8: Minh họa cho ví dụ về tính toán phương trình đạo hàm.

💡 Ví dụ minh họa: Với hàm số $y = f(x) = x^2$, tính toán phương trình đạo hàm cho hàm số này.

Từ công thức gốc ở trên, ta thay $f(x) = x^2$, ta thu được kết quả:


$$\begin{aligned} f'(x) &= \lim_{\Delta x \rightarrow 0} \frac{(x + \Delta x)^2 - x^2}{\Delta x}, \quad \Delta x \neq 0 \\ &= \lim_{\Delta x \rightarrow 0} \frac{x^2 + 2x \times \Delta x + (\Delta x)^2 - x^2}{\Delta x} \\ &= \lim_{\Delta x \rightarrow 0} 2x + \Delta x \end{aligned}$$

Vậy, khi Δx tiến về 0, phương trình đạo hàm $f'(x)$ của hàm số $y = x^2$ lúc này sẽ là $f'(x) = 2x$.

Mục đích của việc tìm được phương trình đạo hàm của một hàm số là để có thể xác định được giá trị đạo hàm tại một giá trị số cụ thể. Nói cách khác, khi cần xét một điểm và có phương trình đạo hàm thì ta có thể dễ dàng tính toán được giá trị đạo hàm. Đối với cùng ví dụ trên, ta có $x = 5$ phương trình của hàm số là $y = x^2$ và có phương trình đạo hàm là $f'(x) = 2x$, lúc này, đạo hàm tại $x = 5$ sẽ là $f'(5) = 10$.


II.3. Từ đạo hàm đến bài toán tối ưu hóa

Giá trị của đạo hàm hỗ trợ một phần không thể thiếu trong quá trình đi tìm giá trị mà tại đó giúp cho hàm số tối ưu. Giá trị này sẽ góp phần cho ta biết được độ lớn của đạo hàm tại thời điểm đó và chiều hướng thay đổi của hàm số khi x thay đổi một đoạn Δ_x . Trục tiếp ở **Hình 9**, ta có một điểm khởi đầu bất kì là x_0 và việc cần làm là dựa vào một thông tin nào đó để xử lý sao cho x_0 tiến tới được giá trị x_{opt} .



Hình 9: Minh họa cho sự thay đổi của giá trị đạo hàm khi thay đổi x một đoạn Δ_x .

Ta dễ dàng quan sát được từ **Hình 9**, khi x nằm phía bên phải x_{opt} thì các giá trị đạo hàm là dương và giảm dần theo chiều của x tiến tới x_{opt} . Sau đó, khi x đã đạt tới và vượt qua x_{opt} hay x nằm bên trái x_{opt} thì đạo hàm lại có giá trị âm. Do đó, ta quy ước trong bài này, với giá trị đạo hàm dương thì chiều mũi tên sẽ là từ trái qua phải và ngược lại, giá trị đạo hàm âm thì chiều mũi tên sẽ là từ phải qua trái.



Hình 10: Minh họa cho chiều giá trị của đạo hàm khi ta thay đổi giá trị của x .

Nhận định đối với trường hợp trên cả **Hình 9** và **Hình 10**, vị trí ta đang cần hướng tới là x_{opt} do đó chiều thay đổi của x phải là chiều ngược lại với chiều đạo hàm. Lúc này, ta quan sát giá trị x_1 và x_2 cùng $f(x_1)$, $f(x_2)$. Như đã phân tích ở **mục II.2.**, ta nhận định chiều đạo hàm lúc này là **chiều dương** hay **chiều từ trái sang phải**. Do đó, khi cho x đi ngược hướng đạo hàm, giá trị x mới sẽ phải đi theo chiều từ phải sang trái để x_0 tiến được về phía x_{opt} . Đối với trường hợp đạo hàm âm, ta cũng cần phân tích tương tự, để hướng tới x_{opt} thì chiều cần phải thay đổi của x là chiều ngược lại với hướng của đạo hàm hiện tại là chiều từ trái sang phải.

💡 Ví dụ minh họa: Với hàm số $y = f(x) = x^2$, giả sử ta cần tính toán x_2 sao cho nó tiến tới gần x_{opt} nhất.


TH1: $x_1 = 5$, $f'(x_1) = 10$, nhận thấy lúc này đạo hàm dương, ta cần đi ngược lại về hướng âm:

- $x_2 = x_1 - f'(x_1) = 5 - 2 \times 5 = -5.$

TH2: $x_2 = -50$, $f'(x_2) = -100$, nhận thấy đạo hàm lúc này âm, ta cần đi ngược lại về hướng dương:

- $x_2 = x_1 - f'(x_1) = -50 - (2 \times (-50)) = -50 + 100 = 50.$

Vậy, trong trường hợp này, x_1 sẽ được trừ đi với giá trị đạo hàm tại chính điểm đó là $f'(x_1)$ để đảm bảo rằng chúng ta luôn đi đúng hướng về phía x_{opt} như minh họa ở **Hình 10**.



Hình 11: Đi ngược hướng đạo hàm để tiến về giá trị tối ưu θ_{opt} .

Như vậy, ta kết luận rằng với một điểm x_1 nếu ta muốn tìm điểm x_2 tối ưu hơn, x_2 sẽ xuất phát từ vị trí ban đầu của x_1 và đi ngược lại hướng của đạo hàm:

$$x_2 = x_1 - f'(x_1),$$

Tuy nhiên, miền giá trị của $f'(x)$ thuộc từ $-\infty$ đến $+\infty$ và khả năng khi ta thực hiện phép trừ để đi ngược hướng đạo hàm thì giá trị mới lúc này sẽ vượt xa hơn so với dự tính dẫn tới thời gian tìm ra giá trị tối ưu sẽ lâu hơn. Lúc này, ta sử dụng một chiến lược khác là sử dụng hệ số η để đảm bảo chỉ đúng hướng đi là ngược hướng đạo hàm nhưng sẽ không nhảy quá xa như trước đó. η sẽ đóng vai trò như một chiếc la bàn chỉ đường, giúp ta đi đúng hướng tính toán. Tương ứng với mỗi lần đạo hàm, ta sẽ lấy “la bàn” ra xem và chấp nhận mình đi ngắn lại nhưng sẽ đảm bảo mình không đi lố vạch đích.

$$x_2 = x_1 - \eta \times f'(x_1),$$

Do đó, ta có công thức cuối cùng:

$$x_{new} = x_{old} - \eta \times \frac{d}{dx} J(x_{old})$$


Trong đó:

- x_{old} là giá trị x khởi tạo ban đầu.
- x_{new} là giá trị x sau khi đạo hàm để tối ưu hơn.
- η là learning rate (Tạm dịch: tốc độ học) để giúp kéo lại giá trị đạo hàm quá lớn.
- $f'(x_{old})$ là giá trị đạo hàm của hàm số $f(x)$ tại x_{old} , cho biết hướng và độ dốc của hàm số.

Đây cũng chính là công thức cơ bản của **Gradient Descent** (Tạm dịch: phương pháp hạ dốc) mà ta tiếp tục sử dụng trong rất nhiều bài toán liên quan đến Machine learning và Deep learning sau này.

⚠ Lưu ý: Để sử dụng được các công thức mạnh mẽ đã đề cập như Gradient Descent hay đạo hàm, điều kiện cực kỳ quan trọng là hàm số ta đang tối ưu lúc này hay Loss function cần phải có tính **differentiable** (tạm dịch: khả vi):

- Hàm được sử dụng phải là hàm liên tục.
- Tại một điểm a xác định trên hàm số, $f'(a)$ phải tồn tại một giá trị cụ thể.
- $\lim_{x \rightarrow a^-} f'(x) = \lim_{x \rightarrow a^+} f'(x) = f'(a)$.



Hình 12: Minh họa hàm số khả vi và không khả vi.

💡 Ví dụ minh họa: Xét trường hợp của hàm số $f(x) = x^{\frac{1}{3}}$, ta kiểm tra tính khả vi của hàm này như sau:

Lấy đạo hàm của hàm số $f(x)$, ta có:

$$f'(x) = \frac{1}{3}x^{-\frac{2}{3}} = \frac{1}{3 \times x^{\frac{2}{3}}},$$

Tiếp tục xét vị trí $x = 0$ tại $f'(x)$:

$$f'(x=0) = \frac{1}{3 \times (0)^{\frac{2}{3}}} = \frac{1}{0} = \infty.$$

Như vậy giá trị của đạo hàm $f'(x)$ tại $x = 0$ là không xác định do đó hàm số $f(x) = x^{\frac{1}{3}}$ là không khả vi.

Trên thực tế, để tránh sự phức tạp không cần thiết, các hàm như x^2 (MSE) và $|x|$ (MAE) thường được áp dụng rộng rãi phổ biến như hàm mất mát trong quá trình tối ưu.

II.4. Tối ưu hóa hàm số bằng Gradient Descent

Trong phần này, ta trình bày mối liên hệ giữa **đạo hàm** và **quá trình cực tiểu hóa hàm mục tiêu** bằng phương pháp Gradient Descent.

Gradient Descent là một thuật toán tối ưu hóa được sử dụng phổ biến trong học máy nhằm tìm ra giá trị của các tham số sao cho hàm mất mát đạt giá trị nhỏ nhất. Ý tưởng cốt lõi là tại mỗi bước lặp, ta điều chỉnh tham số mô hình theo hướng **ngược lại với hướng của gradient**, vì gradient chỉ hướng tăng nhanh nhất của hàm. Khi đi ngược lại hướng đó, ta tiến dần đến điểm cực tiểu toàn cục.

Nói cách khác, Gradient Descent giúp mô hình “học” bằng cách liên tục giảm dần sai số thông qua việc cập nhật tham số lặp đi lặp lại. Phương pháp này là nền tảng cho nhiều mô hình học máy, từ Linear Regression đến Deep Learning. Để hiểu rõ cơ chế của Gradient Descent, ta sẽ lần lượt đi từ trường hợp một biến đến nhiều biến, và cuối cùng là hàm hợp, qua đó quan sát cách đạo hàm được sử dụng để dẫn hướng tối ưu.

II.4.1. Bài toán 1 biến

Giả sử ta cần cực tiểu hóa hàm số $f(x) = x^2$, một hàm số đơn giản nhưng tiêu biểu cho bài toán tối ưu một biến trong học máy. Mục tiêu là tìm giá trị x sao cho $f(x)$ nhỏ nhất.

Trong trường hợp này, *đạo hàm* cho ta biết được *độ dốc* và *hướng thay đổi* của hàm tại mỗi điểm. Dựa vào dấu của đạo hàm, ta có thể xác định hướng di chuyển phù hợp:

- **Khi $f'(x) > 0$:** Đồ thị đang dốc lên, nghĩa là giá trị hàm tăng khi x tăng. Để giảm giá trị hàm, ta cần di chuyển theo hướng ngược lại, tức là *giảm x* .
- **Khi $f'(x) < 0$:** Đồ thị đang dốc xuống, nghĩa là giá trị hàm giảm khi x tăng. Khi đó, ta cần *tăng x* để tiến về vùng thấp hơn.
- **Khi $f'(x) = 0$:** Hàm đạt trạng thái bằng phẳng, đây là vị trí mà thuật toán Gradient Descent sẽ dừng lại vì không còn hướng giảm rõ rệt.


Từ trực giác đó, ta hình thành ý tưởng cốt lõi của Gradient Descent: **di chuyển ngược hướng gradient** để liên tục giảm giá trị của hàm mục tiêu. Dựa trên ý tưởng này, ta có công thức cập nhật giá trị của x qua từng bước lặp như sau:

$$x_{t+1} = x_t - \eta \times f'(x_t)$$

Trong đó:

- x_{t+1} là giá trị của biến x ở bước lặp tiếp theo.
- x_t là giá trị của biến x ở bước lặp hiện tại.

- η là learning rate, một hằng số dương quyết định độ lớn của bước cập nhật.
- $f'(x_t)$ là giá trị đạo hàm của hàm số $f(x)$ tại điểm x_t , cho biết hướng và độ dốc của hàm.



Hình 13: Quá trình Gradient Descent trên hàm $f(x) = x^2$. Các mũi tên biểu diễn hướng di chuyển ngược chiều đạo hàm từ điểm khởi tạo $x_0 = 70$ về điểm cực tiểu toàn cục $x = 0$.

Áp dụng vào hàm số $f(x) = x^2$, ta có $f'(x) = 2x$. Công thức cập nhật trở thành:

$$x_{t+1} = x_t - \eta \times (2x_t).$$


💡 **Ví dụ minh họa:** Với $x_0 = 70$ và $\eta = 0.1$:

$$\begin{aligned} x_1 &= 70 - 0.1 \times 2 \times 70 = 56.0, \\ x_2 &= 56 - 0.1 \times 2 \times 56 = 44.8, \\ x_3 &= 44.8 - 0.1 \times 2 \times 44.8 = 35.84, \\ x_{1000} &\approx 10^{-38}. \end{aligned}$$

Ta thấy x khởi tạo tại 70 dần tiến về 0 — điểm cực tiểu toàn cục của $f(x)$. Việc chọn giá trị η phù hợp là yếu tố quan trọng đảm bảo thuật toán hội tụ nhanh và ổn định.

II.4.2. Bài toán 2 biến

Từ bài toán một biến, ta mở rộng sang hàm hai biến: $f(x, y) = x^2 + y^2$. Đây là bề mặt hình parabol có cực tiểu toàn cục tại gốc tọa độ $(0, 0)$. Để tối ưu hàm nhiều biến, ta cần cập nhật tất cả các biến *đồng thời* bằng cách di chuyển ngược hướng với **gradient** của hàm. Gradient, ký hiệu là ∇f , là một vector chứa tất cả các đạo hàm riêng, chỉ hướng tăng nhanh nhất của hàm.



Hình 14: Hàm $f(x, y) = x^2 + y^2$. Màu sắc thể hiện độ cao của bề mặt. Quỹ đạo di chuyển của Gradient Descent được mô tả như quá trình “trượt xuống” đáy parabol.

Công thức cập nhật cho từng biến trong trường hợp hai biến là:

$$\begin{aligned}x_{t+1} &= x_t - \eta \times \frac{\partial f}{\partial x} \\y_{t+1} &= y_t - \eta \times \frac{\partial f}{\partial y}\end{aligned}$$

Trong đó:

- (x_{t+1}, y_{t+1}) là tọa độ của điểm ở bước lặp tiếp theo.
- (x_t, y_t) là tọa độ của điểm ở bước lặp hiện tại.
- η là learning rate.
- $\frac{\partial f}{\partial x}$ và $\frac{\partial f}{\partial y}$ là các **partial derivatives** (Tạm dịch: đạo hàm riêng) của hàm f theo từng biến x và y . Chúng hợp thành vector gradient $\nabla f = (\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y})$.

Áp dụng vào hàm số $f(x, y) = x^2 + y^2$, ta tính được gradient:

$$\nabla f(x, y) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) = (2x, 2y).$$

Khi đó, công thức cập nhật cụ thể là:

$$\begin{aligned} x_{t+1} &= x_t - \eta \times (2x_t), \\ y_{t+1} &= y_t - \eta \times (2y_t). \end{aligned}$$


Ví dụ minh họa: Khởi tạo $(x_0, y_0) = (6.0, 9.0)$, chọn $\eta = 0.1$:

$$\begin{aligned} x_1 &= 6.0 - 0.1 \times 2 \times 6.0 = 4.8, \\ y_1 &= 9.0 - 0.1 \times 2 \times 9.0 = 7.2, \\ x_2 &= 4.8 - 0.1 \times 2 \times 4.8 = 3.84, \\ y_2 &= 7.2 - 0.1 \times 2 \times 7.2 = 5.76. \\ &\dots \end{aligned}$$

Tại mỗi bước, điểm (x_t, y_t) sẽ di chuyển theo đường cong dốc dần về phía gốc tọa độ, tương tự như việc “trượt xuống” đáy một chiếc chảo parabol.

II.4.3. Sử dụng hàm hợp (Chain-rule)

Trong thực tế, hàm mục tiêu thường là một *hàm hợp*, ví dụ $g(f(x))$. Để áp dụng Gradient Descent, ta cần tính đạo hàm của toàn bộ hàm hợp theo **chain rule** (Tạm dịch: Quy tắc chuỗi). Quy tắc này cho phép phân rã đạo hàm của hàm phức tạp thành tích của các đạo hàm đơn giản hơn.



Hình 15: Minh họa hàm $f(x) = 2x - 1$, $g(f) = (f - 3)^2$ và hàm hợp $g(f(x)) = (2x - 4)^2$. Đường đỏ cho thấy hình dạng tổng thể của hàm hợp cần tối ưu.

Xét hàm hợp $g(f(x))$ với $f(x) = 2x - 1$ và $g(f) = (f - 3)^2$. Để tính đạo hàm của g theo x , ta áp dụng quy tắc chuỗi:

$$\frac{d}{dx}g(f(x)) = \frac{dg}{df} \times \frac{df}{dx}$$

Trong đó:

- $\frac{d}{dx}g(f(x))$ là đạo hàm của hàm hợp (hàm ngoài g theo biến cuối cùng x).
- $\frac{dg}{df}$ là đạo hàm của hàm ngoài g theo hàm trong f .
- $\frac{df}{dx}$ là đạo hàm của hàm trong f theo biến x .

Ta tính đạo hàm từng phần:

$$\begin{aligned}\frac{df}{dx} &= \frac{d}{dx}(2x - 1) = 2, \\ \frac{dg}{df} &= \frac{d}{df}(f - 3)^2 = 2(f - 3).\end{aligned}$$

Thay $f = 2x - 1$ vào, ta có $\frac{dg}{df} = 2((2x - 1) - 3) = 2(2x - 4)$. Áp dụng quy tắc chuỗi:

$$\frac{d}{dx}g(f(x)) = \underbrace{2(2x - 4)}_{\frac{dg}{df}} \times \underbrace{2}_{\frac{df}{dx}} = 8x - 16.$$

Khi đó, công thức cập nhật của Gradient Descent là:

$$x_{t+1} = x_t - \eta \cdot (8x_t - 16).$$

💡 **Ví dụ minh họa:** Khởi tạo $x_0 = 3$, chọn $\eta = 0.1$:

$$\begin{aligned}x_1 &= 3 - 0.1 \times (8 \times 3 - 16) = 2.2 \\ x_2 &= 2.2 - 0.1 \times (8 \times 2.2 - 16) = 2.04 \\ x_3 &= 2.04 - 0.1 \times (8 \times 2.04 - 16) = 2.008 \\ &\dots\end{aligned}$$

Ta thấy x_t dần tiến về 2, chính là điểm cực tiểu của hàm hợp. Điều này minh họa cách quy tắc chuỗi là nền tảng cho thuật toán **backpropagation** (Tạm dịch: lan truyền ngược) trong mạng nơ-ron, giúp tối ưu các mô hình học sâu phức tạp.


II.5. Các vấn đề cần lưu ý về Linear Regression

Sau khi đã xây dựng nền tảng từ các khái niệm toán học cơ bản đến việc áp dụng chúng trong bài toán Hồi quy tuyến tính, phần này sẽ thảo luận sâu hơn về một số khía cạnh lý thuyết và thực tiễn quan trọng, nhằm củng cố sự hiểu biết về bản chất và cách vận hành của mô hình.

1. Lưu ý trong việc chọn learning rate

Learning rate, ký hiệu là η , là một trong những siêu tham số quan trọng nhất, quyết định độ lớn của mỗi bước cập nhật trong công thức Gradient Descent. Việc lựa chọn giá trị η có ảnh hưởng trực tiếp đến tốc độ và sự ổn định của quá trình hội tụ, như được minh họa trong các ví dụ về tối ưu hóa hàm số $f(x) = x^2$.


- Nếu η **quá nhỏ**: Quá trình huấn luyện sẽ hội tụ rất chậm. Thuật toán sẽ cần rất nhiều bước lặp để có thể tiến đến gần điểm cực tiểu.
- Nếu η **quá lớn**: Thuật toán có thể “nhảy” qua điểm cực tiểu và không thể hội tụ. Trong trường hợp tệ hơn, giá trị của x có thể dao động mạnh và ngày càng xa điểm tối ưu, dẫn đến hiện tượng **divergence** (Tạm dịch: phân kỳ).



Hình 16: Ảnh hưởng của learning rate (η) đến quá trình hội tụ của Gradient Descent. Bên trái: η nhỏ dẫn đến hội tụ chậm. Giữa: η vừa phải giúp hội tụ hiệu quả. Phải: η lớn dẫn đến dao động và không thể hội tụ.

Do đó, việc tìm ra một giá trị η phù hợp, không quá lớn cũng không quá nhỏ chính là một trong các yếu tố then chốt để đảm bảo mô hình hội tụ nhanh và ổn định.

2. Điều kiện đối với Hàm mục tiêu



Hình 17: Minh họa các loại hàm mục tiêu. Từ trái qua: Hàm liên tục và khả vi, hàm không khả vi tại $x=0$, và hàm không liên tục tại $x=0$.

Gradient Descent là một phương pháp tối ưu hóa dựa trên đạo hàm. Do đó, để thuật toán có thể hoạt động, hàm mục tiêu (hay hàm mất mát) mà chúng ta cần cực tiểu hóa phải có khả năng lấy đạo hàm (khả vi).

- Các hàm liên tục và khả vi, như hàm Parabol $f(x) = x^2$, là điều kiện lý tưởng cho Gradient Descent.
- Tuy nhiên, trong thực tế, ta có thể gặp các hàm không khả vi tại một vài điểm, ví dụ như hàm Mean Absolute Error có dạng $f(x) = |x|$, không khả vi tại $x = 0$. Tại những điểm này, ta cần các kỹ thuật xử lý nâng cao hơn, nhưng ý tưởng chung về việc di chuyển ngược hướng độ dốc vẫn được áp dụng.
- Các hàm discontinuous (Tạm dịch: Không liên tục) sẽ gây ra khó khăn lớn cho Gradient Descent, vì khái niệm đạo hàm không được xác định tại các điểm gián đoạn.

3. Phương pháp cập nhật với nhiều điểm dữ liệu

Khi tập dữ liệu có nhiều hơn một mẫu, ta có những cách tiếp cận khác nhau để tính toán và cập nhật gradient. Đối với phương pháp này, ta có hai hướng chính:

1. **Cập nhật tuần tự:** Với cách tiếp cận này, ta duyệt qua từng mẫu dữ liệu. Sau mỗi mẫu, ta tính toán gradient và cập nhật ngay lập tức các tham số của mô hình. Quá trình này được lặp lại cho đến khi duyệt qua hết dữ liệu. Cách làm này tương ứng với sơ đồ cập nhật tại mỗi thời điểm t và $t + 1$.
2. **Cập nhật theo batch** Thay vì cập nhật riêng lẻ, ta tính toán gradient cho tất cả các mẫu dữ liệu theo từng batch. Sau đó, ta tính trung bình các gradient này lại và chỉ thực hiện một lần cập nhật duy nhất cho các tham số dựa trên giá trị trung bình đó.

Đối với mỗi phương pháp cập nhật, ta đều thấy rằng nó sẽ có ưu và nhược điểm riêng, và việc lựa chọn phương pháp nào cũng sẽ ảnh hưởng đến tốc độ cũng như quỹ đạo hội tụ của mô hình.

III. Thực hành: Xây dựng mô hình dự đoán giá vàng

Sau khi đã nắm vững nền tảng lý thuyết về tối ưu hóa và Gradient Descent, bây giờ là lúc chúng ta áp dụng những kiến thức đó vào một bài toán cụ thể. Trong phần này, chúng ta sẽ cùng nhau xây dựng một mô hình Hồi quy tuyến tính đa biến từ đầu để dự đoán giá vàng, một trong những bài toán kinh điển và đầy tính ứng dụng trong lĩnh vực tài chính.

III.1. Giới thiệu về bài toán

Hãy tưởng tượng bạn là một nhà phân tích dữ liệu, được giao nhiệm vụ tìm ra mối quan hệ giữa giá vàng và các chỉ số kinh tế vĩ mô. Mục tiêu của chúng ta là xây dựng một mô hình có khả năng dự đoán giá vàng (USD/ounce) dựa trên ba đặc trưng đầu vào quan trọng:

1. **Chỉ số USD Index:** Đo lường sức mạnh của đồng đô la Mỹ so với các loại tiền tệ khác. Dựa trên lý thuyết kinh tế, vàng và USD thường được xem là hai kênh trú ẩn cạnh tranh. Nhiệm vụ của mô hình là định lượng hóa mối quan hệ tiềm ẩn này và đánh giá rằng liệu sự thay đổi của USD Index có thực sự tác động ngược chiều lên giá vàng không, và nếu có thì mạnh đến mức nào?
2. **Tỷ lệ lạm phát (%):** Khi lạm phát tăng cao, sức mua của tiền tệ giảm xuống. Vàng thường được xem là một “hàng rào” chống lạm phát hiệu quả. Chúng ta sẽ xây dựng mô hình để kiểm chứng giả thuyết này và đo lường mức độ nhạy cảm của giá vàng trước những thay đổi về lạm phát từ dữ liệu thực tế.
3. **Giá dầu (USD/thùng):** Giá dầu tăng thường là một chỉ báo sớm cho lạm phát, do đó có thể tồn tại một mối tương quan thuận với giá vàng. Mô hình của chúng ta sẽ giúp làm rõ liệu mối tương quan này có đủ mạnh và ổn định để trở thành một yếu tố dự báo hữu ích hay không.

Dữ liệu chúng ta sử dụng là một bộ giả lập gồm 20 bản ghi, thể hiện các quan sát tại những thời điểm khác nhau. Về mặt cấu trúc, bộ dữ liệu này có thể được chia thành hai thành phần chính:

- **Đặc trưng đầu vào (Input Features)** — X : Gồm 3 cột đầu tiên (USD Index, Lạm phát, Giá dầu). Đây là những thông tin chúng ta dùng để đưa ra dự đoán.
- **Biến mục tiêu (Target Variable)** — y : Là cột cuối cùng (Giá vàng), đây là giá trị mà chúng ta muốn mô hình có thể dự đoán được.

Chi tiết của bộ dữ liệu được trình bày trong bảng dưới đây:

USD Index (x_1)	Lạm phát (% - x_2)	Giá dầu (USD - x_3)	Giá vàng (USD - y)
92.5	2.1	65.3	1800
93.2	2.5	67.2	1825
91.8	2.3	64.0	1795
94.0	2.8	70.1	1850
95.2	3.0	72.5	1880
96.1	3.2	74.3	1905
...	...	...	...
90.0	1.7	60.5	1740
98.0	3.7	78.0	1950
99.2	4.0	80.5	1980
88.5	1.3	58.0	1700
87.8	1.1	56.5	1680
86.5	1.0	55.0	1650
100.0	4.2	82.0	2000

Bảng 1: Bộ dữ liệu giả lập về các yếu tố kinh tế và giá vàng (20 mẫu).

Từ những quan sát trực quan này, ta có thể đặt ra giả thuyết về một mối quan hệ gần như tuyến tính giữa các biến đầu vào và giá vàng. Giả định này chính là cơ sở để chúng ta áp dụng mô hình Linear Regression cho bài toán.

Áp dụng lý thuyết Linear Regression, chúng ta cần tìm một phương trình tuyến tính có dạng:

$$\text{Giá vàng dự đoán}(\hat{y}) = w_1 \cdot (\text{USD Index}) + w_2 \cdot (\text{Lạm phát}) + w_3 \cdot (\text{Giá dầu}) + b$$

Nhiệm vụ của chúng ta là chọn và sử dụng thuật toán tối ưu hóa để tìm ra các giá trị tối ưu cho các trọng số $\{w_1, w_2, w_3\}$ và hệ số chặn b .

Để làm được điều này, ta kết hợp phương trình dự đoán với hai yếu tố cốt lõi:

- **Hàm mất mát Mean Squared Error (MSE):** Mục đích nhằm đo lường sai số giữa dự đoán và thực tế.
- **Thuật toán tối ưu hóa Gradient Descent:** Mục đích nhằm điều chỉnh các tham số nhằm giảm thiểu sai số.

Về bản chất, Gradient Descent sẽ lặp đi lặp lại việc tính toán “hướng” mà sai số đang tăng nhanh nhất, sau đó cập nhật các tham số theo hướng ngược lại. Quá trình này sẽ giúp mô hình “học” và hội tụ đến bộ tham số tối ưu nhất.

III.2. Cài đặt và thực nghiệm

Bây giờ, chúng ta sẽ chuyển thể các ý tưởng trên thành mã nguồn Python. Toàn bộ quá trình, từ việc chuẩn bị dữ liệu, cài đặt mô hình, huấn luyện, đến việc đưa ra dự đoán cuối cùng, sẽ tuân theo một luồng thực nghiệm rõ ràng. Tiếp theo, ta sẽ cùng nhau xây dựng luồng thực nghiệm bằng các bước như sau:

☰ Xây dựng luồng thực nghiệm

📊 Bước 1: Chuẩn bị dữ liệu

Chuyển đổi bảng dữ liệu thô thành các cấu trúc toán học mà máy tính có thể hiểu được, bao gồm ma trận đặc trưng $\mathbf{X}$ (các đặc trưng kinh tế) và vector nhãn $\mathbf{y}$ (giá vàng).

✂️ Bước 2: Tiền xử lý, Chuẩn hóa dữ liệu

Sử dụng kỹ thuật Z-score để đưa các cột dữ liệu có thang đo khác nhau (ta sẽ đưa các cột như USD Index có chỉ số từ 86-100 và Lạm phát chỉ số từ 1.0-4.2) về cùng một quy mô. Đây là bước quan trọng để thuật toán Gradient Descent hoạt động hiệu quả.

⚙️ Bước 3: Huấn luyện mô hình

Khởi tạo các tham số $\mathbf{w}$ và $\mathbf{b}$ (thường bằng 0), sau đó lặp đi lặp lại quá trình cập nhật chúng bằng Gradient Descent để giảm thiểu sai số (MSE) giữa dự đoán và thực tế.

📊 Bước 4: Đánh giá và dự đoán

Sau khi mô hình đã “học” xong, ta sử dụng các tham số tối ưu đã tìm được để đưa ra dự đoán trên dữ liệu và so sánh chúng với giá trị thực tế để kiểm tra hiệu quả.

Sau đây, ta sẽ cùng nhau thực hiện code Python hoàn chỉnh, áp dụng quy trình từ luồng thực nghiệm được thiết kế. Với mỗi đoạn code đều được chú thích rõ ràng, tương ứng với từng bước trong luồng.

gold_price_prediction.py

```
import numpy as np

# BƯỚC 1: CHUẨN BỊ DỮ LIỆU
# -----
# Ma trận đặc trưng X (20 mẫu, 3 đặc trưng - USD Index, Lạm phát, Giá dầu)
X = np.array([
    [92.5, 2.1, 65.3], [93.2, 2.5, 67.2], [91.8, 2.3, 64.0],
    [94.0, 2.8, 70.1], [95.2, 3.0, 72.5], [96.1, 3.2, 74.3],
    [90.5, 1.8, 61.0], [92.0, 2.0, 63.2], [89.5, 1.5, 59.8],
    [97.0, 3.5, 76.2], [95.8, 3.1, 73.8], [94.5, 2.9, 71.5],
    [91.2, 2.2, 62.8], [90.0, 1.7, 60.5], [98.0, 3.7, 78.0],
    [99.2, 4.0, 80.5], [88.5, 1.3, 58.0], [87.8, 1.1, 56.5],
    [86.5, 1.0, 55.0], [100.0, 4.2, 82.0]
], dtype=float)

# Vector nhãn y (giá vàng thực tế)
y = np.array([
```

```

    1800, 1825, 1795, 1850, 1880, 1905, 1750, 1780, 1725, 1925,
    1890, 1860, 1775, 1740, 1950, 1980, 1700, 1680, 1650, 2000
], dtype=float)

# BƯỚC 2: TIỀN XỬ LÝ - CHUẨN HÓA DỮ LIỆU (Z-SCORE)
# -----
# Đưa các đặc trưng về cùng thang đo (trung bình 0, độ lệch chuẩn 1)
X_mean = X.mean(axis=0)
X_std = X.std(axis=0)
Xn = (X - X_mean) / X_std

# BƯỚC 3: HUẤN LUYỆN MÔ HÌNH
# -----
class LinearRegressionGD:
    """
    Cài đặt mô hình Hồi quy tuyến tính từ đầu bằng Gradient Descent.
    """
    def __init__(self, lr=0.05, epochs=1000):
        self.lr = lr
        self.epochs = epochs
        self.w = None
        self.b = 0.0

    def predict(self, X):
        return X @ self.w + self.b

    def mse(self, y_true, y_pred):
        return np.mean((y_true - y_pred)**2)

    def fit(self, X, y, verbose_every=100):
        m, n = X.shape # m: số mẫu, n: số đặc trưng
        self.w = np.zeros(n)
        self.b = 0.0

        for ep in range(1, self.epochs + 1):
            y_hat = self.predict(X)
            residual = y_hat - y

            # Tính gradient theo công thức đạo hàm riêng đã vector hóa
            dw = (2/m) * (X.T @ residual)
            db = (2/m) * np.sum(residual)

            # Cập nhật tham số ngược hướng gradient
            self.w -= self.lr * dw
            self.b -= self.lr * db

            if verbose_every and ep % verbose_every == 0:
                print(f"Epoch {ep:4d} | MSE: {self.mse(y, y_hat):.2f}")

# Khởi tạo và huấn luyện mô hình
print("--- Bắt đầu quá trình huấn luyện ---")
model = LinearRegressionGD(lr=0.05, epochs=1000)
model.fit(Xn, y, verbose_every=200)

```

```

print("--- Huấn luyện hoàn tất! ---")

# BƯỚC 4: ĐÁNH GIÁ VÀ DỰ ĐOÁN
# -----
print("\n--- KẾT QUẢ CUỐI CÙNG ---")
print(f"Trọng số w đã học: {model.w}")
print(f"Hệ số chặn b đã học: {model.b:.4f}")

# Dự đoán trên toàn bộ tập dữ liệu đã chuẩn hoá
y_pred = model.predict(Xn)

print("\n--- SO SÁNH 5 MẪU ĐẦU TIÊN ---")
print("Giá thực tế | Giá dự đoán")
print("-----")
for i in range(5):
    print(f"{y[i]:<12.2f} | {y_pred[i]:.2f}")

```

Kết quả huấn luyện

```

--- Bắt đầu quá trình huấn luyện ---
Epoch 200 | MSE: 12.01
Epoch 400 | MSE: 10.93
Epoch 600 | MSE: 10.05
Epoch 800 | MSE: 9.32
Epoch 1000 | MSE: 8.73
--- Huấn luyện hoàn tất! ---

--- KẾT QUẢ CUỐI CÙNG ---
Trọng số w đã học: [44.50968152 29.55847415 23.99202775]
Hệ số chặn b đã học: 1823.0000

--- SO SÁNH 5 MẪU ĐẦU TIÊN ---
Giá thực tế | Giá dự đoán
-----
1800.00      | 1795.52
1825.00      | 1822.35
1795.00      | 1789.60
1850.00      | 1850.19
1880.00      | 1878.13

```


III.2.1. Đánh giá kết quả

Sau khi thực thi mã nguồn, các kết quả thu được cho phép chúng ta tiến hành đánh giá mô hình trên ba phương diện chính: quá trình hội tụ, ý nghĩa của các tham số, và chất lượng dự đoán.

- **Về quá trình hội tụ của mô hình:** Kết quả huấn luyện cho thấy giá trị của hàm mất mát MSE giảm một cách ổn định qua các epochs (từ 12.01 xuống 8.73). Điều này chỉ ra rằng thuật toán Gradient Descent đã hoạt động hiệu quả, thành công trong việc tìm ra một bộ tham số giúp cực tiểu hóa sai số trên tập dữ liệu huấn luyện, đúng như mục tiêu đã được trình bày trong phần lý thuyết.
- **Về ý nghĩa của các hệ số đã học:** Các trọng số w và hệ số chặn b là kết quả của quá trình tối ưu hóa trên bộ dữ liệu cụ thể này. Việc diễn giải chúng cung cấp cái nhìn sâu sắc về các mối quan hệ mà mô hình đã tìm thấy:
 - **Diễn giải các hệ số w_j :** Mỗi hệ số w_j định lượng mức độ và chiều hướng tác động của đặc trưng x_j lên biến mục tiêu y . Dựa trên kết quả, ta thấy cả ba hệ số w_1, w_2, w_3 đều mang giá trị dương. Điều này có nghĩa là, trong phạm vi của bộ dữ liệu này, mô hình đã xác định một mối quan hệ **đồng biến** giữa cả ba đặc trưng (USD Index, Lạm phát, Giá dầu) và biến mục tiêu (giá vàng).
 - **Phân tích và đánh giá dữ liệu:** Việc mô hình tìm thấy mối quan hệ đồng biến cho cả ba yếu tố cần được diễn giải một cách cẩn trọng. Kết quả này phản ánh các quy luật bên trong 20 mẫu dữ liệu giả lập được cung cấp. Do kích thước mẫu nhỏ, các mối tương quan ngẫu nhiên hoặc các yếu tố nhiễu có thể ảnh hưởng lớn đến các hệ số cuối cùng. Trong một bài toán thực tế với bộ dữ liệu lớn và đa dạng hơn, các hệ số này có thể sẽ phản ánh các quy luật kinh tế tổng quát một cách chính xác và khách quan hơn.
 - **Diễn giải hệ số chặn (b):** Hệ số chặn b (khoảng 1823.0) đại diện cho giá trị dự đoán cơ sở của vàng khi tất cả các đặc trưng đầu vào đều bằng 0 (trên thang đo đã được chuẩn hóa), hay nói cách khác, khi các đặc trưng ở giá trị trung bình của chúng.
- **Về chất lượng dự đoán của mô hình:** Bảng so sánh cho thấy các giá trị dự đoán rất sát với giá trị thực tế trên 5 mẫu đầu tiên. Điều này chứng tỏ mô hình có khả năng khớp tốt với dữ liệu đã được dùng để huấn luyện. Tuy nhiên, cần lưu ý rằng việc đánh giá trên chính tập huấn luyện chưa thể kết luận về khả năng tổng quát hóa của mô hình khi đối mặt với dữ liệu mới, chưa từng thấy trước đây.

Như vậy, chúng ta đã cùng nhau đi hết một chu trình hoàn chỉnh, bắt đầu từ việc phân tích một bài toán kinh tế, chúng ta đã vận dụng các khái niệm nền tảng như tối ưu hóa và Gradient Descent để xây dựng một mô hình toán học, và cuối cùng là hiện thực hóa nó bằng mã nguồn. Quá trình phân tích, xây dựng, và đánh giá mô hình như chúng ta vừa thực hiện chính là quy trình nền tảng cho hầu hết các bài toán học máy phức tạp hơn sau này.

IV. Câu hỏi trắc nghiệm

1. Trong thuật toán Gradient Descent, điều gì sẽ xảy ra nếu chọn learning rate (η) quá lớn?
 - (a) Quá trình hội tụ sẽ rất chậm vì bước đi quá nhỏ.
 - (b) Mô hình sẽ hội tụ nhanh hơn và luôn chính xác hơn.
 - (c) Mô hình có thể “nhảy” qua điểm cực tiểu và không thể hội tụ, có thể dẫn đến phân kỳ.
 - (d) Mô hình sẽ không bị ảnh hưởng bởi các điểm dữ liệu ngoại lai (outliers).
2. Nguyên tắc cập nhật tham số cốt lõi của thuật toán Gradient Descent là gì?
 - (a) Di chuyển tham số theo cùng hướng với hướng của đạo hàm (gradient).
 - (b) Di chuyển tham số theo hướng ngược lại với hướng của đạo hàm (gradient).
 - (c) Luôn giảm giá trị của tham số đi một hằng số sau mỗi bước lặp.
 - (d) Tăng giá trị của tham số nếu đạo hàm âm và giảm nếu đạo hàm dương.
3. Một trong những điều kiện quan trọng nhất đối với Loss Function để có thể áp dụng hiệu quả thuật toán Gradient Descent là gì?
 - (a) Hàm số phải là một đường thẳng.
 - (b) Hàm số phải luôn nhận giá trị dương.
 - (c) Hàm số phải khả vi (differentiable) tại hầu hết các điểm.
 - (d) Hàm số phải có ít nhất hai điểm cực tiểu để lựa chọn.

Từ câu hỏi này trở đi, các ví dụ và phép tính sẽ được minh họa dựa trên tập dữ liệu `advertising.csv`, [tải tại đây](#) – một tập dữ liệu kinh điển trong học máy, mô tả mối quan hệ giữa chi phí quảng cáo trên các kênh **TV**, **Radio**, **Newspaper** và doanh số bán hàng (**Sales**).

4. Theo thống kê: `mean Sales = 15.1305`, `std Sales = 5.283892`. Z-score của giá trị `Sales = 20` là bao nhiêu?
 - (a) 0.52.
 - (b) 0.92.
 - (c) 1.22.
 - (d) 1.52.
5. Với $z = 1.322319$ của `Sales`, giá trị `Sales` theo đơn vị gốc xấp xỉ bằng bao nhiêu?
 - (a) 20.41.
 - (b) 21.50.
 - (c) 22.12.
 - (d) 23.45.

6. Với hàng chuẩn hóa đầu tiên: $(x_1, x_2, x_3, y) = (0.969852, 0.981522, 1.778945, 1.322319)$ và khởi tạo $w_1 = w_2 = w_3 = b = 0$. Giá trị $\hat{y}$ là:
- (a) 0.
 - (b) 1.322.
 - (c) 0.97.
 - (d) 2.75.
7. Với dữ kiện câu trên, loss cho một mẫu $L = (\hat{y} - y)^2$ là:
- (a) 0.8743.
 - (b) 1.3223.
 - (c) 1.7485.
 - (d) 2.6446.
8. Dùng learning rate $\eta = 10^{-4}$ trên **mẫu đầu tiên** ở trên. Sau **1** lần cập nhật, w_1 xấp xỉ:
- (a) 0.00006.
 - (b) 0.00026.
 - (c) 0.00256.
 - (d) 0.02565.
9. Vẫn với learning rate $\eta = 10^{-4}$ và **mẫu đầu tiên**, bias mới b sau 1 bước cập nhật xấp xỉ:
- (a) -0.00026 .
 - (b) 0.
 - (c) 0.00026.
 - (d) 0.00264.
10. Dùng các trọng số sau huấn luyện: $w_1 = 0.8905$, $w_2 = 0.3169$, $w_3 = -0.0053$, $b = 0.0066$. Với $x = (0.969852, 0.981522, 1.778945)$, dự đoán chuẩn hóa $\hat{y}$ xấp xỉ:
- (a) 1.24.
 - (b) 1.17.
 - (c) 1.30.
 - (d) 1.33.

V. Tài liệu tham khảo


- [1] G. S. et al., *Calculus Volume 1*, 3rd. Wellesley, MA: Wellesley-Cambridge Press, 2017, p. 706.
- [2] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.

Phụ lục

1. **Datasets:** Các file dataset được đề cập trong bài có thể được tải tại [đây](#).
2. **Hint:** Các file code gợi ý có thể được tải tại [đây](#).
3. **Solution:** Các file code cài đặt hoàn chỉnh và phần trả lời nội dung trắc nghiệm có thể được tải tại [đây](#).
4. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại [đây](#). Tất cả câu hỏi sẽ được trả lời trong vòng tối đa 4 tiếng.

AIO_Family

🔒 Private group · 2.0K members



Hình 18: Hình ảnh group facebook AIO Q&A.



Step-by-Step: Simple Linear Regression


Nguyễn Anh Khôi

Dương Đình Thắng

Đinh Quang Vinh

I. Dẫn nhập

Hãy tưởng tượng chúng ta có một bài toán như sau: *Xây dựng một chương trình tự động dự đoán tiền lương của nhân viên dựa trên số năm kinh nghiệm của họ.* Để trực quan hóa, ta gọi số năm kinh nghiệm là (x) và số tiền lương là (y). Khi đó, với một vài thông tin cho trước của một vài nhân viên, ta có thể sử dụng trực đồ thị Oxy để trực quan hóa dữ liệu như hình sau:




Hình 1: Minh họa dữ liệu tiền lương theo số năm kinh nghiệm trên đồ thị.

Mục lục


I.	Dẫn nhập	1
II.	Thực hành	12
III.	Câu hỏi trắc nghiệm	18
	Phụ lục	20

Câu hỏi đặt ra là, làm cách nào để ta có thể code một chương trình có thể tự động dự đoán tiền lương dựa vào số năm kinh nghiệm? Quan sát thấy rằng, khi ta dùng một đường vẽ ngang qua một điểm dữ liệu, ta thực chất có thể dùng phương trình đường thẳng này để dự đoán được chính xác tiền lương của nhân viên ứng với số năm kinh nghiệm của họ.



Hình 2: Minh họa một đường thẳng tuyến tính trên trục tọa độ.


Như vậy, với một đường thẳng bất kỳ, ta hoàn toàn có thể dùng nó cho “chương trình” dự đoán tiền lương. Khi xét một phương trình đường thẳng $f(x) = wx + b$, có thể thấy mỗi đường thẳng khác nhau sẽ có số w và b khác nhau **(1)**.



Hình 3: Các giá trị w và b khác nhau sẽ cho ta các đường thẳng khác nhau.

Quan sát hình 3, đường thẳng trên cùng (màu tím) đi qua 2 điểm (Experience=3, Salary=60) và (6, 93); đường thẳng dưới cùng (màu vàng) đi qua 2 điểm (4, 55) và (5, 66); đường thẳng màu đỏ nằm giữa 2 đường thẳng trên và không đi qua bất kỳ điểm nào.


Mặc dù không thể nào vẽ được một đường thẳng có thể dự đoán chính xác toàn bộ các điểm cho trước. Tuy nhiên, từ quan sát này, với các điểm dữ liệu cho trước như vậy, liệu rằng chúng ta có thể vẽ được một đường thẳng mà có thể xấp xỉ được gần đúng các điểm dữ liệu hiện có hay không?



Hình 4: Khoảng cách từ một điểm đến một đường thẳng trong ngữ cảnh Linear Regression thường được gọi là **error**.

Để tìm được một đường thẳng xấp xỉ tối ưu nhất, ta có thể nghĩ theo hướng rằng, khoảng cách từ các điểm trong đồ thị đến đường thẳng đó phải là ngắn nhất. Ta sẽ tạm gọi tổng các khoảng cách này với một cái tên là **loss**.

Tiếp theo, chúng ta sẽ xem xét các giá trị có thể thay đổi để khiến loss giảm, xét về phải của phương trình đường thẳng $y = wx + b$, với x là dữ liệu đầu vào nên sẽ không thay đổi được. Vì vậy, ta chỉ có thể thay đổi 2 giá trị w và b để khiến loss giảm đi, sau đây là 2 hình ảnh trực quan cho các đường thẳng với các giá trị w và b khác nhau (được thay đổi theo một hướng tích cực mà chúng ta sẽ tìm hiểu ở các phần sau trong bài đọc này) và giá trị loss tương ứng với đường thẳng đó:



(a) Các đường thẳng với giá trị w và b khác nhau.

(b) Tổng khoảng cách giữa các điểm đến đường thẳng tương ứng của mỗi đường thẳng.

Hình 5: Minh họa về sự thay đổi giá trị của loss khi ta thay đổi giá trị w và b .

Có thể thấy rằng tại hình 5b, khi giá trị w và b thay đổi dần theo một hướng “tích cực” thì loss sẽ giảm dần; cho đến khi w và b là một giá trị phù hợp sẽ tạo ra một đường thẳng tối ưu nhất (đường thẳng đậm nhất trong hình 5a) cho các dữ liệu đang xét và khiến giá trị loss cũng đạt giá trị nhỏ nhất (như đường thẳng $y = 13.47x + 5.58$ với $w = 13.47$ và $b = 5.58$ thì có loss nhỏ nhất $loss = 300$) (2).

Từ (1) và (2), ta có một bài toán mới được phát biểu như sau: *Tìm w và b để giá trị loss là nhỏ nhất.* Để đơn giản và dễ hiểu, chúng ta sẽ xét riêng giá trị b , các bạn có thể nhìn hình dưới đây:


(a) Các đường thẳng với giá trị b khác nhau.

(b) Tổng khoảng cách giữa các điểm đến đường thẳng tương ứng của mỗi đường thẳng.

Hình 6: Minh họa về sự thay đổi giá trị của loss khi ta thay đổi giá trị b .

Xét cụ thể theo ví dụ trong hình, làm cách nào để ta có thể tìm được giá trị b tối ưu sao cho loss là nhỏ nhất? Giả sử ta có phương trình khoảng cách giữa y_i và $f(x_i)$ là $loss = (f(x_i) - y_i)^2 = ((wx_i + b) - y_i)^2$, với y_i là giá trị đúng hay nhãn cho giá trị đầu vào x_i và $f(x_i)$ là một phương


trình đường thẳng bất kỳ, nhận đầu vào là x_i và dự đoán giá trị $f(x_i)$ mới. Để tìm giá trị b tối ưu cho các dữ liệu x_i để hàm loss nhỏ nhất, ta sẽ cố định giá trị của w và chỉ thay đổi giá trị b và có thể trực quan mối quan hệ giữa loss và b như sau:



Hình 7: Thay đổi giá trị b trong khi giữ nguyên giá trị w .


Quan sát thấy, hàm loss của chúng ta lúc này là một đường parabol, và vị trí cực tiểu biểu trưng cho giá trị loss nhỏ nhất. Vậy chẳng phải lúc này nếu ta bằng một cách nào đó có thể tìm được giá trị b tại điểm cực tiểu này, ta sẽ tìm được đường thẳng có loss là thấp nhất không? Nhưng làm cách nào để ta có thể tự động tìm ra được giá trị b tối ưu này?

Nói một cách khác, nếu coi giá trị bias ta có ban đầu là một điểm nằm trên hàm loss, làm cách nào để ta có thể di chuyển điểm đó tiến về phía cực tiểu?




Hình 8: Di chuyển b đến vị trí làm cho hàm loss đạt cực tiểu

Để hiện thực được ý tưởng này, chúng ta có thể sử dụng công cụ đạo hàm. Nhắc qua một chút về khái niệm đạo hàm, khi chúng ta có giá trị đạo hàm tại một vị trí trên hàm số, chúng ta sẽ biết được thông tin về độ dốc của hàm tại điểm đó, biểu thị bằng đường tiếp tuyến tại một điểm, như hình dưới đây:




(a) Đường tiếp tuyến của một hàm tại một điểm.




(b) Giá trị đạo hàm (độ dốc) tại các điểm khác nhau.

Hình 9: Minh họa về đạo hàm.

Nếu giá trị đạo hàm dương, ta biết rằng hàm số đang tăng tại điểm đó. Ngược lại, nếu giá trị đạo hàm âm, ta biết rằng hàm số đang giảm tại điểm đó (như hình 9b). Tận dụng tính chất này, chúng ta có thể dùng thông tin đạo hàm để giúp đẩy điểm b đang ở một vị trí bất kỳ tiến về điểm cực tiểu bằng cách **đi ngược về hướng đạo hàm**:



(a) Khởi tạo một x bất kỳ và tính đạo hàm tại điểm đó.




(b) Áp dụng tính chất đi ngược hướng đạo hàm để tiến về cực tiểu.

Hình 10: Minh họa về việc đi ngược hướng đạo hàm.


Hãy thử lấy ví dụ một hàm bất kỳ có hình dạng như Hình 10a, nếu ta khởi tạo một điểm x bất kỳ và có đạo hàm tại điểm x này lớn hơn 0 (hoặc có thể quan sát thấy hàm đang tăng thì nghĩa là đạo hàm đang dương). Để tìm được điểm cực tiểu, ta sẽ đi ngược hướng đạo hàm, đó là đi sang trái (xem Hình 10b).

Và nếu hành động này cứ được tiếp diễn, dần dần ta sẽ có thể đưa được điểm b tiến gần đến điểm cực tiểu như hình sau:



Hình 11: Lặp lại quá trình tính đạo hàm và di chuyển ngược hướng đạo hàm cho đến khi điểm x làm cho hàm y đạt giá trị cực tiểu.

Từ đây, ý tưởng từ đây được hình thành như sau: Với lần lượt các điểm dữ liệu có sẵn, ta thực hiện tính đạo hàm b tại điểm đang xét và cập nhật lại giá trị b nhằm đưa b tiến gần đến điểm cực tiểu của hàm loss, dẫn đến ta có một đường thẳng tối ưu cho bài toán dự đoán tiền lương. Tổng hợp lại toàn bộ các thông tin trên, ta sẽ có một quy trình các bước tính toán (pipeline) để tìm được đường thẳng tối ưu như sau:



Hình 12: Pipeline tổng qua các bước tính toán để được tìm tham số w và b tối ưu.

Vì đường thẳng được xác định từ hai biến là w và b , ta xét trường hợp tổng quát trong pipeline này bao gồm đi tìm giá trị tối ưu cho hai biến w và b . Như vậy, các bước thực hiện trong pipeline trên có thể diễn giải như sau:

1. Khởi tạo ngẫu nhiên giá trị cho hai tham số là w và b .
2. Với mỗi mẫu dữ liệu thứ i trong bộ dữ liệu, ta áp dụng các bước tính toán sau:
 - (a) Thực hiện dự đoán output $\hat{y}_i$ với input là x_i . Ta có công thức sau:

$$\hat{y}_i = f(x_i) = wx_i + b$$

- (b) Để tính toán sự chênh lệch giữa giá trị dự đoán so với giá trị thực tế, ta đưa y_i và $\hat{y}_i$ vào hàm tính loss. Trong trường hợp này, hàm loss của chúng ta là hàm Squared Error có công thức như sau:

$$L(\hat{y}_i, y_i) = (\hat{y}_i - y_i)^2$$

- (c) Ta tìm giá trị đạo hàm tại mẫu dữ liệu thứ i cho hai tham số w và b để từ đó cập nhật lại đường tuyến tính với công thức sau:

$$\frac{\partial L}{\partial b} = \frac{\partial L}{\partial \hat{y}_i} \frac{\partial \hat{y}_i}{\partial b} = 2(\hat{y}_i - y_i)$$

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial \hat{y}_i} \frac{\partial \hat{y}_i}{\partial w} = 2x_i(\hat{y}_i - y_i)$$

- (d) Với giá trị đạo hàm riêng vừa tìm được cho hai tham số w và b trên mẫu dữ liệu i , ta cập nhật lại giá trị mới cho hai tham số này với công thức sau:

$$w = w - \eta \frac{\partial L}{\partial w}$$

$$b = b - \eta \frac{\partial L}{\partial b}$$

Với η là một hằng số không đổi. Theo thuật ngữ, ta gọi η là **learning rate**.

Sau đó, như đã đề cập, ta lặp lại quy trình ở bước 2 cho đến khi xử lý hết tất cả các mẫu dữ liệu trong bộ dữ liệu.

II. Thực hành

Dựa theo cách triển khai đã đề cập ở phía trên, chúng ta sẽ thử áp dụng để xây dựng một hàm có khả năng dự đoán số tiền lương của nhân viên dựa theo số năm kinh nghiệm của họ. Đầu tiên, chúng ta xem qua một bộ dữ liệu nhỏ theo bảng dưới đây:

Index	Experience	Salary (.million VND)
0	3	60
1	4	55
2	5	66
3	6	93

Bảng 1: Bộ dữ liệu về thông tin tiền lương của nhân viên theo số năm kinh nghiệm tương ứng tại một công ty X.

Bộ dữ liệu trên gồm có 4 mẫu (sample), ứng với số năm kinh nghiệm (Experience) sẽ có số tiền lương tương ứng (Salary). Ví dụ, tại mẫu dữ liệu có Index bằng 1, một nhân viên có 4 năm kinh nghiệm sẽ có tiền lương tương ứng là 55 triệu VND. Với đề bài trên, ta sẽ tiến hành áp dụng thuật toán mô tả ở phần Dẫn nhập theo từng bước như sau:

1. Khởi tạo giá trị ngẫu nhiên cho hai tham số w và b . Ở đây, mình giả sử $w = 10$ và $b = 5$. Chúng ta cũng sẽ chọn giá trị $\eta = 0.01$ để sử dụng cho phần cập nhật tham số.

Với hai giá trị này, ta thử áp dụng các công thức dự đoán và tính loss để dùng cho việc so sánh giữa giá trị trước và sau khi áp dụng thuật toán xem mức độ hiệu quả đến đâu. Đầu tiên, ta sẽ dự đoán mức lương của một nhân viên có 7 năm kinh nghiệm với công thức sau:


$$\hat{y} = wx + b = 10 \times 7 + 5 = 75$$

Tiếp theo là tính loss, mình sẽ dự đoán dựa trên trực giác dựa theo dữ liệu có được, nhìn chung số năm kinh nghiệm càng lớn thì mức lương càng cao. Mình nghĩ mức lương cho một nhân viên 7 năm sẽ là 100 triệu. Vậy loss sẽ có giá trị bằng:

$$L(\hat{y}, y) = (\hat{y} - y)^2 = (75 - 100)^2 = 625$$

Như có thể thấy, với giá trị loss tương đối cao, do đó, kết quả dự đoán của mô hình không được như mong đợi. Để cải thiện mô hình Linear Regression, chúng ta sẽ từng bước điều chỉnh các tham số w và b sao cho phù hợp với bộ dữ liệu trên.

2. Ta tiến hành duyệt qua lần lượt các mẫu trong bộ dữ liệu: Trước tiên là mẫu dữ liệu thứ 0, gồm có $x_0 = 3$, $y_0 = 60$ và thực hiện các bước tính toán:




Hình 13: Minh hoạ cho các bước 2.(a) và 2.(b).

(a) Output:

$$\hat{y}_0 = x_0 w + b = 3 \times 10 + 5 = 35$$

(b) Loss:

$$L(\hat{y}_0, y_0) = (\hat{y}_0 - y_0)^2 = (35 - 60)^2 = 625$$



Hình 14: Minh hoạ cho các bước 2.(c) và 2.(d).

(c) Tính đạo hàm:

- Tham số w :

$$\frac{\partial L}{\partial w} = 2x_0(\hat{y}_0 - y_0) = 2 \times 3 \times (35 - 60) = -150$$

- Tham số b :

$$\frac{\partial L}{\partial b} = 2(\hat{y}_0 - y_0) = 2 \times (35 - 60) = -50$$

(d) Cập nhật tham số:

- Tham số w :


$$w = w - \eta \frac{\partial L}{\partial w} = 10 - 0.01 \times (-150) = 11.5$$

- Tham số b :

$$b = b - \eta \frac{\partial L}{\partial b} = 5 - 0.01 \times (-50) = 5.5$$

Sau khi cập nhật, ta thu được giá trị tham số mới là $w = 11.5$ và $b = 5.5$.

3. Lặp lại như bước (2) cho mẫu dữ liệu tiếp theo gồm có $x_1 = 4$, $y_1 = 55$ và thực hiện các bước tính toán:




Hình 15: Minh hoạ cho các bước 3.(a) và 3.(b).

(a) Output:

$$\hat{y}_1 = x_1 w + b = 4 \times 11.5 + 5.5 = 51.5$$

(b) Loss:

$$L(\hat{y}_1, y_1) = (\hat{y}_1 - y_1)^2 = (51.5 - 55)^2 = 12.25$$



Hình 16: Minh hoạ cho các bước 3.(c) và 3.(d).

(c) Tính đạo hàm:

- Tham số w :

$$\frac{\partial L}{\partial w} = 2x_1(\hat{y}_1 - y_1) = 2 \times 4 \times (51.5 - 55) = -28$$

- Tham số b :

$$\frac{\partial L}{\partial b} = 2(\hat{y}_1 - y_1) = 2 \times (51.5 - 55) = -7$$

(d) Cập nhật tham số:

- Tham số w :

$$w = w - \eta \frac{\partial L}{\partial w} = 11.5 - 0.01 \times (-28) = 11.78$$

- Tham số b :

$$b = b - \eta \frac{\partial L}{\partial b} = 5.5 - 0.01 \times (-7) = 5.57$$

Sau khi cập nhật, ta thu được giá trị tham số mới là $w = 11.78$ và $b = 5.57$.

4. Thực hiện tương tự như đã làm với mẫu dữ liệu 0 và 1, ta lấy mẫu dữ liệu gồm có $x_2 = 5$, $y_2 = 66$ và thực hiện các bước tính toán:

(a) Output:

$$\hat{y}_2 = x_2 w + b = 5 \times 11.78 + 5.57 = 64.47$$

(b) Loss:

$$L(\hat{y}_2, y_2) = (\hat{y}_2 - y_2)^2 = (64.47 - 66)^2 = 2.3409$$

(c) Tính đạo hàm:

- Tham số w :

$$\frac{\partial L}{\partial w} = 2x_2(\hat{y}_2 - y_2) = 2 \times 5 \times (64.47 - 66) = -15.3$$

- Tham số b :

$$\frac{\partial L}{\partial b} = 2(\hat{y}_2 - y_2) = 2 \times (64.47 - 66) = -3.06$$

(d) Cập nhật tham số:

- Tham số w :

$$w = w - \eta \frac{\partial L}{\partial w} = 11.78 - 0.01 \times (-15.3) = 11.933$$

- Tham số b :

$$b = b - \eta \frac{\partial L}{\partial b} = 5.57 - 0.01 \times (-3.06) = 5.6006$$

Sau khi cập nhật, ta thu được giá trị tham số mới là $w = 11.933$ và $b = 5.6006$.

5. Với mẫu dữ liệu cuối cùng gồm có $x_3 = 6$, $y_3 = 93$ và thực hiện các bước tính toán tương tự:

(a) Output:

$$\hat{y}_3 = x_3 w + b = 6 \times 11.933 + 5.6006 = 77.1986$$

(b) Loss:

$$L(\hat{y}_3, y_3) = (\hat{y}_3 - y_3)^2 = (77.1986 - 93)^2 = 249.6842$$

(c) Tính đạo hàm:

- Tham số w :

$$\frac{\partial L}{\partial w} = 2x_3(\hat{y}_3 - y_3) = 2 \times 6 \times (77.1986 - 93) = -189.6168$$

- Tham số b :

$$\frac{\partial L}{\partial b} = 2(\hat{y}_3 - y_3) = 2 \times (77.1986 - 93) = -31.6028$$

(d) Cập nhật tham số:

- Tham số w :

$$w = w - \eta \frac{\partial L}{\partial w} = 11.933 - 0.01 \times (-189.6168) = 13.82916$$

- Tham số b :

$$b = b - \eta \frac{\partial L}{\partial b} = 5.6006 - 0.01 \times (-31.6028) = 5.916628$$

Sau khi cập nhật, ta thu được giá trị tham số mới là $w = 13.82916$ và $b = 5.916628$.

6. Sau khi duyệt qua tất cả các mẫu dữ liệu và các tham số w và b cũng đã được điều chỉnh lại cho phù hợp hơn với bộ dữ liệu của chúng ta. Để kiểm chứng điều này, ta sẽ thử dự đoán mức lương và tính loss với giá trị w và b mới này cho nhân viên có 7 năm kinh nghiệm. Trước tiên, mức lương của người nhân viên này là:

$$\hat{y} = wx + b = 13.82916 \times 7 + 5.916628 \approx 102.72$$

Kết quả dự đoán có vẻ tốt hơn ban đầu và đúng với mong đợi hơn. Để chắc chắn hơn, sau đây là giá trị loss với dự đoán này:

$$L(\hat{y}, y) = (\hat{y} - y)^2 = (102.72 - 100)^2 = 7.3984$$

Với kết quả loss nhỏ hơn so với ban đầu ($7.3984 < 625$) cho thấy mô hình đã được học và điều chỉnh lại các tham số bên trong sao cho phù hợp hơn với dữ liệu huấn luyện và có thể được sử dụng để dự đoán các dữ liệu mới từ bên ngoài mà vẫn đảm bảo độ chính xác cao.

Tóm lại, Simple Linear Regression được khởi tạo với các tham số w và b có giá trị ngẫu nhiên, các tham số này sau đó sẽ được điều chỉnh lại dựa trên dữ liệu được học, sao cho tối ưu nhất có thể. Dẫu vậy, đây cũng chỉ là một phiên bản đơn giản, trong các bài học tiếp theo, chúng ta sẽ đi sâu hơn vào từng bước “học” của mô hình và khái quát hơn cho các trường hợp tổng quát.

III. Câu hỏi trắc nghiệm

1. Trong linear regression, công thức đạo hàm theo b của L :

- (a) $\frac{\partial L}{\partial b} = 2(\hat{y} - y)$
- (b) $\frac{\partial L}{\partial b} = x(\hat{y} - y)$
- (c) $\frac{\partial L}{\partial b} = 2x(\hat{y} - y)$
- (d) $\frac{\partial L}{\partial b} = \hat{y}/y$

2. Với $w = 10$, $b = 5$, $x = 3$, $y = 60$, sai số bình phương là:

- (a) 625
- (b) 25
- (c) 35
- (d) 5

3. Nếu $\frac{\partial L}{\partial w} = -150$, $\eta = 0.01$, $w_{\text{old}} = 10$ thì w_{new} :

- (a) 8.5
- (b) 11.5
- (c) 10.15
- (d) 9.85

4. Với $x = 3$, $y = 60$, $w = 10$, $b = 5$, giá trị $\hat{y}$ là:

- (a) 30
- (b) 35
- (c) 60
- (d) 65

5. Với $L = \sum(\hat{y} - y)^2$, phát biểu đúng là:

- (a) Luôn âm
- (b) Có thể âm
- (c) Luôn không âm
- (d) Luôn bằng 0 khi $\hat{y} \neq y$

6. Tăng w (giữ b cố định) làm đường thẳng dự đoán của mô hình:

- (a) Tịnh tiến song song
- (b) Thay đổi độ nghiêng (độ dốc)
- (c) Dịch theo parabol
- (d) Mất giao điểm trục tung


7. Trong pipeline gradient descent, bước sau khi tính $\hat{y}$ là:
- (a) Cập nhật tham số
 - (b) Tính loss
 - (c) Chuẩn hoá đặc trưng
 - (d) Chia train/val
8. Nếu $\frac{\partial L}{\partial b} = -50$, $\eta = 0.01$, $b_{\text{old}} = 5$ thì b_{new} :
- (a) 4.5
 - (b) 5.95
 - (c) 5.0
 - (d) 5.5
9. Tăng b (giữ w cố định) làm đường thẳng:
- (a) Tịnh tiến dọc theo trục tung
 - (b) Quay quanh gốc tọa độ
 - (c) Co lại theo trục hoành
 - (d) Thay đổi độ cong
10. Với $w = 10$, $b = 5$ và các điểm $(3, 60)$, $(4, 55)$, $(5, 66)$, $(6, 93)$, SSE bằng:
- (a) 930
 - (b) 163
 - (c) 1630
 - (d) 1784

Phụ lục

1. **Hint:** Các file code gợi ý có thể được tải tại [đây](#).
2. **Solution:** Các file code cài đặt hoàn chỉnh và phần trả lời nội dung trắc nghiệm có thể được tải tại [đây](#).
3. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại [đây](#). Tất cả câu hỏi sẽ được trả lời trong vòng tối đa 4 tiếng.

AIO_Family

🔒 Private group · 2.0K members



Hình 17: Hình ảnh group facebook AIO Q&A.