

ĐỀ CƯƠNG LÝ THUYẾT CHI TIẾT PHÂN TÍCH DỮ LIỆU CHUỖI THỜI GIAN

Tổng hợp theo 6 slide: Giới thiệu, Kỹ thuật xử lý, Trích chọn đặc trưng, Mô hình thống kê, Học máy & học sâu, Một số ứng dụng

Mục tiêu: giúp ôn thi lý thuyết, nắm bản chất khái niệm, công thức chính, ví dụ và câu hỏi dễ gặp.

Mục lục

- 1. Tổng quan về dữ liệu chuỗi thời gian
- 2. Kỹ thuật xử lý dữ liệu chuỗi thời gian
- 3. Trích chọn đặc trưng chuỗi thời gian
- 4. Mô hình thống kê cho chuỗi thời gian
- 5. Học máy và học sâu cho chuỗi thời gian
- 6. Một số ứng dụng thực tế
- 7. Bảng so sánh nhanh các nhóm phương pháp
- 8. Bộ câu hỏi ôn tập lý thuyết

Lưu ý ôn tập: nên học theo mạch từ dữ liệu -> xử lý -> đặc trưng -> mô hình -> ứng dụng. Khi trả lời thi, luôn nêu: khái niệm, mục đích, cách làm, ưu/nhược điểm và ví dụ.

1. Tổng quan về dữ liệu chuỗi thời gian

1.1. Khái niệm chuỗi thời gian

Chuỗi thời gian là tập hợp các quan sát của một hiện tượng được thu thập theo trình tự thời gian. Mỗi quan sát gắn với một thời điểm hoặc một chỉ số thời gian cụ thể. Điểm quan trọng nhất là thứ tự của các quan sát mang ý nghĩa phân tích; nếu đảo thứ tự dữ liệu, thông tin về xu hướng, mùa vụ, độ trễ và quan hệ quá khứ - hiện tại có thể bị mất.

Y_t : giá trị quan sát tại thời điểm t
 $t = 1, 2, \dots, T$: chỉ số thời gian

Ví dụ: nhiệt độ trung bình theo ngày, doanh số bán hàng theo tháng, giá cổ phiếu theo phút, lưu lượng mạng theo giây, tín hiệu ECG theo thời gian, mức đường huyết từ thiết bị CGM.

1.2. Chuỗi thời gian liên tục và rời rạc

Chuỗi thời gian liên tục là chuỗi được ghi nhận gần như liên tục theo thời gian, ví dụ tín hiệu ECG, âm thanh, rung động máy móc, dữ liệu cảm biến. Chuỗi thời gian rời rạc là chuỗi chỉ được ghi nhận tại các thời điểm cụ thể, thường cách đều nhau, ví dụ doanh số theo ngày, nhiệt độ mỗi 10 phút, sản lượng theo tháng.

Loại chuỗi	Đặc điểm	Ví dụ
Liên tục	Quan sát diễn ra liên tục hoặc tần suất rất cao	ECG, tín hiệu âm thanh, cảm biến rung
Rời rạc	Quan sát tại các mốc thời gian cụ thể	Doanh số ngày, giá cổ phiếu phút, lượng mưa ngày
Nhị phân	Giá trị chỉ có 0/1 hoặc bật/tắt	Trạng thái thiết bị, công tắc, cảnh báo

1.3. Đặc điểm quan trọng của dữ liệu chuỗi thời gian

- Thứ tự thời gian quan trọng: dữ liệu không thể xáo trộn như dữ liệu bảng thông thường.
- Các quan sát thường phụ thuộc lẫn nhau: giá trị hiện tại có thể liên quan đến các giá trị quá khứ.
- Không i.i.d.: nhiều mô hình thống kê/học máy giả định mẫu độc lập và cùng phân phối, nhưng chuỗi thời gian thường vi phạm giả định này.
- Có thể có trend, seasonality, cyclic và noise.
- Cần chú ý vấn đề nhìn trước (lookahead): không được dùng thông tin tương lai để huấn luyện/dự báo quá khứ.

1.4. Các thành phần của chuỗi thời gian

Thành phần	Ý nghĩa	Ví dụ
Trend	Xu hướng dài hạn tăng hoặc giảm	Doanh số tăng dần qua nhiều năm
Seasonality	Mẫu lặp lại theo chu kỳ cố định như ngày, tuần, tháng, năm	Nhu cầu điện tăng vào mùa hè
Cyclic	Dao động theo chu kỳ dài nhưng không cố định	Chu kỳ kinh tế, thị trường

Irregular/Noise Phần biến động ngẫu nhiên, bất thường, khó dự đoán	Sự kiện đột ngột, nhiễu cảm biến
--	----------------------------------

Trong cách tiếp cận truyền thống, một chuỗi thời gian thường được phân rã thành các thành phần trên để hiểu rõ cấu trúc dữ liệu. Ví dụ, nếu dự báo doanh số, ta cần biết doanh số tăng dài hạn là do trend, tăng theo dịp Tết là do seasonality, còn biến động bất thường do khuyến mãi hoặc sự kiện ngoài dự kiến có thể nằm trong irregular.

1.5. Tính dừng trong chuỗi thời gian

Tính dừng là một khái niệm rất quan trọng. Một chuỗi được xem là dừng nếu các đặc tính thống kê chính như trung bình, phương sai và cấu trúc tương quan không thay đổi theo thời gian. Nhiều mô hình thống kê cổ điển giả định chuỗi là dừng. Nếu chuỗi không dừng, ta thường phải biến đổi trước khi mô hình hóa.

- Không dừng ở trung bình: dữ liệu có xu hướng tăng/giảm rõ ràng.
- Không dừng ở phương sai: mức độ dao động thay đổi theo thời gian.
- Không dừng do mùa vụ: chuỗi có mẫu lặp theo chu kỳ cố định.

Một số cách làm chuỗi gần dừng hơn:

- Sai phân: $Y_t - Y_{t-1}$
- Log transform: $\log(Y_t)$
- Loại bỏ trend/seasonality

1.6. Một số bài toán sử dụng dữ liệu chuỗi thời gian

Bài toán	Mục tiêu	Ví dụ
Dự báo	Dự đoán giá trị tương lai	Dự báo doanh số tháng sau
Phát hiện bất thường	Tìm điểm hoặc đoạn dữ liệu bất thường	Phát hiện lỗi máy, gian lận giao dịch
Phân loại	Gán nhãn cho điểm hoặc toàn chuỗi	Phân loại nhịp tim ECG
Phân cụm	Nhóm các chuỗi có hành vi giống nhau	Nhóm khách hàng theo hành vi mua hàng
Ước lượng trạng thái	Ước lượng trạng thái ẩn của hệ thống Định vị, điều khiển robot	

Câu hỏi ôn tập phần 1

1. Chuỗi thời gian là gì? Vì sao thứ tự thời gian quan trọng?
2. Phân biệt trend, seasonality, cyclic và irregular.
3. Tính dừng là gì? Vì sao nhiều mô hình thống kê cần chuỗi dừng?
4. Vì sao không nên shuffle dữ liệu chuỗi thời gian khi huấn luyện mô hình?

2. Kỹ thuật xử lý dữ liệu chuỗi thời gian

2.1. Nhãn thời gian (Timestamp)

Nhãn thời gian là giá trị biểu diễn thời điểm xảy ra của một quan sát. Đây là thành phần gần như bắt buộc trong dữ liệu chuỗi thời gian vì nó giúp xác định thứ tự, khoảng cách giữa các quan sát, độ trễ, mùa vụ và khả năng đồng bộ nhiều nguồn dữ liệu.

Dạng timestamp	Mô tả	Ví dụ
Real-time Thời điểm cụ thể theo	ngày/giờ/phút/giây 2025-07-22 09:15:23	
Interval	Khoảng thời gian tổng hợp	Tuần 23, Tháng 1/2025
Index-based	Chỉ số thứ tự khi khoảng cách đều	t = 1, 2, 3, ...

Khi xử lý timestamp cần kiểm tra định dạng, múi giờ, độ phân giải và sự đồng nhất của khoảng cách thời gian. Ví dụ dữ liệu giá cổ phiếu theo phút phù hợp cho phân tích biến động ngắn hạn, trong khi dữ liệu doanh thu theo tuần phù hợp hơn nếu số liệu ngày bị nhiễu do cách ghi nhận.

2.2. Làm sạch dữ liệu

Làm sạch dữ liệu là quá trình loại bỏ hoặc chỉnh sửa các lỗi trong dữ liệu như giá trị thiếu, giá trị ngoại lai, sai định dạng thời gian, trùng lặp hoặc sai tần suất. Với chuỗi thời gian, làm sạch dữ liệu đặc biệt quan trọng vì lỗi ở một thời điểm có thể ảnh hưởng đến mô hình ở nhiều bước dự báo sau đó.

- Thiếu dữ liệu: do cảm biến mất tín hiệu, người dùng không ghi nhận, lỗi nhập liệu.
- Ngoại lai: giá trị quá lớn/quá nhỏ bất thường, ví dụ cảm biến trà về 9999.
- Sai timestamp: sai định dạng, sai múi giờ, bị trùng hoặc không cách đều.
- Sai tần suất: dữ liệu phút, giờ, ngày trộn lẫn không đồng nhất.
- Lookahead: vô tình dùng dữ liệu tương lai trong quá trình tạo đặc trưng hoặc đánh giá.

2.3. Xử lý dữ liệu thiếu

Dữ liệu thiếu là vấn đề phổ biến trong chuỗi thời gian. Có ba hướng xử lý chính: điền giá trị thiếu, nội suy từ các điểm lân cận hoặc loại bỏ khoảng thời gian bị ảnh hưởng. Việc chọn phương pháp phụ thuộc vào bản chất dữ liệu và mục tiêu phân tích.

Phương pháp	Cách làm	Khi nên dùng	Hạn chế
Forward fill	Dùng giá trị gần nhất trước đó	Dữ liệu dạng trạng thái, step function	Sai nếu trend mạnh hoặc missing dài
Mean/Median fill	Điền bằng trung bình/trung vị	Dữ liệu ổn định, ít biến động Mất cấu trúc thời gian	
Moving average	Điền/làm mịn bằng trung bình lân cận	Dữ liệu nhiễu, muốn giảm dao động	Có thể làm mờ đỉnh/đáy
Interpolation Ước lượng theo các điểm lân cận	Dùng dữ liệu biến đổi liên tục	Không tốt nếu có đột biến	đột biến thật
Drop interval	Loại bỏ đoạn thiếu	Thiếu quá dài hoặc không	Mất dữ liệu, giảm mẫu

		đáng tin	
--	--	----------	--

Ví dụ forward fill:
Ban đầu: [10, NaN, NaN, 15]
Sau xử lý: [10, 10, 10, 15]

2.4. Khử nhiễu và làm mịn

Khử nhiễu và làm mịn nhằm giảm dao động ngẫu nhiên để nhìn rõ xu hướng hoặc mẫu chính. Một kỹ thuật cơ bản là trung bình động, trong đó mỗi điểm được thay bằng trung bình của một số điểm lân cận.

$$SMA_t = (Y_t + Y_{\{t-1\}} + \dots + Y_{\{t-k+1\}}) / k$$

Nếu cửa sổ quá nhỏ, chuỗi vẫn còn nhiễu. Nếu cửa sổ quá lớn, mô hình có thể làm mất các biến động ngắn hạn quan trọng. Khi làm mịn để dự báo, cần dùng cửa sổ chỉ chứa quá khứ, không dùng điểm tương lai.

2.5. Resampling: thay đổi tần suất dữ liệu

Resampling là thay đổi tần suất quan sát của chuỗi thời gian. Downsampling là giảm tần suất, ví dụ từ phút sang giờ bằng cách lấy trung bình, tổng, max hoặc min. Upsampling là tăng tần suất, ví dụ từ ngày sang giờ và thường cần nội suy.

Loại	Ý nghĩa	Ví dụ	Lưu ý
Downsampling	Giảm tần suất	Dữ liệu phút -> dữ liệu giờ	Chọn phép tổng hợp đúng: sum/mean/max
Upsampling	Tăng tần suất	Dữ liệu ngày -> dữ liệu giờ	Cần nội suy, để tạo dữ liệu giả không chính xác

2.6. Xử lý ngoại lai

Ngoại lai là giá trị khác biệt mạnh so với phần còn lại của chuỗi. Trong chuỗi thời gian, ngoại lai có thể là lỗi đo lường nhưng cũng có thể là sự kiện thật. Do đó không nên xóa ngoại lai một cách máy móc.

- Ngoại lai do lỗi: cảm biến trả về 9999, timestamp trùng, nhập sai đơn vị.
- Ngoại lai do sự kiện thật: khuyến mãi lớn, dịch bệnh, thiên tai, crash hệ thống.
- Cách xử lý: kiểm tra domain knowledge, winsorize, thay bằng giá trị hợp lý, gắn nhãn anomaly hoặc giữ lại nếu là sự kiện quan trọng.

2.7. Tăng cường và mô phỏng dữ liệu chuỗi thời gian

Tăng cường dữ liệu nhằm tạo thêm mẫu huấn luyện, đặc biệt khi dữ liệu ít. Với chuỗi thời gian, không thể tăng cường tùy tiện vì phải giữ cấu trúc phụ thuộc thời gian, mùa vụ, chu kỳ và phân phối nhiễu.

- Có thể thêm nhiễu nhỏ nếu không làm thay đổi nhãn.
- Có thể cắt cửa sổ con để tạo nhiều mẫu.
- Có thể co giãn thời gian nhẹ trong một số bài toán cảm biến/tín hiệu.
- Khi mô phỏng dữ liệu cần mô phỏng autocorrelation, seasonality, heteroscedasticity và outlier nếu dữ liệu thật có các yếu tố này.

2.8. Lưu trữ và trực quan hóa

Dữ liệu chuỗi thời gian nên được lưu cùng timestamp rõ ràng, khóa định danh đối tượng nếu có nhiều chuỗi, giá trị quan sát và metadata. Trực quan hóa là bước rất quan trọng để phát hiện trend, seasonality, missing, outlier và thay đổi phân phối.

- Line chart: quan sát xu hướng theo thời gian.
- Seasonal plot: xem mẫu mùa vụ theo ngày/tuần/tháng.
- Histogram/boxplot: kiểm tra phân phối và ngoại lai.
- ACF/PACF plot: kiểm tra tự tương quan và hỗ trợ chọn mô hình AR/MA.

Câu hỏi ôn tập phần 2

5. Timestamp có vai trò gì trong phân tích chuỗi thời gian?
6. So sánh forward fill, moving average và interpolation.
7. Lookahead là gì? Vì sao nguy hiểm?
8. Downsampling và upsampling khác nhau như thế nào?
9. Khi nào không nên xóa ngoại lai?

3. Trích chọn đặc trưng chuỗi thời gian

3.1. Mục đích trích chọn đặc trưng

Dữ liệu chuỗi thời gian thô thường rất dài, nhiều nhiễu và khó đưa trực tiếp vào mô hình học máy truyền thống. Trích chọn đặc trưng giúp tóm tắt thông tin quan trọng của một đoạn/cửa sổ, giảm chiều dữ liệu, so sánh các chuỗi với nhau và giúp mô hình học dễ hơn.

- Với bài toán phân loại ECG, đặc trưng có thể là nhịp trung bình, độ biến động, peak, energy.
- Với tài chính, đặc trưng có thể là return, volatility, moving average, max drawdown.
- Với cảm biến, đặc trưng có thể là mean, std, entropy, dominant frequency.

3.2. Phân đoạn chuỗi thời gian

Phân đoạn là quá trình chia chuỗi dài thành nhiều đoạn nhỏ, trong đó mỗi đoạn có tính chất ổn định hoặc đồng nhất hơn về xu hướng, phương sai, tần số hoặc biên độ. Phân đoạn giúp phát hiện điểm thay đổi, biểu diễn chuỗi bằng các đoạn có ý nghĩa và giảm nhiễu.

Kiểu phân đoạn	Ý tưởng	Ví dụ
Dựa trên mô hình	Mỗi đoạn được giả định tuân theo một mô hình đơn giản	Piecewise linear trend
Dựa trên thống kê	Tìm điểm thay đổi mean/variance/trend/distribution Change point detection	
Dựa trên tín hiệu	Phân tích Fourier/Wavelet để tìm thay đổi tần số	Phân đoạn tín hiệu rung

3.3. Cửa sổ trượt

Cửa sổ trượt là kỹ thuật lấy các đoạn con có độ dài cố định từ chuỗi thời gian. Thay vì xử lý toàn bộ chuỗi, ta trượt một cửa sổ theo thời gian và trích đặc trưng trong từng cửa sổ. Đây là kỹ thuật rất phổ biến trong dự báo, phân loại, phát hiện bất thường và tạo dữ liệu huấn luyện.

Window size W: số điểm trong một cửa sổ

Step size S: số điểm dịch chuyển sau mỗi lần trượt

Ví dụ: chuỗi [1, 2, 3, 4, 5, 6], W = 3, S = 1

Các cửa sổ: [1,2,3], [2,3,4], [3,4,5], [4,5,6]

Khi tạo đặc trưng cho dự báo, cửa sổ phải được căn chỉnh sao cho chỉ dùng dữ liệu quá khứ. Nếu dùng cửa sổ chứa dữ liệu tương lai, mô hình sẽ bị lookahead và kết quả đánh giá bị ảo.

3.4. Đặc trưng thống kê

Đặc trưng thống kê là nhóm đặc trưng cơ bản nhất, giúp tóm tắt phân phối và mức độ dao động của chuỗi trong một đoạn/cửa sổ.

Nhóm đặc trưng	Đặc trưng	Ý nghĩa
Mức độ trung tâm	Mean, median	Mức giá trị điển hình của cửa sổ
Độ phân tán	Variance, std, range	Mức dao động, biến động
Giá trị cực trị	Min, max, peak	Phát hiện đỉnh, đáy, bất thường

Hình dạng phân phối	Skewness, kurtosis	Mức lệch và độ nhọn phân phối
Phụ thuộc thời gian	Autocovariance, ACF	Mức liên hệ giữa hiện tại và quá khứ
Độ phức tạp	Entropy, energy	Mức hỗn loạn hoặc sức mạnh tín hiệu

```

Mean = (x_1 + x_2 + ... + x_n) / n
Variance = trung bình của bình phương độ lệch so với mean
Std = sqrt(Variance)
Range = Max - Min
Energy = sum(x_i^2)

```

3.5. Skewness, entropy và energy

Skewness đo mức độ bất đối xứng của phân phối. Nếu skewness > 0, phân phối lệch phải, thường do một số giá trị lớn đột biến. Nếu skewness < 0, phân phối lệch trái. Nếu gần 0, phân phối tương đối đối xứng.

Entropy đo mức hỗn loạn hoặc độ khó đoán của chuỗi. Chuỗi lặp lại đều thường có entropy thấp, còn chuỗi ngẫu nhiên hoặc nhiều biến động có entropy cao. Energy là tổng bình phương giá trị tín hiệu, thường dùng trong xử lý tín hiệu để đo cường độ.

3.6. Autocovariance và ACF

Autocovariance đo mức liên kết tuyến tính giữa các giá trị của cùng một chuỗi tại hai thời điểm khác nhau. ACF chuẩn hóa autocovariance để đo tương quan giữa chuỗi với chính nó tại các độ trễ khác nhau.

```

ACF tại lag k = Corr(Y_t, Y_{t-k})

```

- ACF lag 0 luôn bằng 1 vì chuỗi tương quan hoàn hảo với chính nó.
- ACF giảm chậm thường gợi ý chuỗi có trend hoặc phụ thuộc dài hạn.
- ACF giảm nhanh thường gợi ý chuỗi gần dừng hơn.
- ACF/PACF thường dùng để định hướng chọn bậc AR/MA trong ARIMA.

3.7. Đặc trưng miền thời gian và miền tần số

Đặc trưng miền thời gian được tính trực tiếp trên chuỗi gốc, ví dụ mean, trend, peak, slope, zero crossing. Đặc trưng miền tần số phân tích chuỗi theo thành phần dao động, thường dùng Fourier hoặc Wavelet để tìm tần số chi phối, chu kỳ và năng lượng theo từng dải tần.

Miền	Đặc trưng ví dụ	Khi hữu ích
Thời gian	Mean, std, slope, peak, ACF	Dữ liệu có xu hướng, đỉnh, độ trễ rõ
Tần số	Dominant frequency, spectral energy	Tín hiệu âm thanh, rung động, ECG, mùa vụ

3.8. Lựa chọn đặc trưng dựa trên domain knowledge

Domain knowledge giúp chọn đặc trưng có ý nghĩa thực tế. Không phải đặc trưng nào cũng hữu ích cho mọi bài toán. Ví dụ trong y tế, peak và nhịp tim có ý nghĩa lớn với ECG; trong tài chính, volatility và return quan trọng hơn giá trị tuyệt đối; trong mạng máy tính, số gói tin bất thường và traffic burst có thể quan trọng hơn mean đơn giản.

Câu hỏi ôn tập phần 3

- 10. Vì sao cần trích chọn đặc trưng cho chuỗi thời gian?
- 11. Phân đoạn khác gì cửa sổ trượt?
- 12. ACF cho biết điều gì về chuỗi?
- 13. Khi nào nên dùng đặc trưng miền tần số?
- 14. Domain knowledge ảnh hưởng thế nào đến lựa chọn đặc trưng?

4. Mô hình thống kê cho chuỗi thời gian

4.1. Tư duy chung của mô hình thống kê

Mô hình thống kê cố gắng mô tả cơ chế sinh dữ liệu bằng các giả định rõ ràng về trend, seasonality, tự tương quan, nhiễu trắng hoặc trạng thái ẩn. Ưu điểm lớn của nhóm này là dễ giải thích, phù hợp khi dữ liệu không quá lớn và khi ta cần hiểu cấu trúc của chuỗi.

4.2. Hồi quy tuyến tính cho chuỗi thời gian

Hồi quy tuyến tính mô hình hóa quan hệ giữa biến phụ thuộc và một hoặc nhiều biến độc lập. Với chuỗi thời gian, biến độc lập có thể gồm chỉ số thời gian, biến mùa vụ, biến ngoại sinh và giá trị trễ của chính chuỗi.

$$Y_t = \beta_0 + \beta_1 * t + \beta_2 * X_t + \epsilon_t$$

- $\beta_1 > 0$ có thể biểu thị xu hướng tăng theo thời gian.
- X_t có thể là chi phí quảng cáo, nhiệt độ, ngày lễ, giá nhiên liệu...
- Có thể thêm biến giả mùa vụ như tháng, quý, ngày trong tuần.
- Có thể thêm biến trễ Y_{t-1} , Y_{t-2} để mô hình có thông tin quá khứ.

Hạn chế: hồi quy tuyến tính cơ bản giả định tuyến tính, dễ bị tự tương quan phần dư và không xử lý tốt chuỗi không dừng. Vì vậy cần mở rộng sang ARIMA, ARIMAX, VAR hoặc mô hình phi tuyến khi cần.

4.3. Mô hình tự hồi quy AR

Autoregression là mô hình trong đó giá trị hiện tại được biểu diễn như hàm tuyến tính của các giá trị quá khứ của chính nó. AR phù hợp khi chuỗi có tính nhớ quá khứ rõ ràng.

$$AR(p): Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \epsilon_t$$

Trong AR(1), nếu hệ số phi dương, giá trị cao ở thời điểm trước có xu hướng kéo giá trị hiện tại cao theo. Nếu phi âm, chuỗi có thể dao động lên xuống kiểu zig-zag. Điều kiện dừng đơn giản của AR(1) là $|\phi| < 1$.

4.4. Mô hình trung bình động MA

Moving Average trong mô hình thống kê không giống hoàn toàn với moving average dùng để làm mịn. MA mô tả giá trị hiện tại dựa trên nhiễu hiện tại và nhiễu trong quá khứ. Nó phù hợp khi ảnh hưởng của các cú sốc ngẫu nhiên kéo dài một số bước rồi mất dần.

$$MA(q): Y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

4.5. ARMA, ARIMA và SARIMA

ARMA kết hợp phần AR và MA, phù hợp với chuỗi dừng. ARIMA thêm thành phần I (Integrated), tức sai phân, để xử lý chuỗi không dừng. SARIMA mở rộng ARIMA bằng thành phần mùa vụ, phù hợp với chuỗi có chu kỳ lặp lại rõ như tuần, tháng hoặc năm.

Mô hình	Thành phần	Khi dùng
AR	Giá trị quá khứ của chuỗi	Chuỗi phụ thuộc mạnh vào quá khứ
MA	Nhiều hiện tại và nhiễu quá khứ	Cú sốc ngắn hạn ảnh hưởng vài

		bước
ARMA	AR + MA	Chuỗi dừng có cả tự hồi quy và nhiễu quá khứ
ARIMA	AR + sai phân + MA	Chuỗi không dừng, có trend
SARIMA	ARIMA + mùa vụ	Chuỗi có seasonality rõ

ARIMA (p,d,q) :
p = bậc AR, d = số lần sai phân, q = bậc MA
SARIMA (p,d,q) (P,D,Q)_s: thêm thành phần mùa vụ với chu kỳ s

4.6. VAR - Vector Autoregression

VAR là mô hình tự hồi quy véc tơ dừng cho chuỗi thời gian đa biến. Trong VAR, mỗi biến được giải thích bởi giá trị quá khứ của chính nó và giá trị quá khứ của các biến khác. VAR hữu ích khi nhiều chuỗi có tương tác qua lại, ví dụ GDP, lãi suất, lạm phát hoặc nhiều cảm biến trong cùng hệ thống.

Ví dụ 2 biến:
 $Y_t = a_1 + b_{11} Y_{t-1} + b_{12} X_{t-1} + e_{1t}$
 $X_t = a_2 + b_{21} Y_{t-1} + b_{22} X_{t-1} + e_{2t}$

4.7. Kalman Filter

Kalman Filter là phương pháp ước lượng trạng thái ẩn của một hệ thống động khi quan sát có nhiễu. Mô hình gồm hai phần: phương trình trạng thái mô tả trạng thái thật thay đổi theo thời gian và phương trình quan sát mô tả dữ liệu đo được từ trạng thái đó.

State equation: $x_t = A x_{t-1} + w_t$
Observation equation: $y_t = H x_t + v_t$

- Predict: dự đoán trạng thái hiện tại từ trạng thái trước.
- Update: cập nhật dự đoán bằng quan sát mới.
- Ứng dụng: định vị GPS, robot, cảm biến, tracking, mô hình local level/local trend.

4.8. Hidden Markov Model - HMM

HMM giả định hệ thống có các trạng thái ẩn không quan sát trực tiếp được, còn dữ liệu quan sát được sinh ra từ các trạng thái đó. HMM phù hợp với bài toán chuỗi trong đó trạng thái thật không nhìn thấy trực tiếp, ví dụ trạng thái thị trường, trạng thái sức khỏe, hoạt động người dùng hoặc âm vị trong speech recognition.

Thành phần HMM	Ý nghĩa
Trạng thái ẩn	Các trạng thái thật của hệ thống nhưng không quan sát trực tiếp
Quan sát	Dữ liệu nhìn thấy được tại mỗi thời điểm
Xác suất chuyển trạng thái	Khả năng chuyển từ trạng thái này sang trạng thái khác
Xác suất phát xạ	Khả năng sinh quan sát từ một trạng thái
Xác suất ban đầu	Phân phối trạng thái ở thời điểm đầu

- Forward algorithm: tính xác suất quan sát.
- Viterbi algorithm: tìm chuỗi trạng thái ẩn có khả năng cao nhất.

- Baum-Welch/EM: học tham số khi trạng thái ẩn chưa biết.

4.9. Mô hình Bayes cho chuỗi thời gian

Cách tiếp cận Bayes xem tham số mô hình là biến ngẫu nhiên. Khi có dữ liệu mới, niềm tin về tham số được cập nhật từ prior thành posterior. Điều này phù hợp với chuỗi thời gian vì dữ liệu thường đến dần theo thời gian và hệ thống có thể thay đổi.

$$\text{Posterior} \propto \text{Likelihood} \times \text{Prior}$$

- Prior: niềm tin ban đầu về tham số.
- Likelihood: xác suất sinh dữ liệu theo tham số.
- Posterior: niềm tin sau khi quan sát dữ liệu.

Bayesian Structural Time Series (BSTS) thường kết hợp các thành phần như trend, seasonality, regression, Kalman Filter và Bayesian model averaging để dự báo có kèm độ bất định.

Câu hỏi ôn tập phần 4

15. Phân biệt AR và MA.
16. ARIMA khác ARMA ở điểm nào?
17. SARIMA dùng trong trường hợp nào?
18. VAR phù hợp với dữ liệu loại nào?
19. Kalman Filter và HMM giống và khác nhau như thế nào?
20. Mô hình Bayes có lợi ích gì trong chuỗi thời gian?

5. Học máy và học sâu cho chuỗi thời gian

5.1. Vì sao ML/DL cho chuỗi thời gian cần xử lý riêng?

Nhiều thuật toán học máy truyền thống giả định dữ liệu độc lập và có thể xáo trộn. Tuy nhiên chuỗi thời gian có phụ thuộc theo thời gian, thứ tự quan trọng và thường có trend/seasonality. Do đó khi áp dụng ML/DL cần biến đổi dữ liệu thành đặc trưng, cửa sổ hoặc dùng kiến trúc sequence.

- Cách 1: trích đặc trưng rồi đưa vào mô hình như Random Forest, XGBoost.
- Cách 2: dùng cửa sổ gồm nhiều bước quá khứ để dự báo bước tiếp theo.
- Cách 3: dùng mô hình sequence như RNN, LSTM, GRU, Transformer.
- Cách 4: dùng khoảng cách chuỗi như Dynamic Time Warping cho phân cụm/phân loại.

5.2. Phân loại chuỗi thời gian

Phân loại chuỗi thời gian là bài toán gán nhãn rời rạc cho từng điểm, từng đoạn hoặc toàn bộ chuỗi. Khác với dự báo giá trị, phân loại trả lời câu hỏi chuỗi thuộc loại nào hoặc tại thời điểm đó có sự kiện gì xảy ra.

Dạng phân loại	Đầu ra	Ví dụ
Point-wise classification	Nhãn cho từng thời điểm	Bình thường/bất thường tại mỗi giây
Window classification	Nhãn cho từng đoạn	Đoạn ECG bình thường hay bất thường
Whole-series classification	Nhãn cho toàn chuỗi	Phân loại hoạt động đi/chạy/ngồi

5.3. Decision Tree, Random Forest và Gradient Boosting

Decision Tree học các luật phân chia theo ngưỡng để dự đoán nhãn hoặc giá trị. Với chuỗi thời gian, cây thường không dùng trực tiếp chuỗi thô mà dùng đặc trưng như mean, std, lag, moving average, volatility. Random Forest kết hợp nhiều cây để giảm overfitting. Gradient Boosting xây các cây tuần tự, mỗi cây sau sửa lỗi của các cây trước.

Mô hình	Ý tưởng	Ưu điểm	Hạn chế
Decision Tree	Chia dữ liệu bằng các luật if-else Dễ hiểu, xử lý phi tuyến	Dễ overfit	
Random Forest	Nhiều cây/biểu quyết tử	Ổn định hơn, giảm overfit	Ít giải thích hơn một cây đơn
Gradient Boosting	Cây sau sửa lỗi cây trước	Mạnh với dữ liệu đặc trưng tốt	Cần tuning, dễ overfit nếu sai cách

Các mô hình cây thường hữu ích khi chuỗi đã được nén thành đặc trưng tóm tắt. Chúng không tự hiểu thứ tự thời gian nếu ta không cung cấp lag, rolling feature hoặc đặc trưng theo cửa sổ.

5.4. Phân cụm chuỗi thời gian

Phân cụm giúp nhóm các chuỗi có hành vi tương tự. Có thể phân cụm dựa trên đặc trưng trích xuất hoặc dùng khoảng cách trực tiếp giữa các chuỗi. Một khoảng cách phổ biến là Dynamic Time Warping, cho phép so sánh hai chuỗi có tốc độ biến đổi khác nhau.

- Phân cụm khách hàng theo hành vi mua hàng theo tháng.
- Nhóm cảm biến có mẫu dao động giống nhau.
- Nhóm chuỗi tài chính có xu hướng tương tự.

Khi phân cụm để dự báo tương lai, chỉ nên dùng phần quá khứ của chuỗi để tạo cụm, không dùng toàn bộ chuỗi nếu phần sau thuộc tương lai cần dự báo.

5.5. Feed Forward Network

Mạng truyền thẳng có thể dùng cho chuỗi thời gian nếu đầu vào là vector đặc trưng hoặc một cửa sổ quá khứ được trải phẳng. Ví dụ dùng 24 giờ gần nhất để dự báo giờ tiếp theo, input là $[Y_{t-23}, \dots, Y_t]$.

Input: $[Y_{t-W+1}, \dots, Y_t]$

Output: Y_{t+1} hoặc nhân của cửa sổ

5.6. CNN cho chuỗi thời gian

CNN có thể dùng cho chuỗi thời gian bằng tích chập 1D để phát hiện các mẫu cục bộ như đỉnh, dao động ngắn, motif tín hiệu. Một cách khác là chuyển chuỗi thành ảnh hoặc biểu đồ rồi dùng CNN 2D, nhưng cách này cần cẩn thận để không làm mất ý nghĩa thời gian.

- Ưu điểm: học mẫu cục bộ tốt, tính toán song song nhanh.
- Hạn chế: khó nắm phụ thuộc rất dài nếu kiến trúc không đủ sâu hoặc không có cơ chế mở rộng receptive field.

5.7. RNN, LSTM và GRU

RNN xử lý chuỗi từng bước theo thứ tự và duy trì trạng thái ẩn để ghi nhớ thông tin quá khứ. LSTM và GRU là biến thể cải tiến giúp học phụ thuộc dài hạn tốt hơn và giảm vấn đề vanishing gradient.

Mô hình	Ý tưởng	Khi dùng
RNN Cập nhật hidden state qua từng	bước thời gian	Chuỗi ngắn, cấu trúc đơn giản
LSTM Có cổng nhớ/quên để giữ thông tin dài hạn	tín dài hạn	Dự báo, NLP, tín hiệu dài
GRU Đơn giản hơn LSTM, vẫn giữ khả năng nhớ	năng nhớ	Khi muốn cân bằng hiệu năng và tốc độ

5.8. Attention và Transformer

Attention cho phép mô hình học mức độ quan trọng giữa các thời điểm khác nhau trong chuỗi. Thay vì chỉ truyền thông tin tuần tự, attention có thể liên kết trực tiếp thời điểm hiện tại với các thời điểm xa trong quá khứ. Transformer dùng self-attention để mô hình hóa phụ thuộc dài hạn và có khả năng song song tốt hơn RNN.

- Ưu điểm: học quan hệ xa tốt, song song hóa tốt, mạnh với dữ liệu lớn.
- Hạn chế: tốn tài nguyên, cần nhiều dữ liệu, cần xử lý positional/time encoding.

5.9. Chỉ số đánh giá

Bài toán	Metric thường dùng	Ý nghĩa
Dự báo giá trị	MAE, MSE, RMSE, MAPE	Đo sai số giữa dự báo và thực tế
Phân loại	Accuracy, Precision, Recall, F1	Đo chất lượng gán nhãn
Phát hiện bất thường	Precision, Recall, F1, PR-AUC	Quan trọng khi dữ liệu bất thường hiếm
Phân cụm	Silhouette, Davies-Bouldin	Đo mức tách biệt và gắn kết cụm

Câu hỏi ôn tập phần 5

- 21. Vì sao Random Forest không nên dùng trực tiếp trên chuỗi thô?
- 22. Gradient Boosting hoạt động theo ý tưởng nào?
- 23. Phân biệt forecast và classification trong chuỗi thời gian.
- 24. RNN khác Feed Forward Network ở điểm nào?
- 25. Attention giúp ích gì cho dữ liệu chuỗi thời gian?

6. Một số ứng dụng thực tế

6.1. Vai trò của domain knowledge

Trong ứng dụng thực tế, domain knowledge là yếu tố rất quan trọng. Không thể làm sạch dữ liệu, chọn đặc trưng hoặc đánh giá mô hình một cách mù quáng nếu không hiểu ý nghĩa của dữ liệu. Một giá trị bất thường có thể là lỗi cảm biến, nhưng cũng có thể là sự kiện thật rất quan trọng.

6.2. Chăm sóc sức khỏe: dự báo cúm

Dự báo cúm là bài toán y tế công cộng quan trọng vì cúm có tính mùa vụ rõ ràng và ảnh hưởng đến kế hoạch phân bổ nguồn lực y tế. Dữ liệu tỷ lệ cúm thường được ghi nhận theo tuần và có mẫu tăng/giảm theo mùa.

- Do tính mùa vụ mạnh, SARIMA với chu kỳ 52 tuần có thể được dùng.
- ACF/PACF của chuỗi đã sai phân giúp định hướng chọn tham số.
- Hạn chế của SARIMA: có thể dự báo giá trị âm, nhạy với outlier, có thể đánh giá quá cao đỉnh dịch.
- Dynamic Harmonic Regression dùng Fourier để mô tả mùa vụ và có thể kết hợp ARIMA, nhưng nếu mùa vụ không đều thì mô hình quá cứng nhắc.

6.3. Chăm sóc sức khỏe: dự báo đường huyết

Dự báo mức đường huyết giúp bệnh nhân tiểu đường điều chỉnh insulin và thời gian ăn uống, đặc biệt để tránh mức đường huyết thấp nguy hiểm khi ngủ. Dữ liệu thường đến từ thiết bị CGM, nhưng có thể bị trùng lặp, thiếu dữ liệu hoặc ghi nhận không đều.

- Cần loại bỏ bản ghi trùng lặp hoàn toàn hoặc trùng timestamp nhưng giá trị khác nhẹ.
- Cần vẽ dữ liệu theo ngày/giờ để phát hiện pattern hàng ngày.
- Cần kiểm tra thời điểm thu thập có ngẫu nhiên hay bị tập trung vào một số khung giờ.

6.4. Phát hiện bất thường

Phát hiện bất thường trong chuỗi thời gian xuất hiện trong nhiều lĩnh vực: y tế, mạng máy tính, công nghiệp, tài chính, vận hành hệ thống. Anomaly có thể là điểm đơn lẻ, đoạn bất thường hoặc thay đổi cấu trúc dài hạn.

Loại bất thường	Mô tả	Ví dụ
Point anomaly	Một điểm khác biệt mạnh	Nhiệt độ cảm biến đột ngột = 9999
Contextual anomaly	Bất thường trong bối cảnh cụ thể	Lưu lượng cao lúc 3h sáng
Collective anomaly	Một đoạn dữ liệu bất thường	CPU tăng liên tục 30 phút
Change point	Điểm thay đổi chế độ hoạt động	Máy chuyển từ bình thường sang lỗi

6.5. Phân tích tài chính

Trong tài chính, chuỗi thời gian được dùng để phân tích giá cổ phiếu, lợi suất, biến động, rủi ro, lãi suất, lạm phát và các chỉ báo kinh tế. Dữ liệu tài chính thường có noise cao, volatility thay đổi theo thời gian và nhiều outlier do sự kiện thị trường.

- Return thường quan trọng hơn giá tuyệt đối trong nhiều mô hình.

- Volatility là đặc trưng quan trọng để đánh giá rủi ro.
- ARCH/GARCH phù hợp khi phương sai thay đổi theo thời gian.
- VAR dùng để mô hình hóa tương tác giữa nhiều biến kinh tế.

6.6. Dự báo trong vận hành và kinh doanh

Dự báo là ứng dụng trung tâm của chuỗi thời gian. Doanh nghiệp dùng dự báo để lên kế hoạch tồn kho, nhân sự, năng lượng, giao thông, tài chính và tài nguyên hệ thống.

- Dự báo nhu cầu điện theo giờ để cân bằng tải.
- Dự báo doanh số để chuẩn bị hàng tồn kho.
- Dự báo lưu lượng hệ thống để tự động mở rộng tài nguyên.
- Dự báo thời tiết, lượng mưa, ô nhiễm để hỗ trợ ra quyết định.

Câu hỏi ôn tập phần 6

- 26. Vì sao domain knowledge quan trọng trong ứng dụng chuỗi thời gian?
- 27. SARIMA phù hợp với dự báo cúm vì lý do gì?
- 28. Dữ liệu CGM cần làm sạch những gì trước khi dự báo đường huyết?
- 29. Phân biệt point anomaly, contextual anomaly và collective anomaly.
- 30. Trong tài chính, vì sao volatility quan trọng?

7. Bảng so sánh nhanh các nhóm phương pháp

Nhóm phương pháp Đầu vào phù hợp	Ưu điểm	Hạn chế	Ví dụ	
Thống kê cổ điển	Chuỗi có cấu trúc rõ, dữ liệu vừa/nhỏ	Dễ giải thích, có giá định rõ	Cần dừng/mùa vụ, khó với phi tuyến mạnh	ARIMA, SARIMA
State-space	Hệ thống có trạng thái ẩn, quan sát nhiều	Cập nhật online tốt	Cần thiết kế trạng thái hợp lý	Kalman Filter
HMM Chuỗi có trạng thái ẩn rời rạc		Tốt cho phân đoạn/trạng thái	Giả định Markov đơn giản	Speech, hành vi người dùng
ML truyền thống	Đặt Man, dễ triển khai	Cần feature	engineering RF, XGBoost	
Deep Learning	Dữ liệu lớn, quan hệ phi tuyến phức tạp	Học biểu diễn tự động	Tốn dữ liệu/tài nguyên, khó giải thích	CNN, LSTM, Transformer

8. Bộ câu hỏi ôn tập lý thuyết

8.1. Câu hỏi khái niệm

- 31. Chuỗi thời gian là gì? Cho 3 ví dụ thực tế.
- 32. Vì sao dữ liệu chuỗi thời gian không được xem là i.i.d.?
- 33. Phân biệt chuỗi thời gian liên tục và rời rạc.
- 34. Giải thích các thành phần trend, seasonality, cyclic, irregular.
- 35. Tính dừng là gì? Nêu ví dụ chuỗi dừng và không dừng.
- 36. Timestamp có vai trò gì? Vì sao cần xử lý múi giờ?
- 37. Lookahead bias là gì? Cho ví dụ trong tạo rolling feature.
- 38. Forward fill phù hợp với loại dữ liệu nào? Khi nào không nên dùng?
- 39. Moving average dùng để làm gì? Cửa sổ quá lớn gây vấn đề gì?
- 40. Outlier trong chuỗi thời gian có luôn là lỗi không? Giải thích.

8.2. Câu hỏi về đặc trưng

- 41. Vì sao cần trích chọn đặc trưng thay vì dùng chuỗi thô?
- 42. Cửa sổ trượt được xác định bởi những tham số nào?
- 43. Phân đoạn chuỗi thời gian dùng để làm gì?
- 44. Mean, variance, standard deviation, range biểu diễn điều gì?
- 45. Skewness cho biết điều gì về phân phối?
- 46. Entropy và energy có ý nghĩa gì trong tín hiệu?
- 47. ACF là gì? ACF giảm chậm và giảm nhanh gợi ý điều gì?
- 48. Đặc trưng miền tần số phù hợp với bài toán nào?
- 49. Domain knowledge giúp chọn đặc trưng như thế nào?

8.3. Câu hỏi về mô hình

- 50. Hồi quy tuyến tính trong chuỗi thời gian cần bổ sung những biến nào?
- 51. Mô hình tĩnh khác mô hình động ở điểm nào?
- 52. AR(p) mô hình hóa giá trị hiện tại bằng gì?
- 53. MA(q) mô hình hóa ảnh hưởng của yếu tố nào?
- 54. ARMA, ARIMA, SARIMA khác nhau thế nào?
- 55. VAR dùng trong trường hợp nào?
- 56. Kalman Filter gồm hai bước chính nào?
- 57. HMM có những thành phần nào?
- 58. Viterbi algorithm dùng để làm gì?
- 59. Mô hình Bayes cập nhật prior thành posterior như thế nào?

8.4. Câu hỏi về ML/DL và ứng dụng

- 60. Vì sao Random Forest cần đặc trưng tóm tắt khi làm với chuỗi thời gian?
- 61. Gradient Boosting học theo cơ chế nào?
- 62. Phân loại chuỗi thời gian khác dự báo chuỗi thời gian thế nào?
- 63. Phân cụm chuỗi thời gian có thể dùng trong dự báo như thế nào?
- 64. RNN xử lý thứ tự thời gian ra sao?
- 65. LSTM/GRU cải thiện RNN ở điểm nào?
- 66. Attention có lợi ích gì với phụ thuộc dài hạn?
- 67. Vì sao dự báo cúm có thể dùng SARIMA?
- 68. Vì sao dữ liệu đường huyết cần kiểm tra pattern theo giờ trong ngày?
- 69. Cho ví dụ ứng dụng phát hiện bất thường trong mạng máy tính hoặc y tế.

9. Gợi ý cách trả lời bài thi tự luận

Khi gặp câu hỏi lý thuyết, có thể trả lời theo khuôn mẫu sau:

- 70. Nêu khái niệm ngắn gọn.
- 71. Giải thích bản chất bằng lời đơn giản.
- 72. Nêu công thức hoặc thành phần chính nếu có.
- 73. Nêu ưu điểm, hạn chế hoặc điều kiện sử dụng.
- 74. Cho ví dụ thực tế.

Ví dụ với câu "ACF là gì?": ACF là hàm tự tương quan đo mức tương quan giữa chuỗi và chính nó tại các độ trễ. Nó cho biết chuỗi nhớ quá khứ nhiều hay ít. Nếu ACF giảm chậm, chuỗi có thể có trend hoặc phụ thuộc dài hạn; nếu giảm nhanh, chuỗi gần dừng hơn. ACF thường dùng khi phân tích ARIMA.

Nguồn nội dung

Tài liệu được tổng hợp từ các slide người dùng cung cấp trong cuộc trò chuyện:

- 01. Giới thiệu.pptx
- 02. Kỹ thuật xử lý.pptx
- 03. Trích chọn đặc trưng.pptx
- 04. Mô hình thống kê.pptx
- 05. Học máy và học sâu.pptx
- 06. Một số ứng dụng.pptx